

Estadística Experiencial Aplicada

Aprendizaje práctico de la estadística descriptiva con R

Francisco Javier León Miguel Oswaldo Pérez Pulido
Leonardo Andrés Pinto Guarguati

2026-03-24

Tabla de contenido

Prefacio	2
1. Introducción	4
2. Autores	5
3. Introducción a la estadística descriptiva	6
3.1. ¿Qué es la estadística descriptiva?	6
3.2. Fases del análisis de datos	6
3.3. Tipos de variables	6
3.4. Importancia de la identificación de variables estadísticas y escalas de medición	8
3.5. Escalas de medición	10
3.6. Base de datos de trabajo	10
3.6.1. bd S07D_Acuicultura.csv	10
3.6.2. bd medidas antropométricas	10
3.7. Trabajando con las bases de datos	12
3.8. bd Acuicultura	12
3.8.1. ¿Qué estamos haciendo?	13
3.8.2. Reflexión del estudiante	14
3.8.3. Diccionario de datos	14
3.9. Actividad experiencial	15
3.9.1. Explorando una base de datos del DANE	15
3.9.2. Desarrollo de la actividad	16
3.10. Mini reto analítico	18
4. Preparación de datos	19
4.1. Carga de datos en R	19
4.2. Limpieza de datos	19
5. Organización e interpretación de datos estadísticos	22
5.1. Datos simples	22
5.2. Datos agrupados	22
5.3. Tablas de frecuencia	23
5.3.1. Frecuencia absoluta	23
5.3.2. Frecuencia relativa	23
5.3.3. Frecuencia acumulada	24
5.3.4. Frecuencia relativa acumulada	24
5.4. Ejemplo de tabla de frecuencia: Variable P_S7P97	24
5.5. Estructura general de una tabla de frecuencia	25
5.6. Marca de clase	26
5.7. Organización de datos en contextos reales	27
5.8. Actividad Experiencial	27
5.8.1. Situación problema	27

5.8.2. Ejemplo: Género	29
5.9. Ejemplo: Peso corporal	31
5.10. Actividad experiencial: Organización de datos y tablas estadísticas	31
5.10.1. Objetivos de aprendizaje	32
5.11. Desarrollo de la actividad	32
5.11.1. Parte 1. Exploración inicial de los datos	32
5.11.2. Parte 2. Identificación de variables	33
5.11.3. Parte 3. Organización y análisis del peso corporal	33
5.12. Situación problema	33
5.12.1. Parte 4. Preguntas orientadoras	34
5.12.2. Parte 5. Construcción de tablas agrupadas	34
5.12.3. Parte 6. Visualización gráfica	34
5.12.4. Recomendación metodológica	34
5.12.5. Reflexión final	34
6. Visualización de datos	36
6.1. Gráficos en R	36
6.2. Gráfico de sectores	37
6.3. Gráfico de barras	39
6.4. Histograma	41
6.4.1. Ejemplo con funciones básicas de R	42
6.5. Boxplot	42
6.5.1. Ejemplo con funciones básicas de R	44
6.5.2. Ejemplo peso y género con ggplot2	45
7. Medidas de tendencia central y dispersión	47
7.1. Medidas de tendencia central	47
7.1.1. Media aritmética	47
7.1.2. Cálculo en R	48
7.1.3. Mediana	48
7.1.4. Cálculo en R	49
7.1.5. Moda	49
7.1.6. Cálculo en R	49
7.2. Visualización de las medidas de tendencia central	49
7.3. Interpretación del gráfico: Distribución del peso	51
7.3.1. Análisis estadístico	51
7.4. Ejercicio experiencial propuesto	51
7.5. Actividad: Explorando las características antropométricas	51
7.6. Actividad práctica	52
7.6.1. Construcción del gráfico	52
7.6.2. Interpretación	52
8. Medidas de dispersión o variabilidad	53
8.0.1. Rango	53
8.0.2. Cálculo en R	53
8.0.3. Varianza muestral	53
8.0.4. Cálculo en R	53
8.0.5. Varianza poblacional	54
8.0.6. Desviación estándar muestral	54
8.0.7. Cálculo en R	54
8.0.8. Desviación estándar poblacional	54
8.0.9. Coeficiente de variación	54
8.0.10. Cálculo en R	54
8.1. Resumen estadístico en R	54
8.2. Histograma + desviación estándar	55

8.2.1. Interpretación	56
8.3. Comparar dispersión entre géneros	56
8.3.1. Interpretación	57
8.3.2. Interpretación	58
8.4. Resumen gráfico	59
9. Medidas de posición y forma	60
9.1. Medidas de posición	60
9.2. Clasificación de las medidas de posición	60
9.3. Cuartiles	61
9.3.1. Fórmula de posición	61
9.4. Deciles	62
9.4.1. Fórmula de posición	62
9.5. Aplicaciones de los deciles	62
9.6. Percentiles	62
9.6.1. Fórmula de posición	62
9.6.2. Aplicaciones de los percentiles	62
9.7. Medidas de forma	62
9.7.1. Asimetría	64
9.7.2. Curtosis	64
9.8. Actividad experiencial	64
9.8.1. Explorando medidas de posición y forma con datos antropométricos	64
9.9. Mini reto analítico	65
10. Análisis bivariado	67
10.1. Tipos de análisis bivariado	67
10.2. Conjunto de datos de trabajo	68
10.3. Carga de datos en R	68
10.4. Exploración inicial de variables	69
10.5. Evaluación de supuestos	69
10.5.1. Variables cuantitativas continuas	69
10.5.2. Prueba de normalidad Shapiro-Wilk	70
10.5.3. Independencia de las observaciones	71
10.5.4. Relación lineal	71
10.5.5. Regresión lineal múltiple	73
10.5.6. Homocedasticidad	74
10.5.7. Ausencia de valores atípicos extremos	75
10.6. Estructura general para seleccionar la técnica adecuada	76
10.7. Cuando se cumplen los supuestos	76
10.7.1. Correlación de Pearson	76
10.8. Cuando no se cumplen los supuestos	81
10.8.1. Correlación de Spearman	82
10.9. Otras medidas de asociación	85
10.9.1. Diagrama de dispersión	85
10.9.2. Covarianza	88
10.9.3. Tablas de contingencia	90
10.9.4. Interpretación	90
10.9.5. Ejercicio contextual	90
10.9.6. Ejemplo en R	91
10.10 Integración y aplicación	93
10.10.1. Estructura general para seleccionar la técnica adecuada	93
10.10.2. Laboratorio experiencial	93
10.10.3. Actividades del estudiante	94
11. Declaración sobre el uso de herramientas de inteligencia artificial	95

Prefacio

La estadística constituye una herramienta fundamental para comprender, interpretar y transformar la realidad a partir de los datos. En un contexto caracterizado por el crecimiento exponencial de la información, el análisis estadístico se ha consolidado como una competencia esencial en múltiples disciplinas, especialmente en escenarios académicos, científicos, sociales y organizacionales.

Este libro surge como una propuesta orientada al aprendizaje experiencial de la estadística descriptiva mediante el uso del lenguaje R y el entorno de publicación científica Quarto. Su propósito principal es acercar al estudiante a situaciones reales de análisis de datos, promoviendo no solo el cálculo de medidas estadísticas, sino también la interpretación crítica de la información y la toma de decisiones basadas en evidencia.

A lo largo de los capítulos se integran ejemplos aplicados, visualizaciones estadísticas, actividades experienciales y bases de datos reales provenientes de contextos académicos y oficiales, permitiendo que el lector comprenda cómo la estadística trasciende los ejercicios mecánicos y se convierte en una herramienta para explorar fenómenos del mundo real.

El uso de R permite desarrollar habilidades contemporáneas asociadas al análisis reproducible, la programación estadística y la ciencia de datos, fortaleciendo competencias analíticas cada vez más demandadas en la educación superior y en el ámbito profesional.

Cómo citar este libro

León, F. J., Pérez Pulido, M. O., & Pinto Guarguati, L. A. (2026). *Estadística experiencial aplicada: Aprendizaje práctico de la estadística descriptiva con R*. Universidad de Santander (UDES), Dirección de Planeación Institucional. <https://udesanalitica.github.io/estadistica-experiencial/> <https://doi.org/10.5281/zenodo.XXXXX>

```
```\bibtex
@book{leon2026estadistica,
 author = {León, Francisco Javier and Pérez Pulido, Miguel Oswaldo and Pinto Guarguati, Leonardo A.},
 title = {Estadística Experiencial Aplicada: Aprendizaje práctico de la estadística descriptiva con R},
 year = {2026},
 publisher = {Universidad de Santander (UDES)},
 address = {Bucaramanga, Colombia},
 institution = {Universidad de Santander (UDES), Dirección de Planeación Institucional},
 url = {https://udesanalitica.github.io/estadistica-experiencial/},
 doi = {10.5281/zenodo.XXXXX},
 isbn = {Pendiente},
 language = {spanish}
}
```

**! Derechos de Autor**

Universidad de Santander (UDES)  
Calle 70 #Nº 55-210  
Bucaramanga, Santander, Colombia  
<https://www.udes.edu.co/>

# Capítulo 1

## Introducción

La estadística descriptiva representa el punto de partida para el análisis de datos. A través de técnicas de organización, resumen y visualización, es posible transformar grandes volúmenes de información en conocimiento útil para comprender fenómenos, identificar patrones y apoyar procesos de investigación y toma de decisiones.

Este libro ha sido diseñado bajo un enfoque práctico y aplicado, integrando herramientas computacionales modernas mediante el lenguaje R, uno de los entornos más utilizados en estadística, ciencia de datos e investigación científica a nivel mundial.

Cada capítulo combina fundamentos conceptuales con ejercicios desarrollados sobre bases de datos reales, favoreciendo un aprendizaje activo y experiencial. El lector encontrará actividades orientadas a:

organizar datos, construir tablas de frecuencia, interpretar gráficos estadísticos, analizar medidas descriptivas, identificar patrones y valores atípicos, y comunicar resultados mediante visualizaciones claras y reproducibles.

Además de fortalecer las competencias estadísticas básicas, este texto busca fomentar el pensamiento crítico frente a los datos y promover una cultura de análisis basada en evidencia.

## Capítulo 2

### Autores



**Francisco Javier León:** Bacteriólogo y laboratorista clínico, magíster en estadística aplicada, magíster en ciencias básicas biomédicas y especialista en educación con nuevas tecnologías. Desde 2007, está relacionado con la Universidad de Santander (UDES), en la que ha trabajado como profesor en la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Actualmente, trabaja como Coordinador de Analítica Académica en Planeación Institucional. Es un miembro de CIBAS y un investigador junior premiado por MinCiencias en la convocatoria 957 del año 2024.



**Miguel Oswaldo Pérez Pulido:** Licenciado en matemáticas y magíster en estadística. Actualmente se desempeña como Director de Planeación Institucional. Está vinculado a la Universidad de Santander (UDES) desde 2011, donde ha sido docente en programas de pregrado y posgrado de la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Es investigador asociado reconocido por MinCiencias en la convocatoria 957 de 2024 y miembro del grupo de investigación CIBAS.



**Leonardo Andrés Pinto Guarguati:** Economista, especialista en Evaluación y Gerencia de Proyectos, y estudiante de la Maestría en Evaluación y Gerencia de Proyectos (Universidad Industrial de Santander). Con experiencia en docencia universitaria, análisis de mercados y coordinación de proyectos de Ciencia, Tecnología e innovación - CTel.

## Capítulo 3

# Introducción a la estadística descriptiva

Actualmente los datos se han convertido en un activo fundamental para la toma de decisiones en las empresas, la sociedad, la académica entre otros y es por eso que la **estadística descriptiva constituye el primer paso para transformar información en conocimiento útil** (Seoane et al., 2007). Su aplicación permite un mejor entendimiento del mundo que nos rodea, ya que prácticamente cada aspecto de nuestra existencia es una fuente potencial de datos (Obando, 2021). Este capítulo introduce los conceptos básicos necesarios para comprender, organizar y analizar datos, utilizando un enfoque experiencial basado en ejemplos reales y herramientas computacionales como R.

### 3.1. ¿Qué es la estadística descriptiva?

La **estadística descriptiva** es la rama de la estadística encargada de recolectar, organizar, resumir y presentar datos de manera clara y comprensible.

A diferencia de la estadística inferencial, que busca demostrar asociaciones o hacer comparaciones para extrapolar resultados de una muestra a una población, la descriptiva se limita a **sintetizar la información contenida en los datos recogidos** sin realizar inferencias más allá de la información disponible (Bonita et al., 2008; Posada, 2016).

Su propósito fundamental es facilitar la comprensión de grandes volúmenes de información mediante el uso de **tablas, representaciones gráficas y medidas resumen** (como la media o la desviación estándar), permitiendo “hacerse una idea” de la naturaleza de un conjunto de datos sin tener que analizar cada uno de ellos individualmente (Posada, 2016; Rey, 2007; Spiegel & Stephens, 2009).

### 3.2. Fases del análisis de datos

Todo el proceso del análisis estadístico se muestra en la Figura 3.1. Se parte de una **pregunta de investigación** que orienta el proceso y define la información necesaria para responderla. A continuación, se realiza la **recopilación de los datos** mediante observación, medición, encuestas o fuentes secundarias. Una vez obtenida la información, es necesario efectuar la **depuración de los datos** para identificar errores, inconsistencias y valores faltantes que puedan afectar los resultados. Posteriormente, se desarrolla el **análisis estadístico** utilizando técnicas descriptivas o inferenciales que permitan extraer información relevante. Los resultados obtenidos deben ser **interpretados** en función del contexto del estudio y de la pregunta de investigación planteada inicialmente. Por último, la **visualización de los datos** mediante tablas, gráficos e infografías facilita la comunicación de los hallazgos y contribuye a la toma de decisiones basada en evidencia.

### 3.3. Tipos de variables

Las **variables** son los **atributos, cualidades o características** que pueden ser observadas, clasificadas o medidas en las personas, objetos o fenómenos de una población o muestra. En estadística, su identificación es esencial porque posibilita



Figura 3.1

la descripción, el análisis y la interpretación de la información recopilada. Las variables se dividen en cualitativas y cuantitativas, tal como se muestra en la Figura 3.2.

Las variables cualitativas, que son nominales u ordinales, describen atributos o categorías; por otro lado, las variables cuantitativas, que se dividen en discretas y continuas dependiendo si surgen de procesos de conteo o de medición, ilustran cantidades numéricas. Esta clasificación es esencial porque determina el tipo de análisis estadístico, representación gráfica y medidas descriptivas que pueden aplicarse a los datos.




Figura 3.2

### 3.4. Importancia de la identificación de variables estadísticas y escalas de medición

Una parte fundamental del análisis estadístico es la clasificación de las variables, porque a partir de esta se determina qué métodos, procedimientos y representaciones gráficas son los más idóneos para tratar los datos. Las variables cualitativas, como se ilustra en la Figura 3.3, delinean categorías o características y habitualmente se examinan a través de porcentajes, frecuencias y medidas como la moda o la mediana en el caso de las variables ordinales.

Las variables cuantitativas, en cambio, son valores numéricos que provienen de procesos de conteo o medición. Estas variables posibilitan el uso de medidas de tendencia central y dispersión, como la varianza, la media, la desviación estándar y el coeficiente de variación. En esta línea, si se identifica apropiadamente el tipo de variable, se logra una interpretación correcta de la información y se asegura que las técnicas estadísticas aplicadas sean congruentes con la naturaleza de los datos.

(Armitage et al., 2002).



# 1. VARIABLES ESTADÍSTICAS

Son características que pueden observarse o medirse en individuos, objetos o fenómenos.

## A. VARIABLES CUALITATIVAS (ATRIBUTOS)

Describen cualidades o categorías que no pueden expresarse numéricamente.

### A1 Nominales

Categorías sin orden natural.



Ejemplos:

- Género
- Estado civil
- Lugar de nacimiento

Escala asociada:  
Escala nominal

Medidas estadísticas sugeridas:



Moda



Frecuencias



Porcentajes

### A2 Ordinales

Existe orden o jerarquía entre categorías.



Ejemplos:

- Estrato socioeconómico
- Nivel educativo
- Grado militar

Escala asociada:  
Escala ordinal

Medidas estadísticas sugeridas:



Mediana



Percentiles  
(Cuartiles)



Rangos



Moda

## B. VARIABLES CUANTITATIVAS

Representan cantidades numéricas obtenidas mediante conteo o medición.

### B1 Discretas

Resultan de procesos de conteo.  
Toman valores enteros aislados.



Ejemplos:

- Número de hijos
- Número de artículos defectuosos

Escala asociada:  
Intervalo o Razón

Medidas estadísticas sugeridas:



Media



Varianza



Desviación  
estándar



Rango  
(Recorrido)

### B2 Continuas

Resultan de procesos de medición.  
Pueden tomar cualquier valor dentro de un intervalo.



Ejemplos:

- Peso
- Estatura
- Edad

Escala asociada:  
Intervalo o Razón

Medidas estadísticas sugeridas:



Media



Mediana



Desviación  
estándar



Coefficiente de  
variación



CONTEO

(proceso de enumeración)



Variables  
discretas



MEDICIÓN

(proceso de medición)



Variables  
continuas

Fuente: Adaptado de Armitage, P. (2002). Statistical methods in medical research; Kleinbaum, D. G., et al. (1982). Epidemiologic research: Principles and quantitative methods; y lineamientos de bioestadística aplicada.

Figura 3.3

### 3.5. Escalas de medición

Las **escalas de medición** representan el nivel de información que poseen los datos y constituyen un elemento fundamental en estadística, ya que determinan las operaciones matemáticas y los análisis que pueden realizarse sobre las variables.

Como se observa en la Figura 3.4, las escalas nominal y ordinal se emplean principalmente en variables cualitativas, mientras que las escalas de intervalo y razón se asocian con variables cuantitativas. A medida que aumenta el nivel de medición, también incrementa la precisión estadística y la complejidad de los métodos analíticos que pueden aplicarse. Por ello, la correcta identificación de la escala permite seleccionar adecuadamente medidas descriptivas, pruebas estadísticas y representaciones gráficas acordes con la naturaleza de los datos.

Las escalas de medición permiten clasificar las variables según el tipo de información que proporcionan.

- La **escala nominal** organiza datos en categorías sin orden, por lo que suele analizarse mediante frecuencias y porcentajes.
- La **escala ordinal** incorpora jerarquía entre categorías, permitiendo el uso de medidas como mediana, rangos y percentiles.
- Por su parte, la **escala de intervalo** presenta distancias iguales entre valores, aunque sin un cero absoluto, lo que posibilita análisis como correlaciones y desviaciones estándar.
- Finalmente, la **escala de razón** posee todas las propiedades anteriores y un cero real, permitiendo realizar operaciones matemáticas completas y análisis estadísticos más avanzados. La figura resume las principales características, ejemplos, medidas estadísticas y representaciones gráficas asociadas a cada escala.

La selección de las técnicas estadísticas depende directamente de la escala de medición de las variables. Como se presenta en la figura, las variables medidas en escala nominal suelen representarse mediante gráficos de barras o pastel y analizarse con frecuencias y moda.

Las escalas ordinales permiten incorporar análisis basados en orden y posición, como percentiles o cuartiles. En contraste, las escalas de intervalo y razón posibilitan el cálculo de medidas paramétricas como media, varianza, desviación estándar y análisis de regresión. En consecuencia, conocer la escala de medición garantiza la aplicación de procedimientos estadísticos válidos y una interpretación adecuada de los resultados obtenidos.

### 3.6. Base de datos de trabajo

Este libro empleará dos bases de datos, con fines pedagógicos y prácticos.

#### 3.6.1. bd S07D\_Acuicultura.csv

La primera base de datos utilizada en este libro corresponde al **Tercer Censo Nacional Agropecuario (CNA) de Colombia, realizado en 2014**, específicamente a la subbase del **sector acuícola**, cuya información fue suministrada por el **Departamento Administrativo Nacional de Estadística (DANE)**. Esta fuente constituye un insumo oficial de carácter nacional que permite trabajar con datos reales asociados a la actividad productiva acuícola del país. Ver diccionario de variables en sitio web del DANE [Diccionario\\_S07D\\_Acuicultura](#)



#### 3.6.2. bd medidas antropométricas

La segunda base de datos corresponde a un conjunto de información antropométrica recopilada en estudiantes universitarios durante actividades académicas de la asignatura **Estadística Descriptiva y Probabilidad**, orientadas por el profesor **Miguel Oswaldo Pérez Pulido**. Esta base incluye variables relacionadas con el peso corporal, la estatura, la longitud de diferentes segmentos corporales, el índice de masa corporal (IMC) y otras medidas antropométricas de interés.

Esta base de datos fue construida a partir del **Taller de Clase No. 2: Práctica sobre Medidas Antropométricas**, desarrollado en el marco de la asignatura **Estadística Descriptiva y Probabilidad**, constituyéndose en un recurso

## 2. ESCALAS DE MEDICIÓN Y ANÁLISIS ESTADÍSTICO

La naturaleza de las observaciones determina el nivel de medición, lo cual es fundamental para elegir el método estadístico apropiado.

ESCALA	CARACTERÍSTICA	EJEMPLOS	MEDIDAS ESTADÍSTICAS QUE SE UTILIZAN	GRÁFICOS SUGERIDOS
<b>1</b> <b>NOMINAL</b> 	Clasifica categorías mutuamente excluyentes sin orden.	• Género     • Ciudad de origen     • Tipo de sangre      	• <b>Moda</b>     • <b>Frecuencias</b>     • <b>Porcentajes</b>	Barras o pastel 
<b>2</b> <b>ORDINAL</b> 	Existe jerarquía o orden entre las categorías, pero las distancias no son uniformes.	• Estrato socioeconómico     • Nivel académico     • Grado militar      	• <b>Mediana</b>     • <b>Cuartiles</b>     • <b>Percentiles</b>     • <b>Rangos</b>     • <b>Moda</b>	Barras ordenadas 
<b>3</b> <b>INTERVALO</b> 	Posee orden y distancias iguales entre valores. El cero es arbitrario y no indica ausencia de la propiedad.	• Temperatura (°C o °F)     • Años en el calendario      	• <b>Media</b>     • <b>Desviación estándar</b>     • <b>Varianza</b>     • <b>Correlación</b>     • <b>Análisis de regresión</b>	Histograma o curva 
<b>4</b> <b>RAZÓN</b> 	Posee todas las propiedades anteriores y un cero absoluto que indica ausencia total de la característica.	• Edad     • Peso     • Ingresos     • Longitud      	• <b>Media</b>     • <b>Varianza</b>     • <b>Desviación estándar</b>     • <b>Coefficiente de variación</b>     • <b>Análisis de regresión</b>     • <b>Razones y proporciones</b>	Histogramas, dispersión, boxplot 

Mayor  
precisión  
y complejidad  
estadística





Elegir correctamente el tipo de variable y su escala de medición garantiza el uso adecuado de las técnicas estadísticas y la validez de los resultados.



Figura 3.4

didáctico para el aprendizaje experiencial de la estadística mediante el análisis de datos obtenidos por los propios estudiantes.

#### Material complementario

☐ Taller utilizado para la recolección de las medidas antropométricas:

**Taller de Medidas Antropométricas**

El empleo de bases de datos reales tiene como objetivo potenciar el aprendizaje a partir de la experiencia, fomentando que el alumno no solamente asimile conceptos estadísticos, sino que además adquiera capacidades para analizar información, tomar decisiones y usar herramientas de análisis de datos con R en entornos próximos a su realidad laboral.

## 3.7. Trabajando con las bases de datos

### 3.8. bd Acuicultura

```
=====
CARGA Y EXPLORACIÓN DE LA BASE DE DATOS
=====

Librerías
library(readr)
library(dplyr)

Cargar base de datos de acuicultura
acuicultura <- read_csv(
 "data/S07D_Acuicultura.csv"
)

Visualizar primeras filas
head(acuicultura)
```

```
A tibble: 6 x 14
 ...1 TIPO_REG PAIS P_DEPTO P_MUNIC UC_UO ENCUESTA COD_VEREDA P_S7PNUMPEZ
 <dbl> <dbl> <dbl> <dbl> <dbl> <chr> <chr> <dbl> <dbl>
1 1 7 170 68 68001 00310001 022537951 68001007 1
2 2 7 170 68 68001 00420001 022303666 68001009 1
3 3 7 170 68 68001 00690001 022317829 68001027 2
4 4 7 170 68 68001 00900001 022318620 68001002 1
5 5 7 170 68 68001 00920001 022736078 68001009 1
6 6 7 170 68 68001 00970001 022317801 68001024 1
i 5 more variables: P_S7P96 <dbl>, P_S7P97 <dbl>, P_S7P98 <dbl>,
P_S7P99 <dbl>, P_S7P100 <dbl>
```

```
Número de filas y columnas
dim(acuicultura)
```

```
[1] 3447 14
```

```
Nombres de las variables
names(acuicultura)
```

```
[1] "...1" "TIPO_REG" "PAIS" "P_DEPTO" "P_MUNIC"
[6] "UC_UO" "ENCUESTA" "COD_VEREDA" "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97" "P_S7P98" "P_S7P99" "P_S7P100"
```



```
Estructura general de la base
str(acuicultura)

spec_tbl_ [3,447 x 14] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $...1 : num [1:3447] 1 2 3 4 5 6 7 8 9 10 ...
 $ TIPO_REG : num [1:3447] 7 7 7 7 7 7 7 7 7 7 ...
 $ PAIS : num [1:3447] 170 170 170 170 170 170 170 170 170 170 ...
 $ P_DEPTO : num [1:3447] 68 68 68 68 68 68 68 68 68 68 ...
 $ P_MUNIC : num [1:3447] 68001 68001 68001 68001 68001 68001 ...
 $ UC_UO : chr [1:3447] "00310001" "00420001" "00690001" "00900001" ...
 $ ENCUESTA : chr [1:3447] "022537951" "022303666" "022317829" "022318620" ...
 $ COD_VEREDA : num [1:3447] 6.8e+07 6.8e+07 6.8e+07 6.8e+07 6.8e+07 6.8e+07 ...
 $ P_S7PNUMPEZ : num [1:3447] 1 1 2 1 1 1 1 2 1 18 ...
 $ P_S7P96 : num [1:3447] 41190400 41190300 41191000 41190400 41190300 ...
 $ P_S7P97 : num [1:3447] 1 0 1 1 1 1 1 6 0 0 ...
 $ P_S7P98 : num [1:3447] 50 0 300 50 200 50 30 80 0 0 ...
 $ P_S7P99 : num [1:3447] 5 0 5 5 4 3.75 5 5 0 0 ...
 $ P_S7P100 : num [1:3447] 0.25 0 1.5 0.25 0.8 ...
- attr(*, "spec")=
 .. cols(
1 = col_double(),
 .. TIPO_REG = col_double(),
 .. PAIS = col_double(),
 .. P_DEPTO = col_double(),
 .. P_MUNIC = col_double(),
 .. UC_UO = col_character(),
 .. ENCUESTA = col_character(),
 .. COD_VEREDA = col_double(),
 .. P_S7PNUMPEZ = col_double(),
 .. P_S7P96 = col_double(),
 .. P_S7P97 = col_double(),
 .. P_S7P98 = col_double(),
 .. P_S7P99 = col_double(),
 .. P_S7P100 = col_double()
 ..)
- attr(*, "problems")=<externalptr>

Abrir base completa en RStudio
View(acuicultura)
```

### 3.8.1. ¿Qué estamos haciendo?

Antes de realizar cualquier análisis estadístico, es fundamental explorar la base de datos para comprender su estructura, contenido y tipo de información disponible. Esta etapa permite identificar: número de observaciones; cantidad de variables; nombres de las columnas; tipos de datos (numéricos, categóricos o texto); posibles datos faltantes y características generales de la información.

La función `head()` muestra las primeras filas de la base de datos, permitiendo visualizar cómo se encuentran organizadas las observaciones. Por su parte, `dim()` indica el número de filas y columnas, mientras que `names()` permite identificar el nombre de cada variable.

La función `glimpse()` ofrece una visión rápida de la estructura de la base, mostrando el tipo de dato de cada variable y algunos ejemplos de sus valores. Finalmente, `summary()` genera un resumen descriptivo básico de las variables cuantitativas y categóricas.

### 3.8.2. Reflexión del estudiante

- ¿Cuántas variables contiene la base de datos?
- ¿Qué tipos de variables identifica?
- ¿Existen variables cuantitativas y cualitativas?
- ¿Cuál variable considera más importante para el análisis?
- ¿Observa posibles datos faltantes?

### 3.8.3. Diccionario de datos

```
library(readr)
library(dplyr)
library(janitor)

Cargar base
acuicultura <- read_csv("data/S07D_Acuicultura.csv")

Crear estructura inicial del diccionario
diccionario <- tibble(
 variable = names(acuicultura),
 tipo_dato = sapply(acuicultura, class),
 valores_unicos = sapply(acuicultura, n_distinct),
 missing = sapply(acuicultura, function(x) sum(is.na(x)))
)

Ver diccionario
diccionario
```

```
A tibble: 14 x 4
 variable tipo_dato valores_unicos missing
 <chr> <chr> <int> <int>
1 ...1 numeric 3447 0
2 TIPO_REG numeric 1 0
3 PAIS numeric 1 0
4 P_DEPTO numeric 1 0
5 P_MUNIC numeric 84 0
6 UC_UO character 662 0
7 ENCUESTA character 2590 0
8 COD_VEREDA numeric 870 0
9 P_S7PNUMPEZ numeric 11 4
10 P_S7P96 numeric 27 4
11 P_S7P97 numeric 13 0
12 P_S7P98 numeric 125 0
13 P_S7P99 numeric 113 0
14 P_S7P100 numeric 370 0
```

**Interpretación:** La base de datos contiene 3447 observaciones y 14 variables relacionadas con información del sector acuícola. Se identifican variables de tipo categórico (chr) y numérico (dbl), lo que permitirá desarrollar análisis descriptivos tanto para variables cualitativas como cuantitativas. La exploración inicial facilita comprender la estructura de la información antes de aplicar técnicas estadísticas más avanzadas.

Para exportar el diccionario

```
library(writexl)

write_xlsx(diccionario,
 "data/diccionario_acuicultura.xlsx")
```

variable	descripcion
TIPO_REG	Tipo de región
PAIS	País
P_DEPTO	Departamento
P_MUNIC	Municipio
UC_UO	Unidad de cobertura y unidad de observación
ENCUESTA	Encuesta
COD_VEREDA	Código de vereda
P_S7PNUMPEZ	Orden de pez
P_S7P96	Nombre de la especie cultivada
P_S7P97	Número de cosechas en el año
P_S7P98	Número de animales por cosecha
P_S7P99	Peso promedio por animal en gramos
P_S7P100	Producción total durante 2013 en kilogramos

Esta instrucción permite ver el libro en quarto.

```
library(gt)

diccionario_acuicultura <- tibble(
 variable = c(
 "TIPO_REG", "PAIS", "P_DEPTO", "P_MUNIC", "UC_UO",
 "ENCUESTA", "COD_VEREDA", "P_S7PNUMPEZ", "P_S7P96",
 "P_S7P97", "P_S7P98", "P_S7P99", "P_S7P100"
),
 descripcion = c(
 "Tipo de región",
 "País",
 "Departamento",
 "Municipio",
 "Unidad de cobertura y unidad de observación",
 "Encuesta",
 "Código de vereda",
 "Orden de pez",
 "Nombre de la especie cultivada",
 "Número de cosechas en el año",
 "Número de animales por cosecha",
 "Peso promedio por animal en gramos",
 "Producción total durante 2013 en kilogramos"
)
)

diccionario_acuicultura |>
 gt()
```

## 3.9. Actividad experiencial

### 3.9.1. Explorando una base de datos del DANE

**Contexto de la actividad:** En estadística aplicada, antes de realizar cualquier análisis es fundamental comprender las características de las variables contenidas en una base de datos. Para ello, se utilizará una base oficial del Departamento

Administrativo Nacional de Estadística (DANE) correspondiente al módulo de acuicultura. Los estudiantes actuarán como analistas de datos, explorando información real utilizada en estudios productivos y socioeconómicos.

**Objetivo de aprendizaje:** Al finalizar esta actividad, el estudiante será capaz de explorar una base de datos real, identificar tipos de variables y escalas de medición, seleccionar representaciones gráficas adecuadas e interpretar información estadística básica utilizando R.

Fuente oficial: [DANE – Diccionario S07D Acuicultura](#)

### 3.9.2. Desarrollo de la actividad

#### Parte 1. Exploración de la base de datos

##### Instrucciones

Cargar la base de datos en R.

Revisar los nombres de las variables.

Consultar el diccionario oficial del DANE.

Identificar el significado de cada variable, tipo de variable, escala de medición, unidad de medida, posible representación gráfica y medidas estadísticas aplicables.

```
library(readr)
library(dplyr)

Cargar base de datos
acuicultura <- read_csv(
 "data/S07D_Acuicultura.csv"
)

Explorar estructura emplee los siguientes comandos de R
names(acuicultura)
glimpse(acuicultura)
head(acuicultura)
```

#### Parte 2. Completar la tabla de clasificación

**Instrucciones para el estudiante:** Complete la siguiente tabla utilizando la exploración en R, el diccionario del DANE, los conceptos vistos en clase sobre variables y escalas de medición.

Variable	Descripción	Tipo de variable	Escala de medición	Unidad de medida	Ejemplo de gráfico	Medidas estadísticas sugeridas
TIPO_REG						
PAIS						
P_DEPTO						
P_MUNIC						
UC_UO						
ENCUESTA						
COD_VEREDA						
P_S7PNUMPEZ						
P_S7P96						
P_S7P97						
P_S7P98						
P_S7P99						
P_S7P100						

#### Parte 3. Interpretación estadística



**Responda las siguientes preguntas:**

- ¿Qué variables son cualitativas y cuáles cuantitativas?
- ¿Qué variables corresponden a procesos de conteo?
- ¿Qué variables corresponden a procesos de medición?
- ¿Cuál variable podría analizarse mediante: histogramas, diagramas de barras, boxplots, entre otros.
- ¿Qué variable considera más importante para analizar la producción acuícola y por qué?
- ¿Qué variable considera más relevante para evaluar productividad acuícola?
- ¿Qué variables podrían utilizarse para construir indicadores económicos?
- ¿Qué problemas podrían surgir si una variable se clasifica incorrectamente?
- ¿Qué variables podrían presentar valores atípicos?

Ejemplo de una variable estudiada Curva de densidad de la producción acuícola.


```
library(ggplot2)

ggplot(
 acuicultura,
 aes(x = log10(P_S7P100 + 1))
) +

 geom_density(
 fill = "skyblue",
 alpha = 0.5,
 color = "blue",
 linewidth = 1
) +

 labs(
 title = "Curva de densidad de la producción acuícola",
 subtitle = "Escala logarítmica",
 x = "Log10 Producción total (kg)",
 y = "Densidad"
) +

 theme_minimal()
```



**Interpretación:** La distribución de la producción acuícola presenta una marcada asimetría positiva, razón por la cual se utilizó una transformación logarítmica para facilitar la visualización de la densidad de los datos. Este comportamiento es frecuente en variables productivas y económicas, donde pocas observaciones concentran valores muy altos mientras la mayoría presenta valores moderados o bajos.

### 3.10. Mini reto analítico

Imagine que usted trabaja en una entidad gubernamental encargada de monitorear la producción acuícola del país. Con base en la información disponible:

- ¿qué variable utilizaría para estimar productividad?
- ¿qué tipo de gráfico presentaría a un directivo?
- ¿qué indicador resumiría mejor la información?
- ¿qué riesgos tendría interpretar incorrectamente los datos?

#### Conclusión

De acuerdo con lo anterior la estadística descriptiva permite transformar datos brutos en información significativa mediante el uso de tablas, representaciones gráficas y medidas resumen. Este proceso facilita la organización, interpretación y comprensión de los fenómenos analizados, constituyéndose en una herramienta fundamental para la toma de decisiones basadas en evidencia. Asimismo, la correcta identificación del tipo de variable y de la escala de medición resulta esencial para seleccionar las técnicas estadísticas apropiadas. Un error frecuente consiste en analizar variables ordinales como si fueran cuantitativas continuas o asumir que los datos siguen distribuciones normales sin verificar los supuestos requeridos, lo cual puede afectar la validez de los resultados y conducir a interpretaciones erróneas.

## Capítulo 4

# Preparación de datos

La preparación de datos es la etapa inicial del análisis estadístico en la que se revisa, organiza, limpia y transforma la información disponible antes de aplicar técnicas descriptivas o inferenciales. El flujo de trabajo se muestra en la Figura 4.1. Su propósito es garantizar que los datos sean coherentes, completos y adecuados para responder una pregunta de análisis Hair et al. (2019).

Al finalizar este capítulo, el estudiante estará en capacidad de importar bases de datos en R, explorar su estructura, identificar valores faltantes, reconocer inconsistencias, recodificar variables y preparar una base limpia para el análisis estadístico.

### 4.1. Carga de datos en R

Para iniciar el trabajo en R, el primer paso fundamental consiste en definir el directorio de trabajo, es decir, la ubicación donde se encuentran los archivos de datos y donde se almacenarán los resultados del análisis. Esto puede realizarse mediante la función `setwd()` o a través de herramientas gráficas del entorno de desarrollo (RStudio) (Wickham & Golemund, 2017). Existen múltiples métodos para cargar datos dependiendo de su formato:

Tabla 4.1: Métodos de carga de datos en R

Método	Característica	Ejemplo
Archivos de texto y CSV	Uso de funciones como <code>read.csv()</code> o <code>read.csv2()</code> , especificando encabezados y codificación	Importación de archivos <code>.csv</code>
Interfaces gráficas (GUI)	Herramientas como R Commander permiten importar datos sin necesidad de programación	Importación desde Excel, SPSS, STATA
Minería de datos	Paquetes como <code>rattle</code> permiten cargar datos mediante interfaces visuales configurables	Definición de separadores y decimales

### 4.2. Limpieza de datos

La limpieza de datos consiste en detectar, corregir o eliminar inconsistencias que puedan afectar la validez del análisis estadístico (Van den Broeck et al., 2005). Un paso inicial es la inspección visual del conjunto de datos para identificar registros incompletos, errores de digitación o valores atípicos. Por ejemplo, líneas que contienen exclusivamente valores faltantes (NA) deben ser evaluadas antes de su inclusión en el análisis.

## Flujo general de preparación




Figura 4.1: Flujo general de preparación de datos

Tabla 4.2: Aspectos clave en la preparación de datos

Proceso	Subproceso	Descripción	Herramienta / Ejemplo
<b>Limpieza de datos</b>	Valores extremos (Outliers)	Identificación y tratamiento de datos atípicos que pueden distorsionar resultados. Se recomienda corregir o eliminar errores evidentes.	Diagramas de caja ( <i>boxplot</i> ) (Tukey, 1977)
	Consistencia de totales	Verificación de coherencia entre frecuencias, totales y porcentajes acumulados.	Validación de sumas (Agresti, 2018)
	Filtrado de datos	Selección de subconjuntos de datos según criterios específicos para análisis focalizado.	Filtrado en R ( <i>subset</i> , <i>filter</i> )
<b>Valores faltantes</b>	Identificación y codificación	Asignación de códigos (ej: 99, 999) para identificar datos perdidos.	Codificación en R o SPSS
	Eliminación de casos	Eliminación de registros incompletos antes del análisis.	<code>na.omit()</code> , <code>na.exclude()</code>
	Imputación	Estimación de valores faltantes mediante métodos estadísticos.	Métodos de imputación
	Análisis de censura	Tratamiento de datos incompletos en estudios de supervivencia.	(Kleinbaum & Klein, 2012)
<b>Recodificación</b>	Categorización de variables	Transformación de variables cuantitativas en categorías.	Agrupación de edades
	Codificación de atributos	Asignación de valores numéricos a variables cualitativas.	1 = Masculino, 2 = Femenino
	Variables dummy	Conversión de variables categóricas en variables binarias.	(Wooldridge, 2016)
	Tratamiento de etiquetas	Conversión de códigos numéricos a etiquetas descriptivas.	<code>factor()</code> en R

La preparación de datos es una etapa esencial para garantizar la calidad del análisis estadístico. Antes de calcular indicadores o construir gráficos, es necesario comprender la estructura de la base, revisar inconsistencias, identificar valores faltantes y transformar las variables cuando sea necesario. Un análisis confiable comienza con datos bien preparados .

## Capítulo 5

# Organización e interpretación de datos estadísticos

La organización y presentación de datos constituye una fase esencial en el análisis estadístico, dado que facilita la transformación de información dispersa en conocimiento valioso para la comprensión de fenómenos reales y asistencia en la toma de decisiones fundamentadas en pruebas empíricas. En numerosos contextos académicos, científicos, sociales y organizacionales, los datos en sí mismos carecen de relevancia si no se organizan, sintetizan e interpretan de forma apropiada.

En este contexto, las tablas estadísticas y los gráficos constituyen instrumentos esenciales en el ámbito de la estadística descriptiva. Las tablas facilitan la clasificación, organización y síntesis de la información a través de frecuencias, proporciones y distribuciones, mientras que los gráficos promueven una visualización e interpretación más intuitiva y comprensible de los datos.

Este capítulo proporciona los principios para la estructuración y examen de la información mediante diversas categorías de tablas estadísticas y representaciones gráficas, incorporando ejemplos aplicados e implementaciones en R que facilitarán el desarrollo de un aprendizaje práctico y experiencial del análisis descriptivo.

### 5.1. Datos simples

Los **datos simples** corresponden al registro directo, individual y no agrupado de cada observación obtenida en un estudio. En este formato, cada valor se conserva tal como fue recolectado, lo que permite identificar con facilidad observaciones particulares, posibles errores de registro, valores extremos y patrones preliminares.

Si se tiene una variable cuantitativa  $X$  observada en  $n$  individuos, los datos simples pueden representarse como:

$$X = \{x_1, x_2, x_3, \dots, x_n\}$$

donde:

- $x_i$  representa el valor observado en la unidad  $i$
- $n$  es el número total de observaciones

Este tipo de presentación es especialmente útil en etapas iniciales del análisis, cuando interesa inspeccionar la información en bruto antes de resumirla. Sin embargo, cuando el número de observaciones es grande, los datos simples se vuelven poco prácticos para interpretar tendencias generales.

### 5.2. Datos agrupados

Los **datos agrupados** se obtienen cuando los valores individuales se organizan en categorías o intervalos de clase. Esta forma de organización permite resumir grandes volúmenes de información y facilita la identificación de concentraciones,

patrones de distribución y tendencias generales.

Cuando la variable es cuantitativa continua, los intervalos suelen construirse a partir del rango de los datos. El rango de los datos se define como:

$$R = X_{\text{máx}} - X_{\text{mín}}$$

donde:

- $R$  es el rango
- $X_{\text{máx}}$  es el valor máximo observado
- $X_{\text{mín}}$  es el valor mínimo observado

Si se desea formar  $k$  clases, la amplitud del intervalo puede aproximarse mediante: La amplitud de clase se calcula como:

$$A = \frac{R}{k}$$

donde:

- $A$  es la amplitud de clase
- $k$  es el número de intervalos

Una regla empírica ampliamente usada para estimar el número de clases es la **regla de Sturges**:

$$k = 1 + 3.322 \log_{10}(n)$$

Esta expresión proporciona un valor de referencia para construir tablas de frecuencias agrupadas cuando el tamaño muestral es moderado.

## 5.3. Tablas de frecuencia

Las **tablas de frecuencia** permiten resumir la distribución de los datos, indicando cuántas veces aparece cada valor, categoría o intervalo. Son una herramienta central de la estadística descriptiva y constituyen la base para la construcción de histogramas, polígonos de frecuencia, diagramas de barras y otros gráficos.

Una tabla de frecuencia puede incluir los siguientes componentes:

### 5.3.1. Frecuencia absoluta

La **frecuencia absoluta** de una categoría o clase corresponde al número de veces que dicha categoría aparece en el conjunto de datos. Se denota por  $f_i$ .

$f_i$  = número de observaciones en la categoría o clase  $i$

### 5.3.2. Frecuencia relativa

La **frecuencia relativa** expresa la proporción de observaciones que pertenecen a una categoría respecto al total. Se denota por  $h_i$  y se calcula como:

$$h_i = \frac{f_i}{n}$$

Si se desea expresar en porcentaje:

$$h_i(\%) = \frac{f_i}{n} \times 100$$

### 5.3.3. Frecuencia acumulada

La **frecuencia acumulada** representa la suma progresiva de las frecuencias absolutas hasta la clase  $i$ . Se denota por  $F_i$ :

$$F_i = \sum_{j=1}^i f_j$$

### 5.3.4. Frecuencia relativa acumulada

La **frecuencia relativa acumulada** corresponde a la suma progresiva de las frecuencias relativas. Se denota por  $H_i$ :

$$H_i = \sum_{j=1}^i h_j = \frac{F_i}{n}$$

donde:

- $H_i$  es la frecuencia relativa acumulada,
- $F_i$  es la frecuencia absoluta acumulada,
- $n$  es el número total de observaciones.

Estas medidas permiten conocer no solo la cantidad de datos en cada categoría, sino también la proporción acumulada de observaciones hasta determinado punto de la distribución.

## 5.4. Ejemplo de tabla de frecuencia: Variable P\_S7P97

La variable P\_S7P97 corresponde al **número de cosechas realizadas durante el año**, por lo que se clasifica como una **variable cuantitativa discreta**, ya que proviene de un proceso de conteo y solo admite valores enteros. La tabla de frecuencia permite resumir la distribución de esta variable, identificando: cuántas veces aparece cada valor, su porcentaje, y la frecuencia acumulada.

```
library(dplyr)
library(knitr)
library(readr)
library(kableExtra)

Cargar base de datos de Acuicultura
acuicultura <- read_csv(
 "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

Tabla de frecuencia
tabla_frecuencia <- acuicultura %>%
 count(P_S7P97, name = "fi") %>%
 mutate(
 hi = round(fi / sum(fi), 4),
 Porcentaje = round(hi * 100, 2),
 Fi = cumsum(fi),
 Hi = round(cumsum(hi), 4)
)
```



```

Cambiar nombres de columnas
colnames(tabla_frecuencia) <- c(
 "Número de cosechas",
 "f ",
 "h ",
 "Porcentaje (%)",
 "F ",
 "H "
)

Visualizar tabla
tabla_frecuencia %>%
 kable(
 caption = "Tabla de frecuencia del número de cosechas",
 align = "c",
 digits = 3
) %>%
 kable_styling(
 bootstrap_options = c("striped", "hover", "condensed"),
 full_width = FALSE,
 position = "center"
)

```

Tabla 5.1: Tabla de frecuencia del número de cosechas

Número de cosechas	$f_i$	$h_i$	Porcentaje (%)	$F_i$	$H_i$
0	620	0.180	17.99	620	0.180
1	1778	0.516	51.58	2398	0.696
2	678	0.197	19.67	3076	0.892
3	83	0.024	2.41	3159	0.916
4	42	0.012	1.22	3201	0.929
5	31	0.009	0.90	3232	0.938
6	49	0.014	1.42	3281	0.952
7	24	0.007	0.70	3305	0.959
8	23	0.007	0.67	3328	0.966
9	32	0.009	0.93	3360	0.975
10	33	0.010	0.96	3393	0.985
11	28	0.008	0.81	3421	0.993
12	26	0.007	0.75	3447	1.000

**Interpretación:** La tabla de frecuencia permite identificar cuáles son los números de cosechas más frecuentes entre las unidades productivas analizadas. Asimismo, facilita reconocer la concentración de observaciones, la dispersión de los datos y posibles patrones de comportamiento en la actividad acuícola. Cuando la mayoría de las observaciones se concentra en pocos valores, puede inferirse una baja variabilidad en el número de cosechas. Por el contrario, una distribución amplia sugiere heterogeneidad en los sistemas productivos.

## 5.5. Estructura general de una tabla de frecuencia

De manera general, una tabla de distribución de frecuencias para una variable cuantitativa agrupada permite resumir y organizar los datos en intervalos o clases, facilitando la interpretación de la distribución de los valores observados. Este tipo de tabla incluye frecuencias absolutas, relativas y acumuladas, así como la marca de clase, la cual representa el valor central de cada intervalo.

- **Clase o intervalo:** agrupa los datos en rangos numéricos para facilitar el análisis.
- **Marca de clase:** corresponde al punto medio de cada intervalo y representa el valor central de la clase.
- **Frecuencia absoluta** ( $f_i$ ): número de observaciones que pertenecen a cada intervalo.
- **Frecuencia relativa** ( $h_i$ ): proporción de observaciones respecto al total.
- **Frecuencia acumulada** ( $F_i$ ): suma progresiva de las frecuencias absolutas.
- **Frecuencia relativa acumulada** ( $H_i$ ): acumulación progresiva de las frecuencias relativas.

## 5.6. Marca de clase

La marca de clase corresponde al punto medio de cada intervalo:

$$x_i^* = \frac{L_i + U_i}{2}$$

donde:

- ( $x_i^*$ ) es la marca de clase
- ( $L_i$ ) es el límite inferior del intervalo
- ( $U_i$ ) es el límite superior del intervalo

La marca de clase resulta útil para representar la distribución mediante gráficos o para calcular medidas resumen aproximadas cuando los datos están agrupados.

```
library(readr)
library(dplyr)
library(knitr)
library(kableExtra)

Cargar base de datos
acuicultura <- read_csv(
 "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

Crear tabla agrupada
tabla_freq <- acuicultura %>%
 filter(!is.na(P_S7P97)) %>%
 mutate(
 Clase = cut(
 P_S7P97,
 breaks = 5,
 include.lowest = TRUE
)
) %>%
 count(Clase, name = "fi") %>%
 mutate(
 hi = fi / sum(fi),
 Fi = cumsum(fi),
 Hi = cumsum(hi)
)

Cambiar nombres de columnas
colnames(tabla_freq) <- c(
```

```

"Clase",
"f_i",
"h_i",
"F_i",
"H_i"
)

Mostrar tabla
tabla_freq %>%
 kable(
 caption = "Distribución de frecuencias agrupadas",
 escape = FALSE,
 align = "c",
 digits = 3
) %>%
 kable_styling(
 bootstrap_options = c("striped", "hover", "condensed"),
 full_width = FALSE
)

```

Tabla 5.2: Distribución de frecuencias agrupadas

Clase	f_i	h_i	F_i	H_i
[-0.012,2.4]	3076	0.892	3076	0.892
(2.4,4.8]	125	0.036	3201	0.929
(4.8,7.2]	104	0.030	3305	0.959
(7.2,9.6]	55	0.016	3360	0.975
(9.6,12]	87	0.025	3447	1.000

## 5.7. Organización de datos en contextos reales

En estadística aplicada, las tablas de frecuencia permiten transformar grandes volúmenes de datos en información interpretable. A través de ellas es posible identificar patrones, concentraciones, categorías predominantes y características generales de una población.

Para ilustrar estos conceptos, se utilizará una base de datos antropométrica que contiene mediciones corporales de estudiantes, incluyendo variables cualitativas y cuantitativas como género, grupo, peso y estatura.

El objetivo no será únicamente construir tablas estadísticas, sino interpretar cómo se distribuyen los datos y qué información aportan sobre la población estudiada.

## 5.8. Actividad Experiencial

### 5.8.1. Situación problema

Usted hace parte de un equipo de analítica académica encargado de caracterizar físicamente a un grupo de estudiantes para apoyar estudios de ergonomía, salud ocupacional y diseño de espacios educativos. A partir de la base de datos: identifique patrones, organice la información, construya tablas estadísticas, e interprete los resultados.

#### 5.8.1.1. Exploración inicial

```

library(readxl)
library(dplyr)

```

```
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
 "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)
```

```
head(datos)
```

```
A tibble: 6 x 17
```

	Clase	Grupo	Genero	Altura_cm	Peso_Kg	Anchura_hombros_cm	Long_Mano_cm
	<chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	D	A	M	177	73	49	19
2	D	A	M	177	86	45	19
3	D	A	F	160	52	37	16
4	D	A	F	159	53	38	16
5	D	A	F	174	78	41	18
6	D	B	M	186	68	44	19

```
i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
Mano_Dicotica <chr>
```

```
names(datos)
```

[1]	"Clase"	"Grupo"	"Genero"
[4]	"Altura_cm"	"Peso_Kg"	"Anchura_hombros_cm"
[7]	"Long_Mano_cm"	"Lon_Palma_cm"	"Ancho_Palma_cm"
[10]	"Long_Brazo_cm"	"Long_Antebrazo_cm"	"Long_Pierna_cm"
[13]	"Long_Pie_cm"	"Curso"	"Talla_Dicotica"
[16]	"IMC_Dicotico"	"Mano_Dicotica"	

```
glimpse(datos)
```

```
Rows: 260
```

```
Columns: 17
```

\$ Clase	<chr> "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "~
\$ Grupo	<chr> "A", "A", "A", "A", "A", "B", "B", "B", "B", "B", "B", "~
\$ Genero	<chr> "M", "M", "F", "F", "F", "M", "M", "F", "F", "F", "F", "~
\$ Altura_cm	<dbl> 177, 177, 160, 159, 174, 186, 174, 172, 156, 165, 1~
\$ Peso_Kg	<dbl> 73, 86, 52, 53, 78, 68, 115, 50, 62, 64, 94, 60, 63~
\$ Anchura_hombros_cm	<dbl> 49, 45, 37, 38, 41, 44, 49, 42, 42, 44, 48, 45, 36,~
\$ Long_Mano_cm	<dbl> 19, 19, 16, 16, 18, 19, 21, 19, 19, 18, 19, 18, 17,~
\$ Lon_Palma_cm	<dbl> 11.0, 10.0, 8.0, 9.0, 10.0, 11.0, 11.4, 10.1, 10.0,~
\$ Ancho_Palma_cm	<dbl> 9.0, 9.0, 8.0, 8.0, 8.5, 8.0, 9.0, 7.0, 8.0, 8.0, 9~
\$ Long_Brazo_cm	<dbl> 62.0, 59.0, 54.0, 52.0, 59.0, 74.0, 80.0, 76.0, 69.~
\$ Long_Antebrazo_cm	<dbl> 31.0, 31.0, 27.0, 27.0, 29.0, 29.0, 28.0, 26.0, 26.~
\$ Long_Pierna_cm	<dbl> 42.7, 41.8, 40.9, 49.1, 48.0, 43.4, 42.4, 44.2, 47.~
\$ Long_Pie_cm	<dbl> 23.7, 23.1, 25.1, 26.9, 27.0, 24.0, 22.9, 25.6, 24.~
\$ Curso	<chr> "2020-1", "2020-1", "2020-1", "2020-1", "2020-1", "~
\$ Talla_Dicotica	<chr> "Alta", "Alta", "Baja", "Baja", "Baja", "Alta", "Ba~
\$ IMC_Dicotico	<chr> "Normal+", "Normal+", "Normal+", "Normal+", "Normal~
\$ Mano_Dicotica	<chr> "Grande", "Grande", "Pequeña", "Pequeña", "Pequeña"~

### ! Preguntas para el estudiante

1. ¿Qué variables son cualitativas?
2. ¿Qué variables son cuantitativas?
3. ¿Qué variables corresponden a medición?
4. ¿Qué variables podrían agruparse?
5. ¿Qué información sería relevante para caracterizar a los estudiantes?

#### 5.8.1.2. Tablas de frecuencia cualitativas

### 5.8.2. Ejemplo: Género

La variable Género corresponde a una variable cualitativa nominal, ya que clasifica a los individuos en categorías mutuamente excluyentes sin un orden natural. Para este tipo de variables, las tablas de frecuencia permiten identificar la proporción y distribución de las categorías observadas.

#### 5.8.2.0.1. Tratamiento de valores faltantes

En bases de datos reales es común encontrar valores faltantes (NA). Antes de realizar análisis estadísticos, es importante identificar y evaluar la presencia de datos ausentes, ya que estos pueden afectar la interpretación de los resultados y la validez de los análisis.

```
library(readxl)
library(dplyr)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
 "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)
```

```
library(summarytools)
```

```
freq(datos$Genero)
```

Frequencies

datos\$Genero

Type: Character

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
F	208	80.00	80.00	80.00	80.00
M	52	20.00	100.00	20.00	100.00
<NA>	0			0.00	100.00
Total	260	100.00	100.00	100.00	100.00

```
Verificar si realmente existen NA
```

```
sum(is.na(datos$Genero))
```

```
[1] 0
```

En este caso, la variable Género no presenta valores faltantes; sin embargo, la función de resumen estadístico muestra automáticamente la categoría NA. Mediante el argumento `report.nas = FALSE` es posible ocultar esta categoría y presentar la tabla de frecuencias de forma más clara y limpia.

```
freq(
 datos$Genero,
 report.nas = FALSE)
```

Frequencies  
datos\$Genero  
Type: Character

	Freq	%	% Cum.
F	208	80.00	80.00
M	52	20.00	100.00
Total	260	100.00	100.00

#### 5.8.2.1. Preguntas de análisis

1. ¿Qué género presenta mayor frecuencia?
2. ¿La distribución parece equilibrada?
3. ¿Qué implicaciones tendría esto para un estudio antropométrico?
4. ¿La muestra parece representativa?

```
library(readxl)
library(dplyr)
library(knitr)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
 "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)

Tabla de frecuencia para la variable Género
tabla_genero <- datos %>%
 count(Genero, name = "fi") %>%
 mutate(
 hi = round(fi / sum(fi), 3),
 Fi = cumsum(fi),
 Hi = round(cumsum(hi), 3)
)

colnames(tabla_genero) <- c(
 "Categoría",
 "f_i",
 "h_i",
 "F_i",
 "H_i"
)

kable(
 tabla_genero,
 caption = "Tabla de frecuencia para la variable género",
```

```

escape = FALSE,
align = "c"
)

```

Tabla 5.3: Tabla de frecuencia para la variable género

Categoría	$f_i$	$h_i$	$F_i$	$H_i$
F	208	0.8	208	0.8
M	52	0.2	260	1.0

## 5.9. Ejemplo: Peso corporal

La variable Peso\_Kg corresponde a una variable cuantitativa continua obtenida mediante procesos de medición. Debido a que puede asumir múltiples valores dentro de un intervalo, resulta necesario organizar la información mediante intervalos de clase.

```

library(readxl)
library(dplyr)
library(summarytools)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
 "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
#)

Tabla de frecuencias
tabla_peso <- freq(
 datos$Peso_Kg,
 report.nas = FALSE,
 plain.ascii = FALSE
)

head(tabla_peso, 10)

```

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
31	3	1.1538462	1.153846	1.1538462	1.153846
32	3	1.1538462	2.307692	1.1538462	2.307692
34	1	0.3846154	2.692308	0.3846154	2.692308
35	5	1.9230769	4.615385	1.9230769	4.615385
36	9	3.4615385	8.076923	3.4615385	8.076923
37	8	3.0769231	11.153846	3.0769231	11.153846
38	13	5.0000000	16.153846	5.0000000	16.153846
39	8	3.0769231	19.230769	3.0769231	19.230769
39.5	1	0.3846154	19.615385	0.3846154	19.615385
40	17	6.5384615	26.153846	6.5384615	26.153846

## 5.10. Actividad experiencial: Organización de datos y tablas estadísticas

Un grupo de diseñadores y especialistas en ergonomía universitaria necesita analizar las características antropométricas de los estudiantes con el fin de adaptar el mobiliario de las aulas, mejorar la comodidad durante las jornadas académicas

y reducir posibles riesgos asociados a malas posturas.

Para ello, se utilizará la base de datos `bd_antropometricas.xlsx`, la cual contiene información relacionada con peso corporal, estatura y otras medidas físicas de los estudiantes.

El objetivo de esta actividad es transformar datos individuales en información organizada mediante tablas estadísticas y representaciones gráficas que permitan apoyar la toma de decisiones.

### 5.10.1. Objetivos de aprendizaje

Al finalizar la actividad, el estudiante estará en capacidad de:

- Identificar el tipo de variable y su escala de medición.
- Organizar datos mediante tablas de frecuencia.
- Construir tablas agrupadas para variables cuantitativas continuas.
- Interpretar distribuciones estadísticas.
- Analizar patrones, dispersión y posibles valores extremos.
- Relacionar la estadística descriptiva con problemas reales de análisis de datos.

## 5.11. Desarrollo de la actividad

### 5.11.1. Parte 1. Exploración inicial de los datos

Cargue la base de datos y explore las variables disponibles.

```
library(readxl)
library(dplyr)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
 "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

#)

head(datos)

A tibble: 6 x 17
 Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
 <chr> <chr> <chr> <dbl> <dbl> <dbl> <dbl>
1 D A M 177 73 49 19
2 D A M 177 86 45 19
3 D A F 160 52 37 16
4 D A F 159 53 38 16
5 D A F 174 78 41 18
6 D B M 186 68 44 19
i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
Mano_Dicotica <chr>

names(datos)
```



```

[1] "Clase" "Grupo" "Genero"
[4] "Altura_cm" "Peso_Kg" "Anchura_hombros_cm"
[7] "Long_Mano_cm" "Lon_Palma_cm" "Ancho_Palma_cm"
[10] "Long_Brazo_cm" "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm" "Curso" "Talla_Dicotica"
[16] "IMC_Dicotico" "Mano_Dicotica"

```

```
glimpse(datos)
```

Rows: 260

Columns: 17

```

$ Clase <chr> "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "~
$ Grupo <chr> "A", "A", "A", "A", "A", "B", "B", "B", "B", "B", "~
$ Genero <chr> "M", "M", "F", "F", "F", "M", "M", "F", "F", "F", "~
$ Altura_cm <dbl> 177, 177, 160, 159, 174, 186, 174, 172, 156, 165, 1~
$ Peso_Kg <dbl> 73, 86, 52, 53, 78, 68, 115, 50, 62, 64, 94, 60, 63~
$ Anchura_hombros_cm <dbl> 49, 45, 37, 38, 41, 44, 49, 42, 42, 44, 48, 45, 36,~
$ Long_Mano_cm <dbl> 19, 19, 16, 16, 18, 19, 21, 19, 19, 18, 19, 18, 17,~
$ Lon_Palma_cm <dbl> 11.0, 10.0, 8.0, 9.0, 10.0, 11.0, 11.4, 10.1, 10.0,~
$ Ancho_Palma_cm <dbl> 9.0, 9.0, 8.0, 8.0, 8.5, 8.0, 9.0, 7.0, 8.0, 8.0, 9~
$ Long_Brazo_cm <dbl> 62.0, 59.0, 54.0, 52.0, 59.0, 74.0, 80.0, 76.0, 69.~
$ Long_Antebrazo_cm <dbl> 31.0, 31.0, 27.0, 27.0, 29.0, 29.0, 28.0, 26.0, 26.~
$ Long_Pierna_cm <dbl> 42.7, 41.8, 40.9, 49.1, 48.0, 43.4, 42.4, 44.2, 47.~
$ Long_Pie_cm <dbl> 23.7, 23.1, 25.1, 26.9, 27.0, 24.0, 22.9, 25.6, 24.~
$ Curso <chr> "2020-1", "2020-1", "2020-1", "2020-1", "2020-1", "~
$ Talla_Dicotica <chr> "Alta", "Alta", "Baja", "Baja", "Baja", "Alta", "Ba~
$ IMC_Dicotico <chr> "Normal+", "Normal+", "Normal+", "Normal+", "Normal~
$ Mano_Dicotica <chr> "Grande", "Grande", "Pequeña", "Pequeña", "Pequeña"~

```

### 5.11.2. Parte 2. Identificación de variables

Complete la siguiente tabla para las variables seleccionadas:

Variable	Tipo de variable	Escala de medición	Unidad de medida	Herramienta estadística sugerida
Genero				
Grupo				
Peso_Kg				
Altura_cm				

### 5.11.3. Parte 3. Organización y análisis del peso corporal

La variable Peso\_Kg corresponde a una variable cuantitativa continua obtenida mediante procesos de medición. Debido a que puede asumir múltiples valores dentro de un intervalo, resulta conveniente organizar la información mediante tablas agrupadas y representaciones gráficas.

## 5.12. Situación problema

Los diseñadores requieren conocer:

- el rango de peso predominante,

- la dispersión de los datos,
- la presencia de valores extremos,
- y la homogeneidad de la muestra,

con el propósito de definir especificaciones ergonómicas adecuadas para las aulas universitarias.

### 5.12.1. Parte 4. Preguntas orientadoras

A partir del análisis de la variable `Peso_Kg`, responda:

1. ¿Dónde se concentra la mayor parte de los estudiantes?
2. ¿Existen valores extremos o atípicos?
3. ¿La distribución parece simétrica o presenta sesgo?
4. ¿Qué tan homogénea es la muestra?
5. ¿Sería recomendable agrupar los datos?
6. ¿Qué utilidad tendría esta información para el diseño del mobiliario universitario?

### 5.12.2. Parte 5. Construcción de tablas agrupadas

Utilice la regla de Sturges para estimar el número de clases y construya una tabla de distribución de frecuencias agrupadas.

La tabla debe incluir:

- Clase o intervalo
- Marca de clase
- Frecuencia absoluta ( $f_i$ )
- Frecuencia relativa ( $h_i$ )
- Frecuencia acumulada ( $F_i$ )
- Frecuencia relativa acumulada ( $H_i$ )

### 5.12.3. Parte 6. Visualización gráfica

Construya:

- Histograma
- Curva de densidad
- Boxplot

e interprete los resultados obtenidos.

### 5.12.4. Recomendación metodológica

La selección de la herramienta estadística depende del tipo de variable analizada:

Tipo de variable	Herramienta recomendada
Cualitativa	Tablas de frecuencia ( <code>freq()</code> )
Cuantitativa discreta	Tablas de frecuencia ( <code>freq()</code> )
Cuantitativa continua	Histogramas y tablas agrupadas

### 5.12.5. Reflexión final

La organización de datos constituye una etapa fundamental del análisis estadístico. Las tablas de frecuencia permiten transformar datos aislados en información estructurada, facilitando la identificación de patrones, tendencias y características generales de una población.

En contextos reales, estas herramientas son esenciales para apoyar procesos de investigación, caracterización poblacional y toma de decisiones basadas en evidencia. El análisis estadístico no consiste únicamente en calcular indicadores, sino en interpretar los datos y convertirlos en información útil para resolver problemas reales.

## Capítulo 6

# Visualización de datos

La visualización de datos es una etapa fundamental en la estadística descriptiva, ya que permite representar la información de forma clara, resumida e interpretable. Los gráficos facilitan la identificación de patrones, tendencias, valores atípicos y diferencias entre grupos, apoyando así la comprensión de los datos y la toma de decisiones (Figura 6.1).



Figura 6.1

En este capítulo se presentan algunos de los gráficos más utilizados en el análisis descriptivo: gráficos de barras, histogramas y diagramas de caja (*boxplot*), así como su construcción en R.

### 6.1. Gráficos en R

R es un lenguaje ampliamente utilizado para el análisis estadístico y la visualización de datos. Permite elaborar gráficos tanto con funciones básicas como con paquetes especializados, entre ellos `ggplot2`, que ofrece una sintaxis más flexible y una presentación más profesional.

Para los ejemplos de este capítulo se utilizarán las librerías `readxl` y `ggplot2`.

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
A tibble: 6 x 17
 Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
 <chr> <chr> <chr> <dbl> <dbl> <dbl> <dbl>
1 D A M 177 73 49 19
2 D A M 177 86 45 19
3 D A F 160 52 37 16
4 D A F 159 53 38 16
5 D A F 174 78 41 18
6 D B M 186 68 44 19
i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
Mano_Dicotica <chr>
```

```
str(datos)
```

```
tibble [260 x 17] (S3: tbl_df/tbl/data.frame)
 $ Clase : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo : chr [1:260] "A" "A" "A" "A" ...
 $ Genero : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
 $ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
 $ Long_Mano_cm : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
 $ Lon_Palma_cm : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
 $ Ancho_Palma_cm : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
 $ Long_Brazo_cm : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
 $ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
 $ Long_Pierna_cm : num [1:260] 42.7 41.8 40.9 49.1 48 43.4 42.4 44.2 47.8 39.7 ...
 $ Long_Pie_cm : num [1:260] 23.7 23.1 25.1 26.9 27 24 22.9 25.6 24.4 24.4 ...
 $ Curso : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
 $ Talla_Dicotica : chr [1:260] "Alta" "Alta" "Baja" "Baja" ...
 $ IMC_Dicotico : chr [1:260] "Normal+" "Normal+" "Normal+" "Normal+" ...
 $ Mano_Dicotica : chr [1:260] "Grande" "Grande" "Pequeña" "Pequeña" ...
```

## 6.2. Gráfico de sectores

El gráfico de pastel es una representación estadística utilizada para mostrar la distribución porcentual de una variable cualitativa. Cada sector del círculo representa una categoría y su tamaño es proporcional a la frecuencia relativa o porcentaje que dicha categoría aporta al total de observaciones.

```
library(readxl)
library(dplyr)
library(ggplot2)
library(scales)

Cargar base antropométrica
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)
```


```

Tabla de proporciones por género
tabla_genero <- datos %>%
 count(Genero) %>%
 mutate(
 proporcion = n / sum(n),
 porcentaje = percent(proporcion, accuracy = 0.1),
 etiqueta = paste0(Genero, "\n", porcentaje)
)

Gráfico de pastel
ggplot(
 tabla_genero,
 aes(
 x = "",
 y = proporcion,
 fill = Genero
)
) +
 geom_col(
 width = 1,
 color = "white"
) +
 coord_polar(theta = "y") +
 geom_text(
 aes(label = etiqueta),
 position = position_stack(vjust = 0.5),
 size = 4
) +
 labs(
 title = "Distribución porcentual de estudiantes según género",
 fill = "Género"
) +
 theme_void()

```

## Distribución porcentual de estudiantes según género



**Interpretación de la gráfica:** La gráfica evidencia que el 80 % de los estudiantes registrados en la base de datos corresponde al género femenino (F), mientras que el 20 % pertenece al género masculino (M). Esto indica una marcada predominancia de mujeres dentro de la muestra analizada.

Este tipo de representación facilita la comparación visual de proporciones entre categorías y permite identificar rápidamente la participación relativa de cada grupo dentro del conjunto de datos.

### 6.3. Gráfico de barras

El gráfico de barras se utiliza principalmente para representar variables cualitativas o categóricas. Su finalidad es mostrar la frecuencia o proporción de cada categoría mediante barras separadas, cuya altura es proporcional a la cantidad observada.


Por ejemplo, si se desea visualizar la distribución de una variable como el género o la clase, puede emplearse un gráfico de barras.

```
library(readxl)
library(dplyr)
library(ggplot2)

datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Gráfico de barras para Género
datos %>%
 count(Gruo) %>%
 ggplot(aes(x = Gruo, y = n)) +
 geom_col(fill = "#1F77B4", color = "white") +
 geom_text(
 aes(label = n),
 vjust = -0.4,
 size = 4
) +
```

```
labs(
 title = "Distribución de estudiantes según grupo",
 x = "Grupo",
 y = "Frecuencia"
) +
theme_minimal(base_size = 14)
```



```
library(readxl)
library(dplyr)
library(ggplot2)
library(scales)

datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Calcular proporciones por grupo
tabla_grupo <- datos %>%

 count(Grupo) %>%

 mutate(
 proporcion = n / sum(n)
)

Gráfico de barras con proporciones
ggplot(
 tabla_grupo,
 aes(x = Grupo, y = proporcion)
) +

 geom_col(
 fill = "#1F77B4",
```



```

 color = "white"
) +


 geom_text(
 aes(
 label = percent(proporcion)
),
 vjust = -0.4,
 size = 5
) +

 scale_y_continuous(
 labels = percent_format()
) +

 labs(
 title = "Proporción de estudiantes según grupo",
 x = "Grupo",
 y = "Proporción"
) +

 theme_minimal(base_size = 12)

```



**Interpretación:** El gráfico de proporciones permite identificar la participación relativa de cada grupo dentro del total de estudiantes analizados. A diferencia de las frecuencias absolutas, las proporciones facilitan la comparación entre categorías y permiten interpretar la distribución porcentual de la muestra.

## 6.4. Histograma

El histograma se utiliza para representar la distribución de una variable cuantitativa continua. A diferencia del gráfico de barras, en el histograma las barras se presentan unidas, ya que representan intervalos de clase contiguos.

Este tipo de gráfico es útil para identificar la forma de la distribución, la concentración de valores, posibles asimetrías y presencia de valores extremos.

### 6.4.1. Ejemplo con funciones básicas de R

```
library(readr)
library(dplyr)


Cargar base de datos de Acuicultura
acuicultura <- read_csv(
 "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv")

#Número de cosechas en el año (P_S7P97)
#archivo de datos: S07D(Acuicultura)

names(acuicultura)

[1] "...1" "TIPO_REG" "PAIS" "P_DEPTO" "P_MUNIC"
[6] "UC_U0" "ENCUESTA" "COD_VEREDA" "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97" "P_S7P98" "P_S7P99" "P_S7P100"

hist(acuicultura$P_S7P97,
 main = "Número de cosechas en el año (P_S7P97)",
 xlab = "Cosechas",
 ylab = "Frecuencia")
```





## 6.5. Boxplot

El diagrama de caja y bigotes, o *boxplot*, es un gráfico que resume la distribución de una variable cuantitativa a partir de los cuartiles, la mediana y los valores extremos (Figura 6.2). Es especialmente útil para detectar asimetrías y observaciones atípicas. El boxplot se basa en el resumen de cinco números:

# DIAGRAMA DE CAJAS (BOXPLOT)

Resumen visual de la distribución de un conjunto de datos numéricos



**IDEA CLAVE:** El diagrama de cajas permite identificar la tendencia central, la dispersión, la asimetría y la presencia de valores atípicos de manera rápida y efectiva.

Figura 6.2

### 6.5.1. Ejemplo con funciones básicas de R

```
library(readr)
library(ggplot2)

Cargar base de datos
acuicultura <- read_csv(
 "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

Boxplot
ggplot(
 acuicultura,

 aes(x = P_S7P97)
) +

 geom_boxplot(

 fill = "#2C7FB8",

 color = "black",

 alpha = 0.9,


 outlier.color = "red"
) +

 labs(
 title = "Distribución del número de cosechas",

 x = "Número de cosechas",

 y = ""
) +

 theme_minimal()
```



**Interpretación:** El boxplot evidencia que la mayor parte de las unidades productivas presentan un número bajo de cosechas, concentrándose principalmente entre 1 y 2 cosechas. La línea de la mediana se encuentra muy cercana al primer cuartil (Q1), lo cual sugiere una distribución asimétrica positiva, donde los valores altos son menos frecuentes pero considerablemente más dispersos.


Además, se observan múltiples valores atípicos hacia la derecha del gráfico, indicando la existencia de algunas unidades productivas con un número de cosechas significativamente superior al comportamiento general de la muestra. Esto evidencia una alta heterogeneidad en los datos y una posible concentración de productores con niveles excepcionales de producción.

El reducido tamaño de la caja refleja que el 50 % central de las observaciones se encuentra en un rango estrecho, mientras que la presencia de valores extremos amplía considerablemente el rango total de la distribución.

### 6.5.2. Ejemplo peso y género con ggplot2

También es posible comparar una variable cuantitativa entre categorías.

```
ggplot(datos, aes(x = Genero, y = Peso_Kg)) +
 geom_boxplot() +
 labs(
 title = "Distribución del peso según género",
 x = "Género",
 y = "Peso"
)
```



**Interpretación:** el boxplot evidencia diferencias en la distribución del peso corporal según el género. En los hombres (M) se observa una mediana de peso superior y una mayor dispersión de los datos en comparación con las mujeres (F), lo que indica una variabilidad más amplia en los valores registrados.

Asimismo, en ambos grupos se identifican valores atípicos representados por puntos fuera de los bigotes del diagrama, correspondientes a individuos con pesos considerablemente superiores al comportamiento general de la muestra. La amplitud de las cajas sugiere que el 50 % central de los pesos se encuentra más concentrado en las mujeres, mientras que en los hombres existe una mayor heterogeneidad.

Este tipo de representación gráfica permite comparar simultáneamente medidas de tendencia central, dispersión y posibles valores extremos entre categorías.

## Capítulo 7

# Medidas de tendencia central y dispersión

Las medidas de tendencia central son herramientas estadísticas utilizadas para resumir un conjunto de datos mediante un valor representativo o típico. Su principal objetivo es describir el comportamiento general de una distribución y facilitar la comparación entre diferentes conjuntos de información.

En términos generales, una medida de tendencia central representa el punto alrededor del cual tienden a agruparse las observaciones. Estas medidas permiten sintetizar grandes volúmenes de datos en un único valor numérico que describe de manera aproximada el comportamiento de la variable analizada.

Con frecuencia, estas medidas son denominadas “promedios”; sin embargo, cada una posee características particulares y su uso depende de la naturaleza de los datos y del propósito del análisis.

Las tres medidas de tendencia central más utilizadas son:

- **Media aritmética:** representa el promedio de los valores observados.
- **Mediana:** corresponde al valor central de los datos ordenados.
- **Moda:** identifica el valor o categoría que aparece con mayor frecuencia.

La elección de la medida más adecuada depende del tipo de variable, la presencia de valores extremos y la forma de la distribución de los datos. Por ejemplo, la media suele verse afectada por valores atípicos, mientras que la mediana ofrece una medida más robusta en distribuciones asimétricas.

Estas medidas constituyen una base fundamental para el análisis estadístico descriptivo y son ampliamente utilizadas en áreas como la salud, educación, ingeniería, economía y ciencias sociales, ya que permiten resumir información y apoyar la toma de decisiones basada en datos.

En este capítulo se presentan las principales medidas de tendencia central y de dispersión, junto con su formulación matemática y su implementación en R.

### 7.1. Medidas de tendencia central

#### 7.1.1. Media aritmética

La media aritmética es el promedio de los datos y se calcula como la suma de todas las observaciones dividida entre el número total de datos.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Donde:  $(x_i)$ : cada observación,  $(n)$ : número total de datos,  $\bar{x}$ : media aritmética

## 7.1.2. Cálculo en R

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
A tibble: 6 x 7
 Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
 <chr> <chr> <chr> <dbl> <dbl> <dbl> <dbl>
1 D A M 177 73 49 19
2 D A M 177 86 45 19
3 D A F 160 52 37 16
4 D A F 159 53 38 16
5 D A F 174 78 41 18
6 D B M 186 68 44 19
i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
Mano_Dicotica <chr>
```

```
str(datos)
```

```
tibble [260 x 17] (S3: tbl_df/tbl/data.frame)
 $ Clase : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo : chr [1:260] "A" "A" "A" "A" ...
 $ Genero : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
 $ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
 $ Long_Mano_cm : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
 $ Lon_Palma_cm : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
 $ Ancho_Palma_cm : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
 $ Long_Brazo_cm : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
 $ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
 $ Long_Pierna_cm : num [1:260] 42.7 41.8 40.9 49.1 48 43.4 42.4 44.2 47.8 39.7 ...
 $ Long_Pie_cm : num [1:260] 23.7 23.1 25.1 26.9 27 24 22.9 25.6 24.4 24.4 ...
 $ Curso : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
 $ Talla_Dicotica : chr [1:260] "Alta" "Alta" "Baja" "Baja" ...
 $ IMC_Dicotico : chr [1:260] "Normal+" "Normal+" "Normal+" "Normal+" ...
 $ Mano_Dicotica : chr [1:260] "Grande" "Grande" "Pequeña" "Pequeña" ...
```

```
names(datos)
```

```
[1] "Clase" "Grupo" "Genero"
[4] "Altura_cm" "Peso_Kg" "Anchura_hombros_cm"
[7] "Long_Mano_cm" "Lon_Palma_cm" "Ancho_Palma_cm"
[10] "Long_Brazo_cm" "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm" "Curso" "Talla_Dicotica"
[16] "IMC_Dicotico" "Mano_Dicotica"
```

```
mean(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 54.29808
```

## 7.1.3. Mediana

La mediana es el valor que divide el conjunto de datos ordenados en dos partes iguales, de modo que el 50 % de las observaciones queda por debajo y el otro 50 % por encima.



$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, & n \text{ impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & n \text{ par} \end{cases}$$

La mediana es una medida robusta frente a valores extremos.

#### 7.1.4. Cálculo en R

```
median(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 50
```

#### 7.1.5. Moda

La moda es el valor que aparece con mayor frecuencia en el conjunto de datos.

$$\text{Moda} = \arg \max(f_i)$$

#### 7.1.6. Cálculo en R

```
moda <- function(x) {
 ux <- unique(x)
 ux[which.max(tabulate(match(x, ux)))]
}
```

```
moda(datos$Peso_Kg)
```

```
[1] 40
```

## 7.2. Visualización de las medidas de tendencia central

```
library(readxl)
library(ggplot2)

Cargar datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Función para calcular la moda
moda <- function(x) {
 x <- na.omit(x)
 ux <- unique(x)
 ux[which.max(tabulate(match(x, ux)))]
}

Medidas de tendencia central
media <- mean(datos$Peso_Kg, na.rm = TRUE)
mediana <- median(datos$Peso_Kg, na.rm = TRUE)
moda_val <- moda(datos$Peso_Kg)

Histograma
```

```

ggplot(datos, aes(x = Peso_Kg)) +

 geom_histogram(
 bins = 10,
 fill = "skyblue",
 color = "black",
 alpha = 0.7
) +

 # Media
 geom_vline(
 xintercept = media,
 color = "red",
 linewidth = 1.2,
 linetype = "dashed"
) +


 # Mediana
 geom_vline(
 xintercept = mediana,
 color = "blue",
 linewidth = 1.2
) +

 # Moda
 geom_vline(
 xintercept = moda_val,
 color = "darkgreen",
 linewidth = 1.2,
 linetype = "dotdash"
) +

 labs(
 title = "Distribución del peso",
 subtitle = "Media (rojo), Mediana (azul) y Moda (verde)",
 x = "Peso (kg)",
 y = "Frecuencia"
) +

 theme_minimal()

```



### 7.3. Interpretación del gráfico: Distribución del peso

El histograma presenta la distribución de la variable **Peso (kg)** en la muestra analizada, incorporando las tres principales medidas de tendencia central:

□ **Media** (línea roja) □ **Mediana** (línea azul) □ **Moda** (línea verde)

#### 7.3.1. Análisis estadístico

**La media es mayor que la mediana y la moda**

Se observa que:  $Media > Mediana > Moda$ . Esto indica una **asimetría positiva** o sesgo hacia la derecha.

**Existencia de valores extremos**

La presencia de individuos con pesos altos (aproximadamente entre 140 y 190 kg) desplaza la media hacia valores mayores. Estos datos atípicos afectan principalmente la media, mientras que la mediana permanece más estable.

**Concentración principal de los datos**

La mayor frecuencia de observaciones se concentra entre aproximadamente **35 y 65 kg**, lo que indica que la mayoría de los participantes presentan pesos dentro de ese intervalo.

**Comportamiento de la moda**

La moda se ubica en el intervalo de mayor frecuencia, representando el peso más común dentro de la muestra.

### 7.4. Ejercicio experiencial propuesto

### 7.5. Actividad: Explorando las características antropométricas

**Objetivo:** Analizar diferentes variables antropométricas mediante histogramas y medidas de tendencia central para identificar patrones de distribución, variabilidad y posibles valores atípicos.

Variable	Interpretación
Altura_cm	Distribución de estaturas
Anchura_hombros_cm	Variabilidad corporal
Long_Brazo_cm	Proporciones anatómicas
Long_Muslo_cm	Longitud del miembro inferior
Long_Antebrazo_cm	Variabilidad segmentaria

## 7.6. Actividad práctica

### 7.6.1. Construcción del gráfico

Construya un histograma para cada una de las siguientes variables:

- Altura\_cm
- Anchura\_hombros\_cm
- Long\_Brazo\_cm

Incluya mediante líneas verticales de diferentes colores.

- Media, Mediana, Moda

### 7.6.2. Interpretación

Para cada gráfico responda:

1. ¿La distribución parece simétrica o asimétrica?
2. ¿Existen valores extremos?
3. ¿La media y la mediana son similares?
4. ¿Qué medida representa mejor el comportamiento de los datos?
5. ¿Cuál variable presenta mayor dispersión?

## Capítulo 8

# Medidas de dispersión o variabilidad

Las medidas de dispersión o variabilidad complementan a las medidas de tendencia central, ya que permiten describir qué tan agrupados o dispersos se encuentran los datos respecto a un valor representativo, como la media o la mediana.

Mientras que las medidas de tendencia central resumen la distribución mediante un único valor típico, las medidas de dispersión indican el grado de heterogeneidad presente en los datos. En consecuencia, dos conjuntos de datos pueden tener la misma media, pero comportamientos muy diferentes en cuanto a su variabilidad.

Por ejemplo, un grupo de observaciones puede presentar valores muy cercanos entre sí y concentrados alrededor de la media, mientras que otro grupo puede mostrar valores mucho más dispersos. Aunque ambos conjuntos tengan el mismo promedio, el segundo exhibirá mayor variabilidad.

La variabilidad constituye un aspecto fundamental en el análisis estadístico, ya que permite evaluar la estabilidad, consistencia y homogeneidad de los datos. En muchos contextos aplicados, comprender la dispersión resulta tan importante como conocer el promedio.

### 8.0.1. Rango

El rango es la diferencia entre el valor máximo y el mínimo.

$$R = X_{\max} - X_{\min}$$

### 8.0.2. Cálculo en R

```
max(datos$Peso_Kg, na.rm = TRUE) - min(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 84
```

### 8.0.3. Varianza muestral

La varianza mide la dispersión promedio de los datos respecto a la media.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

### 8.0.4. Cálculo en R

```
var(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 297.2303
```

### 8.0.5. Varianza poblacional

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

### 8.0.6. Desviación estándar muestral

La desviación estándar es la raíz cuadrada de la varianza y expresa la dispersión en las mismas unidades de los datos.

$$s = \sqrt{s^2}$$

### 8.0.7. Cálculo en R

```
sd(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 17.24037
```

### 8.0.8. Desviación estándar poblacional

$$\sigma = \sqrt{\sigma^2}$$

### 8.0.9. Coeficiente de variación

El coeficiente de variación permite comparar la dispersión relativa respecto a la media.

$$CV = \frac{s}{\bar{x}} \times 100$$

### 8.0.10. Cálculo en R

```
(sd(datos$Peso_Kg, na.rm = TRUE) / mean(datos$Peso_Kg, na.rm = TRUE)) * 100
```

```
[1] 31.75134
```

## 8.1. Resumen estadístico en R

R permite obtener múltiples medidas descriptivas de manera simultánea.

```
summary(datos$Peso_Kg)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
31.0	40.0	50.0	54.3	64.0	115.0

También es posible calcular varias medidas en conjunto:

```
library(summarytools)
descr(datos, stats=c("mean", "sd", "q1", "med", "q3", "min", "max", "cv"))
```

```
Descriptive Statistics
datos
N: 260
```

Altura_cm	Ancho_Palma_cm	Anchura_hombros_cm	Lon_Palma_cm	Long_Antebrazo_cm
-----------	----------------	--------------------	--------------	-------------------

Mean	166.81	8.07	53.83	9.46	27.54
Std.Dev	8.72	1.31	15.08	1.37	3.70
Q1	160.00	7.00	42.00	9.00	26.00
Median	165.00	8.00	49.00	10.00	27.00
Q3	173.00	9.00	63.00	10.00	29.00
Min	150.00	5.00	36.00	6.00	20.00
Max	192.00	13.50	130.00	12.00	50.00
CV	0.05	0.16	0.28	0.14	0.13

Table: Table continues below

	Long_Brazo_cm	Long_Mano_cm	Long_Pie_cm	Long_Pierna_cm	Peso_Kg
Mean	68.01	17.56	23.96	43.07	54.30
Std.Dev	12.16	4.38	1.53	3.32	17.24
Q1	66.00	16.10	22.90	40.60	40.00
Median	71.00	17.00	23.90	43.15	50.00
Q3	75.00	18.30	25.00	45.30	64.00
Min	17.00	7.00	20.50	33.20	31.00
Max	84.00	83.00	28.10	51.90	115.00
CV	0.18	0.25	0.06	0.08	0.32

## 8.2. Histograma + desviación estándar

```
media <- mean(datos$Peso_Kg, na.rm = TRUE)
desv <- sd(datos$Peso_Kg, na.rm = TRUE)
```

```
ggplot(datos, aes(x = Peso_Kg)) +
```

```
 geom_histogram(
 bins = 10,
 fill = "skyblue",
 color = "black"
) +
```

```
 # Media
 geom_vline(
 xintercept = media,
 color = "red",
 linewidth = 1.2
) +
```

```
 # ±1 desviación estándar
 geom_vline(
 xintercept = media + desv,
 color = "darkgreen",
 linetype = "dashed",
 linewidth = 1
) +
```

```
 geom_vline(
 xintercept = media - desv,
```


```

 color = "darkgreen",
 linetype = "dashed",
 linewidth = 1
) +

labs(
 title = "Distribución del peso y desviación estándar",
 subtitle = "Línea roja = media | Líneas verdes = ± 1 desviación estándar",
 x = "Peso (kg)",
 y = "Frecuencia"
) +

theme_minimal()

```



### 8.2.1. Interpretación

El histograma del peso complementado con la media y la desviación estándar permite analizar tanto la tendencia central como la variabilidad de los datos. La línea roja representa la media del peso de los participantes, mientras que las líneas verdes discontinuas indican un intervalo aproximado de una desviación estándar por encima y por debajo de la media. Este intervalo permite identificar el rango donde se concentra gran parte de las observaciones.

En la distribución analizada se observa que la mayoría de los individuos presentan pesos cercanos a la media, concentrándose principalmente dentro del intervalo delimitado por las líneas de desviación estándar. Sin embargo, también se identifican algunos valores alejados del centro de la distribución, lo que sugiere la presencia de posibles valores atípicos o una dispersión considerable en ciertos casos. Desde el punto de vista estadístico, una desviación estándar pequeña indica que los datos son más homogéneos y se agrupan cerca de la media; por el contrario, una desviación estándar grande refleja una mayor heterogeneidad y dispersión de los datos.

### 8.3. Comparar dispersión entre géneros


```
ggplot(datos, aes(x = Peso_Kg)) +
```



```
geom_density(
 fill = "lightgreen",
 alpha = 0.5
) +

labs(
 title = "Densidad del peso",
 subtitle = "Visualización de la dispersión de los datos",
 x = "Peso (kg)",
 y = "Densidad"
) +

theme_classic()
```



### 8.3.1. Interpretación

La curva de densidad representa una versión suavizada de la distribución de los datos y permite visualizar la concentración de observaciones a lo largo de los valores de la variable peso.

Las zonas más altas de la curva indican intervalos donde existe una mayor concentración de individuos, mientras que las áreas más bajas representan valores menos frecuentes. La forma de la curva permite evaluar características importantes de la distribución, tales como: simetría; presencia de sesgo; concentración de datos; posibles agrupamientos y dispersión general.

Si la curva presenta una forma aproximadamente simétrica, puede inferirse que los datos tienden a distribuirse de manera equilibrada alrededor de la media. En cambio, una cola más larga hacia alguno de los extremos indica asimetría o sesgo en la distribución.

Asimismo, una curva más ancha y extendida refleja mayor dispersión de los datos, mientras que una curva más estrecha indica mayor homogeneidad. La curva de densidad constituye una herramienta útil para comprender visualmente la estructura de la distribución y complementar el análisis realizado mediante histogramas y medidas descriptivas.


```
ggplot(datos, aes(x = Genero, y = Peso_Kg, fill = Genero)) +
```

```
geom_violin(alpha = 0.7) +

geom_boxplot(
 width = 0.1,
 fill = "white"
) +

labs(
 title = "Distribución y dispersión del peso",
 x = "Género",
 y = "Peso (kg)"
) +

theme_minimal()
```



### 8.3.2. Interpretación

El boxplot comparativo del peso según género permite evaluar diferencias en la tendencia central y la dispersión entre los grupos analizados. Cada caja representa el rango intercuartílico de los datos, es decir, el intervalo donde se concentra el 50 % central de las observaciones. La línea ubicada dentro de la caja corresponde a la mediana, mientras que los puntos alejados representan posibles valores atípicos.

A partir de la gráfica es posible identificar: diferencias en la mediana del peso entre géneros; variaciones en la amplitud de las cajas, asociadas al grado de dispersión; presencia de valores extremos; diferencias en la homogeneidad de los grupos.

Un grupo con cajas más amplias y bigotes más extensos presenta mayor variabilidad, indicando que los valores se encuentran más dispersos. Por el contrario, cajas más compactas sugieren una distribución más homogénea. Este tipo de análisis resulta especialmente útil para comparar poblaciones y explorar patrones de comportamiento de variables antropométricas en distintos grupos.

## 8.4. Resumen gráfico

Las medidas de tendencia central y dispersión son esenciales para describir un conjunto de datos. Su correcta interpretación permite comprender la estructura de la información, identificar patrones y apoyar la toma de decisiones basada en evidencia (Figura 8.1). En R, estas medidas pueden calcularse de forma sencilla, lo que facilita su aplicación en análisis estadísticos tanto exploratorios como inferenciales.




Figura 8.1

## Capítulo 9

# Medidas de posición y forma

Las medidas de posición y forma constituyen herramientas fundamentales de la estadística descriptiva, ya que permiten profundizar en la comprensión del comportamiento de una distribución de datos más allá de los valores centrales. Mientras las medidas de posición, como los cuartiles, deciles y percentiles, permiten determinar la ubicación relativa de una observación dentro de un conjunto ordenado de datos, las medidas de forma describen características estructurales de la distribución, tales como la simetría y el grado de concentración de las observaciones alrededor de la media.

El estudio conjunto de estas medidas facilita una interpretación más completa de los fenómenos analizados, permitiendo identificar patrones, desigualdades, concentraciones, sesgos y posibles valores extremos. Asimismo, conceptos asociados como el rango intercuartílico, los diagramas de caja y bigotes (boxplots), las curvas percentilares y los histogramas complementan el análisis estadístico mediante representaciones visuales que favorecen la interpretación de los datos.

Estas herramientas poseen amplias aplicaciones en contextos reales como el análisis del rendimiento académico, la clasificación de riesgo, la distribución salarial, los estudios antropométricos y las evaluaciones en salud pública, donde resulta esencial comprender no solo el valor promedio de una variable, sino también la posición relativa y la forma general de su distribución.

### 9.1. Medidas de posición

Las medidas de posición son indicadores estadísticos que permiten determinar la ubicación relativa de un valor dentro de un conjunto de datos ordenados. Estas medidas dividen la distribución en partes iguales y permiten identificar qué proporción de las observaciones se encuentra por debajo o por encima de un determinado valor.

A diferencia de las medidas de tendencia central, cuyo propósito es resumir el comportamiento típico de los datos mediante un único valor representativo, las medidas de posición permiten describir la distribución desde una perspectiva relativa o acumulativa.

Por ejemplo:

- ¿Qué valor deja por debajo al 25 % de las observaciones?
- ¿Cuál es el punto que supera el 90 % de la población?
- ¿En qué posición relativa se encuentra un estudiante respecto a sus compañeros?

Estas preguntas pueden responderse mediante cuartiles, deciles y percentiles.

### 9.2. Clasificación de las medidas de posición

Las principales medidas de posición son:

Medida	División de los datos
Cuartiles	4 partes iguales
Deciles	10 partes iguales
Percentiles	100 partes iguales

Todas comparten la misma lógica matemática:

1. ordenar los datos;
2. calcular una posición;
3. identificar el valor correspondiente dentro de la distribución.

### 9.3. Cuartiles

Los cuartiles son medidas de posición que dividen un conjunto de datos ordenados en cuatro partes iguales, de tal manera que cada grupo contiene aproximadamente el 25 % de las observaciones. Se representan mediante:

Cuartil	Interpretación
$Q_1$ : primer cuartil	El 25 % de los datos es menor o igual a este valor
$Q_2$ : segundo cuartil	Corresponde a la mediana; el 50 % de los datos queda por debajo
$Q_3$ : tercer cuartil	El 75 % de los datos es menor o igual a este valor

#### 9.3.1. Fórmula de posición

La posición del cuartil se calcula mediante:

$$L_k = \frac{k \cdot n}{4}$$

donde:

- $L_k$ : posición del cuartil,
- $k$ : número del cuartil,
- $n$ : número total de observaciones.

Los cuartiles poseen amplias aplicaciones en diferentes áreas del conocimiento, debido a que permiten dividir una distribución de datos en cuatro partes iguales y analizar la posición relativa de las observaciones dentro de un conjunto ordenado. En estudios antropométricos y ergonómicos, por ejemplo, los cuartiles se utilizan para diseñar mobiliario y espacios adaptados a las características físicas de la población. De igual manera, en evaluación nutricional permiten clasificar individuos según variables como peso, talla o índice de masa corporal.

En el ámbito educativo, los cuartiles facilitan la clasificación académica y la comparación del desempeño relativo de los estudiantes dentro de un grupo. Asimismo, en economía y ciencias sociales son empleados para estudiar la distribución salarial y analizar desigualdades entre diferentes segmentos de la población.

Los cuartiles también constituyen la base de los diagramas de caja y bigotes (boxplots), una representación gráfica ampliamente utilizada para visualizar la distribución de los datos, identificar valores extremos y evaluar la variabilidad de una muestra.

A partir de los cuartiles puede calcularse el rango intercuartílico (RIC), definido como la diferencia entre el tercer y el primer cuartil:

$$RIC = Q_3 - Q_1$$

Esta medida representa la dispersión del 50 % central de los datos y resulta especialmente útil porque no se ve afectada significativamente por valores atípicos o extremos.

## 9.4. Deciles

Los deciles son medidas de posición que dividen un conjunto de datos ordenados en diez partes iguales, de manera que cada grupo representa el 10 % de las observaciones. Se denotan como:

Decil	Interpretación
$D_1$	El 10 % de los datos es menor o igual a este valor
$D_5$	Coincide con la mediana
$D_9$	El 90 % de los datos queda por debajo

### 9.4.1. Fórmula de posición

$$L_k = \frac{k \cdot n}{10}$$

## 9.5. Aplicaciones de los deciles

Los deciles se utilizan frecuentemente en:

- pruebas estandarizadas,
- análisis socioeconómico,
- estudios de desigualdad,
- distribución de ingresos,
- clasificación poblacional.

## 9.6. Percentiles

Los percentiles son medidas de posición que dividen un conjunto de datos ordenados en cien partes iguales, donde cada parte representa el 1 % de las observaciones. Se representan mediante:  $P_1, P_2, P_3, \dots, P_{99}$ . El percentil  $P_k$  indica que el  $k$  % de las observaciones es menor o igual a dicho valor. Por ejemplo:

- $P_{25} = Q_1$
- $P_{50} = Q_2$
- $P_{75} = Q_3$

### 9.6.1. Fórmula de posición

$$L_k = \frac{k \cdot n}{100}$$

### 9.6.2. Aplicaciones de los percentiles

Los percentiles son fundamentales en curvas de crecimiento infantil, evaluación médica, pruebas académicas, clasificación nutricional, análisis de desempeño, entre otras (Figura 9.1).

## 9.7. Medidas de forma

Las medidas de forma permiten describir la estructura general de una distribución estadística, evaluando características como: simetría, concentración, colas extremas, comportamiento alrededor de la media. Las principales medidas de forma son: asimetría y curtosis (Figura 9.2).

## CLASIFICACIÓN DE LAS MEDIDAS DE POSICIÓN




Figura 9.1



### 9.7.1. Asimetría

La asimetría evalúa el grado de sesgo de una distribución.

Tipo	Característica
Simétrica	Ambos lados son similares
Asimetría positiva	Cola hacia la derecha
Asimetría negativa	Cola hacia la izquierda

### 9.7.2. Curtosis

La curtosis describe el grado de concentración de los datos alrededor de la media.

Tipo	Característica
Leptocúrtica	Distribución alta y concentrada
Mesocúrtica	Similar a distribución normal
Platicúrtica	Distribución achatada




Figura 9.2

## 9.8. Actividad experiencial

### 9.8.1. Explorando medidas de posición y forma con datos antropométricos

En los estudios poblacionales y de salud, las medidas de posición y forma permiten comprender cómo se distribuyen los datos dentro de una muestra. Estas herramientas facilitan identificar concentraciones de observaciones, simetrías,



asimetrías y posibles valores extremos, aspectos fundamentales para interpretar adecuadamente fenómenos biológicos y sociales.

En esta actividad, los estudiantes asumirán el rol de analistas de datos biomédicos, utilizando una base de datos antropométrica de estudiantes universitarios para explorar el comportamiento de variables corporales mediante percentiles, cuartiles, asimetría y curtosis.

**Objetivo:** Al finalizar esta actividad, el estudiante estará en capacidad de calcular e interpretar medidas de posición y forma, identificar patrones de distribución y analizar el comportamiento de variables antropométricas utilizando R.

### **Parte 1. Exploración inicial de la base de datos**

#### **Instrucciones**

1. Cargue la base de datos antropométrica.
2. Explore las variables disponibles.
3. Identifique las variables cuantitativas relacionadas con medidas corporales.

### **Parte 2. Medidas de posición y forma**

#### **Instrucciones**

Calcule los cuartiles y percentiles de la variable IMC.

Calcule la asimetría y curtosis de la variable IMC.

#### **Preguntas de análisis**

1. ¿Cuál es el valor de la mediana del IMC?
2. ¿Qué significa el percentil 90?
3. ¿Qué porcentaje de estudiantes presenta un IMC inferior al tercer cuartil?
4. ¿La distribución parece concentrarse en valores bajos, medios o altos?

### **Parte 4. Visualización e interpretación**

#### **Instrucciones**

Construya un histograma y un boxplot para evaluar visualmente la distribución del IMC.

### **Parte 5. Interpretación estadística**

#### **Responda:**

1. ¿La distribución del IMC presenta asimetría positiva o negativa?
2. ¿Existen posibles valores atípicos?
3. ¿La distribución parece concentrada o dispersa?
4. ¿Qué información aporta el boxplot respecto a la mediana y los cuartiles?
5. ¿Considera que el IMC de los estudiantes presenta comportamiento homogéneo o heterogéneo?

## **9.9. Mini reto analítico**

Imagine que usted trabaja en el área de bienestar universitario y debe realizar un informe sobre el estado nutricional de los estudiantes.

Con base en los resultados obtenidos:

- ¿qué hallazgos relevantes comunicaría?
- ¿qué indicadores utilizaría para resumir la información?
- ¿qué grupo considera prioritario para intervención?

- ¿qué limitaciones presenta el análisis realizado?

**Conclusión:** Las medidas de posición y forma permiten comprender cómo se distribuyen los datos más allá del promedio. Estas herramientas facilitan identificar concentraciones, dispersión, asimetrías y comportamientos atípicos dentro de una población, fortaleciendo la interpretación estadística y la toma de decisiones basadas en evidencia.

# Capítulo 10

## Análisis bivariado

En los capítulos anteriores se estudiaron las características de una sola variable a la vez, analizando aspectos como la tendencia central, la dispersión, la posición y la forma de los datos. Sin embargo, en los problemas reales rara vez las variables actúan de manera aislada. En la práctica, los fenómenos sociales, económicos, educativos, biológicos y administrativos suelen depender de la interacción entre múltiples variables.

Por ejemplo, en educación puede surgir la pregunta de si un mayor número de horas de estudio se relaciona con mejores calificaciones; en salud, si existe asociación entre el índice de masa corporal y la presión arterial; o en economía, si el nivel de ingresos influye sobre el gasto familiar. Todas estas situaciones requieren estudiar simultáneamente dos variables y comprender cómo se comportan conjuntamente.

El análisis bivariado corresponde precisamente al conjunto de técnicas estadísticas utilizadas para explorar, describir, cuantificar e interpretar la relación entre dos variables medidas sobre las mismas unidades de análisis. A diferencia del análisis univariado, cuyo propósito es describir individualmente una variable, el análisis bivariado busca identificar patrones de asociación, dependencia o predicción entre variables.

Dependiendo de la naturaleza de las variables involucradas, el análisis bivariado puede abordar diferentes situaciones: relaciones entre variables cuantitativas; asociaciones entre variables categóricas; comparación de una variable cuantitativa entre categorías.

En este capítulo se desarrollan las principales herramientas del análisis bivariado, incluyendo: diagramas de dispersión, covarianza, correlación de Pearson, correlación de Spearman, tablas de contingencia, y regresión lineal simple.

Cada técnica será presentada desde una perspectiva teórica y posteriormente aplicada mediante ejemplos desarrollados en R utilizando un mismo conjunto de datos, con el propósito de facilitar la comprensión progresiva del análisis estadístico y fortalecer el aprendizaje experiencial. Es importante destacar que el análisis bivariado constituye la base de técnicas estadísticas más avanzadas, como la regresión múltiple, el análisis multivariado y los modelos predictivos utilizados actualmente en ciencia de datos, inteligencia artificial y analítica aplicada.

### 10.1. Tipos de análisis bivariado

El tipo de análisis bivariado que puede realizarse depende de la naturaleza de las variables estudiadas. En estadística, las variables pueden ser cuantitativas o categóricas, y cada combinación requiere herramientas específicas de exploración, visualización e interpretación.

Cuando ambas variables son cuantitativas, el interés suele centrarse en evaluar si existe asociación, dependencia o relación funcional entre ellas. En estos casos se utilizan herramientas como diagramas de dispersión, covarianza, correlación y regresión lineal. Por ejemplo, puede analizarse la relación entre horas de estudio y calificación final, o entre peso corporal y estatura.

Si ambas variables son categóricas, el objetivo principal consiste en estudiar asociaciones entre categorías o grupos. Para ello se emplean tablas de contingencia y medidas de asociación categórica. Un ejemplo frecuente corresponde al

análisis de la relación entre género y nivel de satisfacción académica.

También existen situaciones donde una variable es cuantitativa y la otra categórica. En estos casos, el interés radica en comparar el comportamiento de la variable numérica entre diferentes grupos o categorías. Por ejemplo, comparar las calificaciones promedio entre hombres y mujeres, o analizar diferencias salariales entre regiones.

La siguiente tabla resume las principales combinaciones posibles en el análisis bivariado:

Tipo de variable 1	Tipo de variable 2	Objetivo principal	Técnicas utilizadas
Cuantitativa	Cuantitativa	Evaluar asociación o predicción	Correlación, regresión, dispersión
Categórica	Categórica	Analizar asociación entre categorías	Tablas de contingencia
Cuantitativa	Categórica	Comparar grupos	Boxplot, medias, comparación gráfica

Comprender el tipo de variables involucradas constituye un paso fundamental antes de seleccionar cualquier técnica estadística, ya que una elección incorrecta puede conducir a interpretaciones inadecuadas o resultados inconsistentes.

En este capítulo se abordarán ejemplos correspondientes a cada una de estas situaciones, integrando representaciones gráficas, medidas estadísticas y modelos básicos de análisis bivariado mediante implementaciones desarrolladas en R.

## 10.2. Conjunto de datos de trabajo

A lo largo de este capítulo se utilizará un mismo conjunto de datos con el propósito de ilustrar las diferentes técnicas de análisis bivariado de manera integrada y progresiva. El uso de un único dataset facilita la comparación de resultados y permite comprender cómo distintas herramientas estadísticas pueden analizar una misma realidad desde perspectivas complementarias.

La base de datos contiene información correspondiente a estudiantes universitarios e incluye variables cuantitativas y categóricas, entre ellas:

horas de estudio semanales, calificación final, horas de sueño, y género.

Estas variables permiten desarrollar ejemplos relacionados con:

relaciones entre variables cuantitativas, asociaciones entre variables categóricas, y comparación de grupos.

En términos pedagógicos, este enfoque favorece el aprendizaje experiencial, ya que el estudiante puede observar cómo los conceptos teóricos se aplican directamente sobre datos reales mediante análisis reproducibles en R.

## 10.3. Carga de datos en R

```
library(readxl)
library(dplyr)

datos <- read_excel(
 "data/bd_antropometricas.xlsx"
)

head(datos)

A tibble: 6 x 7
 Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
 <chr> <chr> <chr> <dbl> <dbl> <dbl> <dbl>
1 D A M 177 73 49 19
```

```

2 D A M 177 86 45 19
3 D A F 160 52 37 16
4 D A F 159 53 38 16
5 D A F 174 78 41 18
6 D B M 186 68 44 19
i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
Mano_Dicotica <chr>

```

## 10.4. Exploración inicial de variables

```
names(datos)
```

```

[1] "Clase" "Grupo" "Genero"
[4] "Altura_cm" "Peso_Kg" "Anchura_hombros_cm"
[7] "Long_Mano_cm" "Lon_Palma_cm" "Ancho_Palma_cm"
[10] "Long_Brazo_cm" "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm" "Curso" "Talla_Dicotica"
[16] "IMC_Dicotico" "Mano_Dicotica"

```

```
str(datos)
```

```

tibble [260 x 17] (S3: tbl_df/tbl/data.frame)
 $ Clase : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo : chr [1:260] "A" "A" "A" "A" ...
 $ Genero : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
 $ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
 $ Long_Mano_cm : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
 $ Lon_Palma_cm : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
 $ Ancho_Palma_cm : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
 $ Long_Brazo_cm : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
 $ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
 $ Long_Pierna_cm : num [1:260] 42.7 41.8 40.9 49.1 48 43.4 42.4 44.2 47.8 39.7 ...
 $ Long_Pie_cm : num [1:260] 23.7 23.1 25.1 26.9 27 24 22.9 25.6 24.4 24.4 ...
 $ Curso : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
 $ Talla_Dicotica : chr [1:260] "Alta" "Alta" "Baja" "Baja" ...
 $ IMC_Dicotico : chr [1:260] "Normal+" "Normal+" "Normal+" "Normal+" ...
 $ Mano_Dicotica : chr [1:260] "Grande" "Grande" "Pequeña" "Pequeña" ...

```

## 10.5. Evaluación de supuestos

### 10.5.1. Variables cuantitativas continuas

La correlación de Pearson está diseñada para analizar la relación entre variables cuantitativas continuas. Estas variables pueden asumir cualquier valor dentro de un intervalo determinado y suelen corresponder a procesos de medición, como altura, peso corporal, índice de masa corporal, temperatura o presión arterial.

A diferencia de las variables cualitativas o discretas, las variables continuas permiten evaluar cambios graduales en los valores observados, lo que facilita el estudio de relaciones lineales entre ellas. Por esta razón, antes de aplicar una correlación de Pearson es importante verificar que ambas variables correspondan a mediciones cuantitativas continuas.

En el presente ejemplo, las variables altura (cm) y peso corporal (kg) cumplen este supuesto, ya que representan mediciones físicas obtenidas en una escala numérica continua.

### 10.5.2. Prueba de normalidad Shapiro-Wilk

La prueba de Shapiro-Wilk permite evaluar si una variable cuantitativa presenta una distribución aproximadamente normal. En este caso, se analizan las variables altura y peso corporal de los estudiantes.

La hipótesis nula ( $H_0$ ) establece que los datos siguen una distribución normal, mientras que la hipótesis alternativa ( $H_1$ ) plantea que la distribución no es normal.

La decisión se toma a partir del valor  $p$ :

- si  $p > 0.05$ , no se rechaza la normalidad;
- si  $p \leq 0.05$ , se concluye que la variable no presenta distribución normal.

Estas pruebas son importantes porque muchas técnicas estadísticas paramétricas, como la correlación de Pearson y la regresión lineal, asumen normalidad en los datos.

```
library(readxl)
library(dplyr)
library(purrr)

Cargar base de datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Seleccionar variables numéricas
variables_numericas <- datos %>%

 select(where(is.numeric))

Aplicar Shapiro-Wilk a cada variable
normalidad <- map_df(

 names(variables_numericas),

 ~{

 prueba <- shapiro.test(
 na.omit(variables_numericas[[.x]])
)

 data.frame(
 Variable = .x,
 W = round(prueba$statistic, 4),
 p_value = round(prueba$p.value, 6),

 Normalidad = ifelse(
 prueba$p.value > 0.05,
 "Sí presenta normalidad",
 "No presenta normalidad"
)
)
 }
)

Mostrar resultados
normalidad
```

	Variable	W	p_value		Normalidad
W...1	Altura_cm	0.9753	0.000172	No presenta	normalidad
W...2	Peso_Kg	0.9040	0.000000	No presenta	normalidad
W...3	Anchura_hombros_cm	0.8824	0.000000	No presenta	normalidad
W...4	Long_Mano_cm	0.2747	0.000000	No presenta	normalidad
W...5	Lon_Palma_cm	0.9460	0.000000	No presenta	normalidad
W...6	Ancho_Palma_cm	0.9310	0.000000	No presenta	normalidad
W...7	Long_Brazo_cm	0.7635	0.000000	No presenta	normalidad
W...8	Long_Antebraco_cm	0.7616	0.000000	No presenta	normalidad
W...9	Long_Pierna_cm	0.9950	0.564763	Sí presenta	normalidad
W...10	Long_Pie_cm	0.9914	0.134404	Sí presenta	normalidad

### 10.5.3. Independencia de las observaciones

La correlación de Pearson asume que cada observación es independiente de las demás. Esto significa que el valor registrado para un individuo no debe influir sobre los valores observados en otro individuo.

Este supuesto depende principalmente del diseño de recolección de los datos. En estudios donde cada participante aporta una única medición, como ocurre con la altura y el peso corporal de los estudiantes, generalmente se considera que existe independencia entre las observaciones.

### 10.5.4. Relación lineal

La correlación de Pearson evalúa exclusivamente relaciones lineales entre variables. Por ello, antes de calcular el coeficiente de correlación es recomendable construir un diagrama de dispersión para verificar que los datos presentan una tendencia aproximadamente recta.

De manera general, una relación lineal puede representarse mediante la ecuación:  $Y = \beta_0 + \beta_1 X$

donde:

- (Y) representa la variable dependiente;
- (X) corresponde a la variable independiente;
- ( $\beta_0$ ) es el intercepto;
- ( $\beta_1$ ) representa la pendiente de la relación.

Cuando la relación es lineal, un incremento en una variable tiende a estar asociado con un incremento o disminución proporcional en la otra variable. Si la relación presenta formas curvas o patrones complejos, la correlación de Pearson puede subestimar la verdadera asociación existente.

En este ejemplo, la linealidad puede evaluarse visualmente mediante el diagrama de dispersión entre altura y peso corporal.

```
Modelo de regresión
modelo <- lm(
 Peso_Kg ~ Altura_cm,
 data = datos
)

Coeficientes
b0 <- coef(modelo)[1]
b1 <- coef(modelo)[2]

R²
r2 <- summary(modelo)$r.squared

Gráfico
```

```

plot(
 datos$Altura_cm,
 datos$Peso_Kg,
 main = "Relación entre altura y peso corporal",
 xlab = "Altura (cm)",
 ylab = "Peso (kg)",
 pch = 19,
 col = "blue"
)


Línea de regresión
abline(
 modelo,
 col = "red",
 lwd = 2
)

Ecuación y R²
legend(
 "topright",
 legend = c(
 paste0(
 "Peso = ",
 round(b0,2),
 " + ",
 round(b1,2),
 "(Altura)"
),
 paste0(
 "R² = ",
 round(r2,3)
)
),
 bty = "n"
)

```



## Relación entre altura y peso corporal



**Interpretación:** La ecuación de regresión obtenida fue:  $\hat{Peso} = \beta_0 + \beta_1(Altura)$ , donde  $\beta_0$  representa el intercepto y  $\beta_1$  el cambio esperado en el peso corporal por cada centímetro adicional de altura. El coeficiente de determinación ( $R^2$ ) indica la proporción de variabilidad del peso explicada por la altura. Valores cercanos a 0 sugieren una relación débil, mientras que valores cercanos a 1 indican una relación fuerte. De acuerdo con lo anterior el diagrama de dispersión muestra una **tendencia positiva** entre la altura y el peso corporal de los estudiantes. En términos generales, a medida que aumenta la altura, el peso también tiende a incrementarse.

La ecuación de regresión obtenida fue:  $\hat{Peso} = -77.62 + 0.79(Altura)$ . Esto significa que, en promedio, por cada centímetro adicional de altura, el peso corporal aumenta aproximadamente **0.79 kg**.

El coeficiente de determinación fue:  $R^2 = 0.16$ , Lo que indica que la altura explica aproximadamente el **16 % de la variabilidad observada en el peso corporal**. El 84 % restante se debe a otros factores no incluidos en el modelo, como sexo, composición corporal, hábitos alimentarios, actividad física y variabilidad individual.

Visualmente, la nube de puntos presenta una tendencia ascendente compatible con una relación lineal positiva; sin embargo, la dispersión de los datos alrededor de la recta es relativamente amplia, lo que sugiere que la relación entre ambas variables es **débil a moderada**.

### 10.5.5. Regresión lineal múltiple

En la regresión lineal simple se analiza la relación entre una variable respuesta ( $Y$ ) y una única variable explicativa ( $X$ ). Sin embargo, muchos fenómenos reales dependen simultáneamente de varios factores, por lo que resulta necesario incorporar múltiples variables predictoras dentro del modelo. La regresión lineal múltiple puede expresarse como:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

donde:

- $Y$ : variable respuesta o dependiente.
- $\beta_0$ : intercepto del modelo.
- $X_1, X_2, \dots, X_k$ : variables explicativas o predictoras.
- $\beta_1, \beta_2, \dots, \beta_k$ : coeficientes asociados a cada predictor.

En este contexto, el supuesto de linealidad implica que cada variable explicativa mantiene una relación lineal con la variable respuesta, una vez controlado el efecto de las demás variables incluidas en el modelo.

Por ejemplo, en la base antropométrica el peso corporal podría modelarse utilizando simultáneamente variables como la altura, la longitud de la pierna, la longitud del pie, la longitud de la mano, el índice de masa corporal (IMC) y el sexo. De esta manera, el modelo permite evaluar el aporte específico de cada característica sobre el peso corporal, manteniendo constantes las demás variables.

$$Peso = \beta_0 + \beta_1 (Altura) + \beta_2 (LongitudPierna) + \beta_3 (LongitudPie) + \beta_4 (LongitudMano) + \beta_5 (IMC)$$

o incluso:

$$Altura = \beta_0 + \beta_1(Longitud Pierna) + \beta_2(Longitud Pie) + \beta_3(Longitud Mano)$$

### 10.5.6. Homocedasticidad

La homocedasticidad indica que la variabilidad de una variable se mantiene relativamente constante a lo largo de los valores de la otra variable. Por ejemplo:

- altura baja → dispersión similar
- altura media → dispersión similar
- altura alta → dispersión similar

La homocedasticidad implica que la varianza de los errores es constante para todos los valores de la variable independiente:

$$Var(\varepsilon_i) = \sigma^2$$

donde:

$\varepsilon_i$ : error o residuo de la observación  $i$ ;


$\sigma^2$ : varianza constante de los errores.

```
modelo <- lm(
 Peso_Kg ~ Altura_cm,
 data = datos
)

plot(
 fitted(modelo),
 residuals(modelo),
 main = "Residuos vs Valores ajustados",
 xlab = "Valores ajustados",
 ylab = "Residuos",
 pch = 19,
 col = "darkgreen"
)

abline(
 h = 0,
 col = "red",
 lwd = 2
)
```

## Residuos vs Valores ajustados



**Interpretación:** La homocedasticidad hace referencia a la igualdad aproximada de la variabilidad de los datos a lo largo de los diferentes valores de la variable independiente. Este supuesto es importante porque muchas técnicas paramétricas asumen que la dispersión de los errores permanece constante.

La evaluación visual puede realizarse mediante un gráfico de residuos frente a los valores ajustados. Cuando los residuos se distribuyen aleatoriamente alrededor de cero y mantienen una amplitud similar en todo el rango de observaciones, se considera que existe homocedasticidad. Por el contrario, si la dispersión aumenta o disminuye sistemáticamente formando patrones de abanico o embudo, podría existir heterocedasticidad, indicando que la variabilidad de los errores no es constante.

### 10.5.7. Ausencia de valores atípicos extremos

Los valores atípicos extremos (outliers) pueden afectar significativamente el coeficiente de correlación de Pearson, generando estimaciones sesgadas o conclusiones incorrectas sobre la intensidad de la relación entre las variables.

Para identificar posibles valores atípicos se recomienda utilizar diagramas de caja (boxplots) o diagramas de dispersión. Si se detectan observaciones extremas, estas deben revisarse cuidadosamente para determinar si corresponden a errores de registro o a valores reales de la población estudiada.


La presencia de valores atípicos no implica necesariamente su eliminación, pero sí requiere una evaluación crítica antes de realizar el análisis estadístico.

```
library(readxl)

datos <- read_excel(
 "data/bd_antropometricas.xlsx"
)

boxplot(
 datos$Peso_Kg,
 main = "Distribución del peso corporal",
 ylab = "Peso (kg)",
 col = "lightblue"
)
```

## Distribución del peso corporal



### 10.6. Estructura general para seleccionar la técnica adecuada

En el análisis bivariado, la selección de la técnica estadística depende principalmente del tipo de variables que se desean analizar y de los supuestos que cumplen los datos (Figura 10.1). Por esta razón, antes de aplicar cualquier procedimiento es necesario identificar si las variables son cuantitativas o categóricas, revisar su distribución, explorar la forma de la relación y verificar la presencia de valores atípicos.

### 10.7. Cuando se cumplen los supuestos

En el caso de las variables **Long\_Pierna\_cm** y **Long\_Pie\_cm** presentan un comportamiento compatible con una distribución normal según la prueba de Shapiro-Wilk.

Para la variable **Long\_Pierna\_cm**, se obtuvo un estadístico  $W = 0.9950$  y un valor  $p = 0.564763$ . Debido a que el valor  $p$  es mayor que 0.05, no se rechaza la hipótesis nula de normalidad. Esto indica que la distribución de la longitud de la pierna no presenta diferencias significativas respecto a una distribución normal.

De manera similar, la variable **Long\_Pie\_cm** presentó un estadístico  $W = 0.9914$  y un valor  $p = 0.134404$ . Al ser también mayor que 0.05, se concluye que la longitud del pie presenta una distribución aproximadamente normal.

En términos prácticos, estos resultados sugieren que ambas variables antropométricas poseen distribuciones relativamente simétricas y sin desviaciones extremas importantes, lo cual favorece la aplicación de técnicas estadísticas paramétricas, como: correlación de Pearson, pruebas t, análisis de regresión lineal e intervalos de confianza basados en normalidad.

Asimismo, el comportamiento normal de estas variables es coherente con muchas mediciones biológicas y antropométricas, donde las características físicas de una población suelen distribuirse alrededor de un valor promedio central.


#### 10.7.1. Correlación de Pearson

La correlación es una medida estadística utilizada para cuantificar la fuerza y la dirección de la relación entre dos variables cuantitativas. A diferencia del diagrama de dispersión, que permite explorar visualmente el comportamiento conjunto de las variables, la correlación resume dicha relación mediante un valor numérico (Figura 10.2). El coeficiente de correlación de Pearson se calcula como:

# ¿QUÉ TÉCNICA DEBO UTILIZAR?

## Estructura general para seleccionar la técnica adecuada

La elección de la técnica estadística depende del tipo de variables que desea analizar y del cumplimiento de los supuestos. Siga el diagrama de decisión para seleccionar la técnica más apropiada.



RESUMEN DE SELECCIÓN DE TÉCNICA		
Tipo de variables	Condición principal	Técnica recomendada
 Cuantitativa + cuantitativa	Normalidad, linealidad y sin valores extremos importantes	Correlación de Pearson
 Cuantitativa + cuantitativa	No normalidad, valores extremos o relación monotónica	Correlación de Spearman
 Ordinal + ordinal	Relación por rangos	Correlación de Spearman
 Categórica + categórica	Asociación entre categorías	Tabla de contingencia
 Cuantitativa + categórica	Comparación entre grupos	Boxplot, medias o medianas por grupo



**Recuerde:** Antes de aplicar cualquier técnica, explore sus datos: revise la distribución, verifique supuestos (normalidad, linealidad, homocedasticidad) y detecte valores atípicos.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

El coeficiente de correlación indica qué tan estrechamente se relacionan dos variables y si dicha relación es positiva, negativa o inexistente.

#### 10.7.1.1. Ejemplo en R

En el siguiente ejemplo se calcula la correlación entre altura y peso corporal utilizando la base de datos antropométrica.

```
library(readxl)
library(ggplot2)

Cargar base de datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Calcular correlación
r <- cor(
 datos$Long_Pierna_cm,
 datos$Long_Pie_cm,

 method = "pearson",

 use = "complete.obs"
)

Gráfico
ggplot(
 datos,

 aes(
 x = Long_Pierna_cm,
 y = Long_Pie_cm,
 color = Genero
)
) +

 geom_point(
 size = 3,
 alpha = 0.75
) +

 scale_color_manual(
 values = c(
 "F" = "#D95F02",
 "M" = "#1B9E77"
)
) +

 geom_smooth(
 method = "lm",
 se = FALSE,
```




# CORRELACIÓN LINEAL

La correlación cuantifica la fuerza y la dirección de la relación lineal entre dos variables cuantitativas.

## Correlación positiva, negativa y nula

La relación entre dos variables puede presentar diferentes comportamientos:



En términos prácticos:

- **correlación positiva** → tendencia ascendente;
- **correlación negativa** → tendencia descendente;
- **correlación cercana a cero** → ausencia de asociación lineal.

## FÓRMULA DE PEARSON

El coeficiente de correlación de Pearson ( $r$ ) se calcula como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde:

- $x_i, y_i$ : valores de las variables X e Y.
- $\bar{x}, \bar{y}$ : medias de X e Y.
- $n$ : número de observaciones.

## COEFICIENTE DE PEARSON

El coeficiente de correlación de Pearson es la medida más utilizada para evaluar relaciones lineales entre variables cuantitativas.

Se representa mediante la letra  $r$  y toma valores entre -1 y 1:

$$-1 \leq r \leq 1$$



donde:

- $r = 1$ : correlación positiva perfecta;
- $r = -1$ : correlación negativa perfecta;
- $r = 0$ : ausencia de relación lineal.

## INTERPRETACIÓN GENERAL DEL COEFICIENTE

Valor de $r$	Interpretación aproximada	Fuerza de la relación
0.00 – 0.19	Muy débil	★☆☆☆☆
0.20 – 0.39	Débil	★★☆☆☆
0.40 – 0.59	Moderada	★★★☆☆
0.60 – 0.79	Fuerte	★★★★☆
0.80 – 1.00	Muy fuerte	★★★★★

## EL SIGNO DEL COEFICIENTE INDICA LA DIRECCIÓN DE LA RELACIÓN:



**POSITIVO**  
relación directa  
(variables aumentan juntas)



**NEGATIVO**  
relación inversa  
(una aumenta cuando la otra disminuye)



**CERCANO A CERO**  
no hay asociación lineal aparente



## EN RESUMEN

La correlación mide asociación lineal, NO causalidad.  
Dos variables pueden estar correlacionadas sin que una cause la otra.

### Positiva ( $r > 0$ )



A mayor X, mayor Y

### Negativa ( $r < 0$ )



A mayor X, menor Y

### Nula ( $r \approx 0$ )



No hay tendencia lineal clara

Figura 10.2

```

 color = "black",
 linewidth = 1
) +

annotate(
 "text",

 x = min(datos$Long_Pierna_cm) + 5,

 y = max(datos$Long_Pie_cm) - 5,

 label = paste0(
 "r = ",
 round(r, 3)
),

 size = 5,

 fontface = "bold",

 color = "black"
) +

labs(
 title = "Relación entre Longitud Pierna y Longitud pie",

 subtitle = "Diagrama de dispersión y correlación de Pearson",

 x = "Longitud Pierna (cm)",

 y = "Longitud pie (cm)",


 color = "Género",

 caption = "Fuente: Base antropométrica Prof. Miguel Pérez"
) +

theme_minimal(base_size = 12)

```





**Interpretación:** El diagrama de dispersión permite explorar la relación entre la longitud de la pierna y la longitud del pie en los estudiantes, diferenciando las observaciones según el género. Visualmente, los puntos se encuentran ampliamente dispersos y no muestran una tendencia lineal clara entre ambas variables.

El **coeficiente de correlación de Pearson** obtenido ( $r = 0.012$ ) indica una **asociación lineal prácticamente nula entre la longitud de la pierna y la longitud del pie**. Este valor, al encontrarse muy cercano a cero, sugiere que el aumento en una de las variables no se relaciona de manera consistente con cambios en la otra dentro de la muestra analizada.

Asimismo, la línea de tendencia horizontal observada en el gráfico confirma la ausencia de una relación lineal significativa. Aunque existen diferencias naturales entre hombres y mujeres en la distribución de las observaciones, dichas variaciones no generan un patrón de asociación fuerte entre las variables estudiadas.

En términos prácticos, estos resultados indican que la longitud de la pierna no constituye un buen predictor lineal de la longitud del pie en esta población específica. Este tipo de análisis es importante porque demuestra que no todas las variables antropométricas presentan relaciones lineales fuertes, incluso cuando pertenecen a una misma dimensión biológica..

## 10.8. Cuando no se cumplen los supuestos

**Interpretación Altura\_cm y Peso\_Kg:** La prueba de Shapiro-Wilk indica que ninguna de las dos variables presenta una distribución normal al nivel de significancia del 5 %.

Para la variable **Altura\_cm**, se obtuvo un estadístico  $W = 0.9752$  y un valor  $p = 0.000171$ . Debido a que el valor  $p$  es menor que 0.05, se rechaza la hipótesis nula de normalidad, concluyendo que la distribución de la altura difiere significativamente de una distribución normal.

De manera similar, para la variable **Peso\_Kg**, el estadístico obtenido fue  $W = 0.9040$  con un valor  $p = 7.916 \times 10^{-12}$ , valor extremadamente pequeño que también conduce al rechazo de la hipótesis de normalidad. Esto indica que la distribución del peso corporal presenta desviaciones importantes respecto a la normalidad.

En términos prácticos, estos resultados sugieren que las variables antropométricas analizadas no cumplen completamente el supuesto de normalidad requerido por algunas técnicas paramétricas. Por esta razón, en determinados contextos podría ser recomendable complementar el análisis utilizando métodos no paramétricos, como la correlación de Spearman, especialmente si existen valores extremos o distribuciones asimétricas.

### 10.8.1. Correlación de Spearman

La correlación de Spearman es una medida estadística utilizada para evaluar la asociación entre dos variables ordinales o cuantitativas cuando no se cumplen los supuestos de normalidad o linealidad requeridos por la correlación de Pearson (Figura 10.3).

A diferencia de Pearson, Spearman no trabaja directamente con los valores originales de las variables, sino con sus rangos o posiciones dentro de la distribución. Por esta razón, se considera una medida no paramétrica de asociación.

```
library(readxl)
library(ggplot2)
library(dplyr)

Cargar base de datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Correlación por género
datos %>%

 group_by(Genero) %>%

 summarise(
 Correlacion = cor(
 Altura_cm,
 Peso_Kg,

 method = "spearman",

 use = "complete.obs"
)
)
```

```
A tibble: 2 x 2
 Genero Correlacion
 <chr> <dbl>
1 F 0.0657
2 M 0.178
```

```
Diagrama de dispersión por género
```

```
ggplot(
 datos,


 aes(
 x = Altura_cm,
 y = Peso_Kg,
 color = Genero
)
) +

 geom_point(
 size = 3,
 alpha = 0.75
) +

 geom_smooth(
```

# CORRELACIÓN DE SPEARMAN

Una medida no paramétrica para evaluar la asociación monotónica entre dos variables.



## 1. COEFICIENTE DE SPEARMAN

El coeficiente de Spearman se representa mediante la letra griega rho:

$\rho$


y toma valores entre -1 y 1:

$$-1 \leq \rho \leq 1$$

donde:

$\rho = 1$

asociación positiva perfecta



$\rho = -1$

asociación negativa perfecta



$\rho = 0$

ausencia de asociación monotónica



## 2. ¿CUÁNDO UTILIZAR SPEARMAN?

La correlación de Spearman se recomienda cuando:



las variables presentan valores extremos



la relación entre variables no es estrictamente lineal



los datos son ordinales



no se cumple normalidad



existen distribuciones asimétricas



Esta medida evalúa si, en general, cuando una variable aumenta, la otra también tiende a aumentar o disminuir, independientemente de que la relación sea perfectamente lineal.

## 3. INTERPRETACIÓN GENERAL

Valor de $\rho$	Interpretación aproximada
0.00 - 0.19	Muy débil ★☆☆☆☆
0.20 - 0.39	Débil ★★☆☆☆
0.40 - 0.59	Moderada ★★★☆☆
0.60 - 0.79	Fuerte ★★★★☆
0.80 - 1.00	Muy fuerte ★★★★★

El signo del coeficiente indica la dirección de la asociación:



positivo →

ambas variables aumentan conjuntamente



negativo →

una variable aumenta mientras la otra disminuye



## 4. FÓRMULA DE SPEARMAN

Cuando no existen empates, el coeficiente de Spearman puede calcularse mediante:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde:

- $d_i$ : diferencia entre rangos
- $n$ : número de observaciones




## EN RESUMEN



Spearman mide la asociación monotónica entre variables utilizando rangos. Es una alternativa robusta cuando no se cumplen los supuestos de la correlación de Pearson.

Positiva ( $\rho > 0$ )



A mayor X, mayor Y

Negativa ( $\rho < 0$ )



A mayor X, menor Y

Nula ( $\rho \approx 0$ )



No hay tendencia monotónica clara

Figura 10.3

```

 method = "lm",
 se = FALSE,
 linewidth = 1
) +

scale_color_manual(
 values = c(
 "F" = "#D95F02",
 "M" = "#1B9E77"
)
) +

labs(
 title = "Relación entre altura y peso corporal según género",

 subtitle = "Comparación de patrones de asociación",

 x = "Altura (cm)",

 y = "Peso (kg)",

 color = "Género",

 caption = "Fuente: Base antropométrica"
) +

theme_minimal(base_size = 12) +


theme(
 plot.title = element_text(
 face = "bold",
 size = 15
),

 plot.subtitle = element_text(
 size = 11
)
)

```

## Relación entre altura y peso corporal según género

Comparación de patrones de asociación



Fuente: Base antropométrica

## 10.9. Otras medidas de asociación

### 10.9.1. Diagrama de dispersión

El diagrama de dispersión, también conocido como nube de puntos, es una representación gráfica utilizada para explorar la relación entre dos variables cuantitativas. Cada punto del gráfico representa una observación y su posición en el plano cartesiano depende de los valores registrados para las variables  $X$  y  $Y$ .

Esta herramienta constituye generalmente el primer paso del análisis bivariado, ya que permite identificar visualmente patrones de asociación, tendencias, agrupamientos y posibles valores atípicos antes de aplicar medidas numéricas de correlación o modelos de regresión (Figura 10.4). A partir de un diagrama de dispersión pueden identificarse diferentes comportamientos entre las variables:

#### 10.9.1.1. Ejemplo en R

En el siguiente ejemplo se utiliza la base de datos antropométrica para analizar la relación entre la estatura de los estudiantes y su peso corporal. El objetivo consiste en explorar visualmente si existe asociación entre ambas variables mediante un diagrama de dispersión.

```
library(readxl)
library(ggplot2)

Cargar base de datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Diagrama de dispersión
ggplot(
 datos,

 aes(
 x = Altura_cm,
```




Figura 10.4

```

 y = Peso_Kg,
 color = Genero
)
) +

geom_point(
 size = 3,
 alpha = 0.75
) +

scale_color_manual(
 values = c(
 "F" = "#D95F02",
 "M" = "#1B9E77"
)
) +

labs(
 title = "Relación entre altura y peso corporal",

 subtitle = "Distribución según género",

 x = "Altura (cm)",

 y = "Peso (kg)",

 color = "Género",

 caption = "Fuente: Base antropométrica prof. Miguel Pérez"
) +

theme_minimal(base_size = 12) +

theme(
 plot.title = element_text(
 face = "bold",
 size = 15
),

 plot.subtitle = element_text(
 size = 11
),


 legend.position = "right"
)

```



## Relación entre altura y peso corporal

Distribución según género



Fuente: Base antropométrica prof. Miguel Pérez

**Interpretación:** El diagrama de dispersión permite explorar visualmente la relación entre la altura y el peso corporal de los estudiantes, diferenciando las observaciones según el género. En general, se observa una tendencia positiva entre ambas variables, indicando que a mayores valores de altura tienden a presentarse mayores valores de peso corporal.

La diferenciación por color facilita identificar posibles agrupamientos entre hombres y mujeres, evidenciando patrones distintos en la distribución de las observaciones. Este tipo de visualización resulta útil para detectar comportamientos particulares dentro de subgrupos poblacionales y constituye una herramienta exploratoria fundamental antes de aplicar medidas numéricas de asociación o modelos estadísticos más complejos.

### ⚠ Advertencia

El **diagrama de dispersión** es principalmente una herramienta de análisis exploratorio y visualización bivariada. NO es todavía una correlación numérica.

### 10.9.2. Covarianza

La covarianza es una medida estadística utilizada para evaluar cómo varían conjuntamente dos variables cuantitativas respecto a sus medias. Esta medida permite identificar si ambas variables tienden a aumentar simultáneamente, disminuir conjuntamente o comportarse de manera independiente (Figura 10.5).

La covarianza constituye uno de los fundamentos matemáticos de la correlación lineal y de la regresión.

#### 10.9.2.1. Ejemplo en R

```
library(readxl)

Cargar base de datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

Covarianza
cov(
```



# COVARIANZA

Mide cómo varían conjuntamente dos variables cuantitativas respecto a sus medias.



## FÓRMULA

$$\text{Cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

## ¿QUÉ SIGNIFICA?

- $X$ : primera variable
- $Y$ : segunda variable
- $\bar{x}$  y  $\bar{y}$ : medias de las variables
- $n$ : número de observaciones

$x_i$ : valor  $i$ -ésimo de la primera variable  
 $y_i$ : valor  $i$ -ésimo de la segunda variable  
 $x_i - \bar{x}$ : desviación de  $x_i$  respecto a su media  
 $y_i - \bar{y}$ : desviación de  $y_i$  respecto a su media

## EN PALABRAS



Multiplica las desviaciones de cada par de valores respecto a sus medias y promedia esos productos. Indica si las variables tienden a moverse juntas (mismo sentido), en sentido opuesto o sin un patrón lineal claro.

## INTERPRETACIÓN

Valor de covarianza	Interpretación	Ejemplo gráfico
Positiva $\oplus$	Ambas variables aumentan conjuntamente. Los puntos tienden a subir juntos.	
Negativa $\ominus$	Una variable aumenta mientras la otra disminuye. Los puntos tienden a bajar.	
Cercana a 0 $\approx 0$	No existe relación lineal clara. La nube de puntos no muestra tendencia.	

## CARACTERÍSTICAS IMPORTANTES



No tiene límites fijos.  
Su magnitud depende de las unidades de las variables.



Depende de la escala.  
Cambiar las unidades cambia el valor de la covarianza.



Simétrica.  
 $\text{Cov}(X, Y) = \text{Cov}(Y, X)$



No mide fuerza, sino dirección conjunta.  
Para medir fuerza use correlación de Pearson.



## IDEA CLAVE

La covarianza indica la dirección de la relación lineal, no su intensidad.

★ **Relación con Pearson:** la correlación de Pearson estandariza la covarianza para obtener valores entre  $-1$  y  $1$ , facilitando la comparación.

Figura 10.5

```
datos$Long_Pierna_cm,
datos$Long_Pie_cm,

use = "complete.obs"
)
```

[1] 0.06261345

**Interpetación:** La covarianza calculada ( $r = 0.062$ ) entre la longitud de la pierna y la longitud del pie presenta un valor cercano a cero, indicando que ambas variables no muestran una variación conjunta importante dentro de la muestra analizada.

Este resultado coincide con el **análisis de correlación de Pearson** previamente realizado ( $r = 0.012$ ), donde también se evidenció una relación lineal prácticamente nula entre las variables. En términos prácticos, los cambios en la longitud de la pierna no se asocian de manera consistente con cambios en la longitud del pie en los estudiantes evaluados.

Asimismo, este ejemplo permite comprender que no todas las variables antropométricas presentan asociaciones lineales fuertes, incluso cuando pertenecen a dimensiones corporales relacionadas.

### 10.9.3. Tablas de contingencia

Las tablas de contingencia son herramientas estadísticas utilizadas para resumir y analizar la relación entre dos variables categóricas. Estas tablas permiten organizar las frecuencias observadas según las diferentes combinaciones de categorías presentes en las variables estudiadas.

También son conocidas como: tablas cruzadas, tablas de doble entrada o tablas de asociación.

Su principal objetivo consiste en identificar posibles patrones de relación o dependencia entre categorías.

#### 10.9.3.1. Estructura general

Una tabla de contingencia distribuye las observaciones en filas y columnas:

	Categoría B1	Categoría B2	Total
Categoría A1	$f_{11}$	$f_{12}$	$f_{1\cdot}$
Categoría A2	$f_{21}$	$f_{22}$	$f_{2\cdot}$
Total	$f_{\cdot 1}$	$f_{\cdot 2}$	$n$

donde:

- las filas representan categorías de una variable;
- las columnas representan categorías de la otra variable;
- cada celda contiene la frecuencia observada.

### 10.9.4. Interpretación

Las tablas de contingencia permiten comparar frecuencias entre grupos; identificar asociaciones entre categorías; calcular porcentajes conjuntos; analizar patrones poblacionales; servir como base para pruebas como Chi-cuadrado. Cuando las proporciones observadas son similares entre categorías, puede inferirse independencia entre las variables. En cambio, diferencias importantes sugieren posibles asociaciones.

### 10.9.5. Ejercicio contextual

En estudios educativos puede analizarse la relación entre género y aprobación académica; modalidad de estudio y rendimiento o nivel socioeconómico y acceso tecnológico. En salud tabaquismo y enfermedad; clasificación nutricional y actividad física.

### 10.9.6. Ejemplo en R

En el siguiente ejemplo se construye una tabla de contingencia entre género y grupo académico utilizando la base antropométrica.

```
library(readxl)
library(dplyr)
library(janitor)
library(knitr)
library(kableExtra)

Cargar base de datos
datos <- read_excel(
 "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

#=====
1. Género vs Talla dicotómica
#=====

datos %>%

 tabyl(
 Genero,
 Talla_Dicotica
) %>%

 adorn_totals(c("row", "col")) %>%

 adorn_percentages("row") %>%

 adorn_pct_formatting(digits = 1) %>%

 adorn_ns(position = "front") %>%

 kable(
 caption = "Tabla de contingencia: Género y talla dicotómica",
 align = "c"
) %>%

 kable_styling(
 full_width = FALSE,
 bootstrap_options = c(
 "striped",
 "hover",
 "condensed"
)
)
)
```

Tabla 10.3: Tabla de contingencia: Género y talla dicotómica

Genero	Alta	Baja	Total
F	23 (11.1 %)	185 (88.9 %)	208 (100.0 %)
M	30 (57.7 %)	22 (42.3 %)	52 (100.0 %)
Total	53 (20.4 %)	207 (79.6 %)	260 (100.0 %)

```

#=====
2. Género vs IMC dicotómico
#=====

datos %>%

 tabyl(
 Genero,
 IMC_Dicotico
) %>%

 adorn_totals(c("row", "col")) %>%

 adorn_percentages("row") %>%

 adorn_pct_formatting(digits = 1) %>%

 adorn_ns(position = "front") %>%

 kable(
 caption = "Tabla de contingencia: Género e IMC dicotómico",
 align = "c"
) %>%

 kable_styling(
 full_width = FALSE,
 bootstrap_options = c(
 "striped",
 "hover",
 "condensed"
)
)
)

```

Tabla 10.4: Tabla de contingencia: Género e IMC dicotómico

Genero	Bajo_Peso	Normal+	Total
F	127 (61.1 %)	81 (38.9 %)	208 (100.0 %)
M	10 (19.2 %)	42 (80.8 %)	52 (100.0 %)
Total	137 (52.7 %)	123 (47.3 %)	260 (100.0 %)

```

#=====
3. Género vs Tamaño de mano
#=====

datos %>%

 tabyl(
 Genero,
 Mano_Dicotica
) %>%

 adorn_totals(c("row", "col")) %>%

```

```

adorn_percentages("row") %>%

adorn_pct_formatting(digits = 1) %>%

adorn_ns(position = "front") %>%

kable(
 caption = "Tabla de contingencia: Género y tamaño de mano",
 align = "c"
) %>%

kable_styling(
 full_width = FALSE,
 bootstrap_options = c(
 "striped",
 "hover",
 "condensed"
)
)

```

Tabla 10.5: Tabla de contingencia: Género y tamaño de mano

Genero	Grande	Pequeña	Total
F	26 (12.5 %)	182 (87.5 %)	208 (100.0 %)
M	38 (73.1 %)	14 (26.9 %)	52 (100.0 %)
Total	64 (24.6 %)	196 (75.4 %)	260 (100.0 %)

**Interpretación:** En términos generales, el 88.9 % de las mujeres se clasifican dentro del rango normal de IMC y el 11.1 % presenta sobrepeso u obesidad. En contraste, entre los hombres solo el 48.1 % presenta IMC normal, mientras que el 51.9 % se ubica en la categoría de sobrepeso-obesidad. Considerando el total de la muestra, el 80.8 % de los estudiantes presenta un IMC normal y el 19.2 % presenta sobrepeso u obesidad.

Estos resultados sugieren una posible asociación entre el género y la clasificación del IMC, evidenciando una mayor proporción de sobrepeso-obesidad en los hombres respecto a las mujeres dentro de la población analizada. Las tablas de contingencia permiten identificar este tipo de patrones descriptivos y constituyen la base para posteriores análisis inferenciales, como la prueba Chi-cuadrado de independencia.

## 10.10. Integración y aplicación

### 10.10.1. Estructura general para seleccionar la técnica adecuada

#### 10.10.2. Laboratorio experiencial

**¿Existe relación entre la altura y el peso corporal?**

**Situación problema:** Un grupo de estudiantes de fisioterapia desea analizar si la altura corporal se relaciona con el peso de los estudiantes universitarios. Para ello, se recolectó información antropométrica de hombres y mujeres de diferentes semestres académicos.

**Objetivo del análisis**

Determinar: si existe relación entre altura y peso; la dirección de la relación; la fuerza de la asociación y si el género modifica visualmente el comportamiento de los datos.

### **10.10.3. Actividades del estudiante**

#### **Parte 1 — Exploración visual**

##### **Preguntas**

- ¿Qué tipo de relación observa en el diagrama? positiva, negativa, nula, urvilínea.
- ¿La relación parece fuerte o débil?
- ¿Existen valores atípicos?
- ¿Se observan diferencias entre hombres y mujeres?

#### **Parte 2 — Correlación**

Calcule: correlación de Pearson y correlación de Spearman.

##### **Preguntas**

- ¿Los coeficientes son similares?
- ¿Cuál considera más apropiado según la distribución de los datos?
- ¿Puede afirmarse causalidad?

#### **Parte 3 — Interpretación aplicada**

Un investigador afirma que “Los estudiantes más altos necesariamente pesan más”.

##### **Preguntas críticas**

- ¿La correlación encontrada permite afirmar eso?
- ¿Qué limitaciones tiene el análisis?
- ¿Qué otras variables podrían influir?

## Capítulo 11

# Declaración sobre el uso de herramientas de inteligencia artificial

La elaboración de este libro contó con el apoyo de diversas herramientas de inteligencia artificial (IA) como recurso complementario para la búsqueda de información, organización de contenidos, revisión de estilo, generación de ejemplos de código y apoyo en procesos de edición y diseño. Entre las herramientas utilizadas se encuentran ChatGPT (OpenAI), Copilot (Microsoft), Quillbot, R y Quarto, entre otras tecnologías de apoyo académico y editorial.

Estas herramientas fueron empleadas exclusivamente como asistentes para facilitar procesos de síntesis, estructuración, corrección y producción de materiales educativos. Todas las decisiones conceptuales, metodológicas, estadísticas, pedagógicas y editoriales fueron realizadas, verificadas y aprobadas por los autores.

La selección de contenidos, la interpretación de los resultados, la validación de los ejemplos, la revisión de las fuentes bibliográficas y la responsabilidad sobre la exactitud de la información presentada corresponden exclusivamente a los autores de la obra.

El uso de herramientas de inteligencia artificial se realizó siguiendo principios de transparencia académica, apoyo a la innovación educativa y fortalecimiento de los procesos de enseñanza y aprendizaje.

# Referencias

- Agresti, A. (2018). *Statistical Methods for the Social Sciences* (5.<sup>a</sup> ed.). Pearson.
- Armitage, P., Berry, G., & Matthews, J. N. S. (2002). *Statistical methods in medical research*. Blackwell Science.
- Bonita, R., Beaglehole, R., & Kjellström, T. (2008). *Epidemiología básica*. Organización Panamericana de la Salud.
- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8.<sup>a</sup> ed.). Cengage Learning.
- Kleinbaum, D. G., & Klein, M. (2012). *Survival Analysis: A Self-Learning Text* (3.<sup>a</sup> ed.). Springer.
- Obando, L. (2021). *Gráficos estadísticos y análisis de datos con R*. Editorial Académica.
- Posada, C. (2016). *Elementos de estadística*. Editorial Académica.
- Rey, J. (2007). *Introducción a la estadística*. Editorial Universitaria.
- Seoane, T. et al. (2007). *Estadística aplicada*. Editorial Académica.
- Spiegel, M. R., & Stephens, L. J. (2009). *Estadística*. McGraw-Hill.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Van den Broeck, J., Cunningham, S. A., Eeckels, R., & Herbst, K. (2005). Data cleaning: Detecting, diagnosing, and editing data abnormalities. *PLoS Medicine*, 2(10), e267. <https://doi.org/10.1371/journal.pmed.0020267>
- Wickham, H., & Grolemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media.
- Wooldridge, J. M. (2016). *Introductory Econometrics: A Modern Approach* (6.<sup>a</sup> ed.). Cengage Learning.