

Estadística Experiencial Aplicada

Aprendizaje práctico de la estadística descriptiva con R

Francisco Javier León Miguel Oswaldo Pérez Pulido
Leonardo Andrés Pinto Guarguati

2026-03-24

Table of contents

Preface	3
1 Introduction	4
2 Summary	5
3 Autores	6
3.1 Francisco Javier León	6
3.2 Miguel Oswaldo Pérez Pulido	6
3.3 Leonardo Andrés Pinto Guarguati	7
 I Parte I. Fundamentos	 8
4 Parte I. Fundamentos	9
5 Capítulo 1. Introducción a la estadística descriptiva	10
5.1 Introducción	10
5.2 ¿Qué es la estadística descriptiva?	10
5.3 Tipos de variables	10
5.3.1 Variables cualitativas(o atributos)	11
5.3.2 Variables cuantitativas	11
5.4 Escalas de medición	11
5.5 Importancia de la identificación de variables	12
6 Caso	13
6.1 Resumen gráfico	14
7 Parte I. Fundamentos	15
7.0.1 Capítulo 2. Preparación de datos	15
7.1 Carga de datos en R	15
7.2 Limpieza de datos	16
 II Parte II. Organización y visualización de datos	 18
8 Parte II. Organización y presentación de datos	19

9	Capítulo 3. Tablas de datos	20
9.1	3.1 Datos simples	20
9.2	3.2 Datos agrupados	20
9.3	3.3 Tablas de frecuencia	21
9.3.1	Frecuencia absoluta	22
9.3.2	Frecuencia relativa	22
9.3.3	Frecuencia acumulada	22
9.3.4	Frecuencia relativa acumulada	22
9.4	3.4 Estructura general de una tabla de frecuencia	23
9.5	Marca de clase	23
9.6	3.5 Ejemplo de tabla de frecuencia	24
9.7	3.6 Ejemplo en R	24
9.8	Tabla de Frecuencias empleando la librería summarytools para exploración de datos	25
9.9	Tablas de frecuencias publicables usando librerías dplyr + gt	27
10	Parte I. Fundamentos	30
11	Capítulo 4. Visualización de datos	31
11.1	4.1 Gráficos en R	31
11.2	4.2 Gráfico de barras	32
11.2.1	Ejemplo con funciones básicas de R	32
11.3	4.3 Histograma	34
11.3.1	Ejemplo con funciones básicas de R	34
11.3.2	Ejemplo con ggplot2	35
11.4	4.4 Boxplot	36
11.4.1	Ejemplo con funciones básicas de R	37
11.4.2	Ejemplo con ggplot2	37
11.4.3	Boxplot por grupo	38
11.5	4.5 Interpretación básica de los gráficos	39
11.6	4.6 Recomendaciones para la elaboración de gráficos	39
III	Parte III. Medidas descriptivas	41
12	Capítulo 5. Medidas de tendencia central y dispersión	42
13	Capítulo 5. Medidas de tendencia central y dispersión	43
14	5.1 Medidas de tendencia central	44
14.0.1	5.1.1 Media aritmética	44
14.0.2	Cálculo en R	44
14.0.3	5.1.2 Mediana	45
14.0.4	Cálculo en R	46
14.0.5	5.1.3 Moda	46

14.0.6	Cálculo en R	46
14.1	Visualización de las medidas de tendencia central	46
14.2	Interpretación del gráfico: Distribución del peso	48
14.2.1	Análisis estadístico	48
15	Ejercicio experiencial propuesto	50
15.1	Actividad: Explorando las características antropométricas	50
15.1.1	Objetivo	50
15.2	Actividad práctica	50
15.3	Parte 1. Construcción del gráfico	50
15.4	Parte 2. Interpretación	51
16	5.2 Medidas de dispersión o variabilidad	52
16.0.1	5.2.1 Rango	52
16.0.2	Cálculo en R	52
16.0.3	5.2.2 Varianza muestral	53
16.0.4	Cálculo en R	53
16.0.5	Varianza poblacional	53
16.0.6	5.2.3 Desviación estándar muestral	53
16.0.7	Cálculo en R	53
16.0.8	Desviación estándar poblacional	54
16.0.9	5.2.4 Coeficiente de variación	54
16.0.10	Cálculo en R	54
16.1	5.3 Resumen estadístico en R	54
16.2	Histograma + desviación estándar	55
16.2.1	Interpretación	57
16.3	Comparar dispersión entre géneros	57
16.3.1	Interpretación	58
16.3.2	Interpretación	60
16.4	Resumen gráfico	60
17	Parte I. Fundamentos	62
17.0.1	Capítulo 6. Medidas de posición	62
18	Parte I. Fundamentos	63
18.0.1	Capítulo 7. Medidas de dispersión	63
19	Parte I. Fundamentos	64
IV	Parte IV. Relaciones entre variables	65
20	Parte IV. Relaciones entre variables	66
20.0.1	Capítulo 9. Análisis bivariado	66

21 Parte I. Fundamentos	67
21.0.1 Capítulo 9. Asociación e interpretación	67
V Parte V. Puente a la inferencia	68
22 Parte V. Puente a la inferencia	69
22.0.1 Capítulo 10. Introducción a la inferencia (opcional pero recomendado)	69
VI Parte VI. Aplicación y divulgación	70
23 Parte I. Fundamentos	71
References	72

Preface

This is a Quarto book.

- portada
- propósito del libro
- público objetivo
- competencias a desarrollar

To learn more about Quarto books visit <https://quarto.org/docs/books>.

1 + 1

[1] 2

1 Introduction

This is a book created from markdown and executable code.

- qué es la estadística descriptiva
- por qué aprenderla con enfoque experiencial
- uso de R y Quarto
- estructura del libro

See Knuth (1984) for additional discussion of literate programming.

```
1 + 1
```

```
[1] 2
```

2 Summary

In summary, this book has no content whatsoever.

- mapa del libro
- ruta de capítulos
- resultados de aprendizaje por unidad

1 + 1

[1] 2

3 Autores



3.1 Francisco Javier León

Bacteriólogo y laboratorista clínico, con formación avanzada como magíster en estadística aplicada, Magíster en ciencias básicas biomédicas y especialista en educación con nuevas tecnologías. Está vinculado a la Universidad de Santander (UDES) desde 2007, donde ha sido docente en la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Actualmente, se desempeña como Coordinador de Analítica Académica, adscrito a la Vicerrectoría de Enseñanza. Es investigador júnior reconocido por MinCiencias en la convocatoria 957 de 2024 y miembro del grupo de investigación CIBAS.



3.2 Miguel Oswaldo Pérez Pulido

Licenciado en matemáticas y magíster en estadística. Actualmente se desempeña como Director de Analítica Académica, adscrito a la Vicerrectoría de Enseñanza. Está vinculado a la Universidad de Santander (UDES) desde 2011, donde ha sido docente en programas de pregrado y posgrado de

la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Es investigador asociado reconocido por MinCiencias en la convocatoria 957 de 2024 y miembro del grupo de investigación CIBAS.

 Tip



3.3 Leonardo Andrés Pinto Guarguati

Economista de la Universidad Santo Tomás de Bucaramanga, especialista en Evaluación y Gerencia de Proyectos de la Universidad Industrial de Santander y estudiante de la Maestría en Evaluación y Gerencia de Proyectos de la misma. Con experiencia en docencia universitaria, análisis de mercados y coordinación de proyectos de Ciencia, Tecnología e innovación CTel.

Parte I

Parte I. Fundamentos

4 Parte I. Fundamentos

5 Capítulo 1. Introducción a la estadística descriptiva

5.1 Introducción

Actualmente los datos se han convertido en un activo fundamental para la toma de decisiones en las empresas, la sociedad, la académica entre otros y es por eso que la **estadística descriptiva constituye el primer paso para transformar información en conocimiento útil** (Seoane et al., 2007). Su aplicación permite un mejor entendimiento del mundo que nos rodea, ya que prácticamente cada aspecto de nuestra existencia es una fuente potencial de datos (Obando, 2021). Este capítulo introduce los conceptos básicos necesarios para comprender, organizar y analizar datos, utilizando un enfoque experiencial basado en ejemplos reales y herramientas computacionales como R.

5.2 ¿Qué es la estadística descriptiva?

La **estadística descriptiva** es la rama de la estadística encargada de recolectar, organizar, resumir y presentar datos de manera clara y comprensible .

A diferencia de la estadística inferencial, que busca demostrar asociaciones o hacer comparaciones para extrapolar resultados de una muestra a una población, la descriptiva se limita a **sintetizar la información contenida en los datos recogidos** sin realizar inferencias más allá de la información disponible (Bonita et al., 2008; Posada, 2016).

Su propósito fundamental es facilitar la comprensión de grandes volúmenes de información mediante el uso de **tablas, representaciones gráficas y medidas resumen** (como la media o la desviación estándar), permitiendo “hacerse una idea” de la naturaleza de un conjunto de datos sin tener que analizar cada uno de ellos individualmente (Posada, 2016; Rey, 2007; Spiegel & Stephens, 2009).

5.3 Tipos de variables

Las variables representan características, cualidades o rasgos que pueden medirse u observarse en los elementos de una población o muestra.

5.3.1 Variables cualitativas(o atributos)

Describen cualidades, atributos o categorías que no pueden medirse numéricamente, pero sí clasificarse.

- **Nominales:** Sus categorías no admiten un orden natural (ej: sexo, estado civil).
- **Ordinales:** Sus categorías indican un orden o jerarquía (ej: nivel socioeconómico, grado académico).

5.3.2 Variables cuantitativas

Son aquellas que toman valores numéricos y se originan mediante procesos de conteo o medición .

- **Discretas:** Asociadas a procesos de conteo, asumen valores enteros aislados (ej: número de hijos, número de artículos defectuosos).
- **Continuas:** Asociadas a procesos de medición, pueden tomar cualquier valor dentro de un intervalo determinado (ej: peso, estatura, edad),.

5.4 Escalas de medición

La naturaleza de las observaciones determina el nivel de medición, lo cual es fundamental para elegir el método estadístico apropiado (Tabla 1)(Armitage et al., 2002; Kleinbaum et al., 1982).

Cuadro 5.1: Clasificación de variables

Escala	Característica	Ejemplo
Nominal	Clasificación en categorías mutuamente excluyentes sin orden.	Género, lugar de nacimiento.
Ordinal	Existe un orden o jerarquía entre niveles, pero la distancia entre ellos no es constante.	Estrato socioeconómico, grado militar.
Intervalo	Orden con distancias iguales entre valores. El cero es arbitrario y no indica ausencia de la propiedad.	Temperatura (Celsius o Fahrenheit).
Razón	Posee todas las propiedades anteriores y un cero absoluto que indica ausencia total de la característica.	Edad, peso, ingresos, longitud.

5.5 Importancia de la identificación de variables

La correcta identificación del tipo de variable es fundamental, ya que determina las técnicas estadísticas que deben utilizarse. Por ejemplo, las **variables cuantitativas permiten calcular medidas de tendencia central** (como la media) y **medidas de dispersión** (como la varianza o desviación típica), mientras que las cualitativas se analizan principalmente mediante tablas de frecuencias y proporciones (Armitage et al., 2002).

Un **error frecuente en el análisis estadístico es tratar variables ordinales como si fueran cuantitativas continuas** sin justificación. Asumir que los datos siguen siempre una distribución normal o aplicar pruebas paramétricas a datos que no cumplen los requisitos merman severamente la validez de los resultados y pueden generar interpretaciones erróneas,.

La estadística descriptiva permite transformar datos brutos en información significativa mediante el uso de medidas resumen y representaciones gráficas. Al proporcionar una base sólida para la organización y el análisis de datos, facilita la interpretación y comprensión de los fenómenos analizados, sirviendo como apoyo esencial para la toma de decisiones informadas.

6 Caso

A continuación se analiza un conjunto de datos de estudiantes de primer ingreso en la universidad, donde se desea identificar características como edad, sexo, estrato socioeconómico y horas de estudio.

Código en R

```
# Crear un dataset simple de datos
datos <- data.frame(
  edad = c(18, 19, 20, 18, 21),
  sexo = c("F", "M", "F", "F", "M"),
  estrato = c(2, 3, 2, 1, 3),
  horas_estudio = c(2.5, 3, 4, 2, 5) )

# Ver estructura
str(datos)
```

```
'data.frame':  5 obs. of  4 variables:
 $ edad      : num  18 19 20 18 21
 $ sexo      : chr  "F" "M" "F" "F" ...
 $ estrato   : num   2  3  2  1  3
 $ horas_estudio: num  2.5 3  4  2  5
```

El conjunto de datos permite identificar diferentes tipos de variables:

- **Edad:** cuantitativa continua (aunque se registre en años enteros, proviene de un proceso de medición del tiempo).
- **Sexo:** cualitativa nominal (categorías sin orden intrínseco).
- **Estrato:** cualitativa ordinal (indica un orden socioeconómico).
- **Horas de estudio:** cuantitativa continua (admite valores fraccionarios en un intervalo).

6.1 Resumen gráfico




Figura 6.1: La figura es una adaptación gráfica realizada por los autores en Napkin a partir del esquema presentado por Derek Rowntree (1981) en *Statistics Without Tears*. La modificación respeta los criterios de uso justo para fines académicos.

7 Parte I. Fundamentos

7.0.1 Capítulo 2. Preparación de datos

La preparación de datos constituye una etapa crítica dentro del análisis estadístico, ya que implica el proceso sistemático de depuración, organización, clasificación y transformación de la información recolectada, con el fin de convertirla en un insumo adecuado para su análisis (Kleinbaum & Klein, 2012; Wickham & Grolemund, 2017).

En esta fase, el estudiante - el investigador debe garantizar la calidad de los datos mediante procesos de validación y verificación, conocidos como crítica de datos, cuyo objetivo es identificar y corregir errores, inconsistencias u omisiones generadas durante la recolección de la información (Hair et al., 2019).

7.1 Carga de datos en R

Para iniciar el trabajo en R, el primer paso fundamental consiste en definir el directorio de trabajo, es decir, la ubicación donde se encuentran los archivos de datos y donde se almacenarán los resultados del análisis. Esto puede realizarse mediante la función `setwd()` o a través de herramientas gráficas del entorno de desarrollo (RStudio) (Wickham & Grolemund, 2017). Existen múltiples métodos para cargar datos dependiendo de su formato:

Cuadro 7.1: Métodos de carga de datos en R

Método	Característica	Ejemplo
Archivos de texto y CSV	Uso de funciones como <code>read.csv()</code> o <code>read.csv2()</code> , especificando encabezados y codificación	Importación de archivos .csv
Interfaces gráficas (GUI)	Herramientas como R Commander permiten importar datos sin necesidad de programación	Importación desde Excel, SPSS, STATA

Método	Característica	Ejemplo
Minería de datos	Paquetes como <i>rattle</i> permiten cargar datos mediante interfaces visuales configurables	Definición de separadores y decimales

7.2 Limpieza de datos

La limpieza de datos consiste en detectar, corregir o eliminar inconsistencias que puedan afectar la validez del análisis estadístico (Van den Broeck et al., 2005). Un paso inicial es la inspección visual del conjunto de datos para identificar registros incompletos, errores de digitación o valores atípicos. Por ejemplo, líneas que contienen exclusivamente valores faltantes (NA) deben ser evaluadas antes de su inclusión en el análisis.

Cuadro 7.2: Aspectos clave en la preparación de datos

Proceso	Subproceso	Descripción	Herramienta / Ejemplo
Limpieza de datos	Valores extremos (Outliers)	Identificación y tratamiento de datos atípicos que pueden distorsionar resultados. Se recomienda corregir o eliminar errores evidentes.	Diagramas de caja (<i>boxplot</i>) (Tukey, 1977)
	Consistencia de totales	Verificación de coherencia entre frecuencias, totales y porcentajes acumulados.	Validación de sumas (Agresti, 2018)
	Filtrado de datos	Selección de subconjuntos de datos según criterios específicos para análisis focalizado.	Filtrado en R (<i>subset</i> , <i>filter</i>)
Valores faltantes	Identificación y codificación	Asignación de códigos (ej: 99, 999) para identificar datos perdidos.	Codificación en R o SPSS

Proceso	Subproceso	Descripción	Herramienta / Ejemplo
Recodificación	Eliminación de casos	Eliminación de registros incompletos antes del análisis.	<code>na.omit()</code> , <code>na.exclude()</code>
	Imputación	Estimación de valores faltantes mediante métodos estadísticos.	Métodos de imputación
	Análisis de censura	Tratamiento de datos incompletos en estudios de supervivencia.	(Kleinbaum & Klein, 2012)
	Categorización de variables	Transformación de variables cuantitativas en categorías.	Agrupación de edades
	Codificación de atributos	Asignación de valores numéricos a variables cualitativas.	1 = Masculino, 2 = Femenino
	Variables dummy	Conversión de variables categóricas en variables binarias.	(Wooldridge, 2016)
	Tratamiento de etiquetas	Conversión de códigos numéricos a etiquetas descriptivas.	<code>factor()</code> en R

La preparación de datos es una fase fundamental que garantiza la calidad y confiabilidad del análisis estadístico. Un manejo adecuado de la limpieza, los valores faltantes y la recodificación permite transformar datos brutos en información estructurada y útil, fortaleciendo la validez de los resultados y la toma de decisiones basada en evidencia (Wickham & Grolemund, 2017; Hair et al., 2019).

Parte II

Parte II. Organización y visualización de datos

8 Parte II. Organización y presentación de datos

9 Capítulo 3. Tablas de datos

En este capítulo se presentan los fundamentos para la organización y presentación de la información mediante diferentes tipos de tablas estadísticas. Estas herramientas permiten resumir, ordenar y estructurar los datos de manera que faciliten su análisis e interpretación. Las tablas constituyen un recurso esencial en la estadística descriptiva, ya que permiten transformar datos individuales en información significativa.

9.1 3.1 Datos simples

Los **datos simples** corresponden al registro directo, individual y no agrupado de cada observación obtenida en un estudio. En este formato, cada valor se conserva tal como fue recolectado, lo que permite identificar con facilidad observaciones particulares, posibles errores de registro, valores extremos y patrones preliminares.

Si se tiene una variable cuantitativa X observada en n individuos, los datos simples pueden representarse como:

$$X = \{x_1, x_2, x_3, \dots, x_n\}$$

donde:

- x_i representa el valor observado en la unidad i
- n es el número total de observaciones

Este tipo de presentación es especialmente útil en etapas iniciales del análisis, cuando interesa inspeccionar la información en bruto antes de resumirla. Sin embargo, cuando el número de observaciones es grande, los datos simples se vuelven poco prácticos para interpretar tendencias generales.

9.2 3.2 Datos agrupados

Los **datos agrupados** se obtienen cuando los valores individuales se organizan en categorías o intervalos de clase. Esta forma de organización permite resumir grandes volúmenes de información y facilita la identificación de concentraciones, patrones de distribución y tendencias generales.

Cuando la variable es cuantitativa continua, los intervalos suelen construirse a partir del rango de los datos. El rango de los datos se define como:

$$R = X_{\max} - X_{\min}$$

donde:

- R es el rango
- $X_{\max}$ es el valor máximo observado
- $X_{\min}$ es el valor mínimo observado

Si se desea formar k clases, la amplitud del intervalo puede aproximarse mediante: La amplitud de clase se calcula como:

$$A = \frac{R}{k}$$

donde:

- A es la amplitud de clase
- k es el número de intervalos

Una regla empírica ampliamente usada para estimar el número de clases es la **regla de Sturges**:

$$k = 1 + 3.322 \log_{10}(n)$$

Esta expresión proporciona un valor de referencia para construir tablas de frecuencias agrupadas cuando el tamaño muestral es moderado.

9.3 3.3 Tablas de frecuencia

Las **tablas de frecuencia** permiten resumir la distribución de los datos, indicando cuántas veces aparece cada valor, categoría o intervalo. Son una herramienta central de la estadística descriptiva y constituyen la base para la construcción de histogramas, polígonos de frecuencia, diagramas de barras y otros gráficos.

Una tabla de frecuencia puede incluir los siguientes componentes:

9.3.1 Frecuencia absoluta

La **frecuencia absoluta** de una categoría o clase corresponde al número de veces que dicha categoría aparece en el conjunto de datos. Se denota por f_i .

f_i = número de observaciones en la categoría o clase i

9.3.2 Frecuencia relativa

La **frecuencia relativa** expresa la proporción de observaciones que pertenecen a una categoría respecto al total. Se denota por h_i y se calcula como:

$$h_i = \frac{f_i}{n}$$

Si se desea expresar en porcentaje:

$$h_i(\%) = \frac{f_i}{n} \times 100$$

9.3.3 Frecuencia acumulada

La **frecuencia acumulada** representa la suma progresiva de las frecuencias absolutas hasta la clase i . Se denota por F_i :

$$F_i = \sum_{j=1}^i f_j$$

9.3.4 Frecuencia relativa acumulada

La **frecuencia relativa acumulada** corresponde a la suma progresiva de las frecuencias relativas. Se denota por H_i :

$$H_i = \sum_{j=1}^i h_j = \frac{f_i}{n}$$

Estas medidas permiten conocer no solo la cantidad de datos en cada categoría, sino también la proporción acumulada de observaciones hasta determinado punto de la distribución.

9.4 3.4 Estructura general de una tabla de frecuencia

De manera general, una tabla de frecuencia para una variable cuantitativa agrupada puede organizarse con las siguientes columnas:

- Clase o intervalo
- Marca de clase
- Frecuencia absoluta (f_i)
- Frecuencia relativa (h_i)
- Frecuencia acumulada (F_i)
- Frecuencia relativa acumulada (H_i)

9.5 Marca de clase

La marca de clase corresponde al punto medio de cada intervalo:

$$x_i^* = \frac{L_i + U_i}{2}$$

donde:

- (x_i^*) es la marca de clase
- (L_i) es el límite inferior del intervalo
- (U_i) es el límite superior del intervalo

La marca de clase resulta útil para representar la distribución mediante gráficos o para calcular medidas resumen aproximadas cuando los datos están agrupados.

9.6 3.5 Ejemplo de tabla de frecuencia

Cuadro 9.1: Ejemplo de tabla de frecuencia

Categoría	(f_i)	(h_i)	(F_i)	(H_i)
A	50	0.3125	50	0.3125
B	80	0.5000	130	0.8125
C	30	0.1875	160	1.0000

Como se observa en la Tabla Table 9.1, las frecuencias permiten describir la distribución de los datos y facilitan su interpretación.

9.7 3.6 Ejemplo en R

Tomando como referencia la base **bd_antropometricas.xlsx**, puede construirse una tabla de frecuencia para una variable cualitativa, por ejemplo **Grupo** o **Clase**, o para una variable cuantitativa, como **Peso**, una vez se haya verificado la consistencia de las unidades registradas.

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 13
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>             <dbl>      <dbl>
1 D     A     M         177     73                49         19
2 D     A     M         177     86                45         19
3 D     A     F         160     52                37         16
4 D     A     F         159     53                38         16
5 D     A     F         174     78                41         18
6 D     B     M         186     68                44         19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>
```

```
names(datos)
```

```
[1] "Clase"           "Grupo"           "Genero"
[4] "Altura_cm"       "Peso_Kg"          "Anchura_hombros_cm"
[7] "Long_Mano_cm"     "Lon_Palma_cm"     "Ancho_Palma_cm"
[10] "Long_Brazo_cm"    "Long_Muslo_cm"    "Long_Antebrazo_cm"
[13] "Curso"
```

```
#View (datos)
```

9.8 Tabla de Frecuencias empleando la libreria summarytools para exploración de datos

```
library(summarytools)
```

Warning: package 'summarytools' was built under R version 4.5.3

```
tabla1 <- freq(datos$Peso_Kg)
tabla1
```

Frequencies
datos\$Peso_Kg
Type: Numeric

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
31	3	1.15	1.15	1.15	1.15
32	3	1.15	2.31	1.15	2.31
34	1	0.38	2.69	0.38	2.69
35	5	1.92	4.62	1.92	4.62
36	9	3.46	8.08	3.46	8.08
37	8	3.08	11.15	3.08	11.15
38	13	5.00	16.15	5.00	16.15
39	8	3.08	19.23	3.08	19.23
39.5	1	0.38	19.62	0.38	19.62
40	17	6.54	26.15	6.54	26.15
40.5	2	0.77	26.92	0.77	26.92
41	6	2.31	29.23	2.31	29.23
42	12	4.62	33.85	4.62	33.85
42.5	1	0.38	34.23	0.38	34.23

43	3	1.15	35.38	1.15	35.38
43.5	2	0.77	36.15	0.77	36.15
44	3	1.15	37.31	1.15	37.31
45	4	1.54	38.85	1.54	38.85
45.5	1	0.38	39.23	0.38	39.23
46	8	3.08	42.31	3.08	42.31
47	6	2.31	44.62	2.31	44.62
48	7	2.69	47.31	2.69	47.31
49	3	1.15	48.46	1.15	48.46
50	5	1.92	50.38	1.92	50.38
51	4	1.54	51.92	1.54	51.92
52	6	2.31	54.23	2.31	54.23
53	7	2.69	56.92	2.69	56.92
55	6	2.31	59.23	2.31	59.23
56	2	0.77	60.00	0.77	60.00
57	3	1.15	61.15	1.15	61.15
59	4	1.54	62.69	1.54	62.69
60	6	2.31	65.00	2.31	65.00
62	5	1.92	66.92	1.92	66.92
63	4	1.54	68.46	1.54	68.46
64	4	1.54	70.00	1.54	70.00
66	2	0.77	70.77	0.77	70.77
68	4	1.54	72.31	1.54	72.31
69	2	0.77	73.08	0.77	73.08
70	2	0.77	73.85	0.77	73.85
72	4	1.54	75.38	1.54	75.38
73	2	0.77	76.15	0.77	76.15
75	2	0.77	76.92	0.77	76.92
76	2	0.77	77.69	0.77	77.69
78	2	0.77	78.46	0.77	78.46
79	2	0.77	79.23	0.77	79.23
80	2	0.77	80.00	0.77	80.00
83	2	0.77	80.77	0.77	80.77
86	4	1.54	82.31	1.54	82.31
88	2	0.77	83.08	0.77	83.08
94	2	0.77	83.85	0.77	83.85
100	2	0.77	84.62	0.77	84.62
115	2	0.77	85.38	0.77	85.38
151	1	0.38	85.77	0.38	85.77
152	3	1.15	86.92	1.15	86.92
154	2	0.77	87.69	0.77	87.69
155	1	0.38	88.08	0.38	88.08
156	1	0.38	88.46	0.38	88.46

158	3	1.15	89.62	1.15	89.62
159	1	0.38	90.00	0.38	90.00
160	4	1.54	91.54	1.54	91.54
161	1	0.38	91.92	0.38	91.92
162	1	0.38	92.31	0.38	92.31
163	1	0.38	92.69	0.38	92.69
164	2	0.77	93.46	0.77	93.46
165	2	0.77	94.23	0.77	94.23
166	2	0.77	95.00	0.77	95.00
168	1	0.38	95.38	0.38	95.38
169	1	0.38	95.77	0.38	95.77
170	3	1.15	96.92	1.15	96.92
171	2	0.77	97.69	0.77	97.69
172	1	0.38	98.08	0.38	98.08
176	1	0.38	98.46	0.38	98.46
179	1	0.38	98.85	0.38	98.85
180	2	0.77	99.62	0.77	99.62
184	1	0.38	100.00	0.38	100.00
<NA>	0			0.00	100.00
Total	260	100.00	100.00	100.00	100.00

```
tabla2 <- freq(datos$Genero)
tabla2
```

Frequencies
datos\$Genero
Type: Character

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
F	208	80.00	80.00	80.00	80.00
M	52	20.00	100.00	20.00	100.00
<NA>	0			0.00	100.00
Total	260	100.00	100.00	100.00	100.00

9.9 Tablas de frecuencias publicables usando librerías dplyr + gt

```
library(dplyr)
```

Categoría	f_i	h_i	F_i	H_i
F	208	0.8	208	0.8
M	52	0.2	260	1.0

Adjuntando el paquete: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(gt)
```

Warning: package 'gt' was built under R version 4.5.3

```
# Tabla de frecuencia para variable (ej: Genero)
tabla <- datos %>%
  count(Genero, name = "fi") %>%
  mutate(
    hi = fi / sum(fi),
    Fi = cumsum(fi),
    Hi = cumsum(hi)
  )
# Mostrar tabla bonita
tabla %>%
  gt() %>%
  cols_label(
    Genero = "Categoría",
    fi = "f ",
    hi = "h ",
    Fi = "F ",
    Hi = "H "
  )
```

Categoría	f_i	h_i	F_i	H_i
A	40	0.1538462	40	0.1538462
B	51	0.1961538	91	0.3500000
C	41	0.1576923	132	0.5076923
D	94	0.3615385	226	0.8692308
E	34	0.1307692	260	1.0000000

```
# Tabla de frecuencia para variable (ej: Genero)
tabla <- datos %>%
  count(Grupo, name = "fi") %>%
  mutate(
    hi = fi / sum(fi),
    Fi = cumsum(fi),
    Hi = cumsum(hi)
  )
# Mostrar tabla bonita
tabla %>%
  gt() %>%
  cols_label(
    Grupo = "Categoría",
    fi = "f ",
    hi = "h ",
    Fi = "F ",
    Hi = "H "
  )
```


10 Parte I. Fundamentos

11 Capítulo 4. Visualización de datos

La visualización de datos es una etapa fundamental en la estadística descriptiva, ya que permite representar la información de forma clara, resumida e interpretable. Los gráficos facilitan la identificación de patrones, tendencias, valores atípicos y diferencias entre grupos, apoyando así la comprensión de los datos y la toma de decisiones.

En este capítulo se presentan algunos de los gráficos más utilizados en el análisis descriptivo: gráficos de barras, histogramas y diagramas de caja (*boxplot*), así como su construcción en R.

11.1 4.1 Gráficos en R

R es un lenguaje ampliamente utilizado para el análisis estadístico y la visualización de datos. Permite elaborar gráficos tanto con funciones básicas como con paquetes especializados, entre ellos *ggplot2*, que ofrece una sintaxis más flexible y una presentación más profesional.

Para los ejemplos de este capítulo se utilizarán las librerías *readxl* y *ggplot2*.

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 13
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>          <dbl>         <dbl>
1 D     A     M         177     73             49            19
2 D     A     M         177     86             45            19
3 D     A     F         160     52             37            16
4 D     A     F         159     53             38            16
5 D     A     F         174     78             41            18
6 D     B     M         186     68             44            19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>
```

```
str(datos)
```

```
tibble [260 x 13] (S3: tbl_df/tbl/data.frame)
 $ Clase           : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo           : chr [1:260] "A" "A" "A" "A" ...
 $ Genero          : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm       : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg         : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
 $ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
 $ Long_Mano_cm    : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
 $ Lon_Palma_cm    : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
 $ Ancho_Palma_cm  : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
 $ Long_Brazo_cm   : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
 $ Long_Muslo_cm   : num [1:260] 55 52 51 50 52 52 47 51 52 53 ...
 $ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
 $ Curso           : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
```


11.2 4.2 Gráfico de barras

El gráfico de barras se utiliza principalmente para representar variables cualitativas o categóricas. Su finalidad es mostrar la frecuencia o proporción de cada categoría mediante barras separadas, cuya altura es proporcional a la cantidad observada.

Por ejemplo, si se desea visualizar la distribución de una variable como el género o la clase, puede emplearse un gráfico de barras.


11.2.1 Ejemplo con funciones básicas de R

```
barplot(table(datos$Genero),
        main = "Distribución del Género",
        xlab = "Género",
        ylab = "Frecuencia")
```



Ejemplo con ggplot2

```
library(ggplot2)
ggplot(datos, aes(x = Genero)) +
  geom_bar() +
  labs(
    title = "Distribución de género",
    x = "Género",
    y = "Frecuencia"
  )
```



El gráfico de barras permite comparar fácilmente las categorías y detectar cuál presenta mayor o menor frecuencia.


11.3 4.3 Histograma

El histograma se utiliza para representar la distribución de una variable cuantitativa continua. A diferencia del gráfico de barras, en el histograma las barras se presentan unidas, ya que representan intervalos de clase contiguos.

Este tipo de gráfico es útil para identificar la forma de la distribución, la concentración de valores, posibles asimetrías y presencia de valores extremos.


11.3.1 Ejemplo con funciones básicas de R

```
hist(datos$Peso_Kg,  
      main = "Histograma del peso",  
      xlab = "Peso",  
      ylab = "Frecuencia")
```



11.3.2 Ejemplo con ggplot2

```
ggplot(datos, aes(x = Peso_Kg)) +  
  geom_histogram(bins = 10) +  
  labs(  
    title = "Histograma del peso",  
    x = "Peso",  
    y = "Frecuencia"  
  )
```



La elección del número de intervalos puede modificar la apariencia del histograma y, por tanto, la interpretación de la distribución.

11.4 4.4 Boxplot


El diagrama de caja y bigotes, o *boxplot*, es un gráfico que resume la distribución de una variable cuantitativa a partir de los cuartiles, la mediana y los valores extremos. Es especialmente útil para detectar asimetrías y observaciones atípicas.

El boxplot se basa en el resumen de cinco números:

- valor mínimo
- primer cuartil (Q_1)
- mediana (Q_2)
- tercer cuartil (Q_3)
- valor máximo


11.4.1 Ejemplo con funciones básicas de R

```
boxplot(datos$Peso_Kg,  
        main = "Boxplot del peso",  
        ylab = "Peso")
```



11.4.2 Ejemplo con ggplot2


```
ggplot(datos, aes(x = Genero, y = Peso_Kg)) +  
  geom_boxplot() +  
  labs(  
    title = "Distribución del peso según género",  
    x = "Género",  
    y = "Peso"  
  )
```

También es posible comparar una variable cuantitativa entre categorías.

11.4.3 Boxplot por grupo

```
ggplot(datos, aes(y = Peso_Kg)) +  
  geom_boxplot() +  
  labs(  
    title = "Boxplot del peso",  
    y = "Peso"  
  )
```



Este tipo de visualización permite comparar la dispersión, la posición central y la presencia de valores atípicos entre grupos.

11.5 4.5 Interpretación básica de los gráficos

Cada tipo de gráfico aporta información distinta:

- El **gráfico de barras** permite comparar frecuencias entre categorías.
- El **histograma** permite analizar la forma de la distribución de una variable cuantitativa.
- El **boxplot** facilita la identificación de la mediana, la dispersión y los valores atípicos.

Por ello, la selección del gráfico debe hacerse de acuerdo con el tipo de variable y el propósito del análisis.

11.6 4.6 Recomendaciones para la elaboración de gráficos

Para garantizar una correcta interpretación, los gráficos deben elaborarse siguiendo algunos principios básicos:

- incluir un título claro y descriptivo;

- nombrar adecuadamente los ejes;
- verificar que la variable utilizada corresponda con el tipo de gráfico;
- evitar sobrecargar la visualización con elementos innecesarios;
- revisar previamente la calidad y consistencia de los datos.

La visualización de datos constituye un componente esencial del análisis descriptivo. Los gráficos permiten resumir la información, identificar patrones y comunicar resultados de manera clara y comprensible.

En R, tanto las funciones básicas como el paquete `ggplot2` ofrecen múltiples posibilidades para representar datos de forma efectiva, favoreciendo un análisis más sólido y una mejor interpretación de la información.

Parte III

Parte III. Medidas descriptivas

12 Capítulo 5. Medidas de tendencia central y dispersión

13 Capítulo 5. Medidas de tendencia central y dispersión

Las medidas de tendencia central son herramientas estadísticas utilizadas para resumir un conjunto de datos mediante un valor representativo o típico. Su principal objetivo es describir el comportamiento general de una distribución y facilitar la comparación entre diferentes conjuntos de información.

En términos generales, una medida de tendencia central representa el punto alrededor del cual tienden a agruparse las observaciones. Estas medidas permiten sintetizar grandes volúmenes de datos en un único valor numérico que describe de manera aproximada el comportamiento de la variable analizada.

Con frecuencia, estas medidas son denominadas “promedios”; sin embargo, cada una posee características particulares y su uso depende de la naturaleza de los datos y del propósito del análisis.

Las tres medidas de tendencia central más utilizadas son:

- **Media aritmética:** representa el promedio de los valores observados.
- **Mediana:** corresponde al valor central de los datos ordenados.
- **Moda:** identifica el valor o categoría que aparece con mayor frecuencia.

La elección de la medida más adecuada depende del tipo de variable, la presencia de valores extremos y la forma de la distribución de los datos. Por ejemplo, la media suele verse afectada por valores atípicos, mientras que la mediana ofrece una medida más robusta en distribuciones asimétricas.

Estas medidas constituyen una base fundamental para el análisis estadístico descriptivo y son ampliamente utilizadas en áreas como la salud, educación, ingeniería, economía y ciencias sociales, ya que permiten resumir información y apoyar la toma de decisiones basada en datos.

En este capítulo se presentan las principales medidas de tendencia central y de dispersión, junto con su formulación matemática y su implementación en R.

14 5.1 Medidas de tendencia central

14.0.1 5.1.1 Media aritmética

La media aritmética es el promedio de los datos y se calcula como la suma de todas las observaciones dividida entre el número total de datos.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Donde: (x_i) : cada observación, (n) : número total de datos, $\bar{x}$: media aritmética

14.0.2 Cálculo en R

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 13
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>           <dbl>         <dbl>
1 D     A     M         177     73             49            19
2 D     A     M         177     86             45            19
3 D     A     F         160     52             37            16
4 D     A     F         159     53             38            16
5 D     A     F         174     78             41            18
6 D     B     M         186     68             44            19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>
```

```
str(datos)
```

```
tibble [260 x 13] (S3: tbl_df/tbl/data.frame)
 $ Clase           : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo           : chr [1:260] "A" "A" "A" "A" ...
 $ Genero          : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm       : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg         : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
 $ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
 $ Long_Mano_cm    : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
 $ Lon_Palma_cm    : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
 $ Ancho_Palma_cm  : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
 $ Long_Brazo_cm   : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
 $ Long_Muslo_cm   : num [1:260] 55 52 51 50 52 52 47 51 52 53 ...
 $ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
 $ Curso           : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
```

```
names(datos)
```

```
[1] "Clase"           "Grupo"           "Genero"
[4] "Altura_cm"       "Peso_Kg"         "Anchura_hombros_cm"
[7] "Long_Mano_cm"    "Lon_Palma_cm"    "Ancho_Palma_cm"
[10] "Long_Brazo_cm"   "Long_Muslo_cm"   "Long_Antebrazo_cm"
[13] "Curso"
```

```
mean(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 68.14808
```

14.0.3 5.1.2 Mediana

La mediana es el valor que divide el conjunto de datos ordenados en dos partes iguales, de modo que el 50% de las observaciones queda por debajo y el otro 50% por encima.

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, & n \text{ impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & n \text{ par} \end{cases}$$

La mediana es una medida robusta frente a valores extremos.

14.0.4 Cálculo en R

```
median(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 50
```

14.0.5 5.1.3 Moda

La moda es el valor que aparece con mayor frecuencia en el conjunto de datos.

$$\text{Moda} = \arg \max(f_i)$$

14.0.6 Cálculo en R

```
moda <- function(x) {  
  ux <- unique(x)  
  ux[which.max(tabulate(match(x, ux)))]  
}  
  
moda(datos$Peso_Kg)
```

```
[1] 40
```

14.1 Visualización de las medidas de tendencia central

```
library(readxl)  
library(ggplot2)  
  
# Cargar datos  
datos <- read_excel(  
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"  
)  
  
# Función para calcular la moda  
moda <- function(x) {
```

```

x <- na.omit(x)
ux <- unique(x)
ux[which.max(tabulate(match(x, ux)))]
}

# Medidas de tendencia central
media <- mean(datos$Peso_Kg, na.rm = TRUE)
mediana <- median(datos$Peso_Kg, na.rm = TRUE)
moda_val <- moda(datos$Peso_Kg)

# Histograma
ggplot(datos, aes(x = Peso_Kg)) +

  geom_histogram(
    bins = 10,
    fill = "skyblue",
    color = "black",
    alpha = 0.7
  ) +

  # Media
  geom_vline(
    xintercept = media,
    color = "red",
    linewidth = 1.2,
    linetype = "dashed"
  ) +

  # Mediana
  geom_vline(
    xintercept = mediana,
    color = "blue",
    linewidth = 1.2
  ) +

  # Moda
  geom_vline(
    xintercept = moda_val,
    color = "darkgreen",
    linewidth = 1.2,
    linetype = "dotdash"
  ) +


```

```

labs(
  title = "Distribución del peso",
  subtitle = "Media (rojo), Mediana (azul) y Moda (verde)",
  x = "Peso (kg)",
  y = "Frecuencia"
) +

theme_minimal()

```



14.2 Interpretación del gráfico: Distribución del peso

El histograma presenta la distribución de la variable **Peso (kg)** en la muestra analizada, incorporando las tres principales medidas de tendencia central:

□ **Media** (línea roja) □ **Mediana** (línea azul) □ **Moda** (línea verde)

14.2.1 Análisis estadístico

La media es mayor que la mediana y la moda

Se observa que: $Media > Mediana > Moda$. Esto indica una **asimetría positiva** o sesgo hacia la derecha.

Existencia de valores extremos

La presencia de individuos con pesos altos (aproximadamente entre 140 y 190 kg) desplaza la media hacia valores mayores. Estos datos atípicos afectan principalmente la media, mientras que la mediana permanece más estable.

Concentración principal de los datos

La mayor frecuencia de observaciones se concentra entre aproximadamente **35 y 65 kg**, lo que indica que la mayoría de los participantes presentan pesos dentro de ese intervalo.

Comportamiento de la moda

La moda se ubica en el intervalo de mayor frecuencia, representando el peso más común dentro de la muestra.

15 Ejercicio experiencial propuesto

15.1 Actividad: Explorando las características antropométricas

15.1.1 Objetivo

Analizar diferentes variables antropométricas mediante histogramas y medidas de tendencia central para identificar patrones de distribución, variabilidad y posibles valores atípicos.

Variable	Interpretación
Altura_cm	Distribución de estaturas
Anchura_hombros_cm	Variabilidad corporal
Long_Brazo_cm	Proporciones anatómicas
Long_Muslo_cm	Longitud del miembro inferior
Long_Antebrazo_cm	Variabilidad segmentaria

15.2 Actividad práctica

15.3 Parte 1. Construcción del gráfico

Construya un histograma para cada una de las siguientes variables:

- Altura_cm
- Anchura_hombros_cm
- Long_Brazo_cm

Incluya mediante líneas verticales de diferentes colores.

- Media, Mediana, Moda

15.4 Parte 2. Interpretación

Para cada gráfico responda:

1. ¿La distribución parece simétrica o asimétrica?
2. ¿Existen valores extremos?
3. ¿La media y la mediana son similares?
4. ¿Qué medida representa mejor el comportamiento de los datos?
5. ¿Cuál variable presenta mayor dispersión?

16 5.2 Medidas de dispersión o variabilidad

Las medidas de dispersión o variabilidad complementan a las medidas de tendencia central, ya que permiten describir qué tan agrupados o dispersos se encuentran los datos respecto a un valor representativo, como la media o la mediana.

Mientras que las medidas de tendencia central resumen la distribución mediante un único valor típico, las medidas de dispersión indican el grado de heterogeneidad presente en los datos. En consecuencia, dos conjuntos de datos pueden tener la misma media, pero comportamientos muy diferentes en cuanto a su variabilidad.

Por ejemplo, un grupo de observaciones puede presentar valores muy cercanos entre sí y concentrados alrededor de la media, mientras que otro grupo puede mostrar valores mucho más dispersos. Aunque ambos conjuntos tengan el mismo promedio, el segundo exhibirá mayor variabilidad.

La variabilidad constituye un aspecto fundamental en el análisis estadístico, ya que permite evaluar la estabilidad, consistencia y homogeneidad de los datos. En muchos contextos aplicados, comprender la dispersión resulta tan importante como conocer el promedio.

16.0.1 5.2.1 Rango

El rango es la diferencia entre el valor máximo y el mínimo.

$$R = X_{\max} - X_{\min}$$

16.0.2 Cálculo en R

```
max(datos$Peso_Kg, na.rm = TRUE) - min(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 153
```

16.0.3 5.2.2 Varianza muestral

La varianza mide la dispersión promedio de los datos respecto a la media.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

16.0.4 Cálculo en R

```
var(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 1815.201
```

16.0.5 Varianza poblacional

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

16.0.6 5.2.3 Desviación estándar muestral

La desviación estándar es la raíz cuadrada de la varianza y expresa la dispersión en las mismas unidades de los datos.

$$s = \sqrt{s^2}$$

16.0.7 Cálculo en R

```
sd(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 42.60518
```


16.0.8 Desviación estándar poblacional

$$\sigma = \sqrt{\sigma^2}$$

16.0.9 5.2.4 Coeficiente de variación

El coeficiente de variación permite comparar la dispersión relativa respecto a la media.

$$CV = \frac{s}{\bar{x}} \times 100$$

16.0.10 Cálculo en R

```
(sd(datos$Peso_Kg, na.rm = TRUE) / mean(datos$Peso_Kg, na.rm = TRUE)) * 100
```

```
[1] 62.51853
```

16.1 5.3 Resumen estadístico en R

R permite obtener múltiples medidas descriptivas de manera simultánea.

```
summary(datos$Peso_Kg)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
31.00	40.00	50.00	68.15	72.00	184.00

También es posible calcular varias medidas en conjunto:

```
library(summarytools)
```

Warning: package 'summarytools' was built under R version 4.5.3

```
descr(datos, stats=c("mean", "sd", "q1", "med", "q3", "min", "max", "cv"))
```

Non-numerical variable(s) ignored: Clase, Grupo, Genero, Curso

Descriptive Statistics

datos

N: 260

	Altura_cm	Ancho_Palma_cm	Anchura_hombros_cm	Lon_Palma_cm	Long_Antebr
Mean	69.47	8.07	53.83	9.46	
Std.Dev	76.49	1.31	15.08	1.37	
Q1	1.65	7.00	42.00	9.00	
Median	1.85	8.00	49.00	10.00	
Q3	162.00	9.00	63.00	10.00	
Min	1.50	5.00	36.00	6.00	
Max	192.00	13.50	130.00	12.00	
CV	1.10	0.16	0.28	0.14	

Table: Table continues below

	Long_Brazo_cm	Long_Mano_cm	Long_Muslo_cm	Peso_Kg
Mean	68.01	17.56	51.11	68.15
Std.Dev	12.16	4.38	4.85	42.61
Q1	66.00	16.10	48.00	40.00
Median	71.00	17.00	51.00	50.00
Q3	75.00	18.30	54.00	72.00
Min	17.00	7.00	38.00	31.00
Max	84.00	83.00	73.00	184.00
CV	0.18	0.25	0.09	0.63

16.2 Histograma + desviación estándar

```
media <- mean(datos$Peso_Kg, na.rm = TRUE)
desv <- sd(datos$Peso_Kg, na.rm = TRUE)

ggplot(datos, aes(x = Peso_Kg)) +

  geom_histogram(
    bins = 10,
    fill = "skyblue",
```

```

    color = "black"
  ) +

  # Media
  geom_vline(
    xintercept = media,
    color = "red",
    linewidth = 1.2
  ) +


  #  $\pm 1$  desviación estándar
  geom_vline(
    xintercept = media + desv,
    color = "darkgreen",
    linetype = "dashed",
    linewidth = 1
  ) +

  geom_vline(
    xintercept = media - desv,
    color = "darkgreen",
    linetype = "dashed",
    linewidth = 1
  ) +

  labs(
    title = "Distribución del peso y desviación estándar",
    subtitle = "Línea roja = media | Líneas verdes =  $\pm 1$  desviación estándar",
    x = "Peso (kg)",
    y = "Frecuencia"
  ) +

  theme_minimal()

```



16.2.1 Interpretación

El histograma del peso complementado con la media y la desviación estándar permite analizar tanto la tendencia central como la variabilidad de los datos. La línea roja representa la media del peso de los participantes, mientras que las líneas verdes discontinuas indican un intervalo aproximado de una desviación estándar por encima y por debajo de la media. Este intervalo permite identificar el rango donde se concentra gran parte de las observaciones.

En la distribución analizada se observa que la mayoría de los individuos presentan pesos cercanos a la media, concentrándose principalmente dentro del intervalo delimitado por las líneas de desviación estándar. Sin embargo, también se identifican algunos valores alejados del centro de la distribución, lo que sugiere la presencia de posibles valores atípicos o una dispersión considerable en ciertos casos. Desde el punto de vista estadístico, una desviación estándar pequeña indica que los datos son más homogéneos y se agrupan cerca de la media; por el contrario, una desviación estándar grande refleja una mayor heterogeneidad y dispersión de los datos.


16.3 Comparar dispersión entre géneros

```
ggplot(datos, aes(x = Peso_Kg)) +
```

```
geom_density(
  fill = "lightgreen",
  alpha = 0.5
) +

labs(
  title = "Densidad del peso",
  subtitle = "Visualización de la dispersión de los datos",
  x = "Peso (kg)",
  y = "Densidad"
) +

theme_classic()
```



16.3.1 Interpretación

La curva de densidad representa una versión suavizada de la distribución de los datos y permite visualizar la concentración de observaciones a lo largo de los valores de la variable peso.


Las zonas más altas de la curva indican intervalos donde existe una mayor concentración de individuos, mientras que las áreas más bajas representan valores menos frecuentes. La forma de la curva

permite evaluar características importantes de la distribución, tales como: simetría; presencia de sesgo; concentración de datos; posibles agrupamientos y dispersión general.

Si la curva presenta una forma aproximadamente simétrica, puede inferirse que los datos tienden a distribuirse de manera equilibrada alrededor de la media. En cambio, una cola más larga hacia alguno de los extremos indica asimetría o sesgo en la distribución.

Asimismo, una curva más ancha y extendida refleja mayor dispersión de los datos, mientras que una curva más estrecha indica mayor homogeneidad. La curva de densidad constituye una herramienta útil para comprender visualmente la estructura de la distribución y complementar el análisis realizado mediante histogramas y medidas descriptivas.

```
ggplot(datos, aes(x = Genero, y = Peso_Kg, fill = Genero)) +  
  
  geom_violin(alpha = 0.7) +  
  
  geom_boxplot(  
    width = 0.1,  
    fill = "white"  
  ) +  
  
  labs(  
    title = "Distribución y dispersión del peso",  
    x = "Género",  
    y = "Peso (kg)"  
  ) +  
  
  theme_minimal()
```



16.3.2 Interpretación

El boxplot comparativo del peso según género permite evaluar diferencias en la tendencia central y la dispersión entre los grupos analizados. Cada caja representa el rango intercuartílico de los datos, es decir, el intervalo donde se concentra el 50 % central de las observaciones. La línea ubicada dentro de la caja corresponde a la mediana, mientras que los puntos alejados representan posibles valores atípicos.

A partir de la gráfica es posible identificar: diferencias en la mediana del peso entre géneros; variaciones en la amplitud de las cajas, asociadas al grado de dispersión; presencia de valores extremos; diferencias en la homogeneidad de los grupos.

Un grupo con cajas más amplias y bigotes más extensos presenta mayor variabilidad, indicando que los valores se encuentran más dispersos. Por el contrario, cajas más compactas sugieren una distribución más homogénea. Este tipo de análisis resulta especialmente útil para comparar poblaciones y explorar patrones de comportamiento de variables antropométricas en distintos grupos.

16.4 Resumen gráfico

Las medidas de tendencia central y dispersión son esenciales para describir un conjunto de datos. Su correcta interpretación permite comprender la estructura de la información, identificar patrones y apoyar la toma de decisiones basada en evidencia. En R, estas medidas pueden calcularse de forma sencilla, lo que facilita su aplicación en análisis estadísticos tanto exploratorios como inferenciales.

MEDIDAS DE TENDENCIA CENTRAL

Y FORMA DE LA DISTRIBUCIÓN DE LOS DATOS




Figura 16.1: Fuente: Autores

17 Parte I. Fundamentos

17.0.1 Capítulo 6. Medidas de posición

- Cuartiles
- Deciles
- Percentiles

18 Parte I. Fundamentos

18.0.1 Capítulo 7. Medidas de dispersión

-
- Rango
-
- Varianza
-
- Desviación estándar
-
- Coeficiente de variación
- ☐ Caso real
- ☐ Código en R
- ☐ Resultado
- ☐ Interpretación
- ☐ Error común
- Introducción
- Concepto
- Fórmula
- Ejemplo manual
- Ejemplo en R
- Interpretación
- Ejercicio aplicado
- Cierre

19 Parte I. Fundamentos

Parte IV

Parte IV. Relaciones entre variables

20 Parte IV. Relaciones entre variables

20.0.1 Capítulo 9. Análisis bivariado

- Tablas cruzadas
- Covarianza
- Correlación

21 Parte I. Fundamentos

21.0.1 Capítulo 9. Asociación e interpretación

- Relación entre variables
- Ejemplos con datos reales
- Interpretación práctica

Parte V

Parte V. Puente a la inferencia

22 Parte V. Puente a la inferencia

22.0.1 Capítulo 10. Introducción a la inferencia (opcional pero recomendado)

-
- Hipótesis
-
- p-valor
-
- significancia estadística
-
- chi-cuadrado básico

Parte VI

Parte VI. Aplicación y divulgación

23 Parte I. Fundamentos

References

- Agresti, A. (2018). *Statistical methods for the social sciences* (5th ed.). Pearson.
- Armitage, P., Berry, G., & Matthews, J. N. S. (2002). *Statistical methods in medical research*. Blackwell Science.
- Bonita, R., Beaglehole, R., & Kjellström, T. (2008). *Epidemiología básica*. Organización Panamericana de la Salud.
- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate data analysis* (8th ed.). Cengage Learning.
- Kleinbaum, D. G. et al. (1982). *Epidemiologic research: Principles and quantitative methods*. Wadsworth.
- Kleinbaum, D. G., & Klein, M. (2012). *Survival analysis: A self-learning text* (3rd ed.). Springer.
- Knuth, D. E. (1984). *The TeXbook*. Addison-Wesley.
- Obando, L. (2021). *Gráficos estadísticos y análisis de datos con r*. Editorial Académica.
- Posada, C. (2016). *Elementos de estadística*. Editorial Académica.
- Rey, J. (2007). *Introducción a la estadística*. Editorial Universitaria.
- Seoane, T. et al. (2007). *Estadística aplicada*. Editorial Académica.
- Spiegel, M. R., & Stephens, L. J. (2009). *Estadística*. McGraw-Hill.
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.
- Van den Broeck, J., Cunningham, S. A., Eeckels, R., & Herbst, K. (2005). Data cleaning: Detecting, diagnosing, and editing data abnormalities. *PLoS Medicine*, 2(10), e267. <https://doi.org/10.1371/journal.pmed.0020267>
- Wickham, H., & Grolemund, G. (2017). *R for data science: Import, tidy, transform, visualize, and model data*. O'Reilly Media.
- Wooldridge, J. M. (2016). *Introductory econometrics: A modern approach* (6th ed.). Cengage Learning.