

Estadística Experiencial Aplicada

Aprendizaje práctico de la estadística descriptiva con R

Francisco Javier León Miguel Oswaldo Pérez Pulido
Leonardo Andrés Pinto Guarguati

2026-03-24

Table of contents

Preface	5
1 Introducción	6
2 Autores	7
2.1 Francisco Javier León	7
2.2 Miguel Oswaldo Pérez Pulido	7
2.3 Leonardo Andrés Pinto Guarguati	8
3 Introducción a la estadística descriptiva	9
3.1 Introducción	9
3.2 ¿Qué es la estadística descriptiva?	9
3.3 Tipos de variables	9
3.3.1 Importancia de la identificación de variables estadísticas y escalas de medición	10
3.3.2 Ver diccionario de variables en sitio web del DANE Diccionario_S07D_Acuicultura	15
3.4 Actividad experiencial: Explorando una base de datos del DANE	16
3.4.1 Identificación y clasificación de variables estadísticas utilizando datos reales de acuicultura del DANE	16
3.5 Contexto de la actividad	16
4 Desarrollo de la actividad	17
4.1 Parte 1. Exploración de la base de datos	17
4.1.1 Instrucciones	17
4.2 Parte 2. Completar la tabla de clasificación	18
4.2.1 Instrucciones para el estudiante	18
4.3 Parte 3. Interpretación estadística	19
5 Preparación de datos	21
5.1 Carga de datos en R	21
5.2 Limpieza de datos	21
6 Organización de datos y tablas estadísticas	23
7 Tablas de datos	24
7.1 Datos simples	24
7.2 Datos agrupados	24
7.3 Tablas de frecuencia	25
7.3.1 Frecuencia absoluta	25
7.3.2 Frecuencia relativa	25
7.3.3 Frecuencia acumulada	25
7.3.4 Frecuencia relativa acumulada	26
7.4 Ejemplo de tabla de frecuencia: Variable P_S7P97	26

7.5	Estructura general de una tabla de frecuencia	27
7.6	Marca de clase	28
8	Organización de datos en contextos reales	30
8.1	Actividad Experiencial	30
8.1.1	Situación problema	30
8.1.2	Ejemplo: Género	31
8.1.3	Ejemplo: Peso corporal	33
9	Actividad experiencial: Organización de datos y tablas estadísticas	35
10	Objetivos de aprendizaje	36
11	Desarrollo de la actividad	37
11.0.1	Parte 1. Exploración inicial de los datos	37
11.0.2	Parte 2. Identificación de variables	38
11.0.3	Parte 3. Organización y análisis del peso corporal	38
11.0.4	Situación problema	38
11.0.5	Parte 4. Preguntas orientadoras	38
11.0.6	Parte 5. Construcción de tablas agrupadas	39
11.0.7	Parte 6. Visualización gráfica	39
11.0.8	Recomendación metodológica	39
11.0.9	Reflexión final	39
12	Visualización de datos	40
12.1	Gráficos en R	40
12.2	Gráfico de sectores	41
12.3	Gráfico de barras	42
12.4	Histograma	45
12.4.1	Ejemplo con funciones básicas de R	45
12.5	Boxplot	46
12.5.1	Ejemplo con funciones básicas de R	47
12.5.2	Ejemplo peso y género con ggplot2	48
12.6	Interpretación básica de los gráficos	50
13	Medidas de tendencia central y dispersión	51
14	Medidas de tendencia central	52
14.0.1	Media aritmética	52
14.0.2	Cálculo en R	52
14.0.3	Mediana	53
14.0.4	Cálculo en R	53
14.0.5	Moda	53
14.0.6	Cálculo en R	53
14.1	Visualización de las medidas de tendencia central	54
14.2	Interpretación del gráfico: Distribución del peso	55
14.2.1	Análisis estadístico	55
15	Ejercicio experiencial propuesto	57
15.1	Actividad: Explorando las características antropométricas	57
15.1.1	Objetivo	57
15.2	Actividad práctica	57
15.3	Parte 1. Construcción del gráfico	57
15.4	Parte 2. Interpretación	57

16 Medidas de dispersión o variabilidad	59
16.0.1 Rango	59
16.0.2 Cálculo en R	59
16.0.3 Varianza muestral	59
16.0.4 Cálculo en R	59
16.0.5 Varianza poblacional	60
16.0.6 Desviación estándar muestral	60
16.0.7 Cálculo en R	60
16.0.8 Desviación estándar poblacional	60
16.0.9 Coeficiente de variación	60
16.0.10 Cálculo en R	60
16.1 Resumen estadístico en R	60
16.2 Histograma + desviación estándar	61
16.2.1 Interpretación	62
16.3 Comparar dispersión entre géneros	63
16.3.1 Interpretación	63
16.3.2 Interpretación	64
16.4 Resumen gráfico	65
17 Medidas de posición y forma	66
18 Medidas de posición	67
18.1 Clasificación de las medidas de posición	67
19 Cuartiles	68
19.1 Fórmula de posición	68
20 Deciles	70
20.1 Fórmula de posición	70
20.2 Aplicaciones de los deciles	70
21 Percentiles	71
21.1 Fórmula de posición	71
21.2 Aplicaciones de los percentiles	71
22 Medidas de forma	73
22.1 Asimetría	73
22.2 Curtosis	73
23 Análisis bivariado	75
24 Código en R	77
25 Diagrama de dispersión: horas de estudio vs. calificación	78
26 Código en R	79
27 Covarianza entre horas de estudio y calificación	80
28 Código en R	82
29 Correlación de Pearson y matriz de correlaciones	83
30 Pearson entre horas y calificación	84
31 Matriz de correlaciones para las tres variables numéricas	85

32 Código en R	87
33 Correlación de Spearman	88
34 Prueba de significancia	89
35 Código en R	91
36 Tabla de contingencia en R	92
37 Prueba chi-cuadrado de independencia	93
38 Código en R	94
39 Regresión lineal simple: calificación ~ horas de estudio	95
40 Gráfico de regresión con intervalo de confianza	96
41 Predicción para un estudiante que estudia 6 horas	97
References	99

Preface

La estadística constituye una herramienta fundamental para comprender, interpretar y transformar la realidad a partir de los datos. En un contexto caracterizado por el crecimiento exponencial de la información, el análisis estadístico se ha consolidado como una competencia esencial en múltiples disciplinas, especialmente en escenarios académicos, científicos, sociales y organizacionales.

Este libro surge como una propuesta orientada al aprendizaje experiencial de la estadística descriptiva mediante el uso del lenguaje R y el entorno de publicación científica Quarto. Su propósito principal es acercar al estudiante a situaciones reales de análisis de datos, promoviendo no solo el cálculo de medidas estadísticas, sino también la interpretación crítica de la información y la toma de decisiones basadas en evidencia.

A lo largo de los capítulos se integran ejemplos aplicados, visualizaciones estadísticas, actividades experienciales y bases de datos reales provenientes de contextos académicos y oficiales, permitiendo que el lector comprenda cómo la estadística trasciende los ejercicios mecánicos y se convierte en una herramienta para explorar fenómenos del mundo real.

El uso de R permite desarrollar habilidades contemporáneas asociadas al análisis reproducible, la programación estadística y la ciencia de datos, fortaleciendo competencias analíticas cada vez más demandadas en la educación superior y en el ámbito profesional.

Chapter 1

Introducción

La estadística descriptiva representa el punto de partida para el análisis de datos. A través de técnicas de organización, resumen y visualización, es posible transformar grandes volúmenes de información en conocimiento útil para comprender fenómenos, identificar patrones y apoyar procesos de investigación y toma de decisiones.

Este libro ha sido diseñado bajo un enfoque práctico y aplicado, integrando herramientas computacionales modernas mediante el lenguaje R, uno de los entornos más utilizados en estadística, ciencia de datos e investigación científica a nivel mundial.

Cada capítulo combina fundamentos conceptuales con ejercicios desarrollados sobre bases de datos reales, favoreciendo un aprendizaje activo y experiencial. El lector encontrará actividades orientadas a:

organizar datos, construir tablas de frecuencia, interpretar gráficos estadísticos, analizar medidas descriptivas, identificar patrones y valores atípicos, y comunicar resultados mediante visualizaciones claras y reproducibles.

Además de fortalecer las competencias estadísticas básicas, este texto busca fomentar el pensamiento crítico frente a los datos y promover una cultura de análisis basada en evidencia.

Chapter 2

Autores



Tip



2.1 Francisco Javier León

Bacteriólogo y laboratorista clínico, con formación avanzada como magíster en estadística aplicada, Magíster en ciencias básicas biomédicas y especialista en educación con nuevas tecnologías. Está vinculado a la Universidad de Santander (UDES) desde 2007, donde ha sido docente en la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Actualmente, se desempeña como Coordinador de Analítica Académica, adscrito a la Vicerrectoría de Enseñanza. Es investigador júnior reconocido por MinCiencias en la convocatoria 957 de 2024 y miembro del grupo de investigación CIBAS.



Tip



2.2 Miguel Oswaldo Pérez Pulido

Licenciado en matemáticas y magíster en estadística. Actualmente se desempeña como Director de Analítica Académica, adscrito a la Vicerrectoría de Enseñanza. Está vinculado a la Universidad de Santander (UDES) desde 2011, donde ha sido docente en programas de pregrado y posgrado de la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Es investigador asociado reconocido por MinCiencias en la convocatoria 957 de

2024 y miembro del grupo de investigación CIBAS.

Tip



2.3 Leonardo Andrés Pinto Guarguati

Economista de la Universidad Santo Tomás de Bucaramanga, especialista en Evaluación y Gerencia de Proyectos de la Universidad Industrial de Santander y estudiante de la Maestría en Evaluación y Gerencia de Proyectos de la misma. Con experiencia en docencia universitaria, análisis de mercados y coordinación de proyectos de Ciencia, Tecnología e innovación CTel.

Chapter 3

Introducción a la estadística descriptiva

3.1 Introducción

Actualmente los datos se han convertido en un activo fundamental para la toma de decisiones en las empresas, la sociedad, la académica entre otros y es por eso que la **estadística descriptiva constituye el primer paso para transformar información en conocimiento útil** (Seoane et al., 2007). Su aplicación permite un mejor entendimiento del mundo que nos rodea, ya que prácticamente cada aspecto de nuestra existencia es una fuente potencial de datos (Obando, 2021). Este capítulo introduce los conceptos básicos necesarios para comprender, organizar y analizar datos, utilizando un enfoque experiencial basado en ejemplos reales y herramientas computacionales como R.

3.2 ¿Qué es la estadística descriptiva?

La **estadística descriptiva** es la rama de la estadística encargada de recolectar, organizar, resumir y presentar datos de manera clara y comprensible .

A diferencia de la estadística inferencial, que busca demostrar asociaciones o hacer comparaciones para extrapolar resultados de una muestra a una población, la descriptiva se limita a **sintetizar la información contenida en los datos recogidos** sin realizar inferencias más allá de la información disponible (Bonita et al., 2008; Posada, 2016).

Su propósito fundamental es facilitar la comprensión de grandes volúmenes de información mediante el uso de **tablas, representaciones gráficas y medidas resumen** (como la media o la desviación estándar), permitiendo “hacerse una idea” de la naturaleza de un conjunto de datos sin tener que analizar cada uno de ellos individualmente (Posada, 2016; Rey, 2007; Spiegel & Stephens, 2009).

3.3 Tipos de variables

Las variables constituyen las características, cualidades o atributos que pueden observarse, clasificarse o medirse en los individuos, objetos o fenómenos de una población o muestra.

Su identificación es fundamental en estadística, ya que permiten describir, analizar e interpretar la información recolectada. Como se observa en la figura, las variables se clasifican en cualitativas y cuantitativas.

Las variables cualitativas describen categorías o atributos y pueden ser nominales u ordinales, mientras que las variables cuantitativas representan cantidades numéricas y se dividen en discretas y continuas según provengan de procesos de conteo o medición. Esta clasificación es esencial porque determina el tipo de análisis estadístico, representación gráfica y medidas descriptivas que pueden aplicarse a los datos.




Figure 3.1: La figura es una adaptación gráfica realizada por los autores en Napkin a partir del esquema presentado por Derek Rowntree (1981) en *Statistics Without Tears*. La modificación respeta los criterios de uso justo para fines académicos.

3.3.1 Importancia de la identificación de variables estadísticas y escalas de medición

La clasificación de las variables constituye un aspecto esencial en el análisis estadístico, ya que de ella depende la selección de los métodos, procedimientos y representaciones gráficas más adecuados para el tratamiento de los datos. Como se muestra en la figura, las variables cualitativas describen atributos o categorías y suelen analizarse mediante frecuencias, porcentajes y medidas como la moda o la mediana en el caso de variables ordinales.

Por su parte, las variables cuantitativas representan cantidades numéricas derivadas de procesos de conteo o medición, lo que permite aplicar medidas de tendencia central y dispersión, tales como la media, la varianza, la desviación estándar y el coeficiente de variación. En este sentido, identificar correctamente el tipo de variable facilita una interpretación adecuada de la información y garantiza la aplicación de técnicas estadísticas coherentes con la naturaleza de los datos (Armitage et al., 2002).

1. VARIABLES ESTADÍSTICAS

Son características que pueden observarse o medirse en individuos, objetos o fenómenos.



Fuente: Adaptado de Armitage, P. (2002). Statistical methods in medical research; Kleinbaum, D. G., et al. (1982). Epidemiologic research: Principles and quantitative methods; y lineamientos de bioestadística aplicada.

Figure 3.2: Fuente: autores

Las **escalas de medición** representan el nivel de información que poseen los datos y constituyen un elemento fundamental en estadística, ya que determinan las operaciones matemáticas y los análisis que pueden realizarse sobre las variables.

Como se observa en la figura, las escalas nominal y ordinal se emplean principalmente en variables cualitativas, mientras que las escalas de intervalo y razón se asocian con variables cuantitativas. A medida que aumenta el nivel de medición, también incrementa la precisión estadística y la complejidad de los métodos analíticos que pueden aplicarse. Por ello, la correcta identificación de la escala permite seleccionar adecuadamente medidas descriptivas, pruebas es-

tadísticas y representaciones gráficas acordes con la naturaleza de los datos.




Figure 3.3: Fuente: autores

Las escalas de medición permiten clasificar las variables según el tipo de información que proporcionan. La escala nominal organiza datos en categorías sin orden, por lo que suele analizarse mediante frecuencias y porcentajes. La escala ordinal incorpora jerarquía entre categorías, permitiendo el uso de medidas como mediana, rangos y percentiles. Por su parte, la escala de intervalo presenta distancias iguales entre valores, aunque sin un cero absoluto, lo que posibilita análisis como correlaciones y desviaciones estándar. Finalmente, la escala de razón posee todas las propiedades anteriores y un cero real, permitiendo realizar operaciones matemáticas completas y análisis estadísticos más avanzados.

La figura resume las principales características, ejemplos, medidas estadísticas y representaciones gráficas asociadas a cada escala.

La selección de las técnicas estadísticas depende directamente de la escala de medición de las variables. Como se presenta en la figura, las variables medidas en escala nominal suelen representarse mediante gráficos de barras o pastel y analizarse con frecuencias y moda.

Las escalas ordinales permiten incorporar análisis basados en orden y posición, como percentiles o cuartiles. En contraste, las escalas de intervalo y razón posibilitan el cálculo de medidas paramétricas como media, varianza, desviación estándar y análisis de regresión. En consecuencia, conocer la escala de medición garantiza la aplicación de procedimientos estadísticos válidos y una interpretación adecuada de los resultados obtenidos.

La estadística descriptiva permite transformar datos brutos en información significativa mediante el uso de tablas, representaciones gráficas y medidas resumen. Este proceso facilita la organización, interpretación y comprensión de los fenómenos analizados, constituyéndose en una herramienta fundamental para la toma de decisiones basadas en evidencia. Asimismo, la correcta identificación del tipo de variable y de la escala de medición resulta esencial para seleccionar las técnicas estadísticas apropiadas. Un error frecuente consiste en analizar variables ordinales como si fueran cuantitativas continuas o asumir que los datos siguen distribuciones normales sin verificar los supuestos requeridos, lo cual puede afectar la validez de los resultados y conducir a interpretaciones erróneas.

```
#| message: false
#| warning: false

library(readr)
library(dplyr)
```

Adjuntando el paquete: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
# Cargar base de datos de Acuicultura
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv")
```

New names:

* `` -> `...1`

Rows: 3447 Columns: 14

-- Column specification -----

Delimiter: ","

chr (2): UC_UO, ENCUESTA

dbl (12): ...1, TIPO_REG, PAIS, P_DEPTO, P_MUNIC, COD_VEREDA, P_S7PNUMPEZ, P...

i Use `spec()` to retrieve the full column specification for this data.

i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
#acuicultura <- read_csv("D:/estadistica-experiencial/data/S07D_Acuicultura.csv")
```

```
# Visualizar primeras filas
```

```
head(acuicultura)
```

```
# A tibble: 6 x 14
```

```

...1 TIPO_REG PAIS P_DEPTO P_MUNIC UC_UO ENCUESTA COD_VEREDA P_S7PNUMPEZ
<dbl> <dbl> <dbl> <dbl> <dbl> <chr> <chr> <dbl> <dbl>
1 1 7 170 68 68001 00310001 022537951 68001007 1
2 2 7 170 68 68001 00420001 022303666 68001009 1
3 3 7 170 68 68001 00690001 022317829 68001027 2
4 4 7 170 68 68001 00900001 022318620 68001002 1
5 5 7 170 68 68001 00920001 022736078 68001009 1
6 6 7 170 68 68001 00970001 022317801 68001024 1
# i 5 more variables: P_S7P96 <dbl>, P_S7P97 <dbl>, P_S7P98 <dbl>,
# P_S7P99 <dbl>, P_S7P100 <dbl>

```

```

# Mostrar nombres de variables
names(acuicultura)

```

```

[1] "...1"      "TIPO_REG"   "PAIS"       "P_DEPTO"    "P_MUNIC"
[6] "UC_UO"     "ENCUESTA"   "COD_VEREDA" "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97"   "P_S7P98"    "P_S7P99"    "P_S7P100"

```

```

# Explorar estructura de la base
glimpse(acuicultura)

```

```

Rows: 3,447
Columns: 14
$ ...1      <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17,~
$ TIPO_REG  <dbl> 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7~
$ PAIS      <dbl> 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170~
$ P_DEPTO   <dbl> 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68~
$ P_MUNIC   <dbl> 68001, 68001, 68001, 68001, 68001, 68001, 68001, 68001, 68~
$ UC_UO     <chr> "00310001", "00420001", "00690001", "00900001", "00920001"~
$ ENCUESTA  <chr> "022537951", "022303666", "022317829", "022318620", "02273~
$ COD_VEREDA <dbl> 68001007, 68001009, 68001027, 68001002, 68001009, 68001024~
$ P_S7PNUMPEZ <dbl> 1, 1, 2, 1, 1, 1, 1, 2, 1, 18, 18, 18, 1, 1, 2, 18, 18, 1,~
$ P_S7P96    <dbl> 41190400, 41190300, 41191000, 41190400, 41190300, 41190400~
$ P_S7P97    <dbl> 1, 0, 1, 1, 1, 1, 1, 6, 0, 0, 1, 1, 3, 1, 1, 1, 1, 1, 1~
$ P_S7P98    <dbl> 50, 0, 300, 50, 200, 50, 30, 80, 0, 0, 30, 500, 100, 200, ~
$ P_S7P99    <dbl> 5.00, 0.00, 5.00, 5.00, 4.00, 3.75, 5.00, 5.00, 0.00, 0.00~
$ P_S7P100   <dbl> 0.2500, 0.0000, 1.5000, 0.2500, 0.8000, 0.1875, 0.1500, 2.~

```

```

# Ver la base completa en RStudio
View(acuicultura)

```

```

library(readr)
library(dplyr)
library(janitor)

```

```

# Cargar base
acuicultura <- read_csv("data/S07D_Acuicultura.csv")

```

```

# Ver nombres de variables
names(acuicultura)

```

```

[1] "...1"      "TIPO_REG"   "PAIS"       "P_DEPTO"    "P_MUNIC"
[6] "UC_UO"     "ENCUESTA"   "COD_VEREDA" "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97"   "P_S7P98"    "P_S7P99"    "P_S7P100"

```

```

# Crear estructura inicial del diccionario
diccionario <- tibble(

```

```

variable = names(acuicultura),
tipo_dato = sapply(acuicultura, class),
valores_unicos = sapply(acuicultura, n_distinct),
missing = sapply(acuicultura, function(x) sum(is.na(x)))
)

```

```

# Ver diccionario
diccionario

```

```

# A tibble: 14 x 4
  variable      tipo_dato valores_unicos missing
  <chr>         <chr>          <int>    <int>
1 ...1         numeric          3447      0
2 TIPO_REG     numeric           1         0
3 PAIS         numeric           1         0
4 P_DEPTO      numeric           1         0
5 P_MUNIC      numeric           84         0
6 UC_UO        character         662         0
7 ENCUESTA     character        2590         0
8 COD_VEREDA   numeric           870         0
9 P_S7PNUMPEZ  numeric           11          4
10 P_S7P96     numeric           27          4
11 P_S7P97     numeric           13          0
12 P_S7P98     numeric          125          0
13 P_S7P99     numeric          113          0
14 P_S7P100    numeric           370          0

```

3.3.2 Ver diccionario de variables en sitio web del DANE [Diccionario_S07D_Acuicultura](#)

Para exportar el diccionario

```
library(writexl)
```

Warning: package 'writexl' was built under R version 4.5.3

```

write_xlsx(diccionario,
           "data/diccionario_acuicultura.xlsx")

```

Esta instrucción permite ver el libro en quarto.

```

library(gt)

diccionario_acuicultura <- tibble(
  variable = c(
    "TIPO_REG", "PAIS", "P_DEPTO", "P_MUNIC", "UC_UO",
    "ENCUESTA", "COD_VEREDA", "P_S7PNUMPEZ", "P_S7P96",
    "P_S7P97", "P_S7P98", "P_S7P99", "P_S7P100"
  ),
  descripcion = c(
    "Tipo de región",
    "País",
    "Departamento",
    "Municipio",
    "Unidad de cobertura y unidad de observación",
    "Encuesta",
    "Código de vereda",

```

variable	descripcion
TIPO_REG	Tipo de región
PAIS	País
P_DEPTO	Departamento
P_MUNIC	Municipio
UC_UO	Unidad de cobertura y unidad de observación
ENCUESTA	Encuesta
COD_VEREDA	Código de vereda
P_S7PNUMPEZ	Orden de pez
P_S7P96	Nombre de la especie cultivada
P_S7P97	Número de cosechas en el año
P_S7P98	Número de animales por cosecha
P_S7P99	Peso promedio por animal en gramos
P_S7P100	Producción total durante 2013 en kilogramos

```

    "Orden de pez",
    "Nombre de la especie cultivada",
    "Número de cosechas en el año",
    "Número de animales por cosecha",
    "Peso promedio por animal en gramos",
    "Producción total durante 2013 en kilogramos"
  )
)

diccionario_acuicultura |>
  gt()

```

3.4 Actividad experiencial: Explorando una base de datos del DANE

3.4.1 Identificación y clasificación de variables estadísticas utilizando datos reales de acuicultura del DANE

Reconocer y clasificar variables estadísticas presentes en una base de datos del DANE, identificando su naturaleza, escala de medición y posibles análisis estadísticos asociados.

3.5 Contexto de la actividad

En estadística aplicada, antes de realizar cualquier análisis es fundamental comprender las características de las variables contenidas en una base de datos. Para ello, se utilizará una base oficial del Departamento Administrativo Nacional de Estadística (DANE) correspondiente al módulo de acuicultura.

Los estudiantes actuarán como analistas de datos, explorando información real utilizada en estudios productivos y socioeconómicos.

Fuente oficial:

[DANE – Diccionario S07D Acuicultura](#)

Chapter 4

Desarrollo de la actividad

4.1 Parte 1. Exploración de la base de datos

4.1.1 Instrucciones

1. Cargar la base de datos en R.
2. Revisar los nombres de las variables.
3. Consultar el diccionario oficial del DANE.
4. Identificar:
 - significado de cada variable,
 - tipo de variable,
 - escala de medición,
 - unidad de medida,
 - posible representación gráfica,
 - medidas estadísticas aplicables.

```
library(readr)
library(dplyr)

# Cargar base de datos
acuicultura <- read_csv(
  "data/S07D_Acuicultura.csv"
)
```

New names:

Rows: 3447 Columns: 14

-- Column specification

----- Delimiter: "," chr

(2): UC_U0, ENCUESTA dbl (12): ...1, TIPO_REG, PAIS, P_DEPTO, P_MUNIC,
COD_VEREDA, P_S7PNUMPEZ, P...

i Use `spec()` to retrieve the full column specification for this data. i

Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

```
* `` -> `...1`
```

```
# Explorar estructura
names(acuicultura)
```

```
[1] "...1"      "TIPO_REG"    "PAIS"        "P_DEPTO"     "P_MUNIC"
[6] "UC_UO"      "ENCUESTA"    "COD_VEREDA"  "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97"    "P_S7P98"     "P_S7P99"     "P_S7P100"
```

```
glimpse(acuicultura)
```

```
Rows: 3,447
```

```
Columns: 14
```

```
$ ...1      <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17,~
$ TIPO_REG  <dbl> 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7~
$ PAIS      <dbl> 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170, 170~
$ P_DEPTO   <dbl> 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68, 68~
$ P_MUNIC   <dbl> 68001, 68001, 68001, 68001, 68001, 68001, 68001, 68001, 68001, 68~
$ UC_UO     <chr> "00310001", "00420001", "00690001", "00900001", "00920001"~
$ ENCUESTA  <chr> "022537951", "022303666", "022317829", "022318620", "02273~
$ COD_VEREDA <dbl> 68001007, 68001009, 68001027, 68001002, 68001009, 68001024~
$ P_S7PNUMPEZ <dbl> 1, 1, 2, 1, 1, 1, 1, 2, 1, 18, 18, 18, 1, 1, 2, 18, 18, 1,~
$ P_S7P96    <dbl> 41190400, 41190300, 41191000, 41190400, 41190300, 41190400~
$ P_S7P97    <dbl> 1, 0, 1, 1, 1, 1, 1, 6, 0, 0, 1, 1, 3, 1, 1, 1, 1, 1, 1~
$ P_S7P98    <dbl> 50, 0, 300, 50, 200, 50, 30, 80, 0, 0, 30, 500, 100, 200, ~
$ P_S7P99    <dbl> 5.00, 0.00, 5.00, 5.00, 4.00, 3.75, 5.00, 5.00, 0.00, 0.00~
$ P_S7P100   <dbl> 0.2500, 0.0000, 1.5000, 0.2500, 0.8000, 0.1875, 0.1500, 2.~
```

```
head(acuicultura)
```

```
# A tibble: 6 x 14
```

```
...1 TIPO_REG PAIS P_DEPTO P_MUNIC UC_UO ENCUESTA COD_VEREDA P_S7PNUMPEZ
<dbl> <dbl> <dbl> <dbl> <dbl> <chr> <chr> <dbl> <dbl>
1 1 7 170 68 68001 00310001 022537951 68001007 1
2 2 7 170 68 68001 00420001 022303666 68001009 1
3 3 7 170 68 68001 00690001 022317829 68001027 2
4 4 7 170 68 68001 00900001 022318620 68001002 1
5 5 7 170 68 68001 00920001 022736078 68001009 1
6 6 7 170 68 68001 00970001 022317801 68001024 1
```

```
# i 5 more variables: P_S7P96 <dbl>, P_S7P97 <dbl>, P_S7P98 <dbl>,
```

```
# P_S7P99 <dbl>, P_S7P100 <dbl>
```

4.2 Parte 2. Completar la tabla de clasificación

4.2.1 Instrucciones para el estudiante

Complete la siguiente tabla utilizando:

- la exploración en R,
- el diccionario del DANE,
- los conceptos vistos en clase sobre variables y escalas de medición.

Variable	Descripción	Tipo de variable	Escala de medición	Unidad de medida	Ejemplo de gráfico	Medidas estadísticas sugeridas
TIPO_REG						
PAIS						
P_DEPTO						
P_MUNIC						
UC_UO						
ENCUESTA						
COD_VEREDA						
P_S7PNUMPEZ						
P_S7P96						
P_S7P97						
P_S7P98						
P_S7P99						
P_S7P100						

4.3 Parte 3. Interpretación estadística

Responda las siguientes preguntas:

1. ¿Qué variables son cualitativas y cuáles cuantitativas?
2. ¿Qué variables corresponden a procesos de conteo?
3. ¿Qué variables corresponden a procesos de medición?
4. ¿Cuál variable podría analizarse mediante:
 - histogramas?
 - diagramas de barras?
 - boxplots?
5. ¿Qué variable considera más importante para analizar la producción acuícola y por qué?

Ejemplo de una variable estudiada Curva de densidad de la producción acuícola.


```
library(ggplot2)

ggplot(
  acuicultura,
  aes(x = log10(P_S7P100 + 1))
) +

  geom_density(
    fill = "skyblue",
    alpha = 0.5,
    color = "blue",
    linewidth = 1
  ) +

  labs(
    title = "Curva de densidad de la producción acuícola",
    subtitle = "Escala logarítmica",
  )
```

```
x = "Log10 Producción total (kg)",  
y = "Densidad"  
) +  
  
theme_minimal()
```



Chapter 5

Preparación de datos

La preparación de datos constituye una etapa crítica dentro del análisis estadístico, ya que implica el proceso sistemático de depuración, organización, clasificación y transformación de la información recolectada, con el fin de convertirla en un insumo adecuado para su análisis (Kleinbaum & Klein, 2012; Wickham & Grolemund, 2017).

En esta fase, el estudiante - el investigador debe garantizar la calidad de los datos mediante procesos de validación y verificación, conocidos como crítica de datos, cuyo objetivo es identificar y corregir errores, inconsistencias u omisiones generadas durante la recolección de la información (Hair et al., 2019).

5.1 Carga de datos en R

Para iniciar el trabajo en R, el primer paso fundamental consiste en definir el directorio de trabajo, es decir, la ubicación donde se encuentran los archivos de datos y donde se almacenarán los resultados del análisis. Esto puede realizarse mediante la función `setwd()` o a través de herramientas gráficas del entorno de desarrollo (RStudio) (Wickham & Grolemund, 2017). Existen múltiples métodos para cargar datos dependiendo de su formato:

Table 5.1: Métodos de carga de datos en R

Método	Característica	Ejemplo
Archivos de texto y CSV	Uso de funciones como <code>read.csv()</code> o <code>read.csv2()</code> , especificando encabezados y codificación	Importación de archivos <code>.csv</code>
Interfaces gráficas (GUI)	Herramientas como R Commander permiten importar datos sin necesidad de programación	Importación desde Excel, SPSS, STATA
Minería de datos	Paquetes como <code>rattle</code> permiten cargar datos mediante interfaces visuales configurables	Definición de separadores y decimales

5.2 Limpieza de datos

La limpieza de datos consiste en detectar, corregir o eliminar inconsistencias que puedan afectar la validez del análisis estadístico (Van den Broeck et al., 2005). Un paso inicial es la inspección visual del conjunto de datos para identificar registros incompletos, errores de digitación o valores atípicos. Por ejemplo, líneas que contienen exclusivamente valores faltantes (NA) deben ser evaluadas antes de su inclusión en el análisis.

Table 5.2: Aspectos clave en la preparación de datos

Proceso	Subproceso	Descripción	Herramienta / Ejemplo
Limpieza de datos	Valores extremos (Outliers)	Identificación y tratamiento de datos atípicos que pueden distorsionar resultados. Se recomienda corregir o eliminar errores evidentes.	Diagramas de caja (<i>boxplot</i>) (Tukey, 1977)
	Consistencia de totales	Verificación de coherencia entre frecuencias, totales y porcentajes acumulados.	Validación de sumas (Agresti, 2018)
	Filtrado de datos	Selección de subconjuntos de datos según criterios específicos para análisis focalizado.	Filtrado en R (<i>subset</i> , <i>filter</i>)
Valores faltantes	Identificación y codificación	Asignación de códigos (ej: 99, 999) para identificar datos perdidos.	Codificación en R o SPSS
	Eliminación de casos	Eliminación de registros incompletos antes del análisis.	<code>na.omit()</code> , <code>na.exclude()</code>
	Imputación	Estimación de valores faltantes mediante métodos estadísticos.	Métodos de imputación
	Análisis de censura	Tratamiento de datos incompletos en estudios de supervivencia.	(Kleinbaum & Klein, 2012)
Recodificación	Categorización de variables	Transformación de variables cuantitativas en categorías.	Agrupación de edades
	Codificación de atributos	Asignación de valores numéricos a variables cualitativas.	1 = Masculino, 2 = Femenino
	Variables dummy	Conversión de variables categóricas en variables binarias.	(Wooldridge, 2016)
	Tratamiento de etiquetas	Conversión de códigos numéricos a etiquetas descriptivas.	<code>factor()</code> en R

La preparación de datos es una fase fundamental que garantiza la calidad y confiabilidad del análisis estadístico. Un manejo adecuado de la limpieza, los valores faltantes y la recodificación permite transformar datos brutos en información estructurada y útil, fortaleciendo la validez de los resultados y la toma de decisiones basada en evidencia (Wickham & Grolemund, 2017; Hair et al., 2019).

Chapter 6

Organización de datos y tablas estadísticas

En este capítulo se presentan los fundamentos para la organización y presentación de la información mediante diferentes tipos de tablas estadísticas. Estas herramientas permiten resumir, ordenar y estructurar los datos de manera que faciliten su análisis e interpretación. Las tablas constituyen un recurso esencial en la estadística descriptiva, ya que permiten transformar datos individuales en información significativa.

Chapter 7

Tablas de datos

7.1 Datos simples

Los **datos simples** corresponden al registro directo, individual y no agrupado de cada observación obtenida en un estudio. En este formato, cada valor se conserva tal como fue recolectado, lo que permite identificar con facilidad observaciones particulares, posibles errores de registro, valores extremos y patrones preliminares.

Si se tiene una variable cuantitativa X observada en n individuos, los datos simples pueden representarse como:

$$X = \{x_1, x_2, x_3, \dots, x_n\}$$

donde:

- x_i representa el valor observado en la unidad i
- n es el número total de observaciones

Este tipo de presentación es especialmente útil en etapas iniciales del análisis, cuando interesa inspeccionar la información en bruto antes de resumirla. Sin embargo, cuando el número de observaciones es grande, los datos simples se vuelven poco prácticos para interpretar tendencias generales.

7.2 Datos agrupados

Los **datos agrupados** se obtienen cuando los valores individuales se organizan en categorías o intervalos de clase. Esta forma de organización permite resumir grandes volúmenes de información y facilita la identificación de concentraciones, patrones de distribución y tendencias generales.

Cuando la variable es cuantitativa continua, los intervalos suelen construirse a partir del rango de los datos. El rango de los datos se define como:

$$R = X_{\max} - X_{\min}$$

donde:

- R es el rango
- $X_{\max}$ es el valor máximo observado
- $X_{\min}$ es el valor mínimo observado

Si se desea formar k clases, la amplitud del intervalo puede aproximarse mediante: La amplitud de clase se calcula como:

$$A = \frac{R}{k}$$

donde:

- A es la amplitud de clase
- k es el número de intervalos

Una regla empírica ampliamente usada para estimar el número de clases es la **regla de Sturges**:

$$k = 1 + 3.322 \log_{10}(n)$$

Esta expresión proporciona un valor de referencia para construir tablas de frecuencias agrupadas cuando el tamaño muestral es moderado.

7.3 Tablas de frecuencia

Las **tablas de frecuencia** permiten resumir la distribución de los datos, indicando cuántas veces aparece cada valor, categoría o intervalo. Son una herramienta central de la estadística descriptiva y constituyen la base para la construcción de histogramas, polígonos de frecuencia, diagramas de barras y otros gráficos.

Una tabla de frecuencia puede incluir los siguientes componentes:

7.3.1 Frecuencia absoluta

La **frecuencia absoluta** de una categoría o clase corresponde al número de veces que dicha categoría aparece en el conjunto de datos. Se denota por f_i .

f_i = número de observaciones en la categoría o clase i

7.3.2 Frecuencia relativa

La **frecuencia relativa** expresa la proporción de observaciones que pertenecen a una categoría respecto al total. Se denota por h_i y se calcula como:

$$h_i = \frac{f_i}{n}$$

Si se desea expresar en porcentaje:

$$h_i(\%) = \frac{f_i}{n} \times 100$$

7.3.3 Frecuencia acumulada

La **frecuencia acumulada** representa la suma progresiva de las frecuencias absolutas hasta la clase i . Se denota por F_i :

$$F_i = \sum_{j=1}^i f_j$$

7.3.4 Frecuencia relativa acumulada

La **frecuencia relativa acumulada** corresponde a la suma progresiva de las frecuencias relativas. Se denota por H_i :

$$H_i = \sum_{j=1}^i h_j = \frac{F_i}{n}$$

donde:

- H_i es la frecuencia relativa acumulada,
- F_i es la frecuencia absoluta acumulada,
- n es el número total de observaciones.

Estas medidas permiten conocer no solo la cantidad de datos en cada categoría, sino también la proporción acumulada de observaciones hasta determinado punto de la distribución.

7.4 Ejemplo de tabla de frecuencia: Variable P_S7P97

La variable P_S7P97 corresponde al **número de cosechas realizadas durante el año**, por lo que se clasifica como una **variable cuantitativa discreta**, ya que proviene de un proceso de conteo y solo admite valores enteros. La tabla de frecuencia permite resumir la distribución de esta variable, identificando: cuántas veces aparece cada valor, su porcentaje, y la frecuencia acumulada.

```
library(dplyr)
library(knitr)
library(readr)
library(kableExtra)

# Cargar base de datos de Acuicultura
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

# Tabla de frecuencia
tabla_frecuencia <- acuicultura %>%
  count(P_S7P97, name = "fi") %>%
  mutate(
    hi = round(fi / sum(fi), 4),
    Porcentaje = round(hi * 100, 2),
    Fi = cumsum(fi),
    Hi = round(cumsum(hi), 4)
  )

# Cambiar nombres de columnas
colnames(tabla_frecuencia) <- c(
  "Número de cosechas",
  "f ",
  "h ",
  "Porcentaje (%)",
  "F ",
  "H "
)
```

```
# Visualizar tabla
tabla_frecuencia %>%
  kable(
    caption = "Tabla de frecuencia del número de cosechas",
    align = "c",
    digits = 3
  ) %>%
  kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    full_width = FALSE,
    position = "center"
  )
```

Table 7.1: Tabla de frecuencia del número de cosechas

Número de cosechas	f_i	h_i	Porcentaje (%)	F_i	H_i
0	620	0.180	17.99	620	0.180
1	1778	0.516	51.58	2398	0.696
2	678	0.197	19.67	3076	0.892
3	83	0.024	2.41	3159	0.916
4	42	0.012	1.22	3201	0.929
5	31	0.009	0.90	3232	0.938
6	49	0.014	1.42	3281	0.952
7	24	0.007	0.70	3305	0.959
8	23	0.007	0.67	3328	0.966
9	32	0.009	0.93	3360	0.975
10	33	0.010	0.96	3393	0.985
11	28	0.008	0.81	3421	0.993
12	26	0.007	0.75	3447	1.000

Interpretación: La tabla de frecuencia permite identificar cuáles son los números de cosechas más frecuentes entre las unidades productivas analizadas. Asimismo, facilita reconocer la concentración de observaciones, la dispersión de los datos y posibles patrones de comportamiento en la actividad acuícola. Cuando la mayoría de las observaciones se concentra en pocos valores, puede inferirse una baja variabilidad en el número de cosechas. Por el contrario, una distribución amplia sugiere heterogeneidad en los sistemas productivos.

7.5 Estructura general de una tabla de frecuencia

De manera general, una tabla de distribución de frecuencias para una variable cuantitativa agrupada permite resumir y organizar los datos en intervalos o clases, facilitando la interpretación de la distribución de los valores observados. Este tipo de tabla incluye frecuencias absolutas, relativas y acumuladas, así como la marca de clase, la cual representa el valor central de cada intervalo.

- **Clase o intervalo:** agrupa los datos en rangos numéricos para facilitar el análisis.
- **Marca de clase:** corresponde al punto medio de cada intervalo y representa el valor central de la clase.
- **Frecuencia absoluta (f_i):** número de observaciones que pertenecen a cada intervalo.
- **Frecuencia relativa (h_i):** proporción de observaciones respecto al total.
- **Frecuencia acumulada (F_i):** suma progresiva de las frecuencias absolutas.
- **Frecuencia relativa acumulada (H_i):** acumulación progresiva de las frecuencias relativas.

7.6 Marca de clase

La marca de clase corresponde al punto medio de cada intervalo:

$$x_i^* = \frac{L_i + U_i}{2}$$

donde:

- (x_i^*) es la marca de clase
- (L_i) es el límite inferior del intervalo
- (U_i) es el límite superior del intervalo

La marca de clase resulta útil para representar la distribución mediante gráficos o para calcular medidas resumen aproximadas cuando los datos están agrupados.

```
library(readr)
library(dplyr)
library(knitr)
library(kableExtra)

# Cargar base de datos
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

# Crear tabla agrupada
tabla_freq <- acuicultura %>%
  filter(!is.na(P_S7P97)) %>%
  mutate(
    Clase = cut(
      P_S7P97,
      breaks = 5,
      include.lowest = TRUE
    )
  ) %>%
  count(Clase, name = "fi") %>%
  mutate(
    hi = fi / sum(fi),
    Fi = cumsum(fi),
    Hi = cumsum(hi)
  )

# Cambiar nombres de columnas
colnames(tabla_freq) <- c(
  "Clase",
  "f_i",
  "h_i",
  "F_i",
  "H_i"
)

# Mostrar tabla
tabla_freq %>%
  kable(
```

```

caption = "Distribución de frecuencias agrupadas",
escape = FALSE,
align = "c",
digits = 3
) %>%
kable_styling(
  bootstrap_options = c("striped", "hover", "condensed"),
  full_width = FALSE
)

```

Table 7.2: Distribución de frecuencias agrupadas

Clase	f _i	h _i	F _i	H _i
[-0.012,2.4]	3076	0.892	3076	0.892
(2.4,4.8]	125	0.036	3201	0.929
(4.8,7.2]	104	0.030	3305	0.959
(7.2,9.6]	55	0.016	3360	0.975
(9.6,12]	87	0.025	3447	1.000

Chapter 8

Organización de datos en contextos reales

En estadística aplicada, las tablas de frecuencia permiten transformar grandes volúmenes de datos en información interpretable. A través de ellas es posible identificar patrones, concentraciones, categorías predominantes y características generales de una población.

Para ilustrar estos conceptos, se utilizará una base de datos antropométrica que contiene mediciones corporales de estudiantes, incluyendo variables cualitativas y cuantitativas como género, grupo, peso y estatura.

El objetivo no será únicamente construir tablas estadísticas, sino interpretar cómo se distribuyen los datos y qué información aportan sobre la población estudiada.

8.1 Actividad Experiencial

8.1.1 Situación problema

Usted hace parte de un equipo de analítica académica encargado de caracterizar físicamente a un grupo de estudiantes para apoyar estudios de ergonomía, salud ocupacional y diseño de espacios educativos. A partir de la base de datos: identifique patrones, organice la información, construya tablas estadísticas, e interprete los resultados.

8.1.1.1 1. Exploración inicial

```
library(readxl)
library(dplyr)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)
```

```
head(datos)
```

```
# A tibble: 6 x 13
```

	Clase	Grupo	Genero	Altura_cm	Peso_Kg	Anchura_hombros_cm	Long_Mano_cm
	<chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	D	A	M	177	73	49	19
2	D	A	M	177	86	45	19
3	D	A	F	160	52	37	16
4	D	A	F	159	53	38	16

```

5 D      A      F      174      78      41      18
6 D      B      M      186      68      44      19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>

```

```
names(datos)
```

```

[1] "Clase"          "Grupo"          "Genero"
[4] "Altura_cm"      "Peso_Kg"        "Anchura_hombros_cm"
[7] "Long_Mano_cm"   "Lon_Palma_cm"   "Ancho_Palma_cm"
[10] "Long_Brazo_cm"  "Long_Muslo_cm"  "Long_Antebrazo_cm"
[13] "Curso"

```

```
glimpse(datos)
```

```

Rows: 260
Columns: 13
$ Clase      <chr> "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "~
$ Grupo      <chr> "A", "A", "A", "A", "A", "B", "B", "B", "B", "~
$ Genero     <chr> "M", "M", "F", "F", "F", "M", "M", "F", "F", "~
$ Altura_cm  <dbl> 177, 177, 160, 159, 174, 186, 174, 172, 156, 165, ~
$ Peso_Kg    <dbl> 73, 86, 52, 53, 78, 68, 115, 50, 62, 64, 94, 60, ~
$ Anchura_hombros_cm <dbl> 49, 45, 37, 38, 41, 44, 49, 42, 42, 44, 48, 45, ~
$ Long_Mano_cm <dbl> 19, 19, 16, 16, 18, 19, 21, 19, 19, 18, 19, 18, ~
$ Lon_Palma_cm <dbl> 11.0, 10.0, 8.0, 9.0, 10.0, 11.0, 11.4, 10.1, 10.0, ~
$ Ancho_Palma_cm <dbl> 9.0, 9.0, 8.0, 8.0, 8.5, 8.0, 9.0, 7.0, 8.0, 8.0, ~
$ Long_Brazo_cm <dbl> 62.0, 59.0, 54.0, 52.0, 59.0, 74.0, 80.0, 76.0, 69.~
$ Long_Muslo_cm <dbl> 55, 52, 51, 50, 52, 52, 47, 51, 52, 53, 57, 46, ~
$ Long_Antebrazo_cm <dbl> 31.0, 31.0, 27.0, 27.0, 29.0, 29.0, 28.0, 26.0, 26.~
$ Curso      <chr> "2020-1", "2020-1", "2020-1", "2020-1", "2020-1", "~

```

! 2. Preguntas para el estudiante

1. ¿Qué variables son cualitativas?
2. ¿Qué variables son cuantitativas?
3. ¿Qué variables corresponden a medición?
4. ¿Qué variables podrían agruparse?
5. ¿Qué información sería relevante para caracterizar a los estudiantes?

8.1.1.2 3. Tablas de frecuencia cualitativas

8.1.2 Ejemplo: Género

La variable Género corresponde a una variable cualitativa nominal, ya que clasifica a los individuos en categorías mutuamente excluyentes sin un orden natural. Para este tipo de variables, las tablas de frecuencia permiten identificar la proporción y distribución de las categorías observadas.

8.1.2.0.1 Tratamiento de valores faltantes

En bases de datos reales es común encontrar valores faltantes (NA). Antes de realizar análisis estadísticos, es importante identificar y evaluar la presencia de datos ausentes, ya que estos pueden afectar la interpretación de los resultados y la validez de los análisis.

```

#\| message: false
#\| warning: false

```

```
library(readxl)
library(dplyr)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)
```

```
library(summarytools)
```

Warning: package 'summarytools' was built under R version 4.5.3

```
freq(datos$Genero)
```

Frequencies

datos\$Genero

Type: Character

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
F	208	80.00	80.00	80.00	80.00
M	52	20.00	100.00	20.00	100.00
<NA>	0			0.00	100.00
Total	260	100.00	100.00	100.00	100.00

```
# Verificar si realmente existen NA
```

```
sum(is.na(datos$Genero))
```

```
[1] 0
```

En este caso, la variable Genero no presenta valores faltantes; sin embargo, la función de resumen estadístico muestra automáticamente la categoría NA. Mediante el argumento `report.nas = FALSE` es posible ocultar esta categoría y presentar la tabla de frecuencias de forma más clara y limpia.

```
freq(
  datos$Genero,
  report.nas = FALSE)
```

Frequencies

datos\$Genero

Type: Character

	Freq	%	% Cum.
F	208	80.00	80.00
M	52	20.00	100.00
Total	260	100.00	100.00

8.1.2.1 4. Preguntas de análisis

1. ¿Qué género presenta mayor frecuencia?
2. ¿La distribución parece equilibrada?
3. ¿Qué implicaciones tendría esto para un estudio antropométrico?
4. ¿La muestra parece representativa?

```

library(readxl)
library(dplyr)
library(knitr)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

#)

# Tabla de frecuencia para la variable Género
tabla_genero <- datos %>%
  count(Genero, name = "fi") %>%
  mutate(
    hi = round(fi / sum(fi), 3),
    Fi = cumsum(fi),
    Hi = round(cumsum(hi), 3)
  )

colnames(tabla_genero) <- c(
  "Categoría",
  "$f_i$",
  "$h_i$",
  "$F_i$",
  "$H_i$"
)

kable(
  tabla_genero,
  caption = "Tabla de frecuencia para la variable género",
  escape = FALSE,
  align = "c"
)

```

Table 8.1: Tabla de frecuencia para la variable género

Categoría	f_i	h_i	F_i	H_i
F	208	0.8	208	0.8
M	52	0.2	260	1.0

8.1.3 Ejemplo: Peso corporal

La variable Peso_Kg corresponde a una variable cuantitativa continua obtenida mediante procesos de medición. Debido a que puede asumir múltiples valores dentro de un intervalo, resulta necesario organizar la información mediante intervalos de clase.

```

library(readxl)
library(dplyr)
library(summarytools)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")

```

```
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

#)

# Tabla de frecuencias
tabla_peso <- freq(
  datos$Peso_Kg,
  report.nas = FALSE,
  plain.ascii = FALSE
)

head(tabla_peso, 10)
```

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
31	3	1.1538462	1.153846	1.1538462	1.153846
32	3	1.1538462	2.307692	1.1538462	2.307692
34	1	0.3846154	2.692308	0.3846154	2.692308
35	5	1.9230769	4.615385	1.9230769	4.615385
36	9	3.4615385	8.076923	3.4615385	8.076923
37	8	3.0769231	11.153846	3.0769231	11.153846
38	13	5.0000000	16.153846	5.0000000	16.153846
39	8	3.0769231	19.230769	3.0769231	19.230769
39.5	1	0.3846154	19.615385	0.3846154	19.615385
40	17	6.5384615	26.153846	6.5384615	26.153846

Chapter 9

Actividad experiencial: Organización de datos y tablas estadísticas

Un grupo de diseñadores y especialistas en ergonomía universitaria necesita analizar las características antropométricas de los estudiantes con el fin de adaptar el mobiliario de las aulas, mejorar la comodidad durante las jornadas académicas y reducir posibles riesgos asociados a malas posturas.

Para ello, se utilizará la base de datos `bd_antropometricas.xlsx`, la cual contiene información relacionada con peso corporal, estatura y otras medidas físicas de los estudiantes.

El objetivo de esta actividad es transformar datos individuales en información organizada mediante tablas estadísticas y representaciones gráficas que permitan apoyar la toma de decisiones.

Chapter 10

Objetivos de aprendizaje

Al finalizar la actividad, el estudiante estará en capacidad de:

- Identificar el tipo de variable y su escala de medición.
- Organizar datos mediante tablas de frecuencia.
- Construir tablas agrupadas para variables cuantitativas continuas.
- Interpretar distribuciones estadísticas.
- Analizar patrones, dispersión y posibles valores extremos.
- Relacionar la estadística descriptiva con problemas reales de análisis de datos.

Chapter 11

Desarrollo de la actividad

11.0.1 Parte 1. Exploración inicial de los datos

Cargue la base de datos y explore las variables disponibles.

```
library(readxl)
library(dplyr)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
#)

head(datos)

# A tibble: 6 x 13
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>           <dbl>       <dbl>
1 D     A     M         177     73             49          19
2 D     A     M         177     86             45          19
3 D     A     F         160     52             37          16
4 D     A     F         159     53             38          16
5 D     A     F         174     78             41          18
6 D     B     M         186     68             44          19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>

names(datos)

[1] "Clase"
[4] "Altura_cm"
[7] "Long_Mano_cm"
[10] "Long_Brazo_cm"
[13] "Curso"

[1] "Grupo"
[4] "Peso_Kg"
[7] "Lon_Palma_cm"
[10] "Long_Muslo_cm"

[1] "Genero"
[4] "Anchura_hombros_cm"
[7] "Ancho_Palma_cm"
[10] "Long_Antebrazo_cm"
```

```
glimpse(datos)
```

```

Rows: 260
Columns: 13
$ Clase      <chr> "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "~
$ Grupo      <chr> "A", "A", "A", "A", "A", "B", "B", "B", "B", "B", "~
$ Genero     <chr> "M", "M", "F", "F", "F", "M", "M", "F", "F", "F", "~
$ Altura_cm  <dbl> 177, 177, 160, 159, 174, 186, 174, 172, 156, 165, 1~
$ Peso_Kg    <dbl> 73, 86, 52, 53, 78, 68, 115, 50, 62, 64, 94, 60, 63~
$ Anchura_hombros_cm <dbl> 49, 45, 37, 38, 41, 44, 49, 42, 42, 44, 48, 45, 36,~
$ Long_Mano_cm <dbl> 19, 19, 16, 16, 18, 19, 21, 19, 19, 18, 19, 18, 17,~
$ Lon_Palma_cm <dbl> 11.0, 10.0, 8.0, 9.0, 10.0, 11.0, 11.4, 10.1, 10.0,~
$ Ancho_Palma_cm <dbl> 9.0, 9.0, 8.0, 8.0, 8.5, 8.0, 9.0, 7.0, 8.0, 8.0, 9~
$ Long_Brazo_cm <dbl> 62.0, 59.0, 54.0, 52.0, 59.0, 74.0, 80.0, 76.0, 69.~
$ Long_Muslo_cm <dbl> 55, 52, 51, 50, 52, 52, 47, 51, 52, 53, 57, 46, 50,~
$ Long_Antebraco_cm <dbl> 31.0, 31.0, 27.0, 27.0, 29.0, 29.0, 28.0, 26.0, 26.~
$ Curso      <chr> "2020-1", "2020-1", "2020-1", "2020-1", "2020-1", "~

```

11.0.2 Parte 2. Identificación de variables

Complete la siguiente tabla para las variables seleccionadas:

Variable	Tipo de variable	Escala de medición	Unidad de medida	Herramienta estadística sugerida
Genero				
Grupo				
Peso_Kg				
Altura_cm				

11.0.3 Parte 3. Organización y análisis del peso corporal

La variable Peso_Kg corresponde a una variable cuantitativa continua obtenida mediante procesos de medición. Debido a que puede asumir múltiples valores dentro de un intervalo, resulta conveniente organizar la información mediante tablas agrupadas y representaciones gráficas.

11.0.4 Situación problema

Los diseñadores requieren conocer:

- el rango de peso predominante,
- la dispersión de los datos,
- la presencia de valores extremos,
- y la homogeneidad de la muestra,

con el propósito de definir especificaciones ergonómicas adecuadas para las aulas universitarias.

11.0.5 Parte 4. Preguntas orientadoras

A partir del análisis de la variable Peso_Kg, responda:

1. ¿Dónde se concentra la mayor parte de los estudiantes?
2. ¿Existen valores extremos o atípicos?
3. ¿La distribución parece simétrica o presenta sesgo?

4. ¿Qué tan homogénea es la muestra?
5. ¿Sería recomendable agrupar los datos?
6. ¿Qué utilidad tendría esta información para el diseño del mobiliario universitario?

11.0.6 Parte 5. Construcción de tablas agrupadas

Utilice la regla de Sturges para estimar el número de clases y construya una tabla de distribución de frecuencias agrupadas.

La tabla debe incluir:

- Clase o intervalo
- Marca de clase
- Frecuencia absoluta (f_i)
- Frecuencia relativa (h_i)
- Frecuencia acumulada (F_i)
- Frecuencia relativa acumulada (H_i)

11.0.7 Parte 6. Visualización gráfica

Construya:

- Histograma
- Curva de densidad
- Boxplot

e interprete los resultados obtenidos.

11.0.8 Recomendación metodológica

La selección de la herramienta estadística depende del tipo de variable analizada:

Tipo de variable	Herramienta recomendada
Cualitativa	Tablas de frecuencia (<code>freq()</code>)
Cuantitativa discreta	Tablas de frecuencia (<code>freq()</code>)
Cuantitativa continua	Histogramas y tablas agrupadas

11.0.9 Reflexión final

La organización de datos constituye una etapa fundamental del análisis estadístico. Las tablas de frecuencia permiten transformar datos aislados en información estructurada, facilitando la identificación de patrones, tendencias y características generales de una población.

En contextos reales, estas herramientas son esenciales para apoyar procesos de investigación, caracterización poblacional y toma de decisiones basadas en evidencia. El análisis estadístico no consiste únicamente en calcular indicadores, sino en interpretar los datos y convertirlos en información útil para resolver problemas reales.

Chapter 12

Visualización de datos

La visualización de datos es una etapa fundamental en la estadística descriptiva, ya que permite representar la información de forma clara, resumida e interpretable. Los gráficos facilitan la identificación de patrones, tendencias, valores atípicos y diferencias entre grupos, apoyando así la comprensión de los datos y la toma de decisiones.

En este capítulo se presentan algunos de los gráficos más utilizados en el análisis descriptivo: gráficos de barras, histogramas y diagramas de caja (*boxplot*), así como su construcción en R.

12.1 Gráficos en R

R es un lenguaje ampliamente utilizado para el análisis estadístico y la visualización de datos. Permite elaborar gráficos tanto con funciones básicas como con paquetes especializados, entre ellos *ggplot2*, que ofrece una sintaxis más flexible y una presentación más profesional.

Para los ejemplos de este capítulo se utilizarán las librerías *readxl* y *ggplot2*.

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 13
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>    <dbl>    <dbl>          <dbl>          <dbl>
1 D     A     M        177      73            49            19
2 D     A     M        177      86            45            19
3 D     A     F        160      52            37            16
4 D     A     F        159      53            38            16
5 D     A     F        174      78            41            18
6 D     B     M        186      68            44            19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>
```

```
str(datos)

tibble [260 x 13] (S3: tbl_df/tbl/data.frame)
 $ Clase      : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo      : chr [1:260] "A" "A" "A" "A" ...
 $ Genero     : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm  : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg    : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
```

```

$ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
$ Long_Mano_cm      : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
$ Lon_Palma_cm      : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
$ Ancho_Palma_cm    : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
$ Long_Brazo_cm     : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
$ Long_Muslo_cm     : num [1:260] 55 52 51 50 52 52 47 51 52 53 ...
$ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
$ Curso             : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...

```

12.2 Gráfico de sectores

El gráfico de pastel es una representación estadística utilizada para mostrar la distribución porcentual de una variable cualitativa. Cada sector del círculo representa una categoría y su tamaño es proporcional a la frecuencia relativa o porcentaje que dicha categoría aporta al total de observaciones.

```

library(readxl)
library(dplyr)
library(ggplot2)
library(scales)

# Cargar base antropométrica
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Tabla de proporciones por género
tabla_genero <- datos %>%
  count(Genero) %>%
  mutate(
    proporcion = n / sum(n),
    porcentaje = percent(proporcion, accuracy = 0.1),
    etiqueta = paste0(Genero, "\n", porcentaje)
  )

# Gráfico de pastel
ggplot(
  tabla_genero,
  aes(
    x = "",
    y = proporcion,
    fill = Genero
  )
) +
  geom_col(
    width = 1,
    color = "white"
  ) +
  coord_polar(theta = "y") +
  geom_text(
    aes(label = etiqueta),
    position = position_stack(vjust = 0.5),
    size = 4
  ) +
  labs(


```

```

title = "Distribución porcentual de estudiantes según género",
fill = "Género"
) +
theme_void()

```

Distribución porcentual de estudiantes según género



Interpretación de la gráfica: La gráfica evidencia que el 80% de los estudiantes registrados en la base de datos corresponde al género femenino (F), mientras que el 20% pertenece al género masculino (M). Esto indica una marcada predominancia de mujeres dentro de la muestra analizada.

Este tipo de representación facilita la comparación visual de proporciones entre categorías y permite identificar rápidamente la participación relativa de cada grupo dentro del conjunto de datos.

12.3 Gráfico de barras

El gráfico de barras se utiliza principalmente para representar variables cualitativas o categóricas. Su finalidad es mostrar la frecuencia o proporción de cada categoría mediante barras separadas, cuya altura es proporcional a la cantidad observada.

Por ejemplo, si se desea visualizar la distribución de una variable como el género o la clase, puede emplearse un gráfico de barras.

```

library(readxl)
library(dplyr)
library(ggplot2)

datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)


# Gráfico de barras para Género
datos %>%
  count(Grupo) %>%
  ggplot(aes(x = Grupo, y = n)) +

```

```

geom_col(fill = "#1F77B4", color = "white") +
geom_text(
  aes(label = n),
  vjust = -0.4,
  size = 4
) +
labs(
  title = "Distribución de estudiantes según grupo",
  x = "Grupo",
  y = "Frecuencia"
) +
theme_minimal(base_size = 14)

```



```

library(readxl)
library(dplyr)
library(ggplot2)
library(scales)

datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Calcular proporciones por grupo
tabla_grupo <- datos %>%

  count(Grupo) %>%

  mutate(
    proporcion = n / sum(n)
  )

# Gráfico de barras con proporciones

```

```
ggplot(
  tabla_grupo,
  aes(x = Grupo, y = proporcion)
) +


  geom_col(
    fill = "#1F77B4",
    color = "white"
  ) +

  geom_text(
    aes(
      label = percent(proporcion)
    ),
    vjust = -0.4,
    size = 5
  ) +

  scale_y_continuous(
    labels = percent_format()
  ) +

  labs(
    title = "Proporción de estudiantes según grupo",
    x = "Grupo",
    y = "Proporción"
  ) +

  theme_minimal(base_size = 12)
```



Interpretación: El gráfico de proporciones permite identificar la participación relativa de cada grupo dentro del total

de estudiantes analizados. A diferencia de las frecuencias absolutas, las proporciones facilitan la comparación entre categorías y permiten interpretar la distribución porcentual de la muestra.

12.4 Histograma

El histograma se utiliza para representar la distribución de una variable cuantitativa continua. A diferencia del gráfico de barras, en el histograma las barras se presentan unidas, ya que representan intervalos de clase contiguos.

Este tipo de gráfico es útil para identificar la forma de la distribución, la concentración de valores, posibles asimetrías y presencia de valores extremos.

12.4.1 Ejemplo con funciones básicas de R

```
library(readr)
library(dplyr)

# Cargar base de datos de Acuicultura
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv")


#Número de cosechas en el año (P_S7P97)
#archivo de datos: S07D(Acuicultura)

names(acuicultura)

[1] "...1"      "TIPO_REG"  "PAIS"      "P_DEPTO"   "P_MUNIC"
[6] "UC_UO"     "ENCUESTA"  "COD_VEREDA" "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97"   "P_S7P98"   "P_S7P99"   "P_S7P100"

hist(acuicultura$P_S7P97,
      main = "Número de cosechas en el año (P_S7P97)",
      xlab = "Cosechas",
      ylab = "Frecuencia")
```

Número de cosechas en el año (P_S7P97)



12.5 Boxplot

El diagrama de caja y bigotes, o *boxplot*, es un gráfico que resume la distribución de una variable cuantitativa a partir de los cuartiles, la mediana y los valores extremos. Es especialmente útil para detectar asimetrías y observaciones atípicas. El boxplot se basa en el resumen de cinco números:




Figure 12.1: Fuente: autores

12.5.1 Ejemplo con funciones básicas de R

```
# Librerías
library(readr)
library(ggplot2)

# Cargar base de datos
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

# Boxplot
ggplot(
  acuicultura,

  aes(x = P_S7P97)
) +

  geom_boxplot(

    fill = "#2C7FB8",

    color = "black",
```

```

alpha = 0.9,

outlier.color = "red"
) +


labs(
  title = "Distribución del número de cosechas",

  x = "Número de cosechas",

  y = ""
) +

theme_minimal()

```



Interpretación: El boxplot evidencia que la mayor parte de las unidades productivas presentan un número bajo de cosechas, concentrándose principalmente entre 1 y 2 cosechas. La línea de la mediana se encuentra muy cercana al primer cuartil (Q1), lo cual sugiere una distribución asimétrica positiva, donde los valores altos son menos frecuentes pero considerablemente más dispersos.

Además, se observan múltiples valores atípicos hacia la derecha del gráfico, indicando la existencia de algunas unidades productivas con un número de cosechas significativamente superior al comportamiento general de la muestra. Esto evidencia una alta heterogeneidad en los datos y una posible concentración de productores con niveles excepcionales de producción.

El reducido tamaño de la caja refleja que el 50% central de las observaciones se encuentra en un rango estrecho, mientras que la presencia de valores extremos amplía considerablemente el rango total de la distribución.

12.5.2 Ejemplo peso y género con ggplot2


También es posible comparar una variable cuantitativa entre categorías.

```

ggplot(datos, aes(x = Genero, y = Peso_Kg)) +
  geom_boxplot() +

```

```
labs(
  title = "Distribución del peso según género",
  x = "Género",
  y = "Peso"
)
```



Interpretación: el boxplot evidencia diferencias en la distribución del peso corporal según el género. En los hombres (M) se observa una mediana de peso superior y una mayor dispersión de los datos en comparación con las mujeres (F), lo que indica una variabilidad más amplia en los valores registrados.

Asimismo, en ambos grupos se identifican valores atípicos representados por puntos fuera de los bigotes del diagrama, correspondientes a individuos con pesos considerablemente superiores al comportamiento general de la muestra. La amplitud de las cajas sugiere que el 50% central de los pesos se encuentra más concentrado en las mujeres, mientras que en los hombres existe una mayor heterogeneidad.

Este tipo de representación gráfica permite comparar simultáneamente medidas de tendencia central, dispersión y posibles valores extremos entre categorías.

12.6 Interpretación básica de los gráficos

Interpretación básica de los gráficos en el análisis de datos




Figure 12.2: Fuente: autores

Chapter 13

Medidas de tendencia central y dispersión

Las medidas de tendencia central son herramientas estadísticas utilizadas para resumir un conjunto de datos mediante un valor representativo o típico. Su principal objetivo es describir el comportamiento general de una distribución y facilitar la comparación entre diferentes conjuntos de información.

En términos generales, una medida de tendencia central representa el punto alrededor del cual tienden a agruparse las observaciones. Estas medidas permiten sintetizar grandes volúmenes de datos en un único valor numérico que describe de manera aproximada el comportamiento de la variable analizada.

Con frecuencia, estas medidas son denominadas “promedios”; sin embargo, cada una posee características particulares y su uso depende de la naturaleza de los datos y del propósito del análisis.

Las tres medidas de tendencia central más utilizadas son:

- **Media aritmética:** representa el promedio de los valores observados.
- **Mediana:** corresponde al valor central de los datos ordenados.
- **Moda:** identifica el valor o categoría que aparece con mayor frecuencia.

La elección de la medida más adecuada depende del tipo de variable, la presencia de valores extremos y la forma de la distribución de los datos. Por ejemplo, la media suele verse afectada por valores atípicos, mientras que la mediana ofrece una medida más robusta en distribuciones asimétricas.

Estas medidas constituyen una base fundamental para el análisis estadístico descriptivo y son ampliamente utilizadas en áreas como la salud, educación, ingeniería, economía y ciencias sociales, ya que permiten resumir información y apoyar la toma de decisiones basada en datos.

En este capítulo se presentan las principales medidas de tendencia central y de dispersión, junto con su formulación matemática y su implementación en R.

Chapter 14

Medidas de tendencia central

14.0.1 Media aritmética

La media aritmética es el promedio de los datos y se calcula como la suma de todas las observaciones dividida entre el número total de datos.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Donde: (x_i) : cada observación, (n) : número total de datos, $\bar{x}$: media aritmética

14.0.2 Cálculo en R

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 13
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>             <dbl>       <dbl>
1 D     A     M         177     73              49         19
2 D     A     M         177     86              45         19
3 D     A     F         160     52              37         16
4 D     A     F         159     53              38         16
5 D     A     F         174     78              41         18
6 D     B     M         186     68              44         19
# i 6 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Muslo_cm <dbl>, Long_Antebrazo_cm <dbl>,
#   Curso <chr>
```

```
str(datos)
```

```
tibble [260 x 13] (S3: tbl_df/tbl/data.frame)
 $ Clase      : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo      : chr [1:260] "A" "A" "A" "A" ...
 $ Genero     : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm  : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg    : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
```

```
$ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
$ Long_Mano_cm      : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
$ Lon_Palma_cm      : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
$ Ancho_Palma_cm    : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
$ Long_Brazo_cm     : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
$ Long_Muslo_cm     : num [1:260] 55 52 51 50 52 52 47 51 52 53 ...
$ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
$ Curso             : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
```

```
names(datos)
```

```
[1] "Clase"          "Grupo"          "Genero"
[4] "Altura_cm"      "Peso_Kg"        "Anchura_hombros_cm"
[7] "Long_Mano_cm"   "Lon_Palma_cm"   "Ancho_Palma_cm"
[10] "Long_Brazo_cm"  "Long_Muslo_cm"  "Long_Antebrazo_cm"
[13] "Curso"
```

```
mean(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 68.14808
```

14.0.3 Mediana

La mediana es el valor que divide el conjunto de datos ordenados en dos partes iguales, de modo que el 50% de las observaciones queda por debajo y el otro 50% por encima.

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, & n \text{ impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & n \text{ par} \end{cases}$$

La mediana es una medida robusta frente a valores extremos.

14.0.4 Cálculo en R

```
median(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 50
```

14.0.5 Moda

La moda es el valor que aparece con mayor frecuencia en el conjunto de datos.

$$\text{Moda} = \arg \max(f_i)$$

14.0.6 Cálculo en R

```
moda <- function(x) {
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

moda(datos$Peso_Kg)
```

```
[1] 40
```

14.1 Visualización de las medidas de tendencia central

```
library(readxl)
library(ggplot2)

# Cargar datos
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Función para calcular la moda
moda <- function(x) {
  x <- na.omit(x)
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

# Medidas de tendencia central
media <- mean(datos$Peso_Kg, na.rm = TRUE)
mediana <- median(datos$Peso_Kg, na.rm = TRUE)
moda_val <- moda(datos$Peso_Kg)

# Histograma
ggplot(datos, aes(x = Peso_Kg)) +

  geom_histogram(
    bins = 10,
    fill = "skyblue",
    color = "black",
    alpha = 0.7
  ) +

  # Media
  geom_vline(
    xintercept = media,
    color = "red",
    linewidth = 1.2,
    linetype = "dashed"
  ) +


  # Mediana
  geom_vline(
    xintercept = mediana,
    color = "blue",
    linewidth = 1.2
  ) +

  # Moda
  geom_vline(
    xintercept = moda_val,
    color = "darkgreen",
    linewidth = 1.2,
    linetype = "dotdash"
  )
```

```
) +

labs(
  title = "Distribución del peso",
  subtitle = "Media (rojo), Mediana (azul) y Moda (verde)",
  x = "Peso (kg)",
  y = "Frecuencia"
) +

theme_minimal()
```



14.2 Interpretación del gráfico: Distribución del peso

El histograma presenta la distribución de la variable **Peso (kg)** en la muestra analizada, incorporando las tres principales medidas de tendencia central:

□ **Media** (línea roja) □ **Mediana** (línea azul) □ **Moda** (línea verde)

14.2.1 Análisis estadístico

La media es mayor que la mediana y la moda

Se observa que: $Media > Mediana > Moda$. Esto indica una **asimetría positiva** o sesgo hacia la derecha.

Existencia de valores extremos

La presencia de individuos con pesos altos (aproximadamente entre 140 y 190 kg) desplaza la media hacia valores mayores. Estos datos atípicos afectan principalmente la media, mientras que la mediana permanece más estable.

Concentración principal de los datos

La mayor frecuencia de observaciones se concentra entre aproximadamente **35 y 65 kg**, lo que indica que la mayoría de los participantes presentan pesos dentro de ese intervalo.

Comportamiento de la moda

La moda se ubica en el intervalo de mayor frecuencia, representando el peso más común dentro de la muestra.

Chapter 15

Ejercicio experiencial propuesto

15.1 Actividad: Explorando las características antropométricas

15.1.1 Objetivo

Analizar diferentes variables antropométricas mediante histogramas y medidas de tendencia central para identificar patrones de distribución, variabilidad y posibles valores atípicos.

Variable	Interpretación
Altura_cm	Distribución de estaturas
Anchura_hombros_cm	Variabilidad corporal
Long_Brazo_cm	Proporciones anatómicas
Long_Muslo_cm	Longitud del miembro inferior
Long_Antebrazo_cm	Variabilidad segmentaria

15.2 Actividad práctica

15.3 Parte 1. Construcción del gráfico

Construya un histograma para cada una de las siguientes variables:

- Altura_cm
- Anchura_hombros_cm
- Long_Brazo_cm

Incluya mediante líneas verticales de diferentes colores.

- Media, Mediana, Moda

15.4 Parte 2. Interpretación

Para cada gráfico responda:

1. ¿La distribución parece simétrica o asimétrica?
2. ¿Existen valores extremos?
3. ¿La media y la mediana son similares?

4. ¿Qué medida representa mejor el comportamiento de los datos?
5. ¿Cuál variable presenta mayor dispersión?

Chapter 16

Medidas de dispersión o variabilidad

Las medidas de dispersión o variabilidad complementan a las medidas de tendencia central, ya que permiten describir qué tan agrupados o dispersos se encuentran los datos respecto a un valor representativo, como la media o la mediana.

Mientras que las medidas de tendencia central resumen la distribución mediante un único valor típico, las medidas de dispersión indican el grado de heterogeneidad presente en los datos. En consecuencia, dos conjuntos de datos pueden tener la misma media, pero comportamientos muy diferentes en cuanto a su variabilidad.

Por ejemplo, un grupo de observaciones puede presentar valores muy cercanos entre sí y concentrados alrededor de la media, mientras que otro grupo puede mostrar valores mucho más dispersos. Aunque ambos conjuntos tengan el mismo promedio, el segundo exhibirá mayor variabilidad.

La variabilidad constituye un aspecto fundamental en el análisis estadístico, ya que permite evaluar la estabilidad, consistencia y homogeneidad de los datos. En muchos contextos aplicados, comprender la dispersión resulta tan importante como conocer el promedio.

16.0.1 Rango

El rango es la diferencia entre el valor máximo y el mínimo.

$$R = X_{\max} - X_{\min}$$

16.0.2 Cálculo en R

```
max(datos$Peso_Kg, na.rm = TRUE) - min(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 153
```

16.0.3 Varianza muestral

La varianza mide la dispersión promedio de los datos respecto a la media.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

16.0.4 Cálculo en R

```
var(datos$Peso_Kg, na.rm = TRUE)
```

[1] 1815.201

16.0.5 Varianza poblacional

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

16.0.6 Desviación estándar muestral

La desviación estándar es la raíz cuadrada de la varianza y expresa la dispersión en las mismas unidades de los datos.

$$s = \sqrt{s^2}$$

16.0.7 Cálculo en R

```
sd(datos$Peso_Kg, na.rm = TRUE)
```

[1] 42.60518

16.0.8 Desviación estándar poblacional

$$\sigma = \sqrt{\sigma^2}$$

16.0.9 Coeficiente de variación

El coeficiente de variación permite comparar la dispersión relativa respecto a la media.

$$CV = \frac{s}{\bar{x}} \times 100$$

16.0.10 Cálculo en R

```
(sd(datos$Peso_Kg, na.rm = TRUE) / mean(datos$Peso_Kg, na.rm = TRUE)) * 100
```

[1] 62.51853

16.1 Resumen estadístico en R

R permite obtener múltiples medidas descriptivas de manera simultánea.

```
summary(datos$Peso_Kg)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
31.00	40.00	50.00	68.15	72.00	184.00

También es posible calcular varias medidas en conjunto:

```
library(summarytools)
```

Warning: package 'summarytools' was built under R version 4.5.3

```
descr(datos, stats=c("mean", "sd", "q1", "med", "q3", "min", "max", "cv"))
```

Non-numerical variable(s) ignored: Clase, Grupo, Genero, Curso

Descriptive Statistics

datos

N: 260

	Altura_cm	Ancho_Palma_cm	Anchura_hombros_cm	Lon_Palma_cm	Long_Antebrazo_cm
Mean	69.47	8.07	53.83	9.46	27.54
Std.Dev	76.49	1.31	15.08	1.37	3.70
Q1	1.65	7.00	42.00	9.00	26.00
Median	1.85	8.00	49.00	10.00	27.00
Q3	162.00	9.00	63.00	10.00	29.00
Min	1.50	5.00	36.00	6.00	20.00
Max	192.00	13.50	130.00	12.00	50.00
CV	1.10	0.16	0.28	0.14	0.13

Table: Table continues below

	Long_Brazo_cm	Long_Mano_cm	Long_Muslo_cm	Peso_Kg
Mean	68.01	17.56	51.11	68.15
Std.Dev	12.16	4.38	4.85	42.61
Q1	66.00	16.10	48.00	40.00
Median	71.00	17.00	51.00	50.00
Q3	75.00	18.30	54.00	72.00
Min	17.00	7.00	38.00	31.00
Max	84.00	83.00	73.00	184.00
CV	0.18	0.25	0.09	0.63

16.2 Histograma + desviación estándar

```
media <- mean(datos$Peso_Kg, na.rm = TRUE)
desv <- sd(datos$Peso_Kg, na.rm = TRUE)
```

```
ggplot(datos, aes(x = Peso_Kg)) +
```

```
  geom_histogram(
    bins = 10,
    fill = "skyblue",
    color = "black"
  ) +
```

```
  # Media
  geom_vline(
    xintercept = media,
    color = "red",
    linewidth = 1.2
  ) +
```

```
  # ±1 desviación estándar
  geom_vline(
    xintercept = media + desv,
```

```


    color = "darkgreen",
    linetype = "dashed",
    linewidth = 1
  ) +

  geom_vline(
    xintercept = media - desv,
    color = "darkgreen",
    linetype = "dashed",
    linewidth = 1
  ) +

  labs(
    title = "Distribución del peso y desviación estándar",
    subtitle = "Línea roja = media | Líneas verdes =  $\pm 1$  desviación estándar",
    x = "Peso (kg)",
    y = "Frecuencia"
  ) +

  theme_minimal()

```



16.2.1 Interpretación


El histograma del peso complementado con la media y la desviación estándar permite analizar tanto la tendencia central como la variabilidad de los datos. La línea roja representa la media del peso de los participantes, mientras que las líneas verdes discontinuas indican un intervalo aproximado de una desviación estándar por encima y por debajo de la media. Este intervalo permite identificar el rango donde se concentra gran parte de las observaciones.

En la distribución analizada se observa que la mayoría de los individuos presentan pesos cercanos a la media, concentrándose principalmente dentro del intervalo delimitado por las líneas de desviación estándar. Sin embargo, también se identifican algunos valores alejados del centro de la distribución, lo que sugiere la presencia de posibles valores atípicos o una dispersión considerable en ciertos casos. Desde el punto de vista estadístico, una desviación estándar

pequeña indica que los datos son más homogéneos y se agrupan cerca de la media; por el contrario, una desviación estándar grande refleja una mayor heterogeneidad y dispersión de los datos.

16.3 Comparar dispersión entre géneros

```
ggplot(datos, aes(x = Peso_Kg)) +  
  
  geom_density(  
    fill = "lightgreen",  
    alpha = 0.5  
  ) +  
  
  labs(  
    title = "Densidad del peso",  
    subtitle = "Visualización de la dispersión de los datos",  
    x = "Peso (kg)",  
    y = "Densidad"  
  ) +  
  
  theme_classic()
```



16.3.1 Interpretación

La curva de densidad representa una versión suavizada de la distribución de los datos y permite visualizar la concentración de observaciones a lo largo de los valores de la variable peso.


Las zonas más altas de la curva indican intervalos donde existe una mayor concentración de individuos, mientras que las áreas más bajas representan valores menos frecuentes. La forma de la curva permite evaluar características importantes de la distribución, tales como: simetría; presencia de sesgo; concentración de datos; posibles agrupamientos y dispersión general.

Si la curva presenta una forma aproximadamente simétrica, puede inferirse que los datos tienden a distribuirse de

manera equilibrada alrededor de la media. En cambio, una cola más larga hacia alguno de los extremos indica asimetría o sesgo en la distribución.

Asimismo, una curva más ancha y extendida refleja mayor dispersión de los datos, mientras que una curva más estrecha indica mayor homogeneidad. La curva de densidad constituye una herramienta útil para comprender visualmente la estructura de la distribución y complementar el análisis realizado mediante histogramas y medidas descriptivas.

```
ggplot(datos, aes(x = Genero, y = Peso_Kg, fill = Genero)) +  
  
  geom_violin(alpha = 0.7) +  
  
  geom_boxplot(  
    width = 0.1,  
    fill = "white"  
  ) +  
  
  labs(  
    title = "Distribución y dispersión del peso",  
    x = "Género",  
    y = "Peso (kg)"  
  ) +  
  
  theme_minimal()
```



16.3.2 Interpretación

El boxplot comparativo del peso según género permite evaluar diferencias en la tendencia central y la dispersión entre los grupos analizados. Cada caja representa el rango intercuartílico de los datos, es decir, el intervalo donde se concentra el 50 % central de las observaciones. La línea ubicada dentro de la caja corresponde a la mediana, mientras que los puntos alejados representan posibles valores atípicos.

A partir de la gráfica es posible identificar: diferencias en la mediana del peso entre géneros; variaciones en la amplitud de las cajas, asociadas al grado de dispersión; presencia de valores extremos; diferencias en la homogeneidad de los grupos.

Un grupo con cajas más amplias y bigotes más extensos presenta mayor variabilidad, indicando que los valores se encuentran más dispersos. Por el contrario, cajas más compactas sugieren una distribución más homogénea. Este tipo de análisis resulta especialmente útil para comparar poblaciones y explorar patrones de comportamiento de variables antropométricas en distintos grupos.

16.4 Resumen gráfico

Las medidas de tendencia central y dispersión son esenciales para describir un conjunto de datos. Su correcta interpretación permite comprender la estructura de la información, identificar patrones y apoyar la toma de decisiones basada en evidencia. En R, estas medidas pueden calcularse de forma sencilla, lo que facilita su aplicación en análisis estadísticos tanto exploratorios como inferenciales.




Figure 16.1: Fuente: Autores

Chapter 17

Medidas de posición y forma

Las medidas de posición y forma constituyen herramientas fundamentales de la estadística descriptiva, ya que permiten profundizar en la comprensión del comportamiento de una distribución de datos más allá de los valores centrales. Mientras las medidas de posición, como los cuartiles, deciles y percentiles, permiten determinar la ubicación relativa de una observación dentro de un conjunto ordenado de datos, las medidas de forma describen características estructurales de la distribución, tales como la simetría y el grado de concentración de las observaciones alrededor de la media.

El estudio conjunto de estas medidas facilita una interpretación más completa de los fenómenos analizados, permitiendo identificar patrones, desigualdades, concentraciones, sesgos y posibles valores extremos. Asimismo, conceptos asociados como el rango intercuartílico, los diagramas de caja y bigotes (boxplots), las curvas percentilares y los histogramas complementan el análisis estadístico mediante representaciones visuales que favorecen la interpretación de los datos.

Estas herramientas poseen amplias aplicaciones en contextos reales como el análisis del rendimiento académico, la clasificación de riesgo, la distribución salarial, los estudios antropométricos y las evaluaciones en salud pública, donde resulta esencial comprender no solo el valor promedio de una variable, sino también la posición relativa y la forma general de su distribución.

Chapter 18

Medidas de posición

Las medidas de posición son indicadores estadísticos que permiten determinar la ubicación relativa de un valor dentro de un conjunto de datos ordenados. Estas medidas dividen la distribución en partes iguales y permiten identificar qué proporción de las observaciones se encuentra por debajo o por encima de un determinado valor.

A diferencia de las medidas de tendencia central, cuyo propósito es resumir el comportamiento típico de los datos mediante un único valor representativo, las medidas de posición permiten describir la distribución desde una perspectiva relativa o acumulativa.

Por ejemplo:

- ¿Qué valor deja por debajo al 25 % de las observaciones?
- ¿Cuál es el punto que supera el 90 % de la población?
- ¿En qué posición relativa se encuentra un estudiante respecto a sus compañeros?

Estas preguntas pueden responderse mediante cuartiles, deciles y percentiles.

18.1 Clasificación de las medidas de posición

Las principales medidas de posición son:

Medida	División de los datos
Cuartiles	4 partes iguales
Deciles	10 partes iguales
Percentiles	100 partes iguales

Todas comparten la misma lógica matemática:

1. ordenar los datos;
2. calcular una posición;
3. identificar el valor correspondiente dentro de la distribución.

Chapter 19

Cuartiles

Los cuartiles son medidas de posición que dividen un conjunto de datos ordenados en cuatro partes iguales, de tal manera que cada grupo contiene aproximadamente el 25 % de las observaciones. Se representan mediante:

Cuartil	Interpretación
Q_1 : primer cuartil	El 25 % de los datos es menor o igual a este valor
Q_2 : segundo cuartil	Corresponde a la mediana; el 50 % de los datos queda por debajo
Q_3 : tercer cuartil	El 75 % de los datos es menor o igual a este valor

19.1 Fórmula de posición

La posición del cuartil se calcula mediante:

$$L_k = \frac{k \cdot n}{4}$$

donde:

- L_k : posición del cuartil,
- k : número del cuartil,
- n : número total de observaciones.

Los cuartiles poseen amplias aplicaciones en diferentes áreas del conocimiento, debido a que permiten dividir una distribución de datos en cuatro partes iguales y analizar la posición relativa de las observaciones dentro de un conjunto ordenado. En estudios antropométricos y ergonómicos, por ejemplo, los cuartiles se utilizan para diseñar mobiliario y espacios adaptados a las características físicas de la población. De igual manera, en evaluación nutricional permiten clasificar individuos según variables como peso, talla o índice de masa corporal.

En el ámbito educativo, los cuartiles facilitan la clasificación académica y la comparación del desempeño relativo de los estudiantes dentro de un grupo. Asimismo, en economía y ciencias sociales son empleados para estudiar la distribución salarial y analizar desigualdades entre diferentes segmentos de la población.

Los cuartiles también constituyen la base de los diagramas de caja y bigotes (boxplots), una representación gráfica ampliamente utilizada para visualizar la distribución de los datos, identificar valores extremos y evaluar la variabilidad de una muestra.

A partir de los cuartiles puede calcularse el rango intercuartílico (RIC), definido como la diferencia entre el tercer y el primer cuartil:

$$RIC = Q_3 - Q_1$$

Esta medida representa la dispersión del 50 % central de los datos y resulta especialmente útil porque no se ve afectada significativamente por valores atípicos o extremos.

Chapter 20

Deciles

Los deciles son medidas de posición que dividen un conjunto de datos ordenados en diez partes iguales, de manera que cada grupo representa el 10 % de las observaciones. Se denotan como:

Decil	Interpretación
D_1	El 10 % de los datos es menor o igual a este valor
D_5	Coincide con la mediana
D_9	El 90 % de los datos queda por debajo

20.1 Fórmula de posición

$$L_k = \frac{k \cdot n}{10}$$

20.2 Aplicaciones de los deciles

Los deciles se utilizan frecuentemente en:

- pruebas estandarizadas,
- análisis socioeconómico,
- estudios de desigualdad,
- distribución de ingresos,
- clasificación poblacional.

Chapter 21

Percentiles

Los percentiles son medidas de posición que dividen un conjunto de datos ordenados en cien partes iguales, donde cada parte representa el 1 % de las observaciones. Se representan mediante: $P_1, P_2, P_3, \dots, P_{99}$. El percentil P_k indica que el $k\%$ de las observaciones es menor o igual a dicho valor. Por ejemplo:

- $P_{25} = Q_1$
- $P_{50} = Q_2$
- $P_{75} = Q_3$

21.1 Fórmula de posición

$$L_k = \frac{k \cdot n}{100}$$

21.2 Aplicaciones de los percentiles

Los percentiles son fundamentales en curvas de crecimiento infantil, evaluación médica, pruebas académicas, clasificación nutricional, análisis de desempeño, entre otras.




Figure 21.1: Fuente: autores

Chapter 22

Medidas de forma

Las medidas de forma permiten describir la estructura general de una distribución estadística, evaluando características como: simetría, concentración, colas extremas, comportamiento alrededor de la media. Las principales medidas de forma son: asimetría y curtosis.

22.1 Asimetría

La asimetría evalúa el grado de sesgo de una distribución.

Tipo	Característica
Simétrica	Ambos lados son similares
Asimetría positiva	Cola hacia la derecha
Asimetría negativa	Cola hacia la izquierda

22.2 Curtosis

La curtosis describe el grado de concentración de los datos alrededor de la media.

Tipo	Característica
Leptocúrtica	Distribución alta y concentrada
Mesocúrtica	Similar a distribución normal
Platicúrtica	Distribución achatada

MEDIDAS DE FORMA

Describen la estructura general de una distribución estadística.
Permiten evaluar la simetría y la concentración de los datos.




Figure 22.1: Fuente: autores

Chapter 23

Análisis bivariado

En los capítulos anteriores se estudiaron las características de una sola variable a la vez —su centro, su dispersión, su forma—. Sin embargo, la realidad que analiza la estadística rara vez involucra una variable en soledad. Las preguntas más interesantes suelen surgir en la intersección: ¿Estudiar más horas se traduce en mejores calificaciones? ¿El género de un estudiante se relaciona con su rendimiento académico? ¿Cuánto mejora la nota por cada hora adicional de estudio?

El análisis bivariado es precisamente el conjunto de técnicas que permite explorar, cuantificar e interpretar la relación entre dos variables medidas sobre las mismas unidades de análisis. A diferencia del análisis univariado, aquí el interés no está en describir cada variable por separado, sino en entender cómo se comportan conjuntamente.

Este capítulo desarrolla las principales herramientas del análisis bivariado: el diagrama de dispersión como recurso visual exploratorio, la covarianza como primera medida de relación lineal, los coeficientes de correlación de Pearson y Spearman para cuantificar esa relación, las tablas de contingencia para variables categóricas, y la regresión lineal simple como modelo predictivo. Todas estas técnicas se ilustran sobre el mismo conjunto de datos, lo que permite al estudiante ver cómo cada herramienta revela una faceta distinta de la misma realidad.

7.1 Conjunto de datos de trabajo A lo largo de todo este capítulo se utilizará el siguiente conjunto de datos, que recoge información sobre 15 estudiantes universitarios. Las variables registradas son: horas de estudio semanales (X), calificación final en una escala de 0 a 5 (Y), horas de sueño diarias (Z) y género. Este dataset es intencionalmente multidisciplinar para permitir ilustrar distintos tipos de análisis bivariado.

Tabla 7.1. Dataset transversal — 15 estudiantes universitarios

Estudiante	Horas de estudio (X)	Calificación (Y)	Horas de sueño (Z)	Género
E01	2	3.2	6	M
E02	3	3.5	7	F
E03	5	4.0	7	M
E04	1	2.8	5	F
E05	4	3.8	8	M
E06	6	4.3	6	F
E07	2	3.0	6	M
E08	7	4.5	7	F
E09	3	3.4	8	M
E10	5	4.1	7	F
E11	1	2.5	5	M
E12	4	3.7	6	F
E13	6	4.2	7	M
E14	2	3.1	6	F
E15	8	4.8	8	M

Nota: Los datos de esta tabla son simulados con fines pedagógicos. Para el análisis de correlación y regresión se trabaja con las variables X (horas de estudio) e Y (calificación).

7.2 Diagrama de dispersión 7.2.1 Definición El diagrama de dispersión (también llamado nube de puntos o gráfico de dispersión) es una representación gráfica que muestra la distribución conjunta de dos variables cuantitativas. Cada punto del plano cartesiano representa una observación: su posición horizontal corresponde al valor de la variable X y su posición vertical al valor de la variable Y. Es siempre el primer paso en el análisis de la relación entre dos variables numéricas, porque permite detectar visualmente el tipo, la dirección y la fuerza de la relación antes de calcular ningún coeficiente (Montgomery & Runger, 2018).

7.2.2 Patrones de asociación La inspección visual de un diagrama de dispersión permite identificar los siguientes patrones principales:

- Relación lineal positiva: a medida que X aumenta, Y también tiende a aumentar. Los puntos se agrupan aproximadamente sobre una recta con pendiente positiva.
- Relación lineal negativa: a medida que X aumenta, Y tiende a disminuir. Los puntos se distribuyen alrededor de una recta con pendiente negativa.
- Relación no lineal (curvilínea): los puntos siguen un patrón curvado —cuadrático, exponencial, logístico— que no puede describirse bien mediante una recta.
- Sin relación aparente: los puntos se dispersan aleatoriamente sin ningún patrón discernible.

7.2.3 Ejemplo resuelto Con los datos de la Tabla 7.1, se construye el diagrama de dispersión entre horas de estudio (X) y calificación final (Y):

Chapter 24

Código en R

Chapter 25

Diagrama de dispersión: horas de estudio vs. calificación

```
horas <- c(2,3,5,1,4,6,2,7,3,5,1,4,6,2,8) calif <- c(3.2,3.5,4.0,2.8,3.8,4.3,3.0,4.5,3.4,4.1,2.5,3.7,4.2,3.1,4.8) genero <- c('M','F','M','F','M','F','M','F','M','F','M','F','M','F','M')
```

```
plot(horas, calif, main = 'Diagrama de dispersión: Estudio vs. Calificación', xlab = 'Horas de estudio semanales (X)', ylab = 'Calificación final (Y)', pch = 19, col = ifelse(genero == 'M', '#2E75B6', '#C00000'), cex = 1.4) abline(lm(calif ~ horas), col = 'gray40', lty = 2, lwd = 1.5) legend('topleft', legend = c('Masculino','Femenino'), col = c('#2E75B6','#C00000'), pch = 19, bty = 'n')
```

Interpretación: La nube de puntos muestra una relación lineal positiva muy marcada entre las horas de estudio y la calificación obtenida. Los puntos se agrupan estrechamente alrededor de una recta imaginaria ascendente, lo que anticipa una correlación alta. No se observan valores atípicos extremos que distorsionen el patrón general.

7.2.4 Aplicación disciplinar En ciencias de la salud, un diagrama de dispersión entre dosis de un fármaco y respuesta terapéutica permite identificar visualmente si existe una relación dosis-respuesta y si esa relación es lineal o presenta una meseta a partir de cierta dosis. En ciencias sociales, la relación entre índice de pobreza y tasa de deserción escolar puede explorarse con este gráfico antes de aplicar técnicas de regresión.

7.2.5 Ejercicios propuestos Ejercicio 1. Con los datos de la Tabla 7.1, construya manualmente el diagrama de dispersión entre horas de sueño (Z) y calificación (Y). ¿Qué tipo de relación anticipa? Ejercicio 2. En un estudio sobre producción agrícola se miden: temperatura promedio mensual (°C) y rendimiento en kg/hectárea. Diseñe el diagrama de dispersión e identifique visualmente si la relación parece lineal o curvilínea. Ejercicio 3. Usando R, reproduzca el diagrama de la sección 7.2.3 pero diferenciando los puntos por calificación alta ($Y \geq 4.0$) y baja ($Y < 4.0$). ¿Qué observa?

7.3 Covarianza 7.3.1 Definición La covarianza es la primera medida numérica de la relación lineal entre dos variables cuantitativas. Mide en qué dirección y en qué magnitud tienden a desplazarse conjuntamente los valores de X e Y respecto a sus respectivas medias (Walpole, Myers & Myers, 2012). Si cuando X está por encima de su media, Y también tiende a estarlo, la covarianza es positiva. Si ocurre lo contrario, es negativa.

7.3.2 Fórmula Para una muestra de n pares de observaciones (x_i, y_i), la covarianza muestral se calcula como: $S_{xy} = \sum[(x_i - \bar{x})(y_i - \bar{y})] / (n - 1)$ donde $\bar{x}$ y $\bar{y}$ son las medias muestrales de X e Y, respectivamente. Para la covarianza poblacional se divide entre N (tamaño de la población) en lugar de (n - 1).

Nota: La covarianza tiene un problema fundamental: su valor depende de las unidades de medición de X e Y. Si X se midiera en minutos en lugar de horas, la covarianza cambiaría aunque la relación entre las variables sea idéntica. Esto limita su interpretabilidad directa y motivó el desarrollo del coeficiente de correlación.

7.3.3 Ejemplo resuelto Con los datos de la Tabla 7.1 (n = 15): media de horas de estudio $\bar{x} = 3.93$; media de calificación $\bar{y} = 3.79$.

Calculando cada término $(x_i - \bar{x})(y_i - \bar{y})$ y sumando: $S_{xy} = \sum[(x_i - 3.93)(y_i - 3.79)] / 14 = 20.28 / 14 \approx 1.449$

Chapter 26

Código en R

Chapter 27

Covarianza entre horas de estudio y calificación

```
horas <- c(2,3,5,1,4,6,2,7,3,5,1,4,6,2,8) calif <- c(3.2,3.5,4.0,2.8,3.8,4.3,3.0,4.5,3.4,4.1,2.5,3.7,4.2,3.1,4.8)
```

```
cov_xy <- cov(horas, calif) cat('Covarianza Sxy =', round(cov_xy, 3)) # Resultado: Covarianza Sxy = 1.449
```

Interpretación: La covarianza positiva ($S_{xy} \approx 1.449$) confirma que existe una relación directa entre las horas de estudio y la calificación: en general, cuando un estudiante estudia más horas que el promedio del grupo, también tiende a obtener una calificación por encima del promedio. Sin embargo, el valor 1.449 por sí solo no indica si la relación es fuerte o débil; para eso se necesita estandarizar mediante el coeficiente de correlación.

7.3.4 Aplicación disciplinar En economía, la covarianza entre el retorno de dos activos financieros es fundamental para la teoría de portafolios de Markowitz: una covarianza positiva alta indica que los activos se mueven juntos, lo que reduce la diversificación del riesgo. En epidemiología, la covarianza entre exposición a un factor de riesgo y la gravedad de una enfermedad orienta la dirección de la relación antes de modelarla formalmente.

7.3.5 Ejercicios propuestos Ejercicio 1. Calcule manualmente la covarianza entre horas de sueño (Z) y calificación (Y) usando los datos de la Tabla 7.1. Compare el signo con el diagrama de dispersión que construyó en el ejercicio 7.2.1. Ejercicio 2. Si se duplicaran todos los valores de horas de estudio ($2X$), ¿qué le ocurriría a la covarianza S_{xy} ? Demuéstrelo algebraicamente y verifíquelo con R. Ejercicio 3. En un conjunto de datos con covarianza $S_{xy} = -3.2$, ¿qué puede concluirse sobre la dirección de la relación entre X e Y ? ¿Puede afirmarse que la relación es fuerte? Justifique.

7.4 Correlación de Pearson 7.4.1 Definición El coeficiente de correlación lineal de Pearson es una medida adimensional que cuantifica la fuerza y la dirección de la relación lineal entre dos variables cuantitativas continuas. A diferencia de la covarianza, está estandarizado en el intervalo $[-1, 1]$, lo que permite comparar relaciones entre variables con distintas unidades de medición (Devore, 2016).

7.4.2 Fórmula El coeficiente de correlación muestral de Pearson se obtiene dividiendo la covarianza entre el producto de las desviaciones estándar de X e Y : $r = S_{xy} / (S_x \cdot S_y)$ de forma equivalente: $r = \Sigma[(x_i - \bar{x})(y_i - \bar{y})] / \sqrt{\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2}$

7.4.3 Interpretación del coeficiente La interpretación del valor de r sigue la siguiente escala orientativa (Cohen, 1988):

- $|r|$ entre 0.00 y 0.19: relación muy débil o nula.
- $|r|$ entre 0.20 y 0.39: relación débil.
- $|r|$ entre 0.40 y 0.59: relación moderada.
- $|r|$ entre 0.60 y 0.79: relación fuerte.
- $|r|$ entre 0.80 y 1.00: relación muy fuerte o casi perfecta.

Nota: El signo indica la dirección: $r > 0$ relación directa (ambas variables aumentan juntas); $r < 0$ relación inversa (cuando una aumenta, la otra disminuye); $r = 0$ ausencia de relación lineal (puede existir relación no lineal).

7.4.4 Supuestos El coeficiente de Pearson asume que: (1) las dos variables son cuantitativas continuas; (2) la relación entre ellas es aproximadamente lineal; (3) los datos no presentan valores atípicos extremos influyentes; y (4) idealmente, ambas variables siguen una distribución normal bivariada. Cuando estos supuestos no se cumplen, debe emplearse la correlación de Spearman.

7.4.5 Ejemplo resuelto Con los datos de la Tabla 7.1 se calculan: $S_{xy} \approx 1.449$, $S_x \approx 2.052$, $S_y \approx 0.648$. $r = 1.449 / (2.052 \times 0.648) = 1.449 / 1.330 \approx 0.989$

Chapter 28

Código en R

Chapter 29

Correlación de Pearson y matriz de correlaciones

```
horas <- c(2,3,5,1,4,6,2,7,3,5,1,4,6,2,8) calif <- c(3.2,3.5,4.0,2.8,3.8,4.3,3.0,4.5,3.4,4.1,2.5,3.7,4.2,3.1,4.8) suenio <- c(6,7,7,5,8,6,6,7,8,7,5,6,7,6,8)
```

Chapter 30

Pearson entre horas y calificación

```
r_pearson <- cor(horas, calif, method = 'pearson') cat('r de Pearson (horas vs calif) =', round(r_pearson, 3))
```

Chapter 31

Matriz de correlaciones para las tres variables numéricas

```
datos_num <- data.frame(horas, calif, suenio) round(cor(datos_num, method = 'pearson'), 3)
```

Tabla 7.2. Matriz de correlaciones de Pearson Par de variables r de Pearson Interpretación Horas estudio – Calificación 0.989 Muy alta positiva Horas estudio – Horas sueño 0.412 Moderada positiva Horas sueño – Calificación 0.398 Moderada positiva

Interpretación: $r = 0.989$ indica una relación lineal positiva muy fuerte entre horas de estudio y calificación: el 97.8% de la variación en las calificaciones (r^2) puede explicarse por la variación en las horas de estudio. La relación entre horas de estudio y horas de sueño ($r = 0.412$) es moderada y positiva, sugiriendo que los estudiantes que más estudian también tienden a dormir algo más, aunque la relación es menos consistente.

7.4.6 Aplicación disciplinar En psicometría, la correlación de Pearson se usa para evaluar la validez convergente de una prueba: se espera que dos instrumentos que miden el mismo constructo presenten $r > 0.70$. En medicina, la correlación entre biomarcadores (p. ej., glucosa en sangre y hemoglobina glicosilada) sirve para validar mediciones indirectas. En ingeniería, la correlación entre variables de proceso (temperatura y presión en una reacción) orienta el diseño de experimentos.

7.4.7 Ejercicios propuestos Ejercicio 1. Calcule manualmente el coeficiente de Pearson entre horas de sueño (Z) y calificación (Y). Interprete el resultado usando la escala de Cohen (1988). Ejercicio 2. ¿Qué ocurre con r si se suma una constante k a todos los valores de X ? ¿Y si se multiplican todos los valores de X por una constante $k > 0$? Demuéstrelo con los datos de la Tabla 7.1. Ejercicio 3. Un investigador obtiene $r = 0.85$ entre el número de horas de televisión y el índice de masa corporal en 200 niños. ¿Puede concluir que ver televisión causa obesidad? Justifique su respuesta desde la perspectiva estadística.

7.5 Correlación de Spearman 7.5.1 Definición El coeficiente de correlación por rangos de Spearman (ρ , ρ_{ho}) es una medida no paramétrica de la asociación monótona entre dos variables. Fue propuesto por Charles Spearman en 1904 y opera sobre los rangos (posiciones en el ordenamiento) de los datos, no sobre los valores originales (Siegel & Castellan, 1988). Es la alternativa indicada cuando los datos son ordinales, cuando la relación no es lineal pero sí monótona, o cuando se presentan valores atípicos que distorsionarían a Pearson.

7.5.2 Fórmula Cuando no hay empates o estos son poco frecuentes, ρ se calcula mediante la fórmula simplificada: $\rho = 1 - (6 \cdot \sum d_i^2) / (n(n^2 - 1))$ donde $d_i = \text{Rango}(x_i) - \text{Rango}(y_i)$ es la diferencia entre los rangos de cada par de observaciones, y n es el número de pares. Cuando hay empates, deben promediarse los rangos y es preferible calcular ρ aplicando la fórmula de Pearson directamente sobre los rangos.

7.5.3 Ejemplo resuelto Con los datos de la Tabla 7.1 se asignan rangos a X e Y . Los empates en X (valores 1, 2, 3, 4, 5, 6) reciben rangos promedio:

Tabla 7.3. Rangos y diferencias al cuadrado para la correlación de Spearman Estud. X (horas) Y (calif.) Rango X Rango Y d^2 E01 2 3.2 3.5 3 0.25 E02 3 3.5 6 6 0 E03 5 4.0 9.5 10 0.25 E04 1 2.8 1.5 1 0 E05 4 3.8 7.5 8 0.25 E06 6

4.3 11.5 13 2.25 E07 2 3.0 3.5 2 2.25 E08 7 4.5 13.5 14 0.25 E09 3 3.4 6 5 1 E10 5 4.1 9.5 11 2.25 E11 1 2.5 1.5 0 2.25
E12 4 3.7 7.5 7 0.25 E13 6 4.2 11.5 12 0.25 E14 2 3.1 3.5 4 0.25 E15 8 4.8 15 15 0 Σd^2 11.75

$$\rho = 1 - (6 \times 11.75) / (15 \times (225 - 1)) = 1 - 70.5 / 3360 = 1 - 0.021 \approx 0.979$$

Chapter 32

Código en R

Chapter 33

Correlación de Spearman

```
horas <- c(2,3,5,1,4,6,2,7,3,5,1,4,6,2,8) calif <- c(3.2,3.5,4.0,2.8,3.8,4.3,3.0,4.5,3.4,4.1,2.5,3.7,4.2,3.1,4.8)
rho_spearman <- cor(horas, calif, method = 'spearman') cat('Rho de Spearman =', round(rho_spearman, 3))
```

Chapter 34

Prueba de significancia

```
cor.test(horas, calif, method = 'spearman')
```

Interpretación: $\rho = 0.979$ indica una asociación monótona positiva muy fuerte entre las horas de estudio y la calificación. El resultado es prácticamente idéntico al de Pearson ($r = 0.989$), lo que confirma que la relación es esencialmente lineal y que no hay valores atípicos influyentes que estén distorsionando el coeficiente paramétrico. En general, Pearson y Spearman convergen cuando se cumplen los supuestos de Pearson.

7.5.4 Pearson vs. Spearman: ¿cuándo usar cada uno? La siguiente regla práctica orienta la elección: • Use Pearson cuando las variables sean continuas, la relación sea lineal y no haya valores atípicos extremos. • Use Spearman cuando los datos sean ordinales, la relación sea monótona no lineal, o cuando haya valores atípicos que no pueden eliminarse. • Si ambos producen resultados similares, la relación es lineal y no hay problemas de supuestos. • Si difieren notablemente, investigue la causa: valores atípicos, no linealidad, o escala ordinal.

7.5.5 Aplicación disciplinar En educación, la correlación de Spearman es apropiada para estudiar la relación entre el puesto en el ranking de una institución (variable ordinal) y la satisfacción estudiantil. En ciencias de la salud, se usa para medir la asociación entre el estadio clínico de una enfermedad (I, II, III, IV) y la respuesta al tratamiento. En administración, permite analizar la relación entre la posición jerárquica de los empleados y su nivel de compromiso organizacional.

7.5.6 Ejercicios propuestos Ejercicio 1. Calcule el coeficiente de Spearman entre horas de sueño (Z) y calificación (Y). Compare con el Pearson obtenido en el ejercicio 7.4.1 y discuta las diferencias. Ejercicio 2. Un investigador agrega al dataset un estudiante atípico: 20 horas de estudio y calificación 2.0. Calcule Pearson y Spearman con y sin este dato. ¿Cuál coeficiente es más robusto? ¿Por qué? Ejercicio 3. Clasifique como ordinales las calificaciones de la Tabla 7.1 en cuatro categorías (Deficiente: <3.0 , Básico: $3.0-3.4$, Alto: $3.5-3.9$, Superior: $4.0-5.0$) y calcule ρ de Spearman entre esta nueva variable ordinal y los rangos de horas de estudio.

7.6 Tablas de contingencia 7.6.1 Definición Una tabla de contingencia (también llamada tabla de doble entrada o tabla cruzada) es una representación matricial que organiza la distribución conjunta de dos variables categóricas. Las filas corresponden a las categorías de una variable y las columnas a las categorías de la otra; cada celda interior contiene el número de observaciones que pertenecen simultáneamente a ambas categorías. Los totales marginales (sumas por filas y columnas) permiten calcular frecuencias relativas condicionales y aplicar pruebas de independencia (Agresti, 2013).

7.6.2 Estructura y elementos Una tabla de contingencia de $r \times c$ (r filas, c columnas) tiene los siguientes elementos: • Frecuencias absolutas (n_{ij}): número de casos en la celda (i, j). • Frecuencias marginales de fila ($n_{i\cdot}$): total de la fila i ; suma de todas las celdas de esa fila. • Frecuencias marginales de columna ($n_{\cdot j}$): total de la columna j . • Frecuencias relativas conjuntas ($f_{ij} = n_{ij} / n$): proporción de casos en la celda (i, j) respecto al total. • Frecuencias relativas condicionales por fila ($n_{ij} / n_{i\cdot}$): distribución de Y dentro de cada categoría de X .

7.6.3 Ejemplo resuelto Con los datos de la Tabla 7.1 se cruzan las variables género (M / F) y nivel de calificación (Baja: $Y < 3.5$; Alta: $Y \geq 3.5$):

Tabla 7.4. Tabla de contingencia: nivel de calificación $\times$ género

Calificación / Género	Masculino	Femenino	Total
Baja (< 3.5)	4	2	6
Alta (≥ 3.5)	4	5	9
Total	8	7	15

Chapter 35

Código en R

Chapter 36

Tabla de contingencia en R

```
calif<- c(3.2,3.5,4.0,2.8,3.8,4.3,3.0,4.5,3.4,4.1,2.5,3.7,4.2,3.1,4.8) genero<- c('M','F','M','F','M','F','M','F','M','F','M','F','M','F','M','F',  
nivel_calif<- ifelse(calif >= 3.5, 'Alta', 'Baja')  
  
tabla <- table(Calificacion = nivel_calif, Genero = genero) print(tabla) addmargins(tabla) # con totales marginales  
prop.table(tabla) # frecuencias relativas conjuntas prop.table(tabla, margin = 1) # condicional por fila (nivel)  
prop.table(tabla, margin = 2) # condicional por columna (género)
```

Chapter 37

Prueba chi-cuadrado de independencia

`chisq.test(tabla)`

Interpretación: Del total de 15 estudiantes, 9 (60%) tienen calificación alta y 6 (40%) calificación baja. Entre los hombres, el 50% tiene calificación alta; entre las mujeres, el 71.4%. La diferencia sugiere una asociación entre género y nivel de calificación, aunque con una muestra tan pequeña la prueba chi-cuadrado puede carecer de potencia suficiente. Con muestras mayores, esta tendencia podría investigarse con mayor rigor estadístico.

7.6.4 Aplicación disciplinar En epidemiología, las tablas de contingencia 2×2 son la herramienta fundamental para calcular la razón de odds (OR) y el riesgo relativo (RR) en estudios caso-control y cohortes. En marketing, permiten cruzar segmento de cliente con preferencia de producto para identificar patrones de consumo. En educación, se usan para analizar si la modalidad de estudio (presencial / virtual) se asocia con la aprobación o reprobación de asignaturas.

7.6.5 Ejercicios propuestos Ejercicio 1. Construya una tabla de contingencia 3×2 cruzando nivel de calificación en tres categorías (Baja: <3.0 , Media: $3.0-3.9$, Alta: ≥ 4.0) con el género. Calcule las frecuencias condicionales por columna. Ejercicio 2. Con la tabla del ejercicio anterior, calcule en R la prueba chi-cuadrado de Pearson. ¿Se puede concluir que existe asociación entre género y nivel de calificación? Justifique con base en el valor p. Ejercicio 3. Un estudio sobre hábitos alimentarios registra el tipo de dieta (omnívora / vegetariana / vegana) y la presencia de anemia (sí / no) en 200 personas. Construya la estructura de una tabla de contingencia para este caso e identifique cuántas celdas tendría.

7.7 Regresión lineal simple **7.7.1 Definición** La regresión lineal simple es un modelo estadístico que describe la relación entre una variable dependiente o respuesta (Y) y una variable independiente o predictora (X) mediante una función lineal. A diferencia de la correlación —que solo mide la fuerza de la asociación—, la regresión permite cuantificar la magnitud del cambio en Y asociado a un cambio unitario en X, y puede usarse para realizar predicciones dentro del rango de los datos observados (Montgomery, Peck & Vining, 2012).

7.7.2 El modelo El modelo de regresión lineal simple tiene la forma: $\hat{Y} = \beta_0 + \beta_1 X$ donde $\hat{Y}$ es el valor predicho de Y, β_0 es el intercepto (valor esperado de Y cuando $X = 0$), β_1 es la pendiente (cambio esperado en Y por cada unidad de incremento en X), y X es el valor de la variable predictora. Los parámetros β_0 y β_1 se estiman mediante el método de mínimos cuadrados ordinarios (MCO), que minimiza la suma de los cuadrados de los residuos (diferencias entre valores observados y predichos).

7.7.3 Estimación de los parámetros Las fórmulas de estimación por MCO para la muestra son: $b_1 = S_{xy} / S_x^2 = \Sigma[(x_i - \bar{x})(y_i - \bar{y})] / \Sigma(x_i - \bar{x})^2$ $b_0 = \bar{y} - b_1 \cdot \bar{x}$

7.7.4 Coeficiente de determinación R^2 El coeficiente de determinación R^2 mide la proporción de la variabilidad total de Y que es explicada por el modelo de regresión: $R^2 = r^2$ (en regresión simple) R^2 varía entre 0 y 1. Un $R^2 = 0.95$ significa que el 95% de la variación en Y queda explicada por X mediante el modelo lineal. El 5% restante corresponde a la variación no explicada (residual).

7.7.5 Ejemplo resuelto Con los datos de la Tabla 7.1: $S_{xy} \approx 1.449$, $S_x^2 \approx 4.210$. $b_1 = 1.449 / 4.210 \approx 0.344$ $b_0 = 3.79 - 0.344 \times 3.93 \approx 2.438$ Modelo estimado: $\hat{Y} = 2.438 + 0.344X$ $R^2 = (0.989)^2 \approx 0.978$

Chapter 38

Código en R

Chapter 39

Regresión lineal simple: calificación ~ horas de estudio

```
horas <- c(2,3,5,1,4,6,2,7,3,5,1,4,6,2,8) calif <- c(3.2,3.5,4.0,2.8,3.8,4.3,3.0,4.5,3.4,4.1,2.5,3.7,4.2,3.1,4.8)
modelo <- lm(calif ~ horas) summary(modelo)
```

Chapter 40

Gráfico de regresión con intervalo de confianza

```
plot(horas, calif, main = 'Regresión lineal: Calificación ~ Horas de estudio', xlab = 'Horas de estudio semanales (X)',  
ylab = 'Calificación (Y)', pch = 19, col = '#2E75B6', cex = 1.3) abline(modelo, col = '#C00000', lwd = 2)
```

Chapter 41

Predicción para un estudiante que estudia 6 horas

```
nuevo <- data.frame(horas = 6) predict(modelo, newdata = nuevo, interval = 'confidence', level = 0.95)
```

Interpretación: El modelo estimado $\hat{Y} = 2.438 + 0.344X$ indica que, en promedio, por cada hora adicional de estudio semanal, la calificación aumenta 0.344 puntos. Un estudiante que estudia 6 horas semanales tendría una calificación predicha de $2.438 + 0.344(6) = 4.50$ puntos. El $R^2 = 0.978$ señala que el 97.8% de la variación en las calificaciones queda explicada por las horas de estudio, lo que indica un ajuste excelente del modelo para estos datos.

Nota: La regresión permite predecir, pero no debe extrapolarse fuera del rango observado de X (1–8 horas). Una predicción para 20 horas de estudio, por ejemplo, podría producir una calificación mayor que 5, lo cual es imposible en la escala utilizada.

7.7.6 Aplicación disciplinar En ciencias de la salud, la regresión lineal simple permite estimar la dosis de medicamento necesaria para alcanzar un nivel terapéutico objetivo. En ingeniería, se usa para modelar la relación entre temperatura de operación y desgaste de componentes. En economía, relaciona el ingreso familiar con el gasto en educación. En ciencias sociales, modela la relación entre años de escolaridad e ingresos laborales.

7.7.7 Ejercicios propuestos Ejercicio 1. Estime el modelo de regresión lineal simple entre horas de sueño (Z , variable predictora) y calificación (Y , variable respuesta). Interprete b_0 , b_1 y R^2 . Ejercicio 2. Use el modelo estimado en la sección 7.7.5 para predecir la calificación de un estudiante que estudia 4.5 horas semanales. ¿Cuál es el intervalo de confianza al 95% para esa predicción en R ? Ejercicio 3. ¿Por qué el coeficiente de determinación R^2 en regresión lineal simple es igual al cuadrado de la correlación de Pearson r ? Demuéstrelo algebraicamente a partir de las fórmulas de ambos estadísticos. Ejercicio 4. Con los datos de la Tabla 7.1, construya el gráfico de residuos (residuos vs. valores predichos). ¿Se observa algún patrón sistemático? ¿Qué implicaría eso para la validez del modelo?

7.8 Síntesis y relación entre las herramientas del análisis bivariado A lo largo de este capítulo se han desarrollado seis herramientas complementarias que, aplicadas sobre el mismo conjunto de datos, han revelado distintas facetas de la relación entre horas de estudio y calificación académica. La siguiente tabla sintetiza las principales características de cada técnica:

Técnica	Tipo de variables	Qué mide	Resultado del ejemplo
Diagrama de dispersión	Cuantitativas	Patrón visual de asociación	Relación lineal positiva fuerte
Covarianza	Cuantitativas	Dirección de la relación	$S_{xy} = 1.449$ (positiva)
Correlación de Pearson	Cuantitativas continuas	Fuerza y dirección lineal	$r = 0.989$ (muy fuerte)
Correlación de Spearman	Ordinales o cuantitativas	Asociación monótona	$\rho = 0.979$ (muy fuerte)
Tabla de contingencia	Catégoricas	Distribución conjunta	Tendencia: mujeres con mayor calificación
Regresión lineal simple	Cuantitativas	Modelo predictivo lineal	$\hat{Y} = 2.438 + 0.344X$; $R^2 = 0.978$

Una conclusión metodológica fundamental de este capítulo es la siguiente: correlación no implica causalidad. El hecho de que $r = 0.989$ entre horas de estudio y calificación sea muy alto no permite concluir que estudiar más horas cause mejores calificaciones en sentido estricto. Pueden existir variables de confusión (motivación, capacidad cognitiva,

calidad del estudio) que expliquen parte de la relación. La causalidad requiere diseños de investigación específicos —experimentos controlados, estudios longitudinales— que van más allá del análisis bivariado descriptivo.

Nota: Antes de aplicar cualquiera de estas técnicas en un estudio real, verifique los supuestos correspondientes, inspeccione visualmente los datos y evalúe la presencia de valores atípicos. Un análisis bivariado riguroso siempre comienza con el diagrama de dispersión.

7.9 Ejercicios integradores

Los siguientes ejercicios requieren integrar varias de las técnicas desarrolladas en el capítulo:

Ejercicio 1. Un grupo de investigadores registra en 20 pacientes hipertensos: presión arterial sistólica (mmHg), edad (años), índice de masa corporal (IMC) y consumo de sodio diario (mg). (a) Construya la matriz de diagramas de dispersión (pairs() en R). (b) Calcule la matriz de correlaciones de Pearson. (c) Identifique el par de variables con mayor correlación y estime el modelo de regresión lineal simple correspondiente. (d) Interprete b_1 y R^2 en términos del problema.

Ejercicio 2. En una encuesta a 50 estudiantes de una facultad de ingeniería se registra: semestre académico (1–10), promedio acumulado (0–5), modalidad de aprendizaje preferida (visual / auditiva / kinestésica) y horas semanales de uso de herramientas digitales. (a) ¿Cuál técnica bivariada usaría para analizar la relación entre semestre y promedio? Justifique. (b) ¿Cuál técnica usaría para analizar la relación entre modalidad de aprendizaje y aprobación del semestre (sí/no)? (c) Diseñe el código R para ambos análisis.

Ejercicio 3. Se afirma que en una empresa de manufactura existe una relación entre el número de horas de capacitación recibidas por los operarios y el número de defectos producidos en su turno. Se tienen los datos de 12 operarios. (a) Estime el modelo de regresión lineal simple. (b) Interprete la pendiente en el contexto del problema. (c) Si la empresa decide aumentar la capacitación de 8 a 12 horas, ¿cuántos defectos menos esperaría según el modelo? (d) ¿Cuál sería el R^2 mínimo que justificaría usar este modelo para tomar decisiones operativas?

Referencias Agresti, A. (2013). *Categorical data analysis* (3.^a ed.). Wiley. Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.^a ed.). Lawrence Erlbaum Associates. Devore, J. L. (2016). *Probability and statistics for engineering and the sciences* (9.^a ed.). Cengage Learning. Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to linear regression analysis* (5.^a ed.). Wiley. Montgomery, D. C., & Runger, G. C. (2018). *Applied statistics and probability for engineers* (7.^a ed.). Wiley. Siegel, S., & Castellan, N. J. (1988). *Nonparametric statistics for the behavioral sciences* (2.^a ed.). McGraw-Hill. Walpole, R. E., Myers, R. H., & Myers, S. L. (2012). *Probability and statistics for engineers and scientists* (9.^a ed.). Pearson.

References

- Agresti, A. (2018). *Statistical methods for the social sciences* (5th ed.). Pearson.
- Armitage, P., Berry, G., & Matthews, J. N. S. (2002). *Statistical methods in medical research*. Blackwell Science.
- Bonita, R., Beaglehole, R., & Kjellström, T. (2008). *Epidemiología básica*. Organización Panamericana de la Salud.
- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate data analysis* (8th ed.). Cengage Learning.
- Kleinbaum, D. G., & Klein, M. (2012). *Survival analysis: A self-learning text* (3rd ed.). Springer.
- Obando, L. (2021). *Gráficos estadísticos y análisis de datos con r*. Editorial Académica.
- Posada, C. (2016). *Elementos de estadística*. Editorial Académica.
- Rey, J. (2007). *Introducción a la estadística*. Editorial Universitaria.
- Seoane, T. et al. (2007). *Estadística aplicada*. Editorial Académica.
- Spiegel, M. R., & Stephens, L. J. (2009). *Estadística*. McGraw-Hill.
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.
- Van den Broeck, J., Cunningham, S. A., Eeckels, R., & Herbst, K. (2005). Data cleaning: Detecting, diagnosing, and editing data abnormalities. *PLoS Medicine*, 2(10), e267. <https://doi.org/10.1371/journal.pmed.0020267>
- Wickham, H., & Grolemund, G. (2017). *R for data science: Import, tidy, transform, visualize, and model data*. O'Reilly Media.
- Wooldridge, J. M. (2016). *Introductory econometrics: A modern approach* (6th ed.). Cengage Learning.