

Estadística Experiencial Aplicada

Aprendizaje práctico de la estadística descriptiva con R

Francisco Javier León Miguel Oswaldo Pérez Pulido
Leonardo Andrés Pinto Guarguati

2026-03-24

Tabla de contenido

Prefacio	2
1. Introducción	3
2. Autores	4
2.0.1. Francisco Javier León	4
2.0.2. Miguel Oswaldo Pérez Pulido	4
2.0.3. Leonardo Andrés Pinto Guarguati	5
3. Introducción a la estadística descriptiva	6
3.1. ¿Qué es la estadística descriptiva?	6
3.2. Tipos de variables	6
3.3. Importancia de la identificación de variables estadísticas y escalas de medición	7
3.4. Escalas de medición	8
3.5. Base de datos de trabajo	10
3.5.1. ¿Qué estamos haciendo?	12
3.5.2. Reflexión del estudiante	12
3.6. Diccionario de datos	12
3.7. Actividad experiencial	13
3.7.1. Explorando una base de datos del DANE	13
3.8. Flujo general del análisis de datos	16
3.9. Mini reto analítico	16
4. Preparación de datos	18
4.1. Carga de datos en R	18
4.2. Limpieza de datos	19
5. Organización de datos y tablas estadísticas	21
5.1. Datos simples	21
5.2. Datos agrupados	21
5.3. Tablas de frecuencia	22
5.3.1. Frecuencia absoluta	22
5.3.2. Frecuencia relativa	22
5.3.3. Frecuencia acumulada	22
5.3.4. Frecuencia relativa acumulada	23
5.4. Ejemplo de tabla de frecuencia: Variable P_S7P97	23
5.5. Estructura general de una tabla de frecuencia	24
5.6. Marca de clase	25
5.7. Organización de datos en contextos reales	26
5.8. Actividad Experiencial	26
5.8.1. Situación problema	26
5.8.2. Ejemplo: Género	28
5.9. Ejemplo: Peso corporal	30

5.10. Actividad experiencial: Organización de datos y tablas estadísticas	30
5.10.1. Objetivos de aprendizaje	30
5.11. Desarrollo de la actividad	31
5.11.1. Parte 1. Exploración inicial de los datos	31
5.11.2. Parte 2. Identificación de variables	32
5.11.3. Parte 3. Organización y análisis del peso corporal	32
5.12. Situación problema	32
5.12.1. Parte 4. Preguntas orientadoras	32
5.12.2. Parte 5. Construcción de tablas agrupadas	33
5.12.3. Parte 6. Visualización gráfica	33
5.12.4. Recomendación metodológica	33
5.12.5. Reflexión final	33
6. Visualización de datos	34
6.1. Gráficos en R	34
6.2. Gráfico de sectores	35
6.3. Gráfico de barras	36
6.4. Histograma	39
6.4.1. Ejemplo con funciones básicas de R	39
6.5. Boxplot	40
6.5.1. Ejemplo con funciones básicas de R	40
6.5.2. Ejemplo peso y género con ggplot2	42
6.6. Interpretación básica de los gráficos	43
7. Medidas de tendencia central y dispersión	44
8. Medidas de tendencia central	45
8.0.1. Media aritmética	45
8.0.2. Cálculo en R	45
8.0.3. Mediana	46
8.0.4. Cálculo en R	46
8.0.5. Moda	46
8.0.6. Cálculo en R	46
8.1. Visualización de las medidas de tendencia central	47
8.2. Interpretación del gráfico: Distribución del peso	48
8.2.1. Análisis estadístico	48
8.3. Ejercicio experiencial propuesto	49
8.4. Actividad: Explorando las características antropométricas	49
8.5. Actividad práctica	49
8.5.1. Construcción del gráfico	49
8.5.2. Interpretación	49
9. Medidas de dispersión o variabilidad	50
9.0.1. Rango	50
9.0.2. Cálculo en R	50
9.0.3. Varianza muestral	50
9.0.4. Cálculo en R	50
9.0.5. Varianza poblacional	51
9.0.6. Desviación estándar muestral	51
9.0.7. Cálculo en R	51
9.0.8. Desviación estándar poblacional	51
9.0.9. Coeficiente de variación	51
9.0.10. Cálculo en R	51
9.1. Resumen estadístico en R	51
9.2. Histograma + desviación estándar	52

9.2.1. Interpretación	53
9.3. Comparar dispersión entre géneros	53
9.3.1. Interpretación	54
9.3.2. Interpretación	55
9.4. Resumen gráfico	56
10. Medidas de posición y forma	57
10.1. Medidas de posición	57
10.2. Clasificación de las medidas de posición	57
10.3. Cuartiles	58
10.3.1. Fórmula de posición	58
10.4. Deciles	59
10.4.1. Fórmula de posición	59
10.5. Aplicaciones de los deciles	59
10.6. Percentiles	59
10.6.1. Fórmula de posición	59
10.6.2. Aplicaciones de los percentiles	59
10.7. Medidas de forma	60
10.7.1. Asimetría	60
10.7.2. Curtosis	60
11. Análisis bivariado	62
11.1. Tipos de análisis bivariado	62
11.2. Conjunto de datos de trabajo	63
11.2.1. Carga de datos en R	63
11.2.2. Exploración inicial de variables	64
11.3. Diagrama de dispersión	64
11.4. Prueba de normalidad Shapiro-Wilk	67
11.5. Cuando la variable presenta distribución normal	68
11.5.1. Correlación de Pearson	69
11.6. Cuando la variable no presenta distribución normal	73
11.6.1. Correlación de Spearman	73
11.6.2. Covarianza	77
11.6.3. Tablas de contingencia	78
11.7. Estructura general	78
11.8. Interpretación	78
11.9. Ejemplo contextual	78
11.10 Ejemplo en R	78
11.10.1. Laboratorio experiencial:	81
11.10.2. Actividades del estudiante	81
Referencias	83

Prefacio

La estadística constituye una herramienta fundamental para comprender, interpretar y transformar la realidad a partir de los datos. En un contexto caracterizado por el crecimiento exponencial de la información, el análisis estadístico se ha consolidado como una competencia esencial en múltiples disciplinas, especialmente en escenarios académicos, científicos, sociales y organizacionales.

Este libro surge como una propuesta orientada al aprendizaje experiencial de la estadística descriptiva mediante el uso del lenguaje R y el entorno de publicación científica Quarto. Su propósito principal es acercar al estudiante a situaciones reales de análisis de datos, promoviendo no solo el cálculo de medidas estadísticas, sino también la interpretación crítica de la información y la toma de decisiones basadas en evidencia.

A lo largo de los capítulos se integran ejemplos aplicados, visualizaciones estadísticas, actividades experienciales y bases de datos reales provenientes de contextos académicos y oficiales, permitiendo que el lector comprenda cómo la estadística trasciende los ejercicios mecánicos y se convierte en una herramienta para explorar fenómenos del mundo real.

El uso de R permite desarrollar habilidades contemporáneas asociadas al análisis reproducible, la programación estadística y la ciencia de datos, fortaleciendo competencias analíticas cada vez más demandadas en la educación superior y en el ámbito profesional.

Capítulo 1

Introducción

La estadística descriptiva representa el punto de partida para el análisis de datos. A través de técnicas de organización, resumen y visualización, es posible transformar grandes volúmenes de información en conocimiento útil para comprender fenómenos, identificar patrones y apoyar procesos de investigación y toma de decisiones.

Este libro ha sido diseñado bajo un enfoque práctico y aplicado, integrando herramientas computacionales modernas mediante el lenguaje R, uno de los entornos más utilizados en estadística, ciencia de datos e investigación científica a nivel mundial.

Cada capítulo combina fundamentos conceptuales con ejercicios desarrollados sobre bases de datos reales, favoreciendo un aprendizaje activo y experiencial. El lector encontrará actividades orientadas a:

organizar datos, construir tablas de frecuencia, interpretar gráficos estadísticos, analizar medidas descriptivas, identificar patrones y valores atípicos, y comunicar resultados mediante visualizaciones claras y reproducibles.

Además de fortalecer las competencias estadísticas básicas, este texto busca fomentar el pensamiento crítico frente a los datos y promover una cultura de análisis basada en evidencia.

Capítulo 2

Autores



2.0.1. Francisco Javier León

Bacteriólogo y laboratorista clínico, magíster en estadística aplicada, magíster en ciencias básicas biomédicas y especialista en educación con nuevas tecnologías. Desde 2007, está relacionado con la Universidad de Santander (UDES), en la que ha trabajado como profesor en la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Actualmente, trabaja como Coordinador de Analítica Académica en Planeación Institucional. Es un miembro de CIBAS y un investigador junior premiado por MinCiencias en la convocatoria 957 del año 2024.



2.0.2. Miguel Oswaldo Pérez Pulido

Licenciado en matemáticas y magíster en estadística. Actualmente se desempeña como Director de Planeación Institucional. Está vinculado a la Universidad de Santander (UDES) desde 2011, donde ha sido docente en programas de pregrado y posgrado de la Facultad de Ciencias Exactas, Naturales y Agropecuarias. Es investigador asociado reconocido por MinCiencias en la convocatoria 957 de 2024 y miembro del grupo de investigación CIBAS.



2.0.3. Leonardo Andrés Pinto Guarguati

Economista, especialista en Evaluación y Gerencia de Proyectos, y estudiante de la Maestría en Evaluación y Gerencia de Proyectos (Universidad Industrial de Santander). Con experiencia en docencia universitaria, análisis de mercados y coordinación de proyectos de Ciencia, Tecnología e innovación - CTel.

Capítulo 3

Introducción a la estadística descriptiva

Actualmente los datos se han convertido en un activo fundamental para la toma de decisiones en las empresas, la sociedad, la académica entre otros y es por eso que la **estadística descriptiva constituye el primer paso para transformar información en conocimiento útil** (Seoane et al., 2007). Su aplicación permite un mejor entendimiento del mundo que nos rodea, ya que prácticamente cada aspecto de nuestra existencia es una fuente potencial de datos (Obando, 2021). Este capítulo introduce los conceptos básicos necesarios para comprender, organizar y analizar datos, utilizando un enfoque experiencial basado en ejemplos reales y herramientas computacionales como R.

3.1. ¿Qué es la estadística descriptiva?

La **estadística descriptiva** es la rama de la estadística encargada de recolectar, organizar, resumir y presentar datos de manera clara y comprensible.

A diferencia de la estadística inferencial, que busca demostrar asociaciones o hacer comparaciones para extrapolar resultados de una muestra a una población, la descriptiva se limita a **sintetizar la información contenida en los datos recogidos** sin realizar inferencias más allá de la información disponible (Bonita et al., 2008; Posada, 2016).

Su propósito fundamental es facilitar la comprensión de grandes volúmenes de información mediante el uso de **tablas, representaciones gráficas y medidas resumen** (como la media o la desviación estándar), permitiendo “hacerse una idea” de la naturaleza de un conjunto de datos sin tener que analizar cada uno de ellos individualmente (Posada, 2016; Rey, 2007; Spiegel & Stephens, 2009).

3.2. Tipos de variables

Las **variables** son los **atributos, cualidades o características** que pueden ser observadas, clasificadas o medidas en las personas, objetos o fenómenos de una población o muestra. En estadística, su identificación es esencial porque posibilita la descripción, el análisis y la interpretación de la información recopilada. Las variables se dividen en cualitativas y cuantitativas, tal como se muestra en la figura 1.

Las variables cualitativas, que son nominales u ordinales, describen atributos o categorías; por otro lado, las variables cuantitativas, que se dividen en discretas y continuas dependiendo si surgen de procesos de conteo o de medición, ilustran cantidades numéricas. Esta clasificación es esencial porque determina el tipo de análisis estadístico, representación gráfica y medidas descriptivas que pueden aplicarse a los datos.




Figura 3.1: La figura 1 es una adaptación gráfica realizada por los autores en Napkin a partir del esquema presentado por Derek Rowntree (1981) en Statistics Without Tears. La modificación respeta los criterios de uso justo para fines académicos.

3.3. Importancia de la identificación de variables estadísticas y escalas de medición

Una parte fundamental del análisis estadístico es la clasificación de las variables, porque a partir de esta se determina qué métodos, procedimientos y representaciones gráficas son los más idóneos para tratar los datos. Las variables cualitativas, como se ilustra en la figura 2, delimitan categorías o características y habitualmente se examinan a través de porcentajes, frecuencias y medidas como la moda o la mediana en el caso de las variables ordinales.

Las variables cuantitativas, en cambio, son valores numéricos que provienen de procesos de conteo o medición. Estas variables posibilitan el uso de medidas de tendencia central y dispersión, como la varianza, la media, la desviación estándar y el coeficiente de variación. En esta línea, si se identifica apropiadamente el tipo de variable, se logra una interpretación correcta de la información y se asegura que las técnicas estadísticas aplicadas sean congruentes con la naturaleza de los datos.

(Armitage et al., 2002).

1. VARIABLES ESTADÍSTICAS

Son características que pueden observarse o medirse en individuos, objetos o fenómenos.

A. VARIABLES CUALITATIVAS (ATRIBUTOS)

Describen cualidades o categorías que no pueden expresarse numéricamente.

A1 Nominales

Categorías sin orden natural.



Ejemplos:

- Género
- Estado civil
- Lugar de nacimiento

Escala asociada:
Escala nominal

Medidas estadísticas sugeridas:



Moda



Frecuencias



Porcentajes

A2 Ordinales

Existe orden o jerarquía entre categorías.

Ejemplos:

- Estrato socioeconómico
- Nivel educativo
- Grado militar



Escala asociada:
Escala ordinal

Medidas estadísticas sugeridas:



Mediana



Percentiles
(Cuartiles)



Rangos



Moda

B. VARIABLES CUANTITATIVAS

Representan cantidades numéricas obtenidas mediante conteo o medición.

B1 Discretas

Resultan de procesos de conteo.
Toman valores enteros aislados.



Ejemplos:

- Número de hijos
- Número de artículos defectuosos

Escala asociada:
Intervalo o Razón

Medidas estadísticas sugeridas:



Media



Varianza



Desviación
estándar



Rango
(Recorrido)

B2 Continuas

Resultan de procesos de medición.
Pueden tomar cualquier valor dentro de un intervalo.



Ejemplos:

- Peso
- Estatura
- Edad

Escala asociada:
Intervalo o Razón

Medidas estadísticas sugeridas:



Media



Mediana



Desviación
estándar



Coeficiente de
variación



CONTEO

(proceso de enumeración)



Variables
discretas



MEDICIÓN

(proceso de medición)



Variables
continuas

Fuente: Adaptado de Armitage, P. (2002). Statistical methods in medical research; Kleinbaum, D. G., et al. (1982). Epidemiologic research: Principles and quantitative methods; y lineamientos de bioestadística aplicada.

Figura 3.2: Figura 2. Fuente: autores

3.4. Escalas de medición

Las **escalas de medición** representan el nivel de información que poseen los datos y constituyen un elemento fundamental en estadística, ya que determinan las operaciones matemáticas y los análisis que pueden realizarse sobre las variables.

Como se observa en la figura 3, las escalas nominal y ordinal se emplean principalmente en variables cualitativas, mientras que las escalas de intervalo y razón se asocian con variables cuantitativas. A medida que aumenta el nivel de

medición, también incrementa la precisión estadística y la complejidad de los métodos analíticos que pueden aplicarse. Por ello, la correcta identificación de la escala permite seleccionar adecuadamente medidas descriptivas, pruebas estadísticas y representaciones gráficas acordes con la naturaleza de los datos.



Figura 3.3: Figura 3. Fuente: autores

Las escalas de medición permiten clasificar las variables según el tipo de información que proporcionan.

- La **escala nominal** organiza datos en categorías sin orden, por lo que suele analizarse mediante frecuencias y porcentajes.
- La **escala ordinal** incorpora jerarquía entre categorías, permitiendo el uso de medidas como mediana, rangos y

percentiles.

- Por su parte, la **escala de intervalo** presenta distancias iguales entre valores, aunque sin un cero absoluto, lo que posibilita análisis como correlaciones y desviaciones estándar.
- Finalmente, la **escala de razón** posee todas las propiedades anteriores y un cero real, permitiendo realizar operaciones matemáticas completas y análisis estadísticos más avanzados. La figura resume las principales características, ejemplos, medidas estadísticas y representaciones gráficas asociadas a cada escala.

La selección de las técnicas estadísticas depende directamente de la escala de medición de las variables. Como se presenta en la figura, las variables medidas en escala nominal suelen representarse mediante gráficos de barras o pastel y analizarse con frecuencias y moda.

Las escalas ordinales permiten incorporar análisis basados en orden y posición, como percentiles o cuartiles. En contraste, las escalas de intervalo y razón posibilitan el cálculo de medidas paramétricas como media, varianza, desviación estándar y análisis de regresión. En consecuencia, conocer la escala de medición garantiza la aplicación de procedimientos estadísticos válidos y una interpretación adecuada de los resultados obtenidos.

3.5. Base de datos de trabajo

Este libro empleará dos bases de datos, con fines pedagógicos y prácticos. La primera es una base de datos del sector acuícola que se adquiere gracias a la información proporcionada por el Departamento Administrativo Nacional de Estadística (DANE). Esta base posibilitará llevar a cabo tareas vinculadas con la clasificación de variables, la organización de datos, las tablas de frecuencia y el análisis descriptivo en escenarios reales económicos y productivos.

La segunda base corresponde a una base de datos antropométrica construida con información de estudiantes universitarios. Esta abarca variables vinculadas con el peso, la altura, la longitud de las extremidades y el índice de masa corporal, así como otras medidas físicas. Esto posibilita tratar asuntos de visualización, análisis bivariado, correlación y medidas descriptivas a través de situaciones aplicadas a ergonomía, salud y caracterización poblacional.

El empleo de bases de datos reales tiene como objetivo potenciar el aprendizaje a partir de la experiencia, fomentando que el alumno no solamente asimile conceptos estadísticos, sino que además adquiera capacidades para analizar información, tomar decisiones y usar herramientas de análisis de datos con R en entornos próximos a su realidad laboral.

3.5.0.1. bd Acuicultura

```
# =====  
# CARGA Y EXPLORACIÓN DE LA BASE DE DATOS  
# =====  
  
# Librerías  
library(readr)  
library(dplyr)  
  
# Cargar base de datos de acuicultura  
acuicultura <- read_csv(  
  "data/S07D_Acuicultura.csv"  
)  
  
# Visualizar primeras filas  
head(acuicultura)
```

```
# A tibble: 6 x 14  
  ...1 TIPO_REG PAIS P_DEPTO P_MUNIC UC_UO ENCUESTA COD_VEREDA P_S7PNUMPEZ  
  <dbl>    <dbl> <dbl>    <dbl> <dbl> <chr>    <chr>    <dbl>    <dbl>  
1      1        7   170      68  68001 00310001 022537951  68001007      1  
2      2        7   170      68  68001 00420001 022303666  68001009      1
```

```

3      3      7  170      68  68001 00690001 022317829  68001027      2
4      4      7  170      68  68001 00900001 022318620  68001002      1
5      5      7  170      68  68001 00920001 022736078  68001009      1
6      6      7  170      68  68001 00970001 022317801  68001024      1
# i 5 more variables: P_S7P96 <dbl>, P_S7P97 <dbl>, P_S7P98 <dbl>,
#   P_S7P99 <dbl>, P_S7P100 <dbl>

```

```

# Número de filas y columnas
dim(acuicultura)

```

```
[1] 3447  14
```

```

# Nombres de las variables
names(acuicultura)

```

```

[1] "...1"      "TIPO_REG"    "PAIS"        "P_DEPTO"     "P_MUNIC"
[6] "UC_UO"      "ENCUESTA"    "COD_VEREDA"  "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97"    "P_S7P98"     "P_S7P99"     "P_S7P100"

```

```

# Estructura general de la base
str(acuicultura)

```

```

spc_tbl_ [3,447 x 14] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ ...1      : num [1:3447] 1 2 3 4 5 6 7 8 9 10 ...
 $ TIPO_REG   : num [1:3447] 7 7 7 7 7 7 7 7 7 7 ...
 $ PAIS       : num [1:3447] 170 170 170 170 170 170 170 170 170 170 ...
 $ P_DEPTO    : num [1:3447] 68 68 68 68 68 68 68 68 68 68 ...
 $ P_MUNIC    : num [1:3447] 68001 68001 68001 68001 68001 68001 ...
 $ UC_UO      : chr [1:3447] "00310001" "00420001" "00690001" "00900001" ...
 $ ENCUESTA   : chr [1:3447] "022537951" "022303666" "022317829" "022318620" ...
 $ COD_VEREDA : num [1:3447] 6.8e+07 6.8e+07 6.8e+07 6.8e+07 6.8e+07 ...
 $ P_S7PNUMPEZ: num [1:3447] 1 1 2 1 1 1 1 2 1 18 ...
 $ P_S7P96    : num [1:3447] 41190400 41190300 41191000 41190400 41190300 ...
 $ P_S7P97    : num [1:3447] 1 0 1 1 1 1 1 6 0 0 ...
 $ P_S7P98    : num [1:3447] 50 0 300 50 200 50 30 80 0 0 ...
 $ P_S7P99    : num [1:3447] 5 0 5 5 4 3.75 5 5 0 0 ...
 $ P_S7P100   : num [1:3447] 0.25 0 1.5 0.25 0.8 ...
- attr(*, "spec")=
 .. cols(
 ..   ...1 = col_double(),
 ..   TIPO_REG = col_double(),
 ..   PAIS = col_double(),
 ..   P_DEPTO = col_double(),
 ..   P_MUNIC = col_double(),
 ..   UC_UO = col_character(),
 ..   ENCUESTA = col_character(),
 ..   COD_VEREDA = col_double(),
 ..   P_S7PNUMPEZ = col_double(),
 ..   P_S7P96 = col_double(),
 ..   P_S7P97 = col_double(),
 ..   P_S7P98 = col_double(),
 ..   P_S7P99 = col_double(),
 ..   P_S7P100 = col_double()
 .. )
- attr(*, "problems")=<externalptr>

```

```

# Abrir base completa en RStudio
# View(acuicultura)

```

3.5.1. ¿Qué estamos haciendo?

Antes de realizar cualquier análisis estadístico, es fundamental explorar la base de datos para comprender su estructura, contenido y tipo de información disponible. Esta etapa permite identificar: número de observaciones; cantidad de variables; nombres de las columnas; tipos de datos (numéricos, categóricos o texto); posibles datos faltantes y características generales de la información.

La función `head()` muestra las primeras filas de la base de datos, permitiendo visualizar cómo se encuentran organizadas las observaciones. Por su parte, `dim()` indica el número de filas y columnas, mientras que `names()` permite identificar el nombre de cada variable.

La función `glimpse()` ofrece una visión rápida de la estructura de la base, mostrando el tipo de dato de cada variable y algunos ejemplos de sus valores. Finalmente, `summary()` genera un resumen descriptivo básico de las variables cuantitativas y categóricas.

3.5.2. Reflexión del estudiante

¿Cuántas variables contiene la base de datos?

¿Qué tipos de variables identifica?

¿Existen variables cuantitativas y cualitativas?

¿Cuál variable considera más importante para el análisis?

¿Observa posibles datos faltantes?

3.6. Diccionario de datos

```
library(readr)
library(dplyr)
library(janitor)

# Cargar base
acuicultura <- read_csv("data/S07D_Acuicultura.csv")

# Crear estructura inicial del diccionario
diccionario <- tibble(
  variable = names(acuicultura),
  tipo_dato = sapply(acuicultura, class),
  valores_unicos = sapply(acuicultura, n_distinct),
  missing = sapply(acuicultura, function(x) sum(is.na(x)))
)

# Ver diccionario
diccionario
```



```
# A tibble: 14 x 4
  variable      tipo_dato valores_unicos missing
  <chr>         <chr>         <int>     <int>
1 ...1        numeric         3447         0
2 TIPO_REG    numeric          1         0
3 PAIS        numeric          1         0
4 P_DEPTO     numeric          1         0
5 P_MUNIC     numeric          84         0
6 UC_UO       character       662         0
7 ENCUESTA    character     2590         0
8 COD_VEREDA  numeric         870         0
9 P_S7PNUMPEZ numeric          11         4
10 P_S7P96    numeric          27         4
```

11	P_S7P97	numeric	13	0
12	P_S7P98	numeric	125	0
13	P_S7P99	numeric	113	0
14	P_S7P100	numeric	370	0

Interpretación: La base de datos contiene 3447 observaciones y 14 variables relacionadas con información del sector acuícola. Se identifican variables de tipo categórico (chr) y numérico (dbl), lo que permitirá desarrollar análisis descriptivos tanto para variables cualitativas como cuantitativas. La exploración inicial facilita comprender la estructura de la información antes de aplicar técnicas estadísticas más avanzadas.

Ver diccionario de variables en sitio web del DANE [Diccionario_S07D_Acuicultura](#)

Para exportar el diccionario

```
library(writexl)

write_xlsx(diccionario,
           "data/diccionario_acuicultura.xlsx")
```

Esta instrucción permite ver el libro en quarto.

```
library(gt)

diccionario_acuicultura <- tibble(
  variable = c(
    "TIPO_REG", "PAIS", "P_DEPTO", "P_MUNIC", "UC_UO",
    "ENCUESTA", "COD_VEREDA", "P_S7PNUMPEZ", "P_S7P96",
    "P_S7P97", "P_S7P98", "P_S7P99", "P_S7P100"
  ),
  descripcion = c(
    "Tipo de región",
    "País",
    "Departamento",
    "Municipio",
    "Unidad de cobertura y unidad de observación",
    "Encuesta",
    "Código de vereda",
    "Orden de pez",
    "Nombre de la especie cultivada",
    "Número de cosechas en el año",
    "Número de animales por cosecha",
    "Peso promedio por animal en gramos",
    "Producción total durante 2013 en kilogramos"
  )
)

diccionario_acuicultura |>
  gt()
```

3.7. Actividad experiencial

3.7.1. Explorando una base de datos del DANE

Contexto de la actividad: En estadística aplicada, antes de realizar cualquier análisis es fundamental comprender las características de las variables contenidas en una base de datos. Para ello, se utilizará una base oficial del Departamento Administrativo Nacional de Estadística (DANE) correspondiente al módulo de acuicultura. Los estudiantes actuarán como analistas de datos, explorando información real utilizada en estudios productivos y socioeconómicos.

variable	descripcion
TIPO_REG	Tipo de región
PAIS	País
P_DEPTO	Departamento
P_MUNIC	Municipio
UC_UO	Unidad de cobertura y unidad de observación
ENCUESTA	Encuesta
COD_VEREDA	Código de vereda
P_S7PNUMPEZ	Orden de pez
P_S7P96	Nombre de la especie cultivada
P_S7P97	Número de cosechas en el año
P_S7P98	Número de animales por cosecha
P_S7P99	Peso promedio por animal en gramos
P_S7P100	Producción total durante 2013 en kilogramos

Objetivo de aprendizaje: Al finalizar esta actividad, el estudiante será capaz de explorar una base de datos real, identificar tipos de variables y escalas de medición, seleccionar representaciones gráficas adecuadas e interpretar información estadística básica utilizando R.

Fuente oficial: [DANE – Diccionario S07D Acuicultura](#)

Desarrollo de la actividad

Parte 1. Exploración de la base de datos

Instrucciones

Cargar la base de datos en R.

Revisar los nombres de las variables.

Consultar el diccionario oficial del DANE.

Identificar el significado de cada variable, tipo de variable, escala de medición, unidad de medida, posible representación gráfica y medidas estadísticas aplicables.

```
library(readr)
library(dplyr)

## Cargar base de datos
acuicultura <- read_csv(
  "data/S07D_Acuicultura.csv"
)

## Explorar estructura emplee los siguientes comandos de R
# names(acuicultura)
# glimpse(acuicultura)
# head(acuicultura)
```

Parte 2. Completar la tabla de clasificación

Instrucciones para el estudiante: Complete la siguiente tabla utilizando la exploración en R, el diccionario del DANE, los conceptos vistos en clase sobre variables y escalas de medición.

Variable	Descripción	Tipo de variable	Escala de medición	Unidad de medida	Ejemplo de gráfico	Medidas estadísticas sugeridas
TIPO_REG						
PAIS						
P_DEPTO						
P_MUNIC						
UC_UO						
ENCUESTA						
COD_VEREDA						
P_S7PNUMPEZ						
P_S7P96						
P_S7P97						
P_S7P98						
P_S7P99						
P_S7P100						

Parte 3. Interpretación estadística

Responda las siguientes preguntas:

- ¿Qué variables son cualitativas y cuáles cuantitativas?
- ¿Qué variables corresponden a procesos de conteo?
- ¿Qué variables corresponden a procesos de medición?
- ¿Cuál variable podría analizarse mediante: histogramas, diagramas de barras, boxplots, entre otros.
- ¿Qué variable considera más importante para analizar la producción acuícola y por qué?
- ¿Qué variable considera más relevante para evaluar productividad acuícola?
- ¿Qué variables podrían utilizarse para construir indicadores económicos?
- ¿Qué problemas podrían surgir si una variable se clasifica incorrectamente?
- ¿Qué variables podrían presentar valores atípicos?

Ejemplo de una variable estudiada Curva de densidad de la producción acuícola.

```
library(ggplot2)


ggplot(
  acuicultura,
  aes(x = log10(P_S7P100 + 1))
) +

  geom_density(
    fill = "skyblue",
    alpha = 0.5,
    color = "blue",
    linewidth = 1
  ) +

  labs(
    title = "Curva de densidad de la producción acuícola",
    subtitle = "Escala logarítmica",
    x = "Log10 Producción total (kg)",
```

```
y = "Densidad"
) +

theme_minimal()
```



Interpretación: La distribución de la producción acuícola presenta una marcada asimetría positiva, razón por la cual se utilizó una transformación logarítmica para facilitar la visualización de la densidad de los datos. Este comportamiento es frecuente en variables productivas y económicas, donde pocas observaciones concentran valores muy altos mientras la mayoría presenta valores moderados o bajos.

3.8. Flujo general del análisis de datos

i Nota

```
Importar datos
↓
Explorar datos
↓
Clasificar variables
↓
Visualizar información
↓
Interpretar resultados
↓
Tomar decisiones
```

3.9. Mini reto analítico

Imagine que usted trabaja en una entidad gubernamental encargada de monitorear la producción acuícola del país. Con base en la información disponible:

- ¿qué variable utilizaría para estimar productividad?
- ¿qué tipo de gráfico presentaría a un directivo?
- ¿qué indicador resumiría mejor la información?
- ¿qué riesgos tendría interpretar incorrectamente los datos?

Conclusion

De acuerdo con lo anterior la estadística descriptiva permite transformar datos brutos en información significativa mediante el uso de tablas, representaciones gráficas y medidas resumen. Este proceso facilita la organización, interpretación y comprensión de los fenómenos analizados, constituyéndose en una herramienta fundamental para la toma de decisiones basadas en evidencia. Asimismo, la correcta identificación del tipo de variable y de la escala de medición resulta esencial para seleccionar las técnicas estadísticas apropiadas. Un error frecuente consiste en analizar variables ordinales como si fueran cuantitativas continuas o asumir que los datos siguen distribuciones normales sin verificar los supuestos requeridos, lo cual puede afectar la validez de los resultados y conducir a interpretaciones erróneas.

Capítulo 4

Preparación de datos

La preparación de datos es la etapa inicial del análisis estadístico en la que se revisa, organiza, limpia y transforma la información disponible antes de aplicar técnicas descriptivas o inferenciales. Su propósito es garantizar que los datos sean coherentes, completos y adecuados para responder una pregunta de análisis Hair et al. (2019).

Al finalizar este capítulo, el estudiante estará en capacidad de importar bases de datos en R, explorar su estructura, identificar valores faltantes, reconocer inconsistencias, recodificar variables y preparar una base limpia para el análisis estadístico.

! Flujo general de preparación

```
Importar datos
↓
Explorar la estructura
↓
Identificar inconsistencias
↓
Revisar valores faltantes
↓
Detectar valores atípicos
↓
Recodificar variables
↓
Guardar base preparada
```

4.1. Carga de datos en R

Para iniciar el trabajo en R, el primer paso fundamental consiste en definir el directorio de trabajo, es decir, la ubicación donde se encuentran los archivos de datos y donde se almacenarán los resultados del análisis. Esto puede realizarse mediante la función `setwd()` o a través de herramientas gráficas del entorno de desarrollo (RStudio) (Wickham & Grolemund, 2017). Existen múltiples métodos para cargar datos dependiendo de su formato:

Tabla 4.1: Métodos de carga de datos en R

Método	Característica	Ejemplo
Archivos de texto y CSV	Uso de funciones como <code>read.csv()</code> o <code>read.csv2()</code> , especificando encabezados y codificación	Importación de archivos <code>.csv</code>

Método	Característica	Ejemplo
Interfaces gráficas (GUI)	Herramientas como R Commander permiten importar datos sin necesidad de programación	Importación desde Excel, SPSS, STATA
Minería de datos	Paquetes como <i>rattle</i> permiten cargar datos mediante interfaces visuales configurables	Definición de separadores y decimales

4.2. Limpieza de datos

La limpieza de datos consiste en detectar, corregir o eliminar inconsistencias que puedan afectar la validez del análisis estadístico (Van den Broeck et al., 2005). Un paso inicial es la inspección visual del conjunto de datos para identificar registros incompletos, errores de digitación o valores atípicos. Por ejemplo, líneas que contienen exclusivamente valores faltantes (NA) deben ser evaluadas antes de su inclusión en el análisis.

Tabla 4.2: Aspectos clave en la preparación de datos

Proceso	Subproceso	Descripción	Herramienta / Ejemplo
Limpieza de datos	Valores extremos (Outliers)	Identificación y tratamiento de datos atípicos que pueden distorsionar resultados. Se recomienda corregir o eliminar errores evidentes.	Diagramas de caja (<i>boxplot</i>) (Tukey, 1977)
	Consistencia de totales	Verificación de coherencia entre frecuencias, totales y porcentajes acumulados.	Validación de sumas (Agresti, 2018)
	Filtrado de datos	Selección de subconjuntos de datos según criterios específicos para análisis focalizado.	Filtrado en R (<i>subset</i> , <i>filter</i>)
Valores faltantes	Identificación y codificación	Asignación de códigos (ej: 99, 999) para identificar datos perdidos.	Codificación en R o SPSS
	Eliminación de casos	Eliminación de registros incompletos antes del análisis.	<code>na.omit()</code> , <code>na.exclude()</code>
	Imputación	Estimación de valores faltantes mediante métodos estadísticos.	Métodos de imputación
	Análisis de censura	Tratamiento de datos incompletos en estudios de supervivencia.	(Kleinbaum & Klein, 2012)
Recodificación	Categorización de variables	Transformación de variables cuantitativas en categorías.	Agrupación de edades
	Codificación de atributos	Asignación de valores numéricos a variables cualitativas.	1 = Masculino, 2 = Femenino
	Variables dummy	Conversión de variables categóricas en variables binarias.	(Wooldridge, 2016)

Proceso	Subproceso	Descripción	Herramienta / Ejemplo
	Tratamiento de etiquetas	Conversión de códigos numéricos a etiquetas descriptivas.	<code>factor()</code> en R

La preparación de datos es una etapa esencial para garantizar la calidad del análisis estadístico. Antes de calcular indicadores o construir gráficos, es necesario comprender la estructura de la base, revisar inconsistencias, identificar valores faltantes y transformar las variables cuando sea necesario. Un análisis confiable comienza con datos bien preparados .

Capítulo 5

Organización de datos y tablas estadísticas

En este capítulo se presentan los fundamentos para la organización y presentación de la información mediante diferentes tipos de tablas estadísticas. Estas herramientas permiten resumir, ordenar y estructurar los datos de manera que faciliten su análisis e interpretación. Las tablas constituyen un recurso esencial en la estadística descriptiva, ya que permiten transformar datos individuales en información significativa.

5.1. Datos simples

Los **datos simples** corresponden al registro directo, individual y no agrupado de cada observación obtenida en un estudio. En este formato, cada valor se conserva tal como fue recolectado, lo que permite identificar con facilidad observaciones particulares, posibles errores de registro, valores extremos y patrones preliminares.

Si se tiene una variable cuantitativa X observada en n individuos, los datos simples pueden representarse como:

$$X = \{x_1, x_2, x_3, \dots, x_n\}$$

donde:

- x_i representa el valor observado en la unidad i
- n es el número total de observaciones

Este tipo de presentación es especialmente útil en etapas iniciales del análisis, cuando interesa inspeccionar la información en bruto antes de resumirla. Sin embargo, cuando el número de observaciones es grande, los datos simples se vuelven poco prácticos para interpretar tendencias generales.

5.2. Datos agrupados

Los **datos agrupados** se obtienen cuando los valores individuales se organizan en categorías o intervalos de clase. Esta forma de organización permite resumir grandes volúmenes de información y facilita la identificación de concentraciones, patrones de distribución y tendencias generales.

Cuando la variable es cuantitativa continua, los intervalos suelen construirse a partir del rango de los datos. El rango de los datos se define como:

$$R = X_{\text{máx}} - X_{\text{mín}}$$

donde:

- R es el rango

- X_{max} es el valor máximo observado
- X_{min} es el valor mínimo observado

Si se desea formar k clases, la amplitud del intervalo puede aproximarse mediante: La amplitud de clase se calcula como:

$$A = \frac{R}{k}$$

donde:

- A es la amplitud de clase
- k es el número de intervalos

Una regla empírica ampliamente usada para estimar el número de clases es la **regla de Sturges**:

$$k = 1 + 3.322 \log_{10}(n)$$

Esta expresión proporciona un valor de referencia para construir tablas de frecuencias agrupadas cuando el tamaño muestral es moderado.

5.3. Tablas de frecuencia

Las **tablas de frecuencia** permiten resumir la distribución de los datos, indicando cuántas veces aparece cada valor, categoría o intervalo. Son una herramienta central de la estadística descriptiva y constituyen la base para la construcción de histogramas, polígonos de frecuencia, diagramas de barras y otros gráficos.

Una tabla de frecuencia puede incluir los siguientes componentes:

5.3.1. Frecuencia absoluta

La **frecuencia absoluta** de una categoría o clase corresponde al número de veces que dicha categoría aparece en el conjunto de datos. Se denota por f_i .

f_i = número de observaciones en la categoría o clase i

5.3.2. Frecuencia relativa

La **frecuencia relativa** expresa la proporción de observaciones que pertenecen a una categoría respecto al total. Se denota por h_i y se calcula como:

$$h_i = \frac{f_i}{n}$$

Si se desea expresar en porcentaje:

$$h_i(\%) = \frac{f_i}{n} \times 100$$

5.3.3. Frecuencia acumulada

La **frecuencia acumulada** representa la suma progresiva de las frecuencias absolutas hasta la clase i . Se denota por F_i :

$$F_i = \sum_{j=1}^i f_j$$

5.3.4. Frecuencia relativa acumulada

La **frecuencia relativa acumulada** corresponde a la suma progresiva de las frecuencias relativas. Se denota por H_i :

$$H_i = \sum_{j=1}^i h_j = \frac{F_i}{n}$$

donde:

- H_i es la frecuencia relativa acumulada,
- F_i es la frecuencia absoluta acumulada,
- n es el número total de observaciones.

Estas medidas permiten conocer no solo la cantidad de datos en cada categoría, sino también la proporción acumulada de observaciones hasta determinado punto de la distribución.

5.4. Ejemplo de tabla de frecuencia: Variable P_S7P97

La variable P_S7P97 corresponde al **número de cosechas realizadas durante el año**, por lo que se clasifica como una **variable cuantitativa discreta**, ya que proviene de un proceso de conteo y solo admite valores enteros. La tabla de frecuencia permite resumir la distribución de esta variable, identificando: cuántas veces aparece cada valor, su porcentaje, y la frecuencia acumulada.

```
library(dplyr)
library(knitr)
library(readr)
library(kableExtra)

# Cargar base de datos de Acuicultura
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

# Tabla de frecuencia
tabla_frecuencia <- acuicultura %>%
  count(P_S7P97, name = "fi") %>%
  mutate(
    hi = round(fi / sum(fi), 4),
    Porcentaje = round(hi * 100, 2),
    Fi = cumsum(fi),
    Hi = round(cumsum(hi), 4)
  )

# Cambiar nombres de columnas
colnames(tabla_frecuencia) <- c(
  "Número de cosechas",
  "f ",
  "h ",
  "Porcentaje (%)",
  "F ",
  "H "
)

# Visualizar tabla
```

```

tabla_frecuencia %>%
  kable(
    caption = "Tabla de frecuencia del número de cosechas",
    align = "c",
    digits = 3
  ) %>%
  kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    full_width = FALSE,
    position = "center"
  )

```

Tabla 5.1: Tabla de frecuencia del número de cosechas

Número de cosechas	f_i	h_i	Porcentaje (%)	F_i	H_i
0	620	0.180	17.99	620	0.180
1	1778	0.516	51.58	2398	0.696
2	678	0.197	19.67	3076	0.892
3	83	0.024	2.41	3159	0.916
4	42	0.012	1.22	3201	0.929
5	31	0.009	0.90	3232	0.938
6	49	0.014	1.42	3281	0.952
7	24	0.007	0.70	3305	0.959
8	23	0.007	0.67	3328	0.966
9	32	0.009	0.93	3360	0.975
10	33	0.010	0.96	3393	0.985
11	28	0.008	0.81	3421	0.993
12	26	0.007	0.75	3447	1.000

Interpretación: La tabla de frecuencia permite identificar cuáles son los números de cosechas más frecuentes entre las unidades productivas analizadas. Asimismo, facilita reconocer la concentración de observaciones, la dispersión de los datos y posibles patrones de comportamiento en la actividad acuícola. Cuando la mayoría de las observaciones se concentra en pocos valores, puede inferirse una baja variabilidad en el número de cosechas. Por el contrario, una distribución amplia sugiere heterogeneidad en los sistemas productivos.

5.5. Estructura general de una tabla de frecuencia

De manera general, una tabla de distribución de frecuencias para una variable cuantitativa agrupada permite resumir y organizar los datos en intervalos o clases, facilitando la interpretación de la distribución de los valores observados. Este tipo de tabla incluye frecuencias absolutas, relativas y acumuladas, así como la marca de clase, la cual representa el valor central de cada intervalo.

- **Clase o intervalo:** agrupa los datos en rangos numéricos para facilitar el análisis.
- **Marca de clase:** corresponde al punto medio de cada intervalo y representa el valor central de la clase.
- **Frecuencia absoluta (f_i):** número de observaciones que pertenecen a cada intervalo.
- **Frecuencia relativa (h_i):** proporción de observaciones respecto al total.
- **Frecuencia acumulada (F_i):** suma progresiva de las frecuencias absolutas.
- **Frecuencia relativa acumulada (H_i):** acumulación progresiva de las frecuencias relativas.

5.6. Marca de clase

La marca de clase corresponde al punto medio de cada intervalo:

$$x_i^* = \frac{L_i + U_i}{2}$$

donde:

- (x_i^*) es la marca de clase
- (L_i) es el límite inferior del intervalo
- (U_i) es el límite superior del intervalo

La marca de clase resulta útil para representar la distribución mediante gráficos o para calcular medidas resumen aproximadas cuando los datos están agrupados.

```
library(readr)
library(dplyr)
library(knitr)
library(kableExtra)

# Cargar base de datos
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

# Crear tabla agrupada
tabla_freq <- acuicultura %>%
  filter(!is.na(P_S7P97)) %>%
  mutate(
    Clase = cut(
      P_S7P97,
      breaks = 5,
      include.lowest = TRUE
    )
  ) %>%
  count(Clase, name = "fi") %>%
  mutate(
    hi = fi / sum(fi),
    Fi = cumsum(fi),
    Hi = cumsum(hi)
  )

# Cambiar nombres de columnas
colnames(tabla_freq) <- c(
  "Clase",
  "f_i",
  "h_i",
  "F_i",
  "H_i"
)

# Mostrar tabla
tabla_freq %>%
  kable()
```



```

caption = "Distribución de frecuencias agrupadas",
escape = FALSE,
align = "c",
digits = 3
) %>%
kable_styling(
  bootstrap_options = c("striped", "hover", "condensed"),
  full_width = FALSE
)

```

Tabla 5.2: Distribución de frecuencias agrupadas

Clase	f _i	h _i	F _i	H _i
[-0.012,2.4]	3076	0.892	3076	0.892
(2.4,4.8]	125	0.036	3201	0.929
(4.8,7.2]	104	0.030	3305	0.959
(7.2,9.6]	55	0.016	3360	0.975
(9.6,12]	87	0.025	3447	1.000

5.7. Organización de datos en contextos reales

En estadística aplicada, las tablas de frecuencia permiten transformar grandes volúmenes de datos en información interpretable. A través de ellas es posible identificar patrones, concentraciones, categorías predominantes y características generales de una población.

Para ilustrar estos conceptos, se utilizará una base de datos antropométrica que contiene mediciones corporales de estudiantes, incluyendo variables cualitativas y cuantitativas como género, grupo, peso y estatura.

El objetivo no será únicamente construir tablas estadísticas, sino interpretar cómo se distribuyen los datos y qué información aportan sobre la población estudiada.

5.8. Actividad Experiencial

5.8.1. Situación problema

Usted hace parte de un equipo de analítica académica encargado de caracterizar físicamente a un grupo de estudiantes para apoyar estudios de ergonomía, salud ocupacional y diseño de espacios educativos. A partir de la base de datos: identifique patrones, organice la información, construya tablas estadísticas, e interprete los resultados.

5.8.1.1. Exploración inicial

```

library(readxl)
library(dplyr)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

```

```

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
#)

```

```
head(datos)
```

```
# A tibble: 6 x 17
```

```

  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>    <dbl>                <dbl>      <dbl>
1 D      A      M        177      73                  49         19
2 D      A      M        177      86                  45         19
3 D      A      F        160      52                  37         16
4 D      A      F        159      53                  38         16
5 D      A      F        174      78                  41         18
6 D      B      M        186      68                  44         19
# i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
#   Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
#   Mano_Dicotica <chr>

```

```
names(datos)
```

```

[1] "Clase"           "Grupo"           "Genero"
[4] "Altura_cm"       "Peso_Kg"         "Anchura_hombros_cm"
[7] "Long_Mano_cm"    "Lon_Palma_cm"    "Ancho_Palma_cm"
[10] "Long_Brazo_cm"   "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm"     "Curso"           "Talla_Dicotica"
[16] "IMC_Dicotico"    "Mano_Dicotica"

```

```
glimpse(datos)
```

```
Rows: 260
```

```
Columns: 17
```

```

$ Clase      <chr> "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "~
$ Grupo      <chr> "A", "A", "A", "A", "A", "B", "B", "B", "B", "B", "~
$ Genero     <chr> "M", "M", "F", "F", "F", "M", "M", "F", "F", "F", "~
$ Altura_cm  <dbl> 177, 177, 160, 159, 174, 186, 174, 172, 156, 165, 1~
$ Peso_Kg    <dbl> 73, 86, 52, 53, 78, 68, 115, 50, 62, 64, 94, 60, 63~
$ Anchura_hombros_cm <dbl> 49, 45, 37, 38, 41, 44, 49, 42, 42, 44, 48, 45, 36,~
$ Long_Mano_cm <dbl> 19, 19, 16, 16, 18, 19, 21, 19, 19, 18, 19, 18, 17,~
$ Lon_Palma_cm <dbl> 11.0, 10.0, 8.0, 9.0, 10.0, 11.0, 11.4, 10.1, 10.0,~
$ Ancho_Palma_cm <dbl> 9.0, 9.0, 8.0, 8.0, 8.5, 8.0, 9.0, 7.0, 8.0, 8.0, 9~
$ Long_Brazo_cm <dbl> 62.0, 59.0, 54.0, 52.0, 59.0, 74.0, 80.0, 76.0, 69.~
$ Long_Antebrazo_cm <dbl> 31.0, 31.0, 27.0, 27.0, 29.0, 29.0, 28.0, 26.0, 26.~
$ Long_Pierna_cm <dbl> 42.7, 41.8, 40.9, 49.1, 48.0, 43.4, 42.4, 44.2, 47.~
$ Long_Pie_cm  <dbl> 23.7, 23.1, 25.1, 26.9, 27.0, 24.0, 22.9, 25.6, 24.~
$ Curso       <chr> "2020-1", "2020-1", "2020-1", "2020-1", "2020-1", "~
$ Talla_Dicotica <chr> "Alta", "Alta", "Baja", "Baja", "Baja", "Alta", "Ba~
$ IMC_Dicotico <chr> "Normal+", "Normal+", "Normal+", "Normal+", "Normal~
$ Mano_Dicotica <chr> "Grande", "Grande", "Pequeña", "Pequeña", "Pequeña"~

```

! Preguntas para el estudiante

1. ¿Qué variables son cualitativas?
2. ¿Qué variables son cuantitativas?
3. ¿Qué variables corresponden a medición?
4. ¿Qué variables podrían agruparse?
5. ¿Qué información sería relevante para caracterizar a los estudiantes?

5.8.1.2. Tablas de frecuencia cualitativas

5.8.2. Ejemplo: Género

La variable Género corresponde a una variable cualitativa nominal, ya que clasifica a los individuos en categorías mutuamente excluyentes sin un orden natural. Para este tipo de variables, las tablas de frecuencia permiten identificar la proporción y distribución de las categorías observadas.

5.8.2.0.1. Tratamiento de valores faltantes

En bases de datos reales es común encontrar valores faltantes (NA). Antes de realizar análisis estadísticos, es importante identificar y evaluar la presencia de datos ausentes, ya que estos pueden afectar la interpretación de los resultados y la validez de los análisis.

```
library(readxl)
library(dplyr)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)
```

```
library(summarytools)
```

```
freq(datos$Genero)
```

Frequencies

datos\$Genero

Type: Character

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
F	208	80.00	80.00	80.00	80.00
M	52	20.00	100.00	20.00	100.00
<NA>	0			0.00	100.00
Total	260	100.00	100.00	100.00	100.00

```
# Verificar si realmente existen NA
```

```
sum(is.na(datos$Genero))
```

```
[1] 0
```

En este caso, la variable Género no presenta valores faltantes; sin embargo, la función de resumen estadístico muestra automáticamente la categoría NA. Mediante el argumento `report.nas = FALSE` es posible ocultar esta categoría y presentar la tabla de frecuencias de forma más clara y limpia.

```
freq(
  datos$Genero,
  report.nas = FALSE)
```

Frequencies

datos\$Genero

Type: Character

	Freq	%	% Cum.
F	208	80.00	80.00

M	52	20.00	100.00
Total	260	100.00	100.00

5.8.2.1. Preguntas de análisis

1. ¿Qué género presenta mayor frecuencia?
 2. ¿La distribución parece equilibrada?
 3. ¿Qué implicaciones tendría esto para un estudio antropométrico?
 4. ¿La muestra parece representativa?
-

```
library(readxl)
library(dplyr)
library(knitr)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

#)

# Tabla de frecuencia para la variable Género
tabla_genero <- datos %>%
  count(Genero, name = "fi") %>%
  mutate(
    hi = round(fi / sum(fi), 3),
    Fi = cumsum(fi),
    Hi = round(cumsum(hi), 3)
  )

colnames(tabla_genero) <- c(
  "Categoría",
  "$f_i$",
  "$h_i$",
  "$F_i$",
  "$H_i$"
)

kable(
  tabla_genero,
  caption = "Tabla de frecuencia para la variable género",
  escape = FALSE,
  align = "c"
)
```

Tabla 5.3: Tabla de frecuencia para la variable género

Categoría	f_i	h_i	F_i	H_i
F	208	0.8	208	0.8
M	52	0.2	260	1.0

5.9. Ejemplo: Peso corporal

La variable `Peso_Kg` corresponde a una variable cuantitativa continua obtenida mediante procesos de medición. Debido a que puede asumir múltiples valores dentro de un intervalo, resulta necesario organizar la información mediante intervalos de clase.

```
library(readxl)
library(dplyr)
library(summarytools)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"

#)

# Tabla de frecuencias
tabla_peso <- freq(
  datos$Peso_Kg,
  report.nas = FALSE,
  plain.ascii = FALSE
)

head(tabla_peso, 10)
```

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
31	3	1.1538462	1.153846	1.1538462	1.153846
32	3	1.1538462	2.307692	1.1538462	2.307692
34	1	0.3846154	2.692308	0.3846154	2.692308
35	5	1.9230769	4.615385	1.9230769	4.615385
36	9	3.4615385	8.076923	3.4615385	8.076923
37	8	3.0769231	11.153846	3.0769231	11.153846
38	13	5.0000000	16.153846	5.0000000	16.153846
39	8	3.0769231	19.230769	3.0769231	19.230769
39.5	1	0.3846154	19.615385	0.3846154	19.615385
40	17	6.5384615	26.153846	6.5384615	26.153846

5.10. Actividad experiencial: Organización de datos y tablas estadísticas

Un grupo de diseñadores y especialistas en ergonomía universitaria necesita analizar las características antropométricas de los estudiantes con el fin de adaptar el mobiliario de las aulas, mejorar la comodidad durante las jornadas académicas y reducir posibles riesgos asociados a malas posturas.

Para ello, se utilizará la base de datos `bd_antropometricas.xlsx`, la cual contiene información relacionada con peso corporal, estatura y otras medidas físicas de los estudiantes.

El objetivo de esta actividad es transformar datos individuales en información organizada mediante tablas estadísticas y representaciones gráficas que permitan apoyar la toma de decisiones.

5.10.1. Objetivos de aprendizaje

Al finalizar la actividad, el estudiante estará en capacidad de:

- Identificar el tipo de variable y su escala de medición.

- Organizar datos mediante tablas de frecuencia.
- Construir tablas agrupadas para variables cuantitativas continuas.
- Interpretar distribuciones estadísticas.
- Analizar patrones, dispersión y posibles valores extremos.
- Relacionar la estadística descriptiva con problemas reales de análisis de datos.

5.11. Desarrollo de la actividad

5.11.1. Parte 1. Exploración inicial de los datos

Cargue la base de datos y explore las variables disponibles.

```
library(readxl)
library(dplyr)

datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
#datos <- read_excel(
  "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
[1] "D:/estadistica-experiencial/data/bd_antropometricas.xlsx"
```

```
#)
```

```
head(datos)
```

```
# A tibble: 6 x 17
```

	Clase	Grupo	Genero	Altura_cm	Peso_Kg	Anchura_hombros_cm	Long_Mano_cm
	<chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	D	A	M	177	73	49	19
2	D	A	M	177	86	45	19
3	D	A	F	160	52	37	16
4	D	A	F	159	53	38	16
5	D	A	F	174	78	41	18
6	D	B	M	186	68	44	19

```
# i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
#   Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
#   Mano_Dicotica <chr>
```

```
names(datos)
```

```
[1] "Clase"           "Grupo"           "Genero"
[4] "Altura_cm"       "Peso_Kg"         "Anchura_hombros_cm"
[7] "Long_Mano_cm"    "Lon_Palma_cm"    "Ancho_Palma_cm"
[10] "Long_Brazo_cm"   "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm"     "Curso"           "Talla_Dicotica"
[16] "IMC_Dicotico"    "Mano_Dicotica"
```

```
glimpse(datos)
```

```
Rows: 260
```

```
Columns: 17
```

```
$ Clase      <chr> "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "D", "~
$ Grupo      <chr> "A", "A", "A", "A", "A", "B", "B", "B", "B", "B", "~
$ Genero     <chr> "M", "M", "F", "F", "F", "M", "M", "F", "F", "F", "~
```

```

$ Altura_cm          <dbl> 177, 177, 160, 159, 174, 186, 174, 172, 156, 165, 1~
$ Peso_Kg            <dbl> 73, 86, 52, 53, 78, 68, 115, 50, 62, 64, 94, 60, 63~
$ Anchura_hombros_cm <dbl> 49, 45, 37, 38, 41, 44, 49, 42, 42, 44, 48, 45, 36,~
$ Long_Mano_cm       <dbl> 19, 19, 16, 16, 18, 19, 21, 19, 19, 18, 19, 18, 17,~
$ Lon_Palma_cm       <dbl> 11.0, 10.0, 8.0, 9.0, 10.0, 11.0, 11.4, 10.1, 10.0,~
$ Ancho_Palma_cm     <dbl> 9.0, 9.0, 8.0, 8.0, 8.5, 8.0, 9.0, 7.0, 8.0, 8.0, 9~
$ Long_Brazo_cm      <dbl> 62.0, 59.0, 54.0, 52.0, 59.0, 74.0, 80.0, 76.0, 69.~
$ Long_Antebraco_cm  <dbl> 31.0, 31.0, 27.0, 27.0, 29.0, 29.0, 28.0, 26.0, 26.~
$ Long_Pierna_cm     <dbl> 42.7, 41.8, 40.9, 49.1, 48.0, 43.4, 42.4, 44.2, 47.~
$ Long_Pie_cm        <dbl> 23.7, 23.1, 25.1, 26.9, 27.0, 24.0, 22.9, 25.6, 24.~
$ Curso              <chr> "2020-1", "2020-1", "2020-1", "2020-1", "2020-1", "~
$ Talla_Dicotica     <chr> "Alta", "Alta", "Baja", "Baja", "Baja", "Alta", "Ba~
$ IMC_Dicotico       <chr> "Normal+", "Normal+", "Normal+", "Normal+", "Normal~
$ Mano_Dicotica      <chr> "Grande", "Grande", "Pequeña", "Pequeña", "Pequeña"~

```

5.11.2. Parte 2. Identificación de variables

Complete la siguiente tabla para las variables seleccionadas:

Variable	Tipo de variable	Escala de medición	Unidad de medida	Herramienta estadística sugerida
Genero				
Grupo				
Peso_Kg				
Altura_cm				

5.11.3. Parte 3. Organización y análisis del peso corporal

La variable Peso_Kg corresponde a una variable cuantitativa continua obtenida mediante procesos de medición. Debido a que puede asumir múltiples valores dentro de un intervalo, resulta conveniente organizar la información mediante tablas agrupadas y representaciones gráficas.

5.12. Situación problema

Los diseñadores requieren conocer:

- el rango de peso predominante,
- la dispersión de los datos,
- la presencia de valores extremos,
- y la homogeneidad de la muestra,

con el propósito de definir especificaciones ergonómicas adecuadas para las aulas universitarias.

5.12.1. Parte 4. Preguntas orientadoras

A partir del análisis de la variable Peso_Kg, responda:

1. ¿Dónde se concentra la mayor parte de los estudiantes?
2. ¿Existen valores extremos o atípicos?
3. ¿La distribución parece simétrica o presenta sesgo?
4. ¿Qué tan homogénea es la muestra?
5. ¿Sería recomendable agrupar los datos?

6. ¿Qué utilidad tendría esta información para el diseño del mobiliario universitario?

5.12.2. Parte 5. Construcción de tablas agrupadas

Utilice la regla de Sturges para estimar el número de clases y construya una tabla de distribución de frecuencias agrupadas.

La tabla debe incluir:

- Clase o intervalo
- Marca de clase
- Frecuencia absoluta (f_i)
- Frecuencia relativa (h_i)
- Frecuencia acumulada (F_i)
- Frecuencia relativa acumulada (H_i)

5.12.3. Parte 6. Visualización gráfica

Construya:

- Histograma
- Curva de densidad
- Boxplot

e interprete los resultados obtenidos.

5.12.4. Recomendación metodológica

La selección de la herramienta estadística depende del tipo de variable analizada:

Tipo de variable	Herramienta recomendada
Cualitativa	Tablas de frecuencia (<code>freq()</code>)
Cuantitativa discreta	Tablas de frecuencia (<code>freq()</code>)
Cuantitativa continua	Histogramas y tablas agrupadas

5.12.5. Reflexión final

La organización de datos constituye una etapa fundamental del análisis estadístico. Las tablas de frecuencia permiten transformar datos aislados en información estructurada, facilitando la identificación de patrones, tendencias y características generales de una población.

En contextos reales, estas herramientas son esenciales para apoyar procesos de investigación, caracterización poblacional y toma de decisiones basadas en evidencia. El análisis estadístico no consiste únicamente en calcular indicadores, sino en interpretar los datos y convertirlos en información útil para resolver problemas reales.

Capítulo 6

Visualización de datos

La visualización de datos es una etapa fundamental en la estadística descriptiva, ya que permite representar la información de forma clara, resumida e interpretable. Los gráficos facilitan la identificación de patrones, tendencias, valores atípicos y diferencias entre grupos, apoyando así la comprensión de los datos y la toma de decisiones.

En este capítulo se presentan algunos de los gráficos más utilizados en el análisis descriptivo: gráficos de barras, histogramas y diagramas de caja (*boxplot*), así como su construcción en R.

6.1. Gráficos en R

R es un lenguaje ampliamente utilizado para el análisis estadístico y la visualización de datos. Permite elaborar gráficos tanto con funciones básicas como con paquetes especializados, entre ellos `ggplot2`, que ofrece una sintaxis más flexible y una presentación más profesional.

Para los ejemplos de este capítulo se utilizarán las librerías `readxl` y `ggplot2`.

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 17
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>             <dbl>       <dbl>
1 D     A     M         177     73              49         19
2 D     A     M         177     86              45         19
3 D     A     F         160     52              37         16
4 D     A     F         159     53              38         16
5 D     A     F         174     78              41         18
6 D     B     M         186     68              44         19
# i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
#   Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
#   Mano_Dicotica <chr>
```

```
str(datos)
```

```
tibble [260 x 17] (S3: tbl_df/tbl/data.frame)
 $ Clase      : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo      : chr [1:260] "A" "A" "A" "A" ...
 $ Genero     : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm  : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg    : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
```

```

$ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
$ Long_Mano_cm      : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
$ Lon_Palma_cm      : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
$ Ancho_Palma_cm    : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
$ Long_Brazo_cm     : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
$ Long_Antebraco_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
$ Long_Pierna_cm    : num [1:260] 42.7 41.8 40.9 49.1 48 43.4 42.4 44.2 47.8 39.7 ...
$ Long_Pie_cm       : num [1:260] 23.7 23.1 25.1 26.9 27 24 22.9 25.6 24.4 24.4 ...
$ Curso             : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
$ Talla_Dicotica    : chr [1:260] "Alta" "Alta" "Baja" "Baja" ...
$ IMC_Dicotico      : chr [1:260] "Normal+" "Normal+" "Normal+" "Normal+" ...
$ Mano_Dicotica     : chr [1:260] "Grande" "Grande" "Pequeña" "Pequeña" ...

```

6.2. Gráfico de sectores

El gráfico de pastel es una representación estadística utilizada para mostrar la distribución porcentual de una variable cualitativa. Cada sector del círculo representa una categoría y su tamaño es proporcional a la frecuencia relativa o porcentaje que dicha categoría aporta al total de observaciones.

```

library(readxl)
library(dplyr)
library(ggplot2)
library(scales)

# Cargar base antropométrica
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Tabla de proporciones por género
tabla_genero <- datos %>%
  count(Genero) %>%
  mutate(
    proporcion = n / sum(n),
    porcentaje = percent(proporcion, accuracy = 0.1),
    etiqueta = paste0(Genero, "\n", porcentaje)
  )

# Gráfico de pastel
ggplot(
  tabla_genero,
  aes(
    x = "",
    y = proporcion,
    fill = Genero
  )
) +
  geom_col(
    width = 1,
    color = "white"
  ) +
  coord_polar(theta = "y") +
  geom_text(
    aes(label = etiqueta),
    position = position_stack(vjust = 0.5),
  )


```

```

size = 4
) +
labs(
  title = "Distribución porcentual de estudiantes según género",
  fill = "Género"
) +
theme_void()

```

Distribución porcentual de estudiantes según género



Interpretación de la gráfica: La gráfica evidencia que el 80 % de los estudiantes registrados en la base de datos corresponde al género femenino (F), mientras que el 20 % pertenece al género masculino (M). Esto indica una marcada predominancia de mujeres dentro de la muestra analizada.

Este tipo de representación facilita la comparación visual de proporciones entre categorías y permite identificar rápidamente la participación relativa de cada grupo dentro del conjunto de datos.

6.3. Gráfico de barras

El gráfico de barras se utiliza principalmente para representar variables cualitativas o categóricas. Su finalidad es mostrar la frecuencia o proporción de cada categoría mediante barras separadas, cuya altura es proporcional a la cantidad observada.

Por ejemplo, si se desea visualizar la distribución de una variable como el género o la clase, puede emplearse un gráfico de barras.

```


library(readxl)
library(dplyr)
library(ggplot2)

datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Gráfico de barras para Género
datos %>%

```

```
count(Grupo) %>%
ggplot(aes(x = Grupo, y = n)) +
geom_col(fill = "#1F77B4", color = "white") +
geom_text(
  aes(label = n),
  vjust = -0.4,
  size = 4
) +
labs(
  title = "Distribución de estudiantes según grupo",
  x = "Grupo",
  y = "Frecuencia"
) +
theme_minimal(base_size = 14)
```



```
library(readxl)
library(dplyr)
library(ggplot2)
library(scales)

datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Calcular proporciones por grupo
tabla_grupo <- datos %>%

  count(Grupo) %>%

  mutate(
    proporcion = n / sum(n)
  )
```

```
# Gráfico de barras con proporciones
ggplot(
  tabla_grupo,
  aes(x = Grupo, y = proporcion)
) +


  geom_col(
    fill = "#1F77B4",
    color = "white"
  ) +

  geom_text(
    aes(
      label = percent(proporcion)
    ),
    vjust = -0.4,
    size = 5
  ) +

  scale_y_continuous(
    labels = percent_format()
  ) +

  labs(
    title = "Proporción de estudiantes según grupo",
    x = "Grupo",
    y = "Proporción"
  ) +

  theme_minimal(base_size = 12)
```



Interpretación: El gráfico de proporciones permite identificar la participación relativa de cada grupo dentro del total

de estudiantes analizados. A diferencia de las frecuencias absolutas, las proporciones facilitan la comparación entre categorías y permiten interpretar la distribución porcentual de la muestra.

6.4. Histograma

El histograma se utiliza para representar la distribución de una variable cuantitativa continua. A diferencia del gráfico de barras, en el histograma las barras se presentan unidas, ya que representan intervalos de clase contiguos.

Este tipo de gráfico es útil para identificar la forma de la distribución, la concentración de valores, posibles asimetrías y presencia de valores extremos.

6.4.1. Ejemplo con funciones básicas de R

```
library(readr)
library(dplyr)


# Cargar base de datos de Acuicultura
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv")

#Número de cosechas en el año (P_S7P97)
#archivo de datos: S07D(Acuicultura)

names(acuicultura)

[1] "...1"      "TIPO_REG"   "PAIS"       "P_DEPTO"    "P_MUNIC"
[6] "UC_U0"     "ENCUESTA"   "COD_VEREDA" "P_S7PNUMPEZ" "P_S7P96"
[11] "P_S7P97"   "P_S7P98"    "P_S7P99"    "P_S7P100"

hist(acuicultura$P_S7P97,
     main = "Número de cosechas en el año (P_S7P97)",
     xlab = "Cosechas",
     ylab = "Frecuencia")
```



6.5. Boxplot

El diagrama de caja y bigotes, o *boxplot*, es un gráfico que resume la distribución de una variable cuantitativa a partir de los cuartiles, la mediana y los valores extremos. Es especialmente útil para detectar asimetrías y observaciones atípicas. El boxplot se basa en el resumen de cinco números:




Figura 6.1: Fuente: autores

6.5.1. Ejemplo con funciones básicas de R

```
library(readr)
library(ggplot2)

# Cargar base de datos
acuicultura <- read_csv(
  "C:/R-Proyectos/estadistica-experiencial/data/S07D_Acuicultura.csv"
)

# Boxplot
ggplot(
  acuicultura,

  aes(x = P_S7P97)
) +

  geom_boxplot(
```

```

fill = "#2C7FB8",

color = "black",

alpha = 0.9,

outlier.color = "red"
) +


labs(
  title = "Distribución del número de cosechas",

  x = "Número de cosechas",

  y = ""
) +

theme_minimal()

```



Interpretación: El boxplot evidencia que la mayor parte de las unidades productivas presentan un número bajo de cosechas, concentrándose principalmente entre 1 y 2 cosechas. La línea de la mediana se encuentra muy cercana al primer cuartil (Q1), lo cual sugiere una distribución asimétrica positiva, donde los valores altos son menos frecuentes pero considerablemente más dispersos.


Además, se observan múltiples valores atípicos hacia la derecha del gráfico, indicando la existencia de algunas unidades productivas con un número de cosechas significativamente superior al comportamiento general de la muestra. Esto evidencia una alta heterogeneidad en los datos y una posible concentración de productores con niveles excepcionales de producción.

El reducido tamaño de la caja refleja que el 50 % central de las observaciones se encuentra en un rango estrecho, mientras que la presencia de valores extremos amplía considerablemente el rango total de la distribución.

6.5.2. Ejemplo peso y género con ggplot2

También es posible comparar una variable cuantitativa entre categorías.

```
ggplot(datos, aes(x = Genero, y = Peso_Kg)) +  
  geom_boxplot() +  
  labs(  
    title = "Distribución del peso según género",  
    x = "Género",  
    y = "Peso"  
  )
```



Interpretación: el boxplot evidencia diferencias en la distribución del peso corporal según el género. En los hombres (M) se observa una mediana de peso superior y una mayor dispersión de los datos en comparación con las mujeres (F), lo que indica una variabilidad más amplia en los valores registrados.

Asimismo, en ambos grupos se identifican valores atípicos representados por puntos fuera de los bigotes del diagrama, correspondientes a individuos con pesos considerablemente superiores al comportamiento general de la muestra. La amplitud de las cajas sugiere que el 50 % central de los pesos se encuentra más concentrado en las mujeres, mientras que en los hombres existe una mayor heterogeneidad.

Este tipo de representación gráfica permite comparar simultáneamente medidas de tendencia central, dispersión y posibles valores extremos entre categorías.

6.6. Interpretación básica de los gráficos



Figura 6.2: Fuente: autores

Capítulo 7

Medidas de tendencia central y dispersión

Las medidas de tendencia central son herramientas estadísticas utilizadas para resumir un conjunto de datos mediante un valor representativo o típico. Su principal objetivo es describir el comportamiento general de una distribución y facilitar la comparación entre diferentes conjuntos de información.

En términos generales, una medida de tendencia central representa el punto alrededor del cual tienden a agruparse las observaciones. Estas medidas permiten sintetizar grandes volúmenes de datos en un único valor numérico que describe de manera aproximada el comportamiento de la variable analizada.

Con frecuencia, estas medidas son denominadas “promedios”; sin embargo, cada una posee características particulares y su uso depende de la naturaleza de los datos y del propósito del análisis.

Las tres medidas de tendencia central más utilizadas son:

- **Media aritmética:** representa el promedio de los valores observados.
- **Mediana:** corresponde al valor central de los datos ordenados.
- **Moda:** identifica el valor o categoría que aparece con mayor frecuencia.

La elección de la medida más adecuada depende del tipo de variable, la presencia de valores extremos y la forma de la distribución de los datos. Por ejemplo, la media suele verse afectada por valores atípicos, mientras que la mediana ofrece una medida más robusta en distribuciones asimétricas.

Estas medidas constituyen una base fundamental para el análisis estadístico descriptivo y son ampliamente utilizadas en áreas como la salud, educación, ingeniería, economía y ciencias sociales, ya que permiten resumir información y apoyar la toma de decisiones basada en datos.

En este capítulo se presentan las principales medidas de tendencia central y de dispersión, junto con su formulación matemática y su implementación en R.

Capítulo 8

Medidas de tendencia central

8.0.1. Media aritmética

La media aritmética es el promedio de los datos y se calcula como la suma de todas las observaciones dividida entre el número total de datos.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Donde: (x_i) : cada observación, (n) : número total de datos, $\bar{x}$: media aritmética

8.0.2. Cálculo en R

```
library(readxl)
datos <- read_excel("C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx")
head(datos)
```

```
# A tibble: 6 x 7
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>    <dbl>          <dbl>          <dbl>
1 D     A     M         177      73             49             19
2 D     A     M         177      86             45             19
3 D     A     F         160      52             37             16
4 D     A     F         159      53             38             16
5 D     A     F         174      78             41             18
6 D     B     M         186      68             44             19
# i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
#   Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
#   Mano_Dicotica <chr>
```

```
str(datos)

tibble [260 x 17] (S3: tbl_df/tbl/data.frame)
 $ Clase      : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo      : chr [1:260] "A" "A" "A" "A" ...
 $ Genero     : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm  : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg    : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
```

```
$ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
$ Long_Mano_cm      : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
$ Lon_Palma_cm      : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
$ Ancho_Palma_cm    : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
$ Long_Brazo_cm     : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
$ Long_Antebrazo_cm : num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
$ Long_Pierna_cm    : num [1:260] 42.7 41.8 40.9 49.1 48 43.4 42.4 44.2 47.8 39.7 ...
$ Long_Pie_cm       : num [1:260] 23.7 23.1 25.1 26.9 27 24 22.9 25.6 24.4 24.4 ...
$ Curso             : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
$ Talla_Dicotica    : chr [1:260] "Alta" "Alta" "Baja" "Baja" ...
$ IMC_Dicotico      : chr [1:260] "Normal+" "Normal+" "Normal+" "Normal+" ...
$ Mano_Dicotica     : chr [1:260] "Grande" "Grande" "Pequeña" "Pequeña" ...
```

```
names(datos)
```

```
[1] "Clase"           "Grupo"           "Genero"
[4] "Altura_cm"       "Peso_Kg"          "Anchura_hombros_cm"
[7] "Long_Mano_cm"    "Lon_Palma_cm"     "Ancho_Palma_cm"
[10] "Long_Brazo_cm"   "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm"     "Curso"            "Talla_Dicotica"
[16] "IMC_Dicotico"    "Mano_Dicotica"
```

```
mean(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 54.29808
```

8.0.3. Mediana

La mediana es el valor que divide el conjunto de datos ordenados en dos partes iguales, de modo que el 50 % de las observaciones queda por debajo y el otro 50 % por encima.

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, & n \text{ impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & n \text{ par} \end{cases}$$

La mediana es una medida robusta frente a valores extremos.

8.0.4. Cálculo en R

```
median(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 50
```

8.0.5. Moda

La moda es el valor que aparece con mayor frecuencia en el conjunto de datos.

$$\text{Moda} = \arg \max(f_i)$$

8.0.6. Cálculo en R

```
moda <- function(x) {
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}
```

```
moda(datos$Peso_Kg)
```

```
[1] 40
```

8.1. Visualización de las medidas de tendencia central

```
library(readxl)
library(ggplot2)

# Cargar datos
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Función para calcular la moda
moda <- function(x) {
  x <- na.omit(x)
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

# Medidas de tendencia central
media <- mean(datos$Peso_Kg, na.rm = TRUE)
mediana <- median(datos$Peso_Kg, na.rm = TRUE)
moda_val <- moda(datos$Peso_Kg)

# Histograma
ggplot(datos, aes(x = Peso_Kg)) +

  geom_histogram(
    bins = 10,
    fill = "skyblue",
    color = "black",
    alpha = 0.7
  ) +

  # Media
  geom_vline(
    xintercept = media,
    color = "red",
    linewidth = 1.2,
    linetype = "dashed"
  ) +

  # Mediana
  geom_vline(
    xintercept = mediana,
    color = "blue",
    linewidth = 1.2
  ) +

  # Moda
  geom_vline(
```


```

xintercept = moda_val,
color = "darkgreen",
linewidth = 1.2,
linetype = "dotdash"
) +

labs(
  title = "Distribución del peso",
  subtitle = "Media (rojo), Mediana (azul) y Moda (verde)",
  x = "Peso (kg)",
  y = "Frecuencia"
) +

theme_minimal()

```



8.2. Interpretación del gráfico: Distribución del peso

El histograma presenta la distribución de la variable **Peso (kg)** en la muestra analizada, incorporando las tres principales medidas de tendencia central:

□ **Media** (línea roja) □ **Mediana** (línea azul) □ **Moda** (línea verde)

8.2.1. Análisis estadístico

La media es mayor que la mediana y la moda

Se observa que: $Media > Mediana > Moda$. Esto indica una **asimetría positiva** o sesgo hacia la derecha.

Existencia de valores extremos

La presencia de individuos con pesos altos (aproximadamente entre 140 y 190 kg) desplaza la media hacia valores mayores. Estos datos atípicos afectan principalmente la media, mientras que la mediana permanece más estable.

Concentración principal de los datos

La mayor frecuencia de observaciones se concentra entre aproximadamente **35 y 65 kg**, lo que indica que la mayoría de los participantes presentan pesos dentro de ese intervalo.

Comportamiento de la moda

La moda se ubica en el intervalo de mayor frecuencia, representando el peso más común dentro de la muestra.

8.3. Ejercicio experiencial propuesto

8.4. Actividad: Explorando las características antropométricas

Objetivo: Analizar diferentes variables antropométricas mediante histogramas y medidas de tendencia central para identificar patrones de distribución, variabilidad y posibles valores atípicos.

Variable	Interpretación
Altura_cm	Distribución de estaturas
Anchura_hombros_cm	Variabilidad corporal
Long_Brazo_cm	Proporciones anatómicas
Long_Muslo_cm	Longitud del miembro inferior
Long_Antebrazo_cm	Variabilidad segmentaria

8.5. Actividad práctica

8.5.1. Construcción del gráfico

Construya un histograma para cada una de las siguientes variables:

- Altura_cm
- Anchura_hombros_cm
- Long_Brazo_cm

Incluya mediante líneas verticales de diferentes colores.

- Media, Mediana, Moda

8.5.2. Interpretación

Para cada gráfico responda:

1. ¿La distribución parece simétrica o asimétrica?
2. ¿Existen valores extremos?
3. ¿La media y la mediana son similares?
4. ¿Qué medida representa mejor el comportamiento de los datos?
5. ¿Cuál variable presenta mayor dispersión?

Capítulo 9

Medidas de dispersión o variabilidad

Las medidas de dispersión o variabilidad complementan a las medidas de tendencia central, ya que permiten describir qué tan agrupados o dispersos se encuentran los datos respecto a un valor representativo, como la media o la mediana.

Mientras que las medidas de tendencia central resumen la distribución mediante un único valor típico, las medidas de dispersión indican el grado de heterogeneidad presente en los datos. En consecuencia, dos conjuntos de datos pueden tener la misma media, pero comportamientos muy diferentes en cuanto a su variabilidad.

Por ejemplo, un grupo de observaciones puede presentar valores muy cercanos entre sí y concentrados alrededor de la media, mientras que otro grupo puede mostrar valores mucho más dispersos. Aunque ambos conjuntos tengan el mismo promedio, el segundo exhibirá mayor variabilidad.

La variabilidad constituye un aspecto fundamental en el análisis estadístico, ya que permite evaluar la estabilidad, consistencia y homogeneidad de los datos. En muchos contextos aplicados, comprender la dispersión resulta tan importante como conocer el promedio.

9.0.1. Rango

El rango es la diferencia entre el valor máximo y el mínimo.

$$R = X_{\max} - X_{\min}$$

9.0.2. Cálculo en R

```
max(datos$Peso_Kg, na.rm = TRUE) - min(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 84
```

9.0.3. Varianza muestral

La varianza mide la dispersión promedio de los datos respecto a la media.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

9.0.4. Cálculo en R

```
var(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 297.2303
```

9.0.5. Varianza poblacional

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

9.0.6. Desviación estándar muestral

La desviación estándar es la raíz cuadrada de la varianza y expresa la dispersión en las mismas unidades de los datos.

$$s = \sqrt{s^2}$$

9.0.7. Cálculo en R

```
sd(datos$Peso_Kg, na.rm = TRUE)
```

```
[1] 17.24037
```

9.0.8. Desviación estándar poblacional

$$\sigma = \sqrt{\sigma^2}$$

9.0.9. Coeficiente de variación

El coeficiente de variación permite comparar la dispersión relativa respecto a la media.

$$CV = \frac{s}{\bar{x}} \times 100$$

9.0.10. Cálculo en R

```
(sd(datos$Peso_Kg, na.rm = TRUE) / mean(datos$Peso_Kg, na.rm = TRUE)) * 100
```

```
[1] 31.75134
```

9.1. Resumen estadístico en R

R permite obtener múltiples medidas descriptivas de manera simultánea.

```
summary(datos$Peso_Kg)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
31.0	40.0	50.0	54.3	64.0	115.0

También es posible calcular varias medidas en conjunto:

```
library(summarytools)
descr(datos, stats=c("mean", "sd", "q1", "med", "q3", "min", "max", "cv"))
```

```
Descriptive Statistics
datos
N: 260
```

Altura_cm	Ancho_Palma_cm	Anchura_hombros_cm	Lon_Palma_cm	Long_Antebrazo_cm
-----------	----------------	--------------------	--------------	-------------------

Mean	166.81	8.07	53.83	9.46	27.54
Std.Dev	8.72	1.31	15.08	1.37	3.70
Q1	160.00	7.00	42.00	9.00	26.00
Median	165.00	8.00	49.00	10.00	27.00
Q3	173.00	9.00	63.00	10.00	29.00
Min	150.00	5.00	36.00	6.00	20.00
Max	192.00	13.50	130.00	12.00	50.00
CV	0.05	0.16	0.28	0.14	0.13

Table: Table continues below

	Long_Brazo_cm	Long_Mano_cm	Long_Pie_cm	Long_Pierna_cm	Peso_Kg
Mean	68.01	17.56	23.96	43.07	54.30
Std.Dev	12.16	4.38	1.53	3.32	17.24
Q1	66.00	16.10	22.90	40.60	40.00
Median	71.00	17.00	23.90	43.15	50.00
Q3	75.00	18.30	25.00	45.30	64.00
Min	17.00	7.00	20.50	33.20	31.00
Max	84.00	83.00	28.10	51.90	115.00
CV	0.18	0.25	0.06	0.08	0.32

9.2. Histograma + desviación estándar

```
media <- mean(datos$Peso_Kg, na.rm = TRUE)
desv <- sd(datos$Peso_Kg, na.rm = TRUE)
```

```
ggplot(datos, aes(x = Peso_Kg)) +
```

```
  geom_histogram(
    bins = 10,
    fill = "skyblue",
    color = "black"
  ) +
```

```
  # Media
  geom_vline(
    xintercept = media,
    color = "red",
    linewidth = 1.2
  ) +
```

```
  # ±1 desviación estándar
  geom_vline(
    xintercept = media + desv,
    color = "darkgreen",
    linetype = "dashed",
    linewidth = 1
  ) +
```

```
  geom_vline(
    xintercept = media - desv,
```


```

    color = "darkgreen",
    linetype = "dashed",
    linewidth = 1
) +

labs(
  title = "Distribución del peso y desviación estándar",
  subtitle = "Línea roja = media | Líneas verdes =  $\pm 1$  desviación estándar",
  x = "Peso (kg)",
  y = "Frecuencia"
) +

theme_minimal()

```



9.2.1. Interpretación

El histograma del peso complementado con la media y la desviación estándar permite analizar tanto la tendencia central como la variabilidad de los datos. La línea roja representa la media del peso de los participantes, mientras que las líneas verdes discontinuas indican un intervalo aproximado de una desviación estándar por encima y por debajo de la media. Este intervalo permite identificar el rango donde se concentra gran parte de las observaciones.

En la distribución analizada se observa que la mayoría de los individuos presentan pesos cercanos a la media, concentrándose principalmente dentro del intervalo delimitado por las líneas de desviación estándar. Sin embargo, también se identifican algunos valores alejados del centro de la distribución, lo que sugiere la presencia de posibles valores atípicos o una dispersión considerable en ciertos casos. Desde el punto de vista estadístico, una desviación estándar pequeña indica que los datos son más homogéneos y se agrupan cerca de la media; por el contrario, una desviación estándar grande refleja una mayor heterogeneidad y dispersión de los datos.


9.3. Comparar dispersión entre géneros

```
ggplot(datos, aes(x = Peso_Kg)) +
```

```
geom_density(
  fill = "lightgreen",
  alpha = 0.5
) +

labs(
  title = "Densidad del peso",
  subtitle = "Visualización de la dispersión de los datos",
  x = "Peso (kg)",
  y = "Densidad"
) +

theme_classic()
```



9.3.1. Interpretación

La curva de densidad representa una versión suavizada de la distribución de los datos y permite visualizar la concentración de observaciones a lo largo de los valores de la variable peso.

Las zonas más altas de la curva indican intervalos donde existe una mayor concentración de individuos, mientras que las áreas más bajas representan valores menos frecuentes. La forma de la curva permite evaluar características importantes de la distribución, tales como: simetría; presencia de sesgo; concentración de datos; posibles agrupamientos y dispersión general.

Si la curva presenta una forma aproximadamente simétrica, puede inferirse que los datos tienden a distribuirse de manera equilibrada alrededor de la media. En cambio, una cola más larga hacia alguno de los extremos indica asimetría o sesgo en la distribución.

Asimismo, una curva más ancha y extendida refleja mayor dispersión de los datos, mientras que una curva más estrecha indica mayor homogeneidad. La curva de densidad constituye una herramienta útil para comprender visualmente la estructura de la distribución y complementar el análisis realizado mediante histogramas y medidas descriptivas.


```
ggplot(datos, aes(x = Genero, y = Peso_Kg, fill = Genero)) +
```

```
geom_violin(alpha = 0.7) +

geom_boxplot(
  width = 0.1,
  fill = "white"
) +

labs(
  title = "Distribución y dispersión del peso",
  x = "Género",
  y = "Peso (kg)"
) +

theme_minimal()
```



9.3.2. Interpretación

El boxplot comparativo del peso según género permite evaluar diferencias en la tendencia central y la dispersión entre los grupos analizados. Cada caja representa el rango intercuartílico de los datos, es decir, el intervalo donde se concentra el 50 % central de las observaciones. La línea ubicada dentro de la caja corresponde a la mediana, mientras que los puntos alejados representan posibles valores atípicos.

A partir de la gráfica es posible identificar: diferencias en la mediana del peso entre géneros; variaciones en la amplitud de las cajas, asociadas al grado de dispersión; presencia de valores extremos; diferencias en la homogeneidad de los grupos.

Un grupo con cajas más amplias y bigotes más extensos presenta mayor variabilidad, indicando que los valores se encuentran más dispersos. Por el contrario, cajas más compactas sugieren una distribución más homogénea. Este tipo de análisis resulta especialmente útil para comparar poblaciones y explorar patrones de comportamiento de variables antropométricas en distintos grupos.

9.4. Resumen gráfico

Las medidas de tendencia central y dispersión son esenciales para describir un conjunto de datos. Su correcta interpretación permite comprender la estructura de la información, identificar patrones y apoyar la toma de decisiones basada en evidencia. En R, estas medidas pueden calcularse de forma sencilla, lo que facilita su aplicación en análisis estadísticos tanto exploratorios como inferenciales.




Figura 9.1: Fuente: Autores

Capítulo 10

Medidas de posición y forma

Las medidas de posición y forma constituyen herramientas fundamentales de la estadística descriptiva, ya que permiten profundizar en la comprensión del comportamiento de una distribución de datos más allá de los valores centrales. Mientras las medidas de posición, como los cuartiles, deciles y percentiles, permiten determinar la ubicación relativa de una observación dentro de un conjunto ordenado de datos, las medidas de forma describen características estructurales de la distribución, tales como la simetría y el grado de concentración de las observaciones alrededor de la media.

El estudio conjunto de estas medidas facilita una interpretación más completa de los fenómenos analizados, permitiendo identificar patrones, desigualdades, concentraciones, sesgos y posibles valores extremos. Asimismo, conceptos asociados como el rango intercuartílico, los diagramas de caja y bigotes (boxplots), las curvas percentilares y los histogramas complementan el análisis estadístico mediante representaciones visuales que favorecen la interpretación de los datos.

Estas herramientas poseen amplias aplicaciones en contextos reales como el análisis del rendimiento académico, la clasificación de riesgo, la distribución salarial, los estudios antropométricos y las evaluaciones en salud pública, donde resulta esencial comprender no solo el valor promedio de una variable, sino también la posición relativa y la forma general de su distribución.

10.1. Medidas de posición

Las medidas de posición son indicadores estadísticos que permiten determinar la ubicación relativa de un valor dentro de un conjunto de datos ordenados. Estas medidas dividen la distribución en partes iguales y permiten identificar qué proporción de las observaciones se encuentra por debajo o por encima de un determinado valor.

A diferencia de las medidas de tendencia central, cuyo propósito es resumir el comportamiento típico de los datos mediante un único valor representativo, las medidas de posición permiten describir la distribución desde una perspectiva relativa o acumulativa.

Por ejemplo:

- ¿Qué valor deja por debajo al 25 % de las observaciones?
- ¿Cuál es el punto que supera el 90 % de la población?
- ¿En qué posición relativa se encuentra un estudiante respecto a sus compañeros?

Estas preguntas pueden responderse mediante cuartiles, deciles y percentiles.

10.2. Clasificación de las medidas de posición

Las principales medidas de posición son:

Medida	División de los datos
Cuartiles	4 partes iguales
Deciles	10 partes iguales
Percentiles	100 partes iguales

Todas comparten la misma lógica matemática:

1. ordenar los datos;
2. calcular una posición;
3. identificar el valor correspondiente dentro de la distribución.

10.3. Cuartiles

Los cuartiles son medidas de posición que dividen un conjunto de datos ordenados en cuatro partes iguales, de tal manera que cada grupo contiene aproximadamente el 25 % de las observaciones. Se representan mediante:

Cuartil	Interpretación
Q_1 : primer cuartil	El 25 % de los datos es menor o igual a este valor
Q_2 : segundo cuartil	Corresponde a la mediana; el 50 % de los datos queda por debajo
Q_3 : tercer cuartil	El 75 % de los datos es menor o igual a este valor

10.3.1. Fórmula de posición

La posición del cuartil se calcula mediante:

$$L_k = \frac{k \cdot n}{4}$$

donde:

- L_k : posición del cuartil,
- k : número del cuartil,
- n : número total de observaciones.

Los cuartiles poseen amplias aplicaciones en diferentes áreas del conocimiento, debido a que permiten dividir una distribución de datos en cuatro partes iguales y analizar la posición relativa de las observaciones dentro de un conjunto ordenado. En estudios antropométricos y ergonómicos, por ejemplo, los cuartiles se utilizan para diseñar mobiliario y espacios adaptados a las características físicas de la población. De igual manera, en evaluación nutricional permiten clasificar individuos según variables como peso, talla o índice de masa corporal.

En el ámbito educativo, los cuartiles facilitan la clasificación académica y la comparación del desempeño relativo de los estudiantes dentro de un grupo. Asimismo, en economía y ciencias sociales son empleados para estudiar la distribución salarial y analizar desigualdades entre diferentes segmentos de la población.

Los cuartiles también constituyen la base de los diagramas de caja y bigotes (boxplots), una representación gráfica ampliamente utilizada para visualizar la distribución de los datos, identificar valores extremos y evaluar la variabilidad de una muestra.

A partir de los cuartiles puede calcularse el rango intercuartílico (RIC), definido como la diferencia entre el tercer y el primer cuartil:

$$RIC = Q_3 - Q_1$$

Esta medida representa la dispersión del 50 % central de los datos y resulta especialmente útil porque no se ve afectada significativamente por valores atípicos o extremos.

10.4. Deciles

Los deciles son medidas de posición que dividen un conjunto de datos ordenados en diez partes iguales, de manera que cada grupo representa el 10 % de las observaciones. Se denotan como:

Decil	Interpretación
D_1	El 10 % de los datos es menor o igual a este valor
D_5	Coincide con la mediana
D_9	El 90 % de los datos queda por debajo

10.4.1. Fórmula de posición

$$L_k = \frac{k \cdot n}{10}$$

10.5. Aplicaciones de los deciles

Los deciles se utilizan frecuentemente en:

- pruebas estandarizadas,
- análisis socioeconómico,
- estudios de desigualdad,
- distribución de ingresos,
- clasificación poblacional.

10.6. Percentiles

Los percentiles son medidas de posición que dividen un conjunto de datos ordenados en cien partes iguales, donde cada parte representa el 1 % de las observaciones. Se representan mediante: $P_1, P_2, P_3, \dots, P_{99}$. El percentil P_k indica que el $k\%$ de las observaciones es menor o igual a dicho valor. Por ejemplo:

- $P_{25} = Q_1$
- $P_{50} = Q_2$
- $P_{75} = Q_3$

10.6.1. Fórmula de posición

$$L_k = \frac{k \cdot n}{100}$$

10.6.2. Aplicaciones de los percentiles

Los percentiles son fundamentales en curvas de crecimiento infantil, evaluación médica, pruebas académicas, clasificación nutricional, análisis de desempeño, entre otras.



Figura 10.1: Fuente: autores

10.7. Medidas de forma

Las medidas de forma permiten describir la estructura general de una distribución estadística, evaluando características como: simetría, concentración, colas extremas, comportamiento alrededor de la media. Las principales medidas de forma son: asimetría y curtosis.

10.7.1. Asimetría

La asimetría evalúa el grado de sesgo de una distribución.

Tipo	Característica
Simétrica	Ambos lados son similares
Asimetría positiva	Cola hacia la derecha
Asimetría negativa	Cola hacia la izquierda

10.7.2. Curtosis

La curtosis describe el grado de concentración de los datos alrededor de la media.

Tipo	Característica
Leptocúrtica	Distribución alta y concentrada
Mesocúrtica	Similar a distribución normal
Platicúrtica	Distribución achatada


MEDIDAS DE FORMA

Describen la estructura general de una distribución estadística.
Permiten evaluar la simetría y la concentración de los datos.

1. ASIMETRÍA (SESGO)

Mide el grado y la dirección del sesgo de una distribución respecto a la simetría.


Simétrica



La distribución es equilibrada a ambos lados de la media.

Asimetría ≈ 0


Asimetría positiva (sesgo a la derecha)



La cola se extiende hacia valores mayores.

Asimetría > 0

Asimetría negativa (sesgo a la izquierda)



La cola se extiende hacia valores menores.

Asimetría < 0

FÓRMULA (Coeficiente de asimetría de Fisher)

$$g_1 = \frac{m_3}{s^3}$$

- m_3 : tercer momento central
- s : desviación estándar

INTERPRETACIÓN

Valor de g_1	Interpretación
$g_1 = 0$	Distribución simétrica
$g_1 > 0$	Asimetría positiva
$g_1 < 0$	Asimetría negativa



IDEAS CLAVE

- En distribuciones simétricas: media = mediana = moda.
- Si la media > mediana → asimetría positiva.
- Si la media < mediana → asimetría negativa.
- La asimetría es sensible a valores extremos.

APLICACIONES



Análisis de ingresos



Rendimiento académico



Estudios en salud




Gestión de riesgos

2. CURTOSIS (APUNTAMIENTO)

Mide el grado de concentración de los datos alrededor de la media y el peso de las colas de la distribución.


Leptocúrtica



Distribución alta y muy concentrada con colas largas y pesadas.

Curtosis > 3


Mesocúrtica (normal)



Similar a la distribución normal.

Curtosis = 3

Platicúrtica



Distribución achatada con colas cortas y livianas.

Curtosis < 3

FÓRMULA (Curtosis de Fisher)

$$g_2 = \frac{m_4}{s^4}$$

- m_4 : cuarto momento central
- s : desviación estándar

INTERPRETACIÓN

Valor de g_2	Interpretación
$g_2 = 0$	Mesocúrtica (normal)
$g_2 > 0$	Leptocúrtica
$g_2 < 0$	Platicúrtica



IDEAS CLAVE

- Curtosis alta → más valores extremos.
- Curtosis baja → datos más dispersos y colas cortas.
- Es útil para evaluar riesgo y estabilidad de procesos.
- La curtosis también es sensible a valores extremos.

APLICACIONES



Mercados financieros



Control de calidad



Modelamiento de riesgos




Investigación biomédica



RELACIÓN ENTRE MEDIDAS DE POSICIÓN Y FORMA

- Las medidas de posición (cuantiles, deciles, percentiles) describen la ubicación relativa de los datos.
- Las medidas de forma (asimetría y curtosis) describen la estructura y el comportamiento de la distribución.
- Juntas permiten un análisis más completo y robusto de los datos.


COMPLEMENTO VISUAL




Simétrica



Asimetría positiva



Asimetría negativa



RECUERDA

Las medidas de forma no dependen únicamente de la media o de la dispersión, sino de toda la distribución. Su interpretación requiere siempre contexto y conocimiento del fenómeno estudiado.



EN RESUMEN:



Asimetría → dirección del sesgo (simétrica, derecha o izquierda).



Curtosis → concentración y peso de las colas (alta, normal o baja).



Ambas medidas aportan información clave para interpretar fenómenos reales.



Su análisis conjunto mejora la toma de decisiones basadas en evidencia.

Figura 10.2: Fuente: autores

Capítulo 11

Análisis bivariado

En los capítulos anteriores se estudiaron las características de una sola variable a la vez, analizando aspectos como la tendencia central, la dispersión, la posición y la forma de los datos. Sin embargo, en los problemas reales rara vez las variables actúan de manera aislada. En la práctica, los fenómenos sociales, económicos, educativos, biológicos y administrativos suelen depender de la interacción entre múltiples variables.

Por ejemplo, en educación puede surgir la pregunta de si un mayor número de horas de estudio se relaciona con mejores calificaciones; en salud, si existe asociación entre el índice de masa corporal y la presión arterial; o en economía, si el nivel de ingresos influye sobre el gasto familiar. Todas estas situaciones requieren estudiar simultáneamente dos variables y comprender cómo se comportan conjuntamente.

El análisis bivariado corresponde precisamente al conjunto de técnicas estadísticas utilizadas para explorar, describir, cuantificar e interpretar la relación entre dos variables medidas sobre las mismas unidades de análisis. A diferencia del análisis univariado, cuyo propósito es describir individualmente una variable, el análisis bivariado busca identificar patrones de asociación, dependencia o predicción entre variables.

Dependiendo de la naturaleza de las variables involucradas, el análisis bivariado puede abordar diferentes situaciones: relaciones entre variables cuantitativas; asociaciones entre variables categóricas; comparación de una variable cuantitativa entre categorías.

En este capítulo se desarrollan las principales herramientas del análisis bivariado, incluyendo:

diagramas de dispersión, covarianza, correlación de Pearson, correlación de Spearman, tablas de contingencia, y regresión lineal simple.

Cada técnica será presentada desde una perspectiva teórica y posteriormente aplicada mediante ejemplos desarrollados en R utilizando un mismo conjunto de datos, con el propósito de facilitar la comprensión progresiva del análisis estadístico y fortalecer el aprendizaje experiencial. Es importante destacar que el análisis bivariado constituye la base de técnicas estadísticas más avanzadas, como la regresión múltiple, el análisis multivariado y los modelos predictivos utilizados actualmente en ciencia de datos, inteligencia artificial y analítica aplicada.

11.1. Tipos de análisis bivariado

El tipo de análisis bivariado que puede realizarse depende de la naturaleza de las variables estudiadas. En estadística, las variables pueden ser cuantitativas o categóricas, y cada combinación requiere herramientas específicas de exploración, visualización e interpretación.

Cuando ambas variables son cuantitativas, el interés suele centrarse en evaluar si existe asociación, dependencia o relación funcional entre ellas. En estos casos se utilizan herramientas como diagramas de dispersión, covarianza, correlación y regresión lineal. Por ejemplo, puede analizarse la relación entre horas de estudio y calificación final, o entre peso corporal y estatura.

Si ambas variables son categóricas, el objetivo principal consiste en estudiar asociaciones entre categorías o grupos. Para ello se emplean tablas de contingencia y medidas de asociación categórica. Un ejemplo frecuente corresponde al análisis de la relación entre género y nivel de satisfacción académica.

También existen situaciones donde una variable es cuantitativa y la otra categórica. En estos casos, el interés radica en comparar el comportamiento de la variable numérica entre diferentes grupos o categorías. Por ejemplo, comparar las calificaciones promedio entre hombres y mujeres, o analizar diferencias salariales entre regiones.

La siguiente tabla resume las principales combinaciones posibles en el análisis bivariado:

Tipo de variable 1	Tipo de variable 2	Objetivo principal	Técnicas utilizadas
C uantitativa	C uantitativa	Evaluar asociación o predicción	Correlación, regresión, dispersión
Categórica	Categórica	Analizar asociación entre categorías	Tablas de contingencia
C uantitativa	Categórica	Comparar grupos	Boxplot, medias, comparación gráfica

Comprender el tipo de variables involucradas constituye un paso fundamental antes de seleccionar cualquier técnica estadística, ya que una elección incorrecta puede conducir a interpretaciones inadecuadas o resultados inconsistentes.

En este capítulo se abordarán ejemplos correspondientes a cada una de estas situaciones, integrando representaciones gráficas, medidas estadísticas y modelos básicos de análisis bivariado mediante implementaciones desarrolladas en R.

11.2. Conjunto de datos de trabajo

A lo largo de este capítulo se utilizará un mismo conjunto de datos con el propósito de ilustrar las diferentes técnicas de análisis bivariado de manera integrada y progresiva. El uso de un único dataset facilita la comparación de resultados y permite comprender cómo distintas herramientas estadísticas pueden analizar una misma realidad desde perspectivas complementarias.

La base de datos contiene información correspondiente a estudiantes universitarios e incluye variables cuantitativas y categóricas, entre ellas:

horas de estudio semanales, calificación final, horas de sueño, y género.

Estas variables permiten desarrollar ejemplos relacionados con:

relaciones entre variables cuantitativas, asociaciones entre variables categóricas, y comparación de grupos.

En términos pedagógicos, este enfoque favorece el aprendizaje experiencial, ya que el estudiante puede observar cómo los conceptos teóricos se aplican directamente sobre datos reales mediante análisis reproducibles en R.

11.2.1. Carga de datos en R

```
library(readxl)
library(dplyr)

datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

head(datos)
```

```
# A tibble: 6 x 17
  Clase Grupo Genero Altura_cm Peso_Kg Anchura_hombros_cm Long_Mano_cm
  <chr> <chr> <chr>      <dbl>   <dbl>             <dbl>         <dbl>
```

```

1 D      A      M      177      73      49      19
2 D      A      M      177      86      45      19
3 D      A      F      160      52      37      16
4 D      A      F      159      53      38      16
5 D      A      F      174      78      41      18
6 D      B      M      186      68      44      19
# i 10 more variables: Lon_Palma_cm <dbl>, Ancho_Palma_cm <dbl>,
#   Long_Brazo_cm <dbl>, Long_Antebrazo_cm <dbl>, Long_Pierna_cm <dbl>,
#   Long_Pie_cm <dbl>, Curso <chr>, Talla_Dicotica <chr>, IMC_Dicotico <chr>,
#   Mano_Dicotica <chr>

```

11.2.2. Exploración inicial de variables

```
names(datos)
```

```

[1] "Clase"           "Grupo"           "Genero"
[4] "Altura_cm"       "Peso_Kg"         "Anchura_hombros_cm"
[7] "Long_Mano_cm"    "Lon_Palma_cm"    "Ancho_Palma_cm"
[10] "Long_Brazo_cm"   "Long_Antebrazo_cm" "Long_Pierna_cm"
[13] "Long_Pie_cm"     "Curso"           "Talla_Dicotica"
[16] "IMC_Dicotico"    "Mano_Dicotica"

```

```
str(datos)
```

```


tibble [260 x 17] (S3: tbl_df/tbl/data.frame)
 $ Clase           : chr [1:260] "D" "D" "D" "D" ...
 $ Grupo           : chr [1:260] "A" "A" "A" "A" ...
 $ Genero           : chr [1:260] "M" "M" "F" "F" ...
 $ Altura_cm       : num [1:260] 177 177 160 159 174 186 174 172 156 165 ...
 $ Peso_Kg         : num [1:260] 73 86 52 53 78 68 115 50 62 64 ...
 $ Anchura_hombros_cm: num [1:260] 49 45 37 38 41 44 49 42 42 44 ...
 $ Long_Mano_cm     : num [1:260] 19 19 16 16 18 19 21 19 19 18 ...
 $ Lon_Palma_cm     : num [1:260] 11 10 8 9 10 11 11.4 10.1 10 10 ...
 $ Ancho_Palma_cm   : num [1:260] 9 9 8 8 8.5 8 9 7 8 8 ...
 $ Long_Brazo_cm    : num [1:260] 62 59 54 52 59 74 80 76 69 70 ...
 $ Long_Antebrazo_cm: num [1:260] 31 31 27 27 29 29 28 26 26 27 ...
 $ Long_Pierna_cm   : num [1:260] 42.7 41.8 40.9 49.1 48 43.4 42.4 44.2 47.8 39.7 ...
 $ Long_Pie_cm      : num [1:260] 23.7 23.1 25.1 26.9 27 24 22.9 25.6 24.4 24.4 ...
 $ Curso           : chr [1:260] "2020-1" "2020-1" "2020-1" "2020-1" ...
 $ Talla_Dicotica   : chr [1:260] "Alta" "Alta" "Baja" "Baja" ...
 $ IMC_Dicotico     : chr [1:260] "Normal+" "Normal+" "Normal+" "Normal+" ...
 $ Mano_Dicotica    : chr [1:260] "Grande" "Grande" "Pequeña" "Pequeña" ...

```

11.3. Diagrama de dispersión

El diagrama de dispersión, también conocido como nube de puntos, es una representación gráfica utilizada para explorar la relación entre dos variables cuantitativas. Cada punto del gráfico representa una observación y su posición en el plano cartesiano depende de los valores registrados para las variables X y Y .

Esta herramienta constituye generalmente el primer paso del análisis bivariado, ya que permite identificar visualmente patrones de asociación, tendencias, agrupamientos y posibles valores atípicos antes de aplicar medidas numéricas de correlación o modelos de regresión. A partir de un diagrama de dispersión pueden identificarse diferentes comportamientos entre las variables:




```

    size = 3,
    alpha = 0.75
) +

scale_color_manual(
  values = c(
    "F" = "#D95F02",
    "M" = "#1B9E77"
  )
) +

labs(
  title = "Relación entre altura y peso corporal",

  subtitle = "Distribución según género",

  x = "Altura (cm)",

  y = "Peso (kg)",

  color = "Género",

  caption = "Fuente: Base antropométrica prof. Miguel Pérez"
) +

theme_minimal(base_size = 12) +

theme(
  plot.title = element_text(
    face = "bold",
    size = 15
  ),


  plot.subtitle = element_text(
    size = 11
  ),

  legend.position = "right"
)

```

Relación entre altura y peso corporal

Distribución según género



Fuente: Base antropométrica prof. Miguel Pérez

Interpretación: El diagrama de dispersión permite explorar visualmente la relación entre la altura y el peso corporal de los estudiantes, diferenciando las observaciones según el género. En general, se observa una tendencia positiva entre ambas variables, indicando que a mayores valores de altura tienden a presentarse mayores valores de peso corporal.

La diferenciación por color facilita identificar posibles agrupamientos entre hombres y mujeres, evidenciando patrones distintos en la distribución de las observaciones. Este tipo de visualización resulta útil para detectar comportamientos particulares dentro de subgrupos poblacionales y constituye una herramienta exploratoria fundamental antes de aplicar medidas numéricas de asociación o modelos estadísticos más complejos.

⚠ Advertencia

El **diagrama de dispersión** es principalmente una herramienta de análisis exploratorio y visualización bivariada. NO es todavía una correlación numérica.

11.4. Prueba de normalidad Shapiro-Wilk

La prueba de Shapiro-Wilk permite evaluar si una variable cuantitativa presenta una distribución aproximadamente normal. En este caso, se analizan las variables altura y peso corporal de los estudiantes.

La hipótesis nula (H_0) establece que los datos siguen una distribución normal, mientras que la hipótesis alternativa (H_1) plantea que la distribución no es normal.

La decisión se toma a partir del valor p :

- si $p > 0.05$, no se rechaza la normalidad;
- si $p \leq 0.05$, se concluye que la variable no presenta distribución normal.

Estas pruebas son importantes porque muchas técnicas estadísticas paramétricas, como la correlación de Pearson y la regresión lineal, asumen normalidad en los datos.

```
library(readxl)
library(dplyr)
library(purrr)
```

```

# Cargar base de datos
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Seleccionar variables numéricas
variables_numericas <- datos %>%

  select(where(is.numeric))

# Aplicar Shapiro-Wilk a cada variable
normalidad <- map_df(

  names(variables_numericas),

  ~{

    prueba <- shapiro.test(
      na.omit(variables_numericas[[.x]])
    )

    data.frame(
      Variable = .x,
      W = round(prueba$statistic, 4),
      p_value = round(prueba$p.value, 6),

      Normalidad = ifelse(
        prueba$p.value > 0.05,
        "Sí presenta normalidad",
        "No presenta normalidad"
      )
    )
  }
)

# Mostrar resultados
normalidad

```

	Variable	W	p_value	Normalidad
W...1	Altura_cm	0.9753	0.000172	No presenta normalidad
W...2	Peso_Kg	0.9040	0.000000	No presenta normalidad
W...3	Anchura_hombros_cm	0.8824	0.000000	No presenta normalidad
W...4	Long_Mano_cm	0.2747	0.000000	No presenta normalidad
W...5	Lon_Palma_cm	0.9460	0.000000	No presenta normalidad
W...6	Ancho_Palma_cm	0.9310	0.000000	No presenta normalidad
W...7	Long_Brazo_cm	0.7635	0.000000	No presenta normalidad
W...8	Long_Antebraco_cm	0.7616	0.000000	No presenta normalidad
W...9	Long_Pierna_cm	0.9950	0.564763	Sí presenta normalidad
W...10	Long_Pie_cm	0.9914	0.134404	Sí presenta normalidad

11.5. Cuando la variable presenta distribución normal

Interpretación: Las variables **Long_Pierna_cm** y **Long_Pie_cm** presentan un comportamiento compatible con una distribución normal según la prueba de Shapiro-Wilk.

Para la variable **Long_Pierna_cm**, se obtuvo un estadístico $W = 0.9950$ y un valor $p = 0.564763$. Debido a que el valor p es mayor que 0.05, no se rechaza la hipótesis nula de normalidad. Esto indica que la distribución de la longitud de la pierna no presenta diferencias significativas respecto a una distribución normal.

De manera similar, la variable **Long_Pie_cm** presentó un estadístico $W = 0.9914$ y un valor $p = 0.134404$. Al ser también mayor que 0.05, se concluye que la longitud del pie presenta una distribución aproximadamente normal.

En términos prácticos, estos resultados sugieren que ambas variables antropométricas poseen distribuciones relativamente simétricas y sin desviaciones extremas importantes, lo cual favorece la aplicación de técnicas estadísticas paramétricas, como: correlación de Pearson, pruebas t, análisis de regresión lineal e intervalos de confianza basados en normalidad.

Asimismo, el comportamiento normal de estas variables es coherente con muchas mediciones biológicas y antropométricas, donde las características físicas de una población suelen distribuirse alrededor de un valor promedio central.

11.5.1. Correlación de Pearson

La correlación es una medida estadística utilizada para cuantificar la fuerza y la dirección de la relación entre dos variables cuantitativas. A diferencia del diagrama de dispersión, que permite explorar visualmente el comportamiento conjunto de las variables, la correlación resume dicha relación mediante un valor numérico.

El coeficiente de correlación de Pearson se calcula como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$


El coeficiente de correlación indica qué tan estrechamente se relacionan dos variables y si dicha relación es positiva, negativa o inexistente.

CORRELACIÓN LINEAL

La correlación cuantifica la fuerza y la dirección de la relación lineal entre dos variables cuantitativas.

Correlación positiva, negativa y nula

La relación entre dos variables puede presentar diferentes comportamientos:



En términos prácticos:

- **correlación positiva** → tendencia ascendente;
- **correlación negativa** → tendencia descendente;
- **correlación cercana a cero** → ausencia de asociación lineal.

FÓRMULA DE PEARSON

El coeficiente de correlación de Pearson (r) se calcula como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde:

- x_i, y_i : valores de las variables X e Y.
- $\bar{x}, \bar{y}$: medias de X e Y.
- n : número de observaciones.

COEFICIENTE DE PEARSON

El coeficiente de correlación de Pearson es la medida más utilizada para evaluar relaciones lineales entre variables cuantitativas.

Se representa mediante la letra r y toma valores entre -1 y 1:

$$-1 \leq r \leq 1$$



donde:

- $r = 1$: correlación positiva perfecta;
- $r = -1$: correlación negativa perfecta;
- $r = 0$: ausencia de relación lineal.

INTERPRETACIÓN GENERAL DEL COEFICIENTE

Valor de r	Interpretación aproximada	Fuerza de la relación
0.00 – 0.19	Muy débil	★☆☆☆☆
0.20 – 0.39	Débil	★★☆☆☆
0.40 – 0.59	Moderada	★★★☆☆
0.60 – 0.79	Fuerte	★★★★☆
0.80 – 1.00	Muy fuerte	★★★★★

EL SIGNO DEL COEFICIENTE INDICA LA DIRECCIÓN DE LA RELACIÓN:



POSITIVO
relación directa
(variables aumentan juntas)



NEGATIVO
relación inversa
(una aumenta cuando la otra disminuye)



CERCANO A CERO
no hay asociación lineal aparente



EN RESUMEN

La correlación mide asociación lineal, NO causalidad.
Dos variables pueden estar correlacionadas sin que una cause la otra.

Positiva ($r > 0$)



A mayor X, mayor Y

Negativa ($r < 0$)



A mayor X, menor Y

Nula ($r \approx 0$)



No hay tendencia lineal clara

Figura 11.2: Fuente: autores

11.5.1.1. Ejemplo en R

En el siguiente ejemplo se calcula la correlación entre altura y peso corporal utilizando la base de datos antropométrica.

```
library(readxl)
library(ggplot2)

# Cargar base de datos
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Calcular correlación
r <- cor(
  datos$Long_Pierna_cm,
  datos$Long_Pie_cm,

  method = "pearson",

  use = "complete.obs"
)

# Gráfico
ggplot(
  datos,

  aes(
    x = Long_Pierna_cm,
    y = Long_Pie_cm,
    color = Genero
  )
) +

  geom_point(
    size = 3,
    alpha = 0.75
  ) +

  scale_color_manual(
    values = c(
      "F" = "#D95F02",
      "M" = "#1B9E77"
    )
  ) +

  geom_smooth(
    method = "lm",
    se = FALSE,
    color = "black",
    linewidth = 1
  ) +

  annotate(
    "text",

    x = min(datos$Long_Pierna_cm) + 5,
```

```

y = max(datos$Long_Pie_cm) - 5,

label = paste0(
  "r = ",
  round(r, 3)
),

size = 5,

fontface = "bold",


color = "black"
) +

labs(
  title = "Relación entre Longitud Pierna y Longitud pie",
  subtitle = "Diagrama de dispersión y correlación de Pearson",
  x = "Longitud Pierna (cm)",
  y = "Longitud pie (cm)",
  color = "Género",

  caption = "Fuente: Base antropométrica Prof. Miguel Pérez"
) +

theme_minimal(base_size = 12)

```



Interpretación: El diagrama de dispersión permite explorar la relación entre la longitud de la pierna y la longitud del pie en los estudiantes, diferenciando las observaciones según el género. Visualmente, los puntos se encuentran ampliamente

dispersos y no muestran una tendencia lineal clara entre ambas variables.

El **coeficiente de correlación de Pearson** obtenido ($r = 0.012$) indica una **asociación lineal prácticamente nula entre la longitud de la pierna y la longitud del pie**. Este valor, al encontrarse muy cercano a cero, sugiere que el aumento en una de las variables no se relaciona de manera consistente con cambios en la otra dentro de la muestra analizada.

Asimismo, la línea de tendencia horizontal observada en el gráfico confirma la ausencia de una relación lineal significativa. Aunque existen diferencias naturales entre hombres y mujeres en la distribución de las observaciones, dichas variaciones no generan un patrón de asociación fuerte entre las variables estudiadas.

En términos prácticos, estos resultados indican que la longitud de la pierna no constituye un buen predictor lineal de la longitud del pie en esta población específica. Este tipo de análisis es importante porque demuestra que no todas las variables antropométricas presentan relaciones lineales fuertes, incluso cuando pertenecen a una misma dimensión biológica..

11.6. Cuando la variable no presenta distribución normal

Interpretación Altura_cm y Peso_Kg: La prueba de Shapiro-Wilk indica que ninguna de las dos variables presenta una distribución normal al nivel de significancia del 5 %.

Para la variable **Altura_cm**, se obtuvo un estadístico $W = 0.9752$ y un valor $p = 0.000171$. Debido a que el valor p es menor que 0.05, se rechaza la hipótesis nula de normalidad, concluyendo que la distribución de la altura difiere significativamente de una distribución normal.

De manera similar, para la variable **Peso_Kg**, el estadístico obtenido fue $W = 0.9040$ con un valor $p = 7.916 \times 10^{-12}$, valor extremadamente pequeño que también conduce al rechazo de la hipótesis de normalidad. Esto indica que la distribución del peso corporal presenta desviaciones importantes respecto a la normalidad.

En términos prácticos, estos resultados sugieren que las variables antropométricas analizadas no cumplen completamente el supuesto de normalidad requerido por algunas técnicas paramétricas. Por esta razón, en determinados contextos podría ser recomendable complementar el análisis utilizando métodos no paramétricos, como la correlación de Spearman, especialmente si existen valores extremos o distribuciones asimétricas.


11.6.1. Correlación de Spearman

La correlación de Spearman es una medida estadística utilizada para evaluar la asociación entre dos variables ordinales o cuantitativas cuando no se cumplen los supuestos de normalidad o linealidad requeridos por la correlación de Pearson.

A diferencia de Pearson, Spearman no trabaja directamente con los valores originales de las variables, sino con sus rangos o posiciones dentro de la distribución. Por esta razón, se considera una medida no paramétrica de asociación.

CORRELACIÓN DE SPEARMAN

Una medida no paramétrica para evaluar la asociación monotónica entre dos variables.



1. COEFICIENTE DE SPEARMAN

El coeficiente de Spearman se representa mediante la letra griega rho:

ρ


y toma valores entre -1 y 1:

$$-1 \leq \rho \leq 1$$

donde:

$\rho = 1$

asociación positiva perfecta



$\rho = -1$

asociación negativa perfecta



$\rho = 0$

ausencia de asociación monotónica



2. ¿CUÁNDO UTILIZAR SPEARMAN?

La correlación de Spearman se recomienda cuando:



las variables presentan valores extremos



la relación entre variables no es estrictamente lineal



los datos son ordinales



no se cumple normalidad



existen distribuciones asimétricas



Esta medida evalúa si, en general, cuando una variable aumenta, la otra también tiende a aumentar o disminuir, independientemente de que la relación sea perfectamente lineal.

3. INTERPRETACIÓN GENERAL

Valor de ρ	Interpretación aproximada
0.00 - 0.19	Muy débil ★☆☆☆☆
0.20 - 0.39	Débil ★★☆☆☆
0.40 - 0.59	Moderada ★★★☆☆
0.60 - 0.79	Fuerte ★★★★☆
0.80 - 1.00	Muy fuerte ★★★★★

El signo del coeficiente indica la dirección de la asociación:



positivo →

ambas variables aumentan conjuntamente



negativo →

una variable aumenta mientras la otra disminuye



4. FÓRMULA DE SPEARMAN

Cuando no existen empates, el coeficiente de Spearman puede calcularse mediante:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde:

- d_i : diferencia entre rangos
- n : número de observaciones




EN RESUMEN




Spearman mide la asociación monotónica entre variables utilizando rangos. Es una alternativa robusta cuando no se cumplen los supuestos de la correlación de Pearson.

Positiva ($\rho > 0$)




A mayor X, mayor Y

Negativa ($\rho < 0$)



A mayor X, menor Y

Nula ($\rho \approx 0$)



No hay tendencia monotónica clara

Figura 11.3: Fuente: autores

```

library(readxl)
library(ggplot2)
library(dplyr)

# Cargar base de datos
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

# Correlación por género
datos %>%

  group_by(Genero) %>%

  summarise(
    Correlacion = cor(
      Altura_cm,
      Peso_Kg,

      method = "spearman",

      use = "complete.obs"
    )
  )

```

```

# A tibble: 2 x 2
  Genero Correlacion
  <chr>      <dbl>
1 F         0.0657
2 M         0.178

```

```

# Diagrama de dispersión por género

```

```

ggplot(
  datos,

  aes(
    x = Altura_cm,
    y = Peso_Kg,
    color = Genero
  )
) +

  geom_point(
    size = 3,
    alpha = 0.75
  ) +

  geom_smooth(
    method = "lm",
    se = FALSE,
    linewidth = 1
  ) +

  scale_color_manual(
    values = c(

```

```

    "F" = "#D95F02",
    "M" = "#1B9E77"
  )
) +


labs(
  title = "Relación entre altura y peso corporal según género",
  subtitle = "Comparación de patrones de asociación",
  x = "Altura (cm)",
  y = "Peso (kg)",
  color = "Género",

  caption = "Fuente: Base antropométrica"
) +

theme_minimal(base_size = 12) +

theme(
  plot.title = element_text(
    face = "bold",
    size = 15
  ),
  plot.subtitle = element_text(
    size = 11
  )
)


```



11.6.2. Covarianza

La covarianza es una medida estadística utilizada para evaluar cómo varían conjuntamente dos variables cuantitativas respecto a sus medias. Esta medida permite identificar si ambas variables tienden a aumentar simultáneamente, disminuir conjuntamente o comportarse de manera independiente.

La covarianza constituye uno de los fundamentos matemáticos de la correlación lineal y de la regresión.



valor cercano a cero, indicando que ambas variables no muestran una variación conjunta importante dentro de la muestra analizada.

Este resultado coincide con el **análisis de correlación de Pearson** previamente realizado ($r = 0.012$), donde también se evidenció una relación lineal prácticamente nula entre las variables. En términos prácticos, los cambios en la longitud de la pierna no se asocian de manera consistente con cambios en la longitud del pie en los estudiantes evaluados.

Asimismo, este ejemplo permite comprender que no todas las variables antropométricas presentan asociaciones lineales fuertes, incluso cuando pertenecen a dimensiones corporales relacionadas.

11.6.3. Tablas de contingencia

Las tablas de contingencia son herramientas estadísticas utilizadas para resumir y analizar la relación entre dos variables categóricas. Estas tablas permiten organizar las frecuencias observadas según las diferentes combinaciones de categorías presentes en las variables estudiadas.

También son conocidas como: tablas cruzadas, tablas de doble entrada o tablas de asociación.

Su principal objetivo consiste en identificar posibles patrones de relación o dependencia entre categorías.

11.7. Estructura general

Una tabla de contingencia distribuye las observaciones en filas y columnas:

	Categoría B1	Categoría B2	Total
Categoría A1	f_{11}	f_{12}	$f_{1\cdot}$
Categoría A2	f_{21}	f_{22}	$f_{2\cdot}$
Total	$f_{\cdot 1}$	$f_{\cdot 2}$	n

donde:

- las filas representan categorías de una variable;
- las columnas representan categorías de la otra variable;
- cada celda contiene la frecuencia observada.

11.8. Interpretación

Las tablas de contingencia permiten comparar frecuencias entre grupos; identificar asociaciones entre categorías; calcular porcentajes conjuntos; analizar patrones poblacionales; servir como base para pruebas como Chi-cuadrado. Cuando las proporciones observadas son similares entre categorías, puede inferirse independencia entre las variables. En cambio, diferencias importantes sugieren posibles asociaciones.

11.9. Ejemplo contextual

En estudios educativos puede analizarse la relación entre género y aprobación académica; modalidad de estudio y rendimiento o nivel socioeconómico y acceso tecnológico. En salud tabaquismo y enfermedad; clasificación nutricional y actividad física.

11.10. Ejemplo en R

En el siguiente ejemplo se construye una tabla de contingencia entre género y grupo académico utilizando la base antropométrica.

```

library(readxl)
library(dplyr)
library(janitor)
library(knitr)
library(kableExtra)

# Cargar base de datos
datos <- read_excel(
  "C:/R-Proyectos/estadistica-experiencial/data/bd_antropometricas.xlsx"
)

#=====
# 1. Género vs Talla dicotómica
#=====

datos %>%

  tabyl(
    Genero,
    Talla_Dicotica
  ) %>%

  adorn_totals(c("row", "col")) %>%

  adorn_percentages("row") %>%

  adorn_pct_formatting(digits = 1) %>%

  adorn_ns(position = "front") %>%

  kable(
    caption = "Tabla de contingencia: Género y talla dicotómica",
    align = "c"
  ) %>%

  kable_styling(
    full_width = FALSE,
    bootstrap_options = c(
      "striped",
      "hover",
      "condensed"
    )
  )
)

```

Tabla 11.3: Tabla de contingencia: Género y talla dicotómica

Genero	Alta	Baja	Total
F	23 (11.1 %)	185 (88.9 %)	208 (100.0 %)
M	30 (57.7 %)	22 (42.3 %)	52 (100.0 %)
Total	53 (20.4 %)	207 (79.6 %)	260 (100.0 %)

```

#=====
# 2. Género vs IMC dicotómico

```

```
#=====

datos %>%

  tabyl(
    Genero,
    IMC_Dicotico
  ) %>%

  adorn_totals(c("row", "col")) %>%

  adorn_percentages("row") %>%

  adorn_pct_formatting(digits = 1) %>%

  adorn_ns(position = "front") %>%

  kable(
    caption = "Tabla de contingencia: Género e IMC dicotómico",
    align = "c"
  ) %>%

  kable_styling(
    full_width = FALSE,
    bootstrap_options = c(
      "striped",
      "hover",
      "condensed"
    )
  )
)
```

Tabla 11.4: Tabla de contingencia: Género e IMC dicotómico

Genero	Bajo_Peso	Normal+	Total
F	127 (61.1 %)	81 (38.9 %)	208 (100.0 %)
M	10 (19.2 %)	42 (80.8 %)	52 (100.0 %)
Total	137 (52.7 %)	123 (47.3 %)	260 (100.0 %)

```
#=====
# 3. Género vs Tamaño de mano
#=====

datos %>%

  tabyl(
    Genero,
    Mano_Dicotica
  ) %>%

  adorn_totals(c("row", "col")) %>%

  adorn_percentages("row") %>%


```

```

adorn_pct_formatting(digits = 1) %>%

adorn_ns(position = "front") %>%

kable(
  caption = "Tabla de contingencia: Género y tamaño de mano",
  align = "c"
) %>%

kable_styling(
  full_width = FALSE,
  bootstrap_options = c(
    "striped",
    "hover",
    "condensed"
  )
)

```

Tabla 11.5: Tabla de contingencia: Género y tamaño de mano

Genero	Grande	Pequeña	Total
F	26 (12.5 %)	182 (87.5 %)	208 (100.0 %)
M	38 (73.1 %)	14 (26.9 %)	52 (100.0 %)
Total	64 (24.6 %)	196 (75.4 %)	260 (100.0 %)

Interpretación: En términos generales, el 88.9 % de las mujeres se clasifican dentro del rango normal de IMC y el 11.1 % presenta sobrepeso u obesidad. En contraste, entre los hombres solo el 48.1 % presenta IMC normal, mientras que el 51.9 % se ubica en la categoría de sobrepeso-obesidad. Considerando el total de la muestra, el 80.8 % de los estudiantes presenta un IMC normal y el 19.2 % presenta sobrepeso u obesidad.

Estos resultados sugieren una posible asociación entre el género y la clasificación del IMC, evidenciando una mayor proporción de sobrepeso-obesidad en los hombres respecto a las mujeres dentro de la población analizada. Las tablas de contingencia permiten identificar este tipo de patrones descriptivos y constituyen la base para posteriores análisis inferenciales, como la prueba Chi-cuadrado de independencia.

11.10.1. Laboratorio experiencial:

¿Existe relación entre la altura y el peso corporal?

Situación problema: Un grupo de estudiantes de fisioterapia desea analizar si la altura corporal se relaciona con el peso de los estudiantes universitarios. Para ello, se recolectó información antropométrica de hombres y mujeres de diferentes semestres académicos.

Objetivo del análisis

Determinar: si existe relación entre altura y peso; la dirección de la relación; la fuerza de la asociación y si el género modifica visualmente el comportamiento de los datos.

11.10.2. Actividades del estudiante

Parte 1 — Exploración visual

Preguntas

¿Qué tipo de relación observa en el diagrama? positiva, negativa, nula, urvilínea.

¿La relación parece fuerte o débil?

¿Existen valores atípicos?

¿Se observan diferencias entre hombres y mujeres?

Parte 2 — Correlación

Calcule: correlación de Pearson y correlación de Spearman.

Preguntas

¿Los coeficientes son similares?

¿Cuál considera más apropiado según la distribución de los datos?

¿Puede afirmarse causalidad?

Parte 3 — Interpretación aplicada

Un investigador afirma que “Los estudiantes más altos necesariamente pesan más”.

Preguntas críticas

¿La correlación encontrada permite afirmar eso?

¿Qué limitaciones tiene el análisis?

¿Qué otras variables podrían influir?

Referencias

- Agresti, A. (2018). *Statistical Methods for the Social Sciences* (5.^a ed.). Pearson.
- Armitage, P., Berry, G., & Matthews, J. N. S. (2002). *Statistical methods in medical research*. Blackwell Science.
- Bonita, R., Beaglehole, R., & Kjellström, T. (2008). *Epidemiología básica*. Organización Panamericana de la Salud.
- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8.^a ed.). Cengage Learning.
- Kleinbaum, D. G., & Klein, M. (2012). *Survival Analysis: A Self-Learning Text* (3.^a ed.). Springer.
- Obando, L. (2021). *Gráficos estadísticos y análisis de datos con R*. Editorial Académica.
- Posada, C. (2016). *Elementos de estadística*. Editorial Académica.
- Rey, J. (2007). *Introducción a la estadística*. Editorial Universitaria.
- Seoane, T. et al. (2007). *Estadística aplicada*. Editorial Académica.
- Spiegel, M. R., & Stephens, L. J. (2009). *Estadística*. McGraw-Hill.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Van den Broeck, J., Cunningham, S. A., Eeckels, R., & Herbst, K. (2005). Data cleaning: Detecting, diagnosing, and editing data abnormalities. *PLoS Medicine*, 2(10), e267. <https://doi.org/10.1371/journal.pmed.0020267>
- Wickham, H., & Grolemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media.
- Wooldridge, J. M. (2016). *Introductory Econometrics: A Modern Approach* (6.^a ed.). Cengage Learning.